

02 — La carte des lois de probabilité

Table des matieres

[1.1 — Loi binomiale](#)

[1.2 — Loi géométrique](#)

[1.3 — Loi hypergéométrique](#)

[1.4 — Loi normale & z-test](#)

[1.5 — Distribution exacte de la somme](#)

[1.6 — Loi Beta & conjugaison Beta-Bernoulli](#)

[1.7 — Fréquences de blocs / n-grammes \(test sériel\)](#)

[Réponses aux exercices](#)

Niveau : base → avancé (tout traité en profondeur). **Prérequis** : 01_fondations.md (processus de Bernoulli, $p = 6/49$, indépendance vs sans remise, espérance/variance), dénombrement. **Couvre les fiches source** : 1.1 à 1.7 de concepts_FR.md. **Documents suivants** : 03_inference_frequentiste.md, 04_inference_bayesienne.md.

Idée directrice. Toutes les lois de ce document sont des **questions différentes posées au même processus de Bernoulli** du document 01. La binomiale compte les succès, la géométrique mesure l'attente, l'hypergéométrique gère le tirage sans remise, la normale approxime les grandes sommes, la loi exacte de la somme énumère, la Beta met une croyance sur p , et les n-grammes généralisent la binomiale aux motifs. Garde en tête l'arbre : **Bernoulli → tout le reste.**

1.1 — Loi binomiale

En une phrase

La binomiale répond à « **combien de succès sur N épreuves ?** » : c'est la somme de N Bernoulli i.i.d., et donc le modèle nul du comptage de sorties d'un numéro.

Intuition

On a fixé un numéro (le 17) et sa pièce truquée à $p = 6/49$. On la relance $N = 4\,377$ fois. La binomiale donne la probabilité de chaque total possible de « faces » : 0 sortie, 1, ..., jusqu'à 4 377. Sa forme est une cloche asymétrique centrée sur $Np \approx 536$. La question « ce numéro est-il sorti anormalement souvent ? » devient alors : « son total observé tombe-t-il dans le gros de la cloche, ou dans une queue improbable ? ».

Formalisation

Définition. Si $Y = \sum_{t=1}^N X_t$ avec $X_t \sim \text{Bernoulli}(p)$ i.i.d., alors $Y \sim \text{Bin}(N, p)$ et

$$P(Y = k) = \binom{N}{k} p^k (1-p)^{N-k}, \quad k = 0, 1, \dots, N.$$

Dérivation. Une suite précise de N épreuves avec succès aux positions choisies a une probabilité $p^k (1-p)^{N-k}$ (par indépendance, on multiplie). Il y a $\binom{N}{k}$ façons de placer les k succès parmi les N positions, toutes de même probabilité. On somme ces cas mutuellement exclusifs, d'où le facteur $\binom{N}{k}$.

Vérification que c'est une loi. Par le binôme de Newton, $\sum_{k=0}^N \binom{N}{k} p^k (1-p)^{N-k} = (p + (1-p))^N = 1$. (C'est là que la loi tient son nom.)

Moments (déjà obtenus en §0.4 par linéarité + additivité) :

$$\mathbb{E}[Y] = Np, \quad \text{Var}(Y) = Np(1-p), \quad \sigma(Y) = \sqrt{Np(1-p)}.$$

Approximation normale et ses limites. Par le théorème central limite (§1.4), pour N grand,

$$Y \approx \mathcal{N}(Np, Np(1-p)), \quad \text{donc} \quad Z = \frac{Y - Np}{\sqrt{Np(1-p)}} \xrightarrow{N \rightarrow \infty} \mathcal{N}(0,1).$$

Règle pratique de validité : approximation correcte si $Np \geq 5$ et $N(1-p) \geq 5$. Ici $Np \approx 536 \gg 5$, l'approximation est excellente *au centre*. **Limites** : elle se dégrade dans les **queues** (événements rares) et pour les **petits comptes** (séries longues du Test 3, où k peut valoir 2 ou 3). C'est pourquoi le projet privilégie le **test binomial exact** quand les effectifs sont petits.

Test binomial exact vs asymptotique. Le test exact calcule la p-value directement à partir de la loi binomiale (somme des $P(Y = k)$ au moins aussi extrêmes que l'observé), sans passer par la cloche normale. Il est **toujours valide**, à n'importe quel N , au prix d'un calcul combinatoire. L'asymptotique (z-score) est plus simple mais ne vaut que si N est grand et p pas trop extrême.

Dans iAlexMG

C'est la loi nulle du **Test 1 (fréquences)** : pour chaque numéro, on confronte son nombre de sorties à $\text{Bin}(4\,377, 6/49)$.

- **Bande à 95 %** : l'intervalle $[\approx 493, \approx 579]$ (centre 536, $\pm 2\sigma$) ; un numéro hors bande est candidat à l'anomalie.
- **Test binomial exact par numéro**, puis correction de Bonferroni sur les 49 tests (§2.5), car ~ 2 -3 numéros sortent hors bande par pur hasard.

- Sert aussi de **loi de référence des séries** (Test 3) : $P(\text{sortie} \mid \text{série de } k)$ est testé par binomial exact (effectifs souvent petits $\rightarrow$ exact obligatoire).

Verdict du projet : **aucun numéro chaud ou froid**, et les biais grossiers sont exclus (voir l'analyse de puissance, §2.4).

Pièges & malentendus

- **Binomiale appliquée à la mauvaise échelle.** Elle vaut pour *un numéro suivi dans le temps* (indépendance verticale). Elle **ne s'applique pas** à la composition d'un tirage (pairs, somme), qui relève du sans-remise $\rightarrow$ hypergéométrique (§1.3).
- « Np doit être entier ». Non : $Np \approx 535,96$ est une espérance, pas un comptage observé. Les valeurs de Y , elles, sont entières.
- **Confondre $P(Y = k)$ et la p-value.** La p-value n'est pas $P(Y = k_{\text{obs}})$ mais la probabilité cumulée des résultats *au moins aussi extrêmes* (voir §2.2).
- **Sur-confiance dans l'approximation normale en queue.** Pour les petits effectifs ou les événements rares, l'écart normale/exact peut être grand ; utiliser l'exact.

Pour vérifier ta compréhension

1. Sur $N = 4\,377$, quelle est l'espérance et l'écart-type du nombre de sorties d'un numéro ? (Tu peux réutiliser le doc 01.)
2. Pourquoi $\sum_k \binom{N}{k} p^k (1-p)^{N-k} = 1$? Quel théorème invoques-tu ?
3. Pour tester si un numéro avec 8 sorties sur une série rare est anormal, vaut-il mieux le test exact ou l'approximation normale ? Pourquoi ?

(Réponses [à la fin.](#))

Pour aller plus loin

- **Loi de Poisson** comme limite de $\text{Bin}(N, p)$ quand $N \rightarrow \infty, p \rightarrow 0, Np \rightarrow \lambda$: utile pour les événements rares.
 - **Intervalles de confiance pour une proportion** : Wald (asymptotique) vs Clopper-Pearson (exact, basé sur la binomiale) — détaillé en §2.7.
 - **Sur-dispersion** : si les données ont une variance $> Np(1-p)$, c'est un signe de violation de H_0 (hétérogénéité, dépendance) — piste de diagnostic.
-

1.2 — Loi géométrique

En une phrase

La géométrie répond à « **combien de tirages avant la prochaine sortie ?** » : c'est le temps d'attente d'un succès de Bernoulli, et son arme secrète est l'**absence de mémoire**, qui pulvérise le sophisme du joueur.

Intuition

Au lieu de compter les succès (binomiale), on chronomètre l'**attente**. On fixe un numéro et on note l'écart (le *gap*) entre deux de ses sorties consécutives. Comme la pièce est sans mémoire, attendre est comme relancer une pièce jusqu'à la première face : la plupart des attentes sont courtes, mais une longue traîne d'attentes longues existe. Point capital : le fait d'avoir *déjà* attendu longtemps **ne raccourcit pas** l'attente restante. C'est contre-intuitif et c'est exactement ce qui rend faux le « il est dû ».

Formalisation

Définition. Soit T le numéro de l'épreuve du **premier succès** d'une suite de Bernoulli i.i.d. de paramètre p . Alors $T \sim \text{Geom}(p)$ avec

$$P(T = k) = (1 - p)^{k-1}p, \quad k = 1, 2, 3, \dots$$

(Échec aux $k - 1$ premières épreuves, succès à la k -ième.) C'est bien une loi : $\sum_{k \geq 1} (1 - p)^{k-1}p = p \cdot \frac{1}{1-(1-p)} = 1$ (série géométrique).

Espérance. $\mathbb{E}[T] = \sum_{k \geq 1} k (1 - p)^{k-1}p = \frac{1}{p}$. (Dérivation : $\sum_{k \geq 1} k x^{k-1} = (1 - x)^{-2}$ pour $|x| < 1$; avec $x = 1 - p$, $\mathbb{E}[T] = p \cdot (1 - (1 - p))^{-2} = p/p^2 = 1/p$.) La variance vaut $\text{Var}(T) = (1 - p)/p^2$.

Pour $p = 6/49$: $\mathbb{E}[T] = 49/6 \approx 8,17$ tirages, $\sigma(T) = \sqrt{(43/49)/(6/49)} \approx 7,66$. **En moyenne, un numéro réapparaît tous les ~8 tirages**, avec une forte dispersion.

La propriété sans mémoire (le cœur du chapitre). Pour tous entiers $m, n \geq 0$:

$$P(T > m + n \mid T > m) = P(T > n).$$

Preuve. D'abord, $P(T > k) = (1 - p)^k$ (aucun succès durant k épreuves). Alors

$$P(T > m + n \mid T > m) = \frac{P(T > m + n, T > m)}{P(T > m)} = \frac{P(T > m + n)}{P(T > m)} = \frac{(1 - p)^{m+n}}{(1 - p)^m} = (1 - p)^n = P(T > n). \quad \blacksquare$$

Interprétation décisive. « Sachant que le numéro n'est pas sorti depuis m tirages, la loi de l'attente restante est identique à celle d'un numéro qui vient de sortir. » Le passé est intégralement effacé. La

géométrique est, sur les lois discrètes, **l'unique** loi sans mémoire (l'exponentielle l'est en continu). Donc « un numéro en retard est dû » est mathématiquement faux : $P(\text{sort} \mid \text{âge} = m) = p$ pour tout m .

Dans iAlexMG

- **Test 2 (gaps)** : on construit la distribution empirique des écarts entre sorties de chaque numéro et on la compare à $\text{Geom}(6/49)$. Conformité $\rightarrow$ aucune mémoire.
- $P(\text{sort} \mid \text{âge})$: estimée empiriquement, elle est **plate autour de** $6/49$ quel que soit l'âge — la traduction directe de la propriété sans mémoire.
- C'est le **support quantitatif** de la réfutation du **sophisme du joueur** (§7.1), avec le coefficient $\text{gap} \approx 0$ de la régression logistique (§5.10) et la cascade n-grammes (§6.3).

Pièges & malentendus

- **Sans mémoire $\neq$ « ne sortira jamais »**. L'espérance reste $1/p$; les attentes longues sont rares mais arrivent. « Sans mémoire » dit seulement que l'attente déjà écoulée n'informe pas sur la suite.
- **Deux conventions de la géométrie**. Certaines définitions comptent le nombre d'**échecs avant** le succès ($k = 0, 1, 2, \dots$, espérance $(1 - p)/p$). Le projet compte le **rang** du succès ($k \geq 1$, espérance $1/p$). Vérifier la convention avant de comparer.
- **Croire que la moyenne « rappelle » les retards**. La loi des grands nombres dilue les écarts relatifs, elle ne rembourse pas les retards absolus (voir §6.4). Sans mémoire et réversion à la moyenne sont des idées **opposées**.

Pour vérifier ta compréhension

1. Un numéro n'est pas sorti depuis 15 tirages. Quelle est la probabilité qu'il attende encore au moins 8 tirages ? Compare à la probabilité, pour un numéro frais, d'attendre au moins 8 tirages.
2. Quelle est l'attente moyenne entre deux sorties d'un numéro au $6/49$? Et au $7/50$?
3. En une phrase, explique pourquoi la propriété sans mémoire réfute « ce numéro est en retard, il va sortir ».

(Réponses [à la fin.](#))

Pour aller plus loin

- **Loi exponentielle** : analogue continu, seule loi continue sans mémoire ; les gaps géométriques en sont la version discrète.

- **Caractérisation** : on peut *démontrer* que toute loi discrète sans mémoire sur $\{1, 2, \dots\}$ est géométrique — l'absence de mémoire force la forme $(1 - p)^{k-1}p$.
- **Loi binomiale négative** : généralise la géométrique au temps d'attente du r -ième succès.

1.3 — Loi hypergéométrique

En une phrase

L'hypergéométrique répond à « **combien de succès dans un tirage sans remise ?** » : c'est la loi exacte du nombre de pairs (ou de tout sous-groupe) parmi les 6 numéros d'un tirage.

Intuition

C'est la cousine de la binomiale, mais l'urne **s'épuise** : chaque boule tirée modifie ce qui reste, donc p change en cours de tirage. Question type : parmi les 6 numéros tirés, combien sont pairs ? Il y a 24 numéros pairs et 25 impairs entre 1 et 49 ; on pioche 6 sans remise. La binomiale supposerait une pioche avec remise (probabilité figée) — ici, c'est faux, et l'hypergéométrique corrige précisément cet épuisement.

Formalisation

Cadre. Population de m éléments dont K « succès » ; on en tire n **sans remise**. Le nombre H de succès tirés suit $\text{Hypergeom}(m, K, n)$:

$$P(H = k) = \frac{\binom{K}{k} \binom{m-K}{n-k}}{\binom{m}{n}}, \quad \max(0, n - (m - K)) \leq k \leq \min(n, K).$$

(Numérateur : choisir k succès parmi K et $n - k$ échecs parmi $m - K$; dénominateur : tous les tirages équiprobables.)

Moments. Avec la proportion de succès $p = K/m$:

$$\mathbb{E}[H] = n \frac{K}{m} = np, \quad \text{Var}(H) = np(1 - p) \underbrace{\frac{m-n}{m-1}}_{\text{correction pop. finie}}.$$

L'espérance est **identique** à celle de la binomiale (np) — la linéarité ne voit pas le sans-remise. La variance, elle, est **réduite** par le **facteur de correction de population finie** $\frac{m-n}{m-1} < 1$: le sans-remise *resserre* la distribution (cohérent avec la corrélation négative $-1/(m-1)$ du doc 01, §0.3).

Application au projet (parité). $m = 49$, $K = 24$ pairs, $n = 6$. Le nombre de pairs tirés $H \sim \text{Hypergeom}(49, 24, 6)$:

$$\mathbb{E}[H] = 6 \cdot \frac{24}{49} \approx 2,94, \quad \text{Var}(H) = 6 \cdot \frac{24}{49} \cdot \frac{25}{49} \cdot \frac{43}{48} \approx 1,34, \quad \sigma(H) \approx 1,16.$$

On attend donc **~3 pairs par tirage**, ce qui est conforme à l'intuition de symétrie.

Convergence vers la binomiale. Quand $m \rightarrow \infty$ à $p = K/m$ fixé, le facteur $\frac{m-n}{m-1} \rightarrow 1$ et $\text{Hypergeom}(m, K, n) \rightarrow \text{Bin}(n, p)$: sur une grande population, retirer n éléments ne change presque rien aux proportions. C'est pourquoi la distinction n'a d'importance ici que parce que $m = 49$ est *petit* devant... rien — elle compte précisément parce qu'on tire 6 sur 49 (fraction non négligeable).

Dans iAlexMG

- **Test 5 (combinaisons)** : loi exacte du **nombre de numéros pairs par tirage**, comparée à $\text{Hypergeom}(49, 24, 6)$ via un χ^2 (§2.6). Verdict : conforme.
- Sert de **garde-fou méthodologique** : montre pourquoi appliquer une binomiale à la parité serait une erreur de modèle (variance surestimée).

Pièges & malentendus

- **Utiliser la binomiale pour la parité.** Erreur classique : elle ignore le facteur de correction et **surestime la variance**, donc sous-estime la significativité d'un écart.
- **Croire que l'espérance change.** Non : $\mathbb{E}[H] = np$ comme la binomiale ; seule la variance diffère. La confusion vient de l'idée fausse que « sans remise » déplace le centre.
- **Oublier le support tronqué.** H ne peut dépasser $\min(n, K)$ ni descendre sous $\max(0, n - (m - K))$; les bornes naïves 0 à n peuvent être fausses.

Pour vérifier ta compréhension

1. Calcule $P(H = 6)$ (les 6 numéros tirés tous pairs) avec la formule hypergéométrique.
2. De combien la variance hypergéométrique de la parité est-elle réduite par rapport à la binomiale $\text{Bin}(6, 24/49)$? Donne le facteur numérique.
3. Pour un jeu « 6 parmi 49 000 » avec la même proportion de pairs, la binomiale serait-elle une bonne approximation ? Pourquoi ?

(Réponses [à la fin.](#))

Pour aller plus loin

- **Test exact de Fisher** : repose sur l'hypergéométrique pour les tables 2×2 .

- **Hypergéométrie multivariée** : généralise à plusieurs catégories (ex. répartition par dizaines des 6 numéros).
 - **Lien §0.3** : la variance réduite et la corrélation $-1/48$ sont deux visages du même phénomène de sans-remise.
-

1.4 — Loi normale & z-test

En une phrase

La normale est la **forme limite** des sommes de beaucoup de variables indépendantes (théorème central limite) ; le **z-test** mesure un écart à la moyenne en unités d'écart-type, et concentre tout un signal *directionnel* dans un seul nombre.

Intuition

Additionne beaucoup de petits aléas indépendants : le résultat, presque toujours, ressemble à une cloche, quelle que soit la loi de départ. C'est le « miracle » du TCL. Conséquence pratique : si un effet est **monotone** (un penchant vers le haut ou vers le bas), il se loge dans la **moyenne** de la somme. Un seul nombre — la moyenne — suffit alors à le détecter, et le z-test demande simplement : « cette moyenne est-elle loin de la moyenne théorique, à l'échelle de sa fluctuation normale ? ».

Formalisation

Loi normale. $X \sim \mathcal{N}(\mu, \sigma^2)$ a pour densité

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right).$$

Théorème central limite (TCL). Soit $X_1, \dots, X_n$ i.i.d. de moyenne μ et variance $\sigma^2 < \infty$. Alors, quand $n \rightarrow \infty$,

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0,1), \quad \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i.$$

Conditions : variance finie ; indépendance (ou faible dépendance) ; n « assez grand » (la vitesse dépend de l'asymétrie de la loi de départ). La binomiale en est un cas particulier (somme d'indicatrices).

Le z-test. Pour tester $H_0: \mu = \mu_0$ contre une moyenne observée $\bar{x}$ avec écart-type (connu ou bien estimé) de la moyenne $\sigma_{\bar{x}}$:

$$z = \frac{\bar{x} - \mu_0}{\sigma_{\bar{x}}}.$$

Sous H_0 , $z \sim \mathcal{N}(0,1)$; la p-value bilatérale est $2(1 - \Phi(|z|))$. Un $|z| > 1,96$ correspond à $p < 0,05$; $|z| \approx 3,2$ correspond à $p \approx 1,4 \times 10^{-3}$.

Pourquoi un test ciblé (moyenne) bat un χ^2 omnibus pour un effet monotone. Le χ^2 (§2.6) répartit sa puissance sur *toutes* les directions d'écart (chaque cellule) ; face à un effet qui ne vit que dans **une** direction (la moyenne monte), il « dilue » le signal sur de nombreux degrés de liberté et perd en puissance. Le z-test, lui, projette tout sur l'unique direction pertinente → puissance maximale pour cet effet. C'est un principe général : **un test sait ce qu'il cherche est plus puissant qu'un test généraliste.**

Dans iAlexMG

- **Test 5 (somme)** : z-test sur la **moyenne de la somme des 6 numéros**. La moyenne théorique est $\mu_0 = 150$ (somme moyenne = 6×25). On observe un **léger penchant vers les gros numéros**, avec $z \approx 3,2$ — détecté par le z-test alors que le χ^2 omnibus sur la forme de la somme, lui, le **rate** (puissance diluée).
- Justifie l'écriture des **bandes à $\pm 1,96 \sigma$** dans les figures (approximation normale du comptage binomial, §1.1).

Pièges & malentendus

- **« Significatif » $\neq$ « utile »**. Le $z \approx 3,2$ est statistiquement significatif *grâce au grand N* , mais l'effet est minuscule et **inexploitable** (voir T6, §4.6). Détectable et exploitable sont deux choses.
- **Appliquer le z-test sans TCL valide**. Pour de petits n ou des lois très asymétriques, l'approximation normale échoue ; préférer l'exact (§1.1) ou un test de permutation (§2.9).
- **Confondre σ de la population et $\sigma_{\bar{x}}$ de la moyenne**. Le dénominateur du z est l'écart-type **de la moyenne** ($\sigma/\sqrt{n}$), pas celui des observations individuelles.
- **Tester après avoir regardé**. Choisir « la moyenne » *parce qu'on y a vu* un écart gonfle le risque de faux positif (p-hacking, §2.2).

Pour vérifier ta compréhension

1. Pourquoi la somme des 6 numéros est-elle « presque normale » alors que chaque numéro est uniforme ? Quel théorème et quelle condition (rappel : sans-remise) ?
2. Un $z = 3,2$ donne $p \approx 0,0014$. Cela prouve-t-il que connaître la somme aide à gagner ? Distingue significatif et exploitable.
3. Pour un effet « le numéro 7 sort un peu trop », vaut-il mieux un z-test ciblé sur sa fréquence ou un χ^2 sur les 49 numéros ? Pourquoi ?

(Réponses [à la fin](#).)

Pour aller plus loin

- **Vitesse de convergence (Berry-Esseen)** : borne l'erreur d'approximation normale en fonction de l'asymétrie et de n .
 - **t de Student** : remplace le z quand σ est estimé sur un petit échantillon.
 - **TCL sous faible dépendance** : versions du TCL pour séries faiblement corrélées — pertinent puisque la somme d'un tirage agrège 6 numéros corrélés à $-1/48$.
-

1.5 — Distribution exacte de la somme

En une phrase

Plutôt qu'approximer la loi de la somme des 6 numéros par une cloche, on l'**énumère exactement** par comptage combinatoire (programmation dynamique), ce qui donne une référence fiable **jusque dans les queues**.

Intuition

La somme S des 6 numéros tirés va de $1 + 2 + 3 + 4 + 5 + 6 = 21$ à $44 + 45 + \dots + 49 = 279$, centrée sur 150. La normale décrit bien le centre, mais on veut une référence **exacte** — notamment pour juger des sommes extrêmes (queues), là où la normale ment. L'idée : compter, pour chaque valeur s , **combien** des $\binom{49}{6}$ combinaisons ont exactement cette somme. Le rapport donne la probabilité exacte. Comme énumérer les $\binom{49}{6} \approx 1,4 \times 10^7$ combinaisons une à une est lourd, on utilise une **récurrence** (programmation dynamique) qui construit le compte progressivement.

Formalisation

Objet. On veut $c(s) = \#\{\text{sous-ensembles de 6 numéros distincts de } \{1, \dots, 49\} \text{ de somme } s\}$, puis $P(S = s) = c(s)/\binom{49}{6}$.

Fonction génératrice. Le nombre cherché est le coefficient extrait du produit

$$\prod_{i=1}^{49} (1 + z x^i),$$

où la variable z « compte » le nombre de numéros choisis et x « porte » leur somme : choisir le numéro i contribue un facteur $z x^i$, ne pas le choisir contribue 1. On veut le coefficient de $z^6 x^s$. Développer ce produit revient exactement à énumérer tous les sous-ensembles.

Programmation dynamique (le « sac à dos »). On construit un tableau $f[j][s] =$

$\#\{\text{sous-ensembles de taille } j \text{ et de somme } s\}$ en insérant les numéros un par un. Initialisation $f[0][0] = 1$. Pour chaque numéro $i = 1, \dots, 49$, on met à jour (en parcourant j et s à rebours pour ne pas réutiliser i) :

$$f[j][s] += f[j-1][s-i].$$

À la fin, $c(s) = f[6][s]$. C'est une **convolution** discrète : ajouter un numéro revient à convoluer la distribution courante par « présent/absent ». Coût $O(49 \times 6 \times S_{\max})$, négligeable, et **exact** (arithmétique entière, aucune approximation).

Moments (par symétrie et §0.3). $\mathbb{E}[S] = 6 \times 25 = 150$; la loi est **symétrique** autour de 150 (à toute combinaison de somme $150 + d$ correspond la combinaison « miroir » $50 - n_i$ de somme $150 - d$). La variance se calcule avec le facteur de population finie : $\text{Var}(S) = 6 \cdot \sigma_{\text{unif}}^2 \cdot \frac{49-6}{49-1}$, où $\sigma_{\text{unif}}^2 = \frac{49^2-1}{12} = 200$, soit $\text{Var}(S) = 6 \cdot 200 \cdot \frac{43}{48} = 1075$ et $\sigma(S) \approx 32,8$.

Pourquoi l'exact bat la normale dans les queues. La normale a des queues $\propto e^{-z^2/2}$ qui peuvent sur- ou sous-estimer les vraies probabilités d'événements rares de plusieurs ordres de grandeur ; de plus S est **bornée** ($21 \leq S \leq 279$) et **discrète**, ce que la normale ignore. Pour juger une somme observée très excentrée, seule la pmf exacte donne une p-value fiable.

Dans iAlexMG

- **Test 5** : la distribution exacte de S est la **référence de forme** contre laquelle on confronte l'histogramme observé des sommes (test du χ^2 d'adéquation, §2.6), et qui sert de toile de fond au z-test de la moyenne (§1.4).
- Illustre concrètement « **énumérer plutôt qu'approximer** » quand le calcul exact est accessible — une exigence de rigueur du projet.

Pièges & malentendus

- **Réutiliser un numéro dans la DP.** Si l'on parcourt j/s dans le mauvais sens, on autorise un même numéro plusieurs fois (tirage *avec remise*) $\rightarrow$ résultat faux. Le parcours à rebours garantit l'unicité (chaque numéro inséré une fois).
- **Croire la somme normale partout.** Au centre oui ; en queue, la normale dérape (et ignore les bornes 21–279). C'est tout l'intérêt de l'exact.
- **Oublier le facteur population finie pour $\sigma(S)$.** Sans lui, on surestime la variance (les 6 numéros sont corrélés négativement).

Pour vérifier ta compréhension

1. Quelle est la plus petite et la plus grande somme possible ? Quelle est la valeur centrale, et pourquoi la loi est-elle symétrique ?
2. Dans la DP, pourquoi met-on à jour $f[j][s]$ en parcourant à rebours ? Que se passerait-il à l'endroit ?
3. Calcule $c(21)$ et $c(279)$ (nombre de combinaisons atteignant les sommes extrêmes).

(Réponses [à la fin.](#))

Pour aller plus loin

- **FFT pour la convolution** : on peut accélérer le produit de fonctions génératrices par transformée de Fourier rapide (inutile ici, mais élégant).
- **Théorie des partitions** : $c(s)$ est lié au comptage de partitions en parts distinctes bornées — un classique combinatoire.
- **Approximations raffinées** : corrections d'Edgeworth ajoutant l'asymétrie/kurtosis à la normale, intermédiaires entre normale brute et exact.

1.6 — Loi Beta & conjugaison Beta-Bernoulli

En une phrase

La loi **Beta** est une loi *sur les probabilités* $[0,1]$; **conjuguée** du Bernoulli, elle transforme la mise à jour bayésienne de la croyance sur p en une simple **addition de compteurs**.

Intuition

On ne connaît pas p avec certitude ; on a une *croyance* à son sujet, représentée par une courbe sur $[0,1]$. La Beta est la forme idéale de cette croyance : selon ses deux paramètres α, β , elle peut être plate (ignorance), piquée (forte conviction), penchée à gauche ou à droite. Le miracle de la **conjugaison** : quand on observe des succès/échecs Bernoulli, la croyance mise à jour reste une Beta — il suffit d'ajouter le nombre de succès à α et le nombre d'échecs à β . Apprendre = compter.

Formalisation

Densité. $\theta \sim \text{Beta}(\alpha, \beta)$ sur $[0,1]$:

$$f(\theta) = \frac{\theta^{\alpha-1}(1-\theta)^{\beta-1}}{B(\alpha, \beta)}, \quad B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)},$$

où B est la fonction Beta (constante de normalisation). Moyenne $\mathbb{E}[\theta] = \frac{\alpha}{\alpha+\beta}$. Le cas Beta(1,1) est la loi **uniforme** sur $[0,1]$ (ignorance totale).

Conjugaison Beta-Bernoulli (démonstration). A priori $\theta \sim \text{Beta}(\alpha, \beta)$. Données : k succès sur N épreuves Bernoulli, de vraisemblance $\mathcal{L}(\theta) \propto \theta^k (1 - \theta)^{N-k}$. Par Bayes, posterior $\propto$ vraisemblance $\times$ a priori :

$$f(\theta \mid \text{données}) \propto \theta^k (1 - \theta)^{N-k} \cdot \theta^{\alpha-1} (1 - \theta)^{\beta-1} = \theta^{(\alpha+k)-1} (1 - \theta)^{(\beta+N-k)-1}.$$

On **reconnait** le noyau d'une Beta. Donc

$$\boxed{\theta \mid \text{données} \sim \text{Beta}(\alpha + k, \beta + N - k).}$$

Aucune intégrale à calculer : la forme est stable, seuls les compteurs bougent. C'est la **conjugaison**.

Rôle de l'a priori et pseudo-observations. α et β agissent comme des **succès et échecs fictifs** ajoutés avant les données (Beta(1,1) = « 1 succès et 1 échec imaginaires »). C'est exactement le **lissage de Laplace**. La moyenne a posteriori,

$$\mathbb{E}[\theta \mid \text{données}] = \frac{\alpha + k}{\alpha + \beta + N},$$

est une **moyenne pondérée** entre l'a priori $\frac{\alpha}{\alpha+\beta}$ et la fréquence observée $\frac{k}{N}$.

Domination des données à grand N . Quand $N \rightarrow \infty$, les compteurs de données $k, N - k$ écrasent α, β : $\mathbb{E}[\theta \mid \text{données}] \rightarrow k/N$ et la variance du posterior $\rightarrow 0$. **L'a priori est « noyé »** : avec $N = 4\,377$, le choix de Beta(1,1) vs un a priori faiblement informatif est sans conséquence pratique.

Dans iAlexMG

- **Étape 2.4 (bayésien)** : pour chaque numéro, on part de Beta(1,1) et on met à jour avec k = nombre de sorties, $N - k$ = nombre d'absences, obtenant un posterior Beta(1 + k , 1 + $N - k$) **analytique**, sans simulation.
- De ce posterior on tire la moyenne a posteriori et l'**intervalle crédible à 95 %** (§3.3, figure 10), comparé à 6/49. Résultat : tous les crédibles encadrent 6/49 $\rightarrow$ rien ne distingue les numéros.

Pièges & malentendus

- **Confondre θ (paramètre, ce qui est aléatoire en bayésien) et les données.** En bayésien, c'est la croyance sur θ qui est une loi ; $p = 6/49$ reste la vérité qu'on essaie de cerner.
- **Croire l'a priori « subjectif donc arbitraire ».** À grand N il est noyé ; son influence est mesurable et, ici, négligeable. À petit N , en revanche, il compte — d'où l'importance de le déclarer.

- **Intervalle crédible vs intervalle de confiance.** Le crédible (Beta) dit « 95 % de probabilité que θ soit là, vu les données » ; le confiance (fréquentiste) parle de la *procédure*. Ne pas les confondre (§2.7 vs §3.3).

Pour vérifier ta compréhension

1. A priori Beta(1,1), on observe $k = 536$ sorties sur $N = 4\,377$. Donne le posterior et sa moyenne. Est-elle proche de $6/49$?
2. Pourquoi Beta(1,1) est-elle la loi uniforme ? (Regarde la densité avec $\alpha = \beta = 1$.)
3. En quoi α, β ressemblent-ils à des « observations imaginaires » ? Lien avec le lissage de Laplace ?

(Réponses [à la fin.](#))

Pour aller plus loin

- **Dirichlet** : généralisation multivariée de la Beta, conjuguée de la multinomiale (utile si l'on modélisait conjointement les 49 probabilités).
- **A priori de Jeffreys** Beta($\frac{1}{2}, \frac{1}{2}$) : a priori « non informatif » invariant, alternative à Beta(1,1).
- **Lien fréquentiste** : l'IC de Clopper-Pearson (§2.7) s'exprime via des quantiles Beta — un pont entre les deux mondes.

1.7 — Fréquences de blocs / n-grammes (test sériel)

Renvoi prérequis. Cette fiche s'appuie sur la notion de **bruit blanc / indépendance temporelle** (§2.10, document 03) et sur le **test de permutation** (§2.9, document 03), lus *après* celui-ci. Tu peux comprendre l'essentiel ici ; le traitement complet de la p-value par permutation est dans le document 03, et l'usage concret dans le document 08 (cascade n-grammes).

En une phrase

Le test sériel généralise la binomiale : au lieu de compter un bit isolé, on compte des **motifs de n bits** dans la séquence binaire d'un numéro, pour débusquer une éventuelle **structure temporelle**.

Intuition

Réduis chaque numéro à son « code-barres » : une suite de 0 (absent) et 1 (tiré) le long des tirages. Regarder un seul bit, c'est la binomiale (fréquence de 1). Mais une mémoire cachée ne se voit pas forcément bit par bit : elle pourrait se nicher dans des **motifs** — par exemple « après deux absences, plus de présences ». On compte donc les motifs de longueur n (paires 01, triplets 101, etc.) et on

compare leur fréquence observée à ce que le pur hasard prédit. Si rien ne dévie, aucune structure temporelle d'ordre n n'existe.

Formalisation

Probabilité d'un motif sous i.i.d. Pour une séquence binaire i.i.d. de paramètre p (probabilité d'un 1), un motif fixé de longueur n contenant a uns et $b = n - a$ zéros a pour probabilité

$$P(\text{motif}) = p^a(1 - p)^b.$$

C'est la **généralisation directe** de la binomiale (qui correspond à $n = 1$: un seul bit, probabilité p ou $1 - p$). Sur une séquence de longueur L , le **nombre attendu** d'occurrences d'un motif donné (fenêtres glissantes) est $\approx (L - n + 1) p^a(1 - p)^b$.

Le piège des fenêtres chevauchantes. Si l'on fait glisser une fenêtre de largeur n d'un cran à la fois, deux fenêtres consécutives **partagent $n - 1$ bits** : leurs comptes sont **corrélés**. Conséquence : la variance du nombre d'occurrences **n'est pas** celle d'un comptage binomial indépendant, et un χ^2 naïf (qui suppose des comptes indépendants) **donne une p-value fausse**. Deux remèdes :

1. Fenêtres **disjointes** (non chevauchantes) $\rightarrow$ comptes indépendants, mais on jette de l'information.
2. Garder le chevauchement mais calibrer la loi nulle par **test de permutation** (§2.9) : on remélange l'ordre temporel (ce qui préserve la fréquence marginale de 1 mais détruit toute structure d'ordre), et on lit où tombe l'observé. C'est le choix du projet.

Lien avec les tests NIST. Cette famille recouvre plusieurs tests de la batterie NIST de qualité d'aléa : *Frequency (Monobit)* ($n = 1$), *Frequency within a Block*, *Serial test* (motifs de longueur n), *Approximate Entropy*. Tous mesurent un écart entre fréquences de motifs observées et théoriques.

Dans iAlexMG

- **Étape 2.5 (cascade binaire, document 08)** : diagnostic n-grammes — pour $n = 1, 2, 3, \dots$, on compare les fréquences de motifs observées aux attendues $p^a(1 - p)^b$, avec une **p-value par permutation** (§2.9) pour contourner le chevauchement.
- **Figure 11a** : les fréquences observées sont **collées au théorique**, $p > 0,05$ partout $\rightarrow$ aucune structure temporelle exploitable, à aucun ordre testé.

Pièges & malentendus

- **Appliquer un χ^2 aux comptes de fenêtres chevauchantes.** Les comptes sont corrélés $\rightarrow$ la loi du χ^2 ne tient plus. Utiliser disjoint ou permutation.

- **Multiplier les longueurs n sans correction.** Tester beaucoup de motifs gonfle le risque de faux positif (comparaisons multiples, §2.5).
- **Confondre motif rare et motif suspect.** Un motif long est *intrinsèquement* rare sous H_0 ; rare $\neq$ anormal. C'est l'écart à l'attendu qui compte, pas la rareté absolue.

Pour vérifier ta compréhension

1. Pour $p = 6/49$, quelle est la probabilité du motif 11 (deux sorties consécutives) sous i.i.d. ? Et du motif 00 ?
2. Pourquoi deux fenêtres chevauchantes de largeur 3 ont-elles des comptes corrélés ? Combien de bits partagent-elles ?
3. Pourquoi le test de permutation est-il préféré au χ^2 ici ?

(Réponses [à la fin.](#))

Pour aller plus loin

- **Approximate Entropy & entropie de blocs** : mesurent la prévisibilité d'une séquence à partir des fréquences de motifs ; lien direct avec le plancher d'entropie (§5.5).
- **Chaînes de Markov d'ordre $n - 1$** : un test sériel d'ordre n teste implicitement contre une dépendance markovienne d'ordre $n - 1$ (voir §6.3).
- **Suites de De Bruijn** : objets combinatoires où chaque motif de longueur n apparaît exactement une fois — l'idéal d'équirépartition des motifs.

Réponses aux exercices

1.1

1. $\mathbb{E}[Y] = 4377 \times 6/49 \approx 535,96$; $\sigma(Y) = \sqrt{4377 \cdot 6/49 \cdot 43/49} \approx 21,68$ (voir doc 01, §0.4).
2. Parce que $\sum_k \binom{N}{k} p^k (1-p)^{N-k} = (p + (1-p))^N = 1^N = 1$: c'est le **binôme de Newton**.
3. Le **test exact** : avec un petit effectif (série rare), Np de la sous-population peut être faible et l'approximation normale dérape en queue. L'exact reste valide à tout N .

1.2

1. Par absence de mémoire, $P(T > 15 + 8 \mid T > 15) = P(T > 8) = (43/49)^8 \approx 0,366$.
Identique à un numéro frais : $\sim 36,6\%$ d'attendre au moins 8 tirages. Le retard de 15 n'y change rien.
2. Au 6/49 : $\mathbb{E}[T] = 49/6 \approx 8,17$ tirages. Au 7/50 : $\mathbb{E}[T] = 50/7 \approx 7,14$ tirages.
3. Parce que $P(\text{sort} \mid \text{âge} = m) = p$ pour tout m : l'attente déjà écoulée n'augmente en rien la probabilité de sortir — le numéro n'est jamais « dû ».

1.3

1. $P(H = 6) = \frac{\binom{24}{6}\binom{25}{0}}{\binom{49}{6}} = \frac{\binom{24}{6}}{\binom{49}{6}} = \frac{134\,596}{13\,983\,816} \approx 0,00963$ ($\sim 0,96\%$).
2. Le facteur de correction de population finie est $\frac{m-n}{m-1} = \frac{43}{48} \approx 0,896$: la variance hypergéométrique vaut **$\sim 89,6\%$** de la binomiale (donc réduite d'environ $10,4\%$).
3. Oui : avec $m = 49\,000$, $\frac{m-n}{m-1} \approx 1$, donc Hypergeom $\approx$ Bin($6, p$). Sur une grande population, retirer 6 éléments ne modifie quasiment pas les proportions.

1.4

1. Parce que S est une **somme** de 6 variables ; le TCL (même en version « faible dépendance », vu la corrélation $-1/48$) rend la somme quasi normale au centre. Condition : variance finie et dépendance faible — toutes deux satisfaites.
2. **Non.** $z = 3,2$ dit seulement que l'écart est réel (improbable sous H_0) **grâce au grand N** . L'effet sur la somme est minuscule et ne se traduit par aucun numéro exploitable (T6, §4.6) : significatif $\neq$ exploitable.
3. Un **z-test ciblé** sur la fréquence du 7 : il concentre toute la puissance sur l'unique direction suspectée, alors que le χ^2 sur 49 numéros dilue le signal sur 48 degrés de liberté.

1.5

1. Min = $1 + 2 + 3 + 4 + 5 + 6 = 21$; max = $44 + 45 + 46 + 47 + 48 + 49 = 279$; centre = 150. Symétrie : la transformation $n_i \mapsto 50 - n_i$ envoie une combinaison de somme s sur une combinaison valide de somme $300 - s$, en bijection — d'où la symétrie autour de 150.
2. À rebours pour que le numéro i ne serve **qu'une fois** : on lit $f[j-1][s-i]$ *avant* qu'il ait été modifié par l'insertion de i . À l'endroit, on réutiliserait i plusieurs fois $\rightarrow$ tirage avec remise $\rightarrow$ faux.
3. $c(21) = 1$ (seule la combinaison $\{1,2,3,4,5,6\}$) et $c(279) = 1$ (seule $\{44, \dots, 49\}$). Cohérent avec la symétrie.

1.6

1. Posterior $\text{Beta}(1 + 536, 1 + 4377 - 536) = \text{Beta}(537, 3842)$. Moyenne = $537/(537 + 3842) = 537/4379 \approx 0,1226$, très proche de $6/49 \approx 0,1224$.
2. Avec $\alpha = \beta = 1 : f(\theta) \propto \theta^0(1 - \theta)^0 = 1$ sur $[0,1]$ — densité **constante**, donc loi uniforme.
3. α joue le rôle de succès « déjà vus » et β d'échecs « déjà vus » avant les données : on les **ajoute** aux compteurs réels. $\text{Beta}(1,1) = 1$ succès + 1 échec fictifs, exactement le **lissage de Laplace** $(k + 1)/(N + 2)$.

1.7

1. $11 : p^2 = (6/49)^2 \approx 0,0150$ (~1,5 %). $00 : (1 - p)^2 = (43/49)^2 \approx 0,770$ (~77 %).
2. Deux fenêtres consécutives de largeur 3 partagent **2 bits** (les positions $t + 1, t + 2$ sont communes aux fenêtres démarrant en t et $t + 1$) ; ces bits communs corréleront mécaniquement leurs comptes.
3. Parce que le chevauchement rend les comptes **corrélés**, ce qui invalide la loi du χ^2 ; la permutation reconstruit la vraie loi nulle (en préservant la fréquence de 1 et en détruisant la structure temporelle) sans rien supposer sur ces corrélations. ``