

03 — Inférence fréquentiste

Table des matieres

[2.1 — Hypothèse nulle \$H_0\$ / alternative \$H_1\$](#)

[2.2 — p-value & seuil \$\alpha\$](#)

[2.3 — Erreurs de type I et II](#)

[2.4 — Puissance & biais minimal détectable](#)

[2.5 — Comparaisons multiples & correction de Bonferroni](#)

[2.6 — Test du \$\chi^2\$ d'adéquation](#)

[2.7 — Intervalle de confiance](#)

[2.8 — Monte-Carlo \(loi nulle empirique\)](#)

[2.9 — Test de permutation](#)

[2.10 — Bruit blanc & indépendance temporelle](#)

[Réponses aux exercices](#)

Niveau : base → avancé (tout traité en profondeur). **Prérequis** : 01_fondations.md (Bernoulli, espérance/variance, indépendance vs sans remise), 02_lois_de_probabilite.md (binomiale, normale/z, hypergéométrique, n-grammes). **Couvre les fiches source** : 2.1 à 2.10 de concepts_FR.md. **Documents suivants** : 04_inference_bayesienne.md, 06_tests_phase1.md.

Idée directrice. L'inférence fréquentiste est le **tribunal de l'aléa**. On présume l'innocence (le hasard, H_0), on fixe les règles de preuve (p-value, seuil α), on quantifie nos deux façons de nous tromper (erreurs I et II), on calibre la sensibilité du juge (puissance), on se protège contre les procès multiples (Bonferroni), et on choisit nos instruments de mesure (χ^2 , intervalles, Monte-Carlo, permutation, tests d'indépendance temporelle). Tous les tests de la Phase 1 (document 06) en découlent.

2.1 — Hypothèse nulle H_0 / alternative H_1

En une phrase

H_0 est le modèle de référence (« le tirage est uniforme et indépendant ») qu'on présume vrai ; on ne le **prouve** jamais, on le **rejette** ou on **échoue à le rejeter**.

Intuition

C'est le **procès de l'aléa**. H_0 joue l'accusé présumé innocent : le Lotto est un pur hasard sans mémoire. H_1 est l'accusation : « il y a une structure ». Le fardeau de la preuve pèse sur H_1 : tant que les données

ne sont pas *suffisamment* incompatibles avec le hasard, on garde H_0 — non parce qu'elle est démontrée vraie, mais faute de preuve du contraire. C'est une asymétrie volontaire, et elle structure tout le projet.

Formalisation

On oppose deux hypothèses sur le mécanisme générateur des données :

- H_0 (**nulle**) : hypothèse précise et testable. Ici, $X_t \sim \text{Bernoulli}(p)$ i.i.d. avec $p = 6/49$ (le processus du document 01). Elle fixe *complètement* la loi des données, ce qui permet de calculer des probabilités sous H_0 .
- H_1 (**alternative**) : la négation, en général **composite** (un ensemble d'hypothèses). « $p \neq 6/49$ », ou « il existe une autocorrélation », ou « un numéro est favorisé » — chacune recouvre une infinité de valeurs de paramètres.

La règle de décision confronte une statistique de test T (résumé des données) à sa loi **sous** H_0 . Deux issues seulement :

1. **Rejeter** H_0 si T tombe dans une zone improbable sous H_0 (preuve à charge suffisante).
2. **Ne pas rejeter** H_0 sinon — ce qui **n'est pas** « accepter H_0 ».

L'asymétrie fondamentale. On ne peut pas « prouver H_0 » car d'innombrables H_1 quasi indiscernables de H_0 existent (un biais de 0,0001 % est indétectable avec 4 377 tirages). D'où la maxime : « **l'absence de preuve n'est pas la preuve de l'absence** ». Un non-rejet ne dit pas « le hasard est parfait » ; il dit « les données ne contredisent pas le hasard, à la résolution permise par N » — d'où la nécessité de l'analyse de **puissance** (§2.4) pour interpréter un non-rejet.

Dans iAlexMG

H_0 — le processus de Bernoulli — est l'accusé commun à **tous** les tests. Chaque étape du projet énonce explicitement son H_0 et son H_1 (consignés dans reports/quiz_FR.md). Exemples :

- **T1** : H_0 : chaque numéro a $p = 6/49$; H_1 : au moins un numéro dévie.
- **T2** : H_0 : les gaps sont géométriques (sans mémoire) ; H_1 : dépendance à l'âge.
- **T4** : H_0 : la série dérivée est un bruit blanc ; H_1 : autocorrélation non nulle.

Le verdict global du projet est un **non-rejet** répété de H_0 — interprété à *la lumière de la puissance*, ce qui exclut les biais grossiers sans prétendre prouver l'aléa parfait.

Pièges & malentendus

- « **Ne pas rejeter** » = « **prouver** H_0 ». Faux. C'est l'erreur la plus courante. Un non-rejet est compatible avec de petits effets non détectés.

- **Choisir H_1 après avoir vu les données.** Formuler l'alternative *après coup* (« tiens, le 7 sort souvent, testons le 7 ») invalide le test (p-hacking, §2.2). H_1 se déclare avant.
- **Croire H_0 « arbitraire ».** Ici H_0 n'est pas un homme de paille : c'est le modèle physique réaliste d'un tirage équitable, avec des conséquences chiffrées précises.

Pour vérifier ta compréhension

1. Reformule en H_0/H_1 l'affirmation « les numéros en retard finissent par sortir ».
2. Pourquoi ne peut-on jamais « prouver » que le Lotto est parfaitement aléatoire ?
3. Un test ne rejette pas H_0 . Quelle information *supplémentaire* faut-il pour savoir si ce non-rejet est rassurant ou simplement non concluant ?

(Réponses [à la fin.](#))

Pour aller plus loin

- **Lemme de Neyman-Pearson** : pour deux hypothèses simples, le test du rapport de vraisemblance est le plus puissant — fondement théorique du choix des statistiques.
- **Tests ciblés vs omnibus** : une H_1 précise (effet directionnel) autorise un test plus puissant qu'une H_1 vague (§1.4, §2.6).

2.2 — p-value & seuil α

En une phrase

La p-value est la probabilité, **si H_0 est vraie**, d'observer un écart au moins aussi extrême que celui mesuré ; on rejette H_0 quand elle passe sous un seuil α fixé d'avance.

Intuition

« À quel point mes données seraient-elles surprenantes sous le pur hasard ? » Si, en supposant le hasard, ce que j'observe (ou pire) n'arrive qu'une fois sur mille, soit j'ai eu une malchance rare, soit le hasard n'est pas le bon modèle. Le seuil α est le niveau de surprise à partir duquel on décide de douter de H_0 — un curseur de tolérance au faux positif, choisi **avant** de regarder.

Formalisation

Soit T une statistique de test dont les grandes valeurs indiquent un écart à H_0 , et t_{obs} sa valeur observée. La **p-value** (cas unilatéral) est

$$p = P_{H_0}(T \geq t_{\text{obs}}),$$

c'est-à-dire la probabilité, **calculée sous H_0** , d'un résultat aussi ou plus extrême. On rejette H_0 si $p < \alpha$ (souvent $\alpha = 0,05$).

Propriété clé : sous H_0 , la p-value est uniforme sur $[0,1]$. Si T est continue de fonction de répartition F sous H_0 , alors $p = 1 - F(T)$ et, pour $u \in [0,1]$,

$$P_{H_0}(p \leq u) = P_{H_0}(1 - F(T) \leq u) = P_{H_0}(F(T) \geq 1 - u) = 1 - (1 - u) = u.$$

Donc $p \sim \text{Uniforme}(0,1)$. **Conséquence directe :** sous H_0 , $P(p < \alpha) = \alpha$ — le taux de faux rejets est exactement α . C'est ce qui *définit* le contrôle de l'erreur de type I (§2.3).

Ce que la p-value n'est PAS (erreurs cardinales) :

- Ce **n'est pas** $P(H_0 \text{ vraie} \mid \text{données})$. Elle conditionne dans l'autre sens : données sachant H_0 , pas H_0 sachant les données (ça, c'est le posterior bayésien, document 04).
- Ce **n'est pas** la probabilité que le résultat soit dû au hasard.
- Une grande p-value ne « prouve » pas H_0 (§2.1).

p-hacking. Comme p est uniforme sous H_0 , tester beaucoup de choses et ne rapporter que les $p < 0,05$ garantit des faux positifs : sur 20 tests indépendants sous H_0 , on attend **1** rejet « significatif » par pur hasard. D'où l'importance de déclarer les tests à l'avance et de corriger pour leur multiplicité (§2.5).

Dans iAlexMG

- La p-value est le **verdict chiffré** de chaque test (T1–T6).
- Le seuil α est **corrigé** pour les comparaisons multiples (Bonferroni, §2.5) : 49 numéros en T1, plusieurs longueurs de série en T3.
- Quand la loi de T sous H_0 est intraitable (tirage sans remise), la p-value est estimée par **Monte-Carlo** (§2.8) ou **permutation** (§2.9).

Pièges & malentendus

- « $p = 0,05 \Rightarrow$ **95 % de chances que H_1 soit vraie** ». Non : confusion entre $P(\text{données} \mid H_0)$ et $P(H_1 \mid \text{données})$.
- « **Significatif** » $\Rightarrow$ « **important** ». Avec un grand N , un effet minuscule devient significatif (cf. le $z \approx 3,2$ de la somme, significatif mais inexploitable, §4.6).
- **Choisir α après coup**, ou tester jusqu'à obtenir $p < 0,05$: p-hacking.

- **Oublier « au moins aussi extrême ».** La p-value cumule la queue, ce n'est pas la probabilité ponctuelle de l'observé.

Pour vérifier ta compréhension

1. Sous H_0 , quelle est la probabilité d'obtenir $p < 0,01$? Et $p < 0,05$? Quelle propriété utilises-tu ?
2. On teste les 49 numéros à $\alpha = 0,05$ sans correction. Combien de « significatifs » attend-on **même si H_0 est vraie partout** ?
3. Un journaliste écrit : « $p = 0,03$, donc il y a 97 % de chances que le tirage soit truqué ». Corrige l'erreur.

(Réponses [à la fin.](#))

Pour aller plus loin

- **Distribution des p-values sous H_1** : concentrée près de 0 ; sa forme renseigne sur la puissance.
- **q-values / FDR (§2.5)** : recalibrage des seuils quand on fait beaucoup de tests.
- **Débat « abandonner $p < 0,05$ »** : discussions sur les seuils (0,005), les facteurs de Bayes, et les intervalles comme alternatives.

2.3 — Erreurs de type I et II

En une phrase

Le type I, c'est rejeter H_0 alors qu'elle est vraie (faux positif, probabilité α) ; le type II, ne pas rejeter H_0 alors qu'elle est fausse (faux négatif, probabilité β).

Intuition

Crier au loup à tort (type I) vs rater un vrai loup (type II). Le juge de l'aléa peut se tromper de deux façons : condamner un tirage honnête (voir une structure qui n'existe pas), ou acquitter un tirage biaisé (manquer une vraie structure). On ne peut pas annuler les deux à la fois ; on choisit où mettre le curseur.

Formalisation

	H_0 vraie	H_0 fausse
Rejeter H_0	Type I (proba α)	Décision correcte (proba $1 - \beta$ = puissance)
Ne pas rejeter	Décision correcte (proba $1 - \alpha$)	Type II (proba β)

- $\alpha = P(\text{rejeter } H_0 \mid H_0 \text{ vraie})$: fixé d'avance (le seuil).
- $\beta = P(\text{ne pas rejeter } H_0 \mid H_1 \text{ vraie})$: dépend de la **taille de l'effet**, de N , et de α .

L'arbitrage $\alpha \leftrightarrow \beta$. À N fixé, abaisser α (juge plus exigeant) **augmente** β (on rate plus de vrais effets), et inversement. On ne réduit les **deux** qu'en augmentant N (plus de données $\rightarrow$ meilleure séparation des lois sous H_0 et H_1). C'est la raison profonde pour laquelle un grand N est précieux.

Effet de la taille d'échantillon. Les lois de T sous H_0 et sous H_1 se chevauchent ; α et β sont les aires de chevauchement de part et d'autre du seuil. Augmenter N resserre ces lois (variance en $1/N$, §0.4) $\rightarrow$ moins de chevauchement $\rightarrow \beta$ chute à α constant.

Dans iAlexMG

- Le projet **fixe** α (souvent 0,05, corrigé par Bonferroni) et **raisonne sur** β via la puissance (§2.4), surtout là où l'on **ne rejette pas** (la quasi-totalité des tests).
- La correction de Bonferroni (§2.5) vise explicitement à **contrôler les erreurs de type I cumulées** sur 49 numéros / plusieurs séries.

Pièges & malentendus

- **Ignorer le type II quand on ne rejette pas.** Un non-rejet avec β élevé (test peu puissant) est **muet**, pas rassurant.
- **Croire qu'on peut tout minimiser à N fixé.** α et β s'échangent ; seul plus de données (ou un test plus puissant) les réduit ensemble.
- **Confondre α (par test) et le risque global** sur plusieurs tests (§2.5).

Pour vérifier ta compréhension

1. On passe α de 0,05 à 0,001 (Bonferroni). Qu'arrive-t-il à β et à la puissance, à N constant ?
2. Pourquoi un test qui « ne rejette jamais rien » a-t-il $\alpha = 0$ mais une puissance nulle ?
3. Associe : (a) condamner un tirage honnête, (b) blanchir un tirage truqué — à type I / II.

(Réponses [à la fin.](#))

Pour aller plus loin

- **Courbes ROC** : tracent $1 - \beta$ contre α quand le seuil varie ; l'aire (AUC) résume le pouvoir discriminant.
 - **Approche de Neyman-Pearson vs Fisher** : contrôle d'erreurs décisionnel vs p-value comme mesure continue de preuve.
-

2.4 — Puissance & biais minimal détectable

En une phrase

La puissance $1 - \beta$ est la probabilité de détecter un effet réel ; le **biais minimal détectable** est le plus petit écart qu'on aurait su voir, et il décroît en $\sim 1/\sqrt{N}$.

Intuition

La puissance, c'est l'acuité visuelle du test : « quel effet aurais-je été capable de repérer ? ». Cette question est **cruciale quand on ne rejette pas** : un non-rejet n'est informatif que si le test était assez puissant pour détecter un effet d'intérêt. Dire « je n'ai rien vu » n'a de valeur que si j'ajoute « ...et j'aurais vu tout biais supérieur à $X\%$ ».

Formalisation

Définition. Puissance = $1 - \beta = P(\text{rejeter } H_0 \mid H_1 \text{ vraie})$. Elle dépend de la **taille d'effet** δ , de N , de α , et du test.

Biais minimal détectable (test sur une proportion). Pour détecter un écart $\delta = |p_1 - p_0|$ de la probabilité d'un numéro, avec un test bilatéral de niveau α et une puissance cible $1 - \beta$, l'effet détectable vérifie approximativement

$$\delta \approx (z_{1-\alpha/2} + z_{1-\beta}) \sqrt{\frac{p_0(1-p_0)}{N}}.$$

Le facteur clé est $\sqrt{p_0(1-p_0)/N}$: le biais détectable **décroît en** $1/\sqrt{N}$. Quadrupler N divise par deux le plus petit effet visible.

Application chiffrée (T1, $p_0 = 6/49$, $N = 4\,377$). Ici $\sqrt{p_0(1-p_0)/N} \approx 0,00496$. Pour $\alpha = 0,05$ ($z = 1,96$) et puissance 0,80 ($z = 0,84$) :

$$\delta \approx (1,96 + 0,84) \times 0,00496 \approx 0,0139,$$

soit un biais **absolu** de $\approx 1,4$ point de pourcentage, ou **relatif** $\approx 0,0139/0,1224 \approx 11\%$. Avec la correction de Bonferroni sur 49 numéros ($\alpha = 0,001$, $z \approx 3,29$), le seuil monte à $\delta \approx (3,29 + 0,84) \times 0,00496 \approx 0,0205$, soit $\approx 17\%$ de biais relatif. **Lecture du projet** : « j’aurais détecté qu’un numéro sorte $\$10$ –17 % plus souvent que les autres ; je n’ai rien vu, donc de tels biais grossiers sont exclus » — tout en restant muet sur des biais infimes.

Ciblé vs omnibus. Un test ciblé (z sur une direction, §1.4) a une puissance bien supérieure à un χ^2 omnibus pour un effet concentré : le calcul de δ ci-dessus suppose qu’on sait où regarder.

Dans iAlexMG

- **T1** s’accompagne d’une **analyse de puissance** explicite : on chiffre le biais minimal détectable pour transformer le non-rejet en énoncé positif (« biais grossiers exclus »).
- C’est l’antidote méthodologique au piège « absence de preuve = preuve d’absence » (§2.1).

Pièges & malentendus

- **Rapporter un non-rejet sans puissance.** Sans δ détectable, « rien trouvé » est ininterprétable.
- **Calcul de puissance *post hoc* basé sur l’effet observé** : trompeur ; la puissance se raisonne sur un effet *d’intérêt* fixé d’avance, pas sur le bruit observé.
- **Oublier la correction multiple dans le calcul.** Le δ détectable par numéro est plus grand après Bonferroni (seuil plus strict).

Pour vérifier ta compréhension

1. De combien faut-il multiplier N pour diviser par 2 le biais minimal détectable ?
2. Avec $N = 4\,377$, on ne détecte pas de biais. Peut-on conclure « le tirage est parfaitement uniforme » ? Que peut-on conclure exactement ?
3. Pourquoi la correction de Bonferroni augmente-t-elle le biais minimal détectable ?

(Réponses [à la fin.](#))

Pour aller plus loin

- **Courbes de puissance** : puissance en fonction de δ , pour visualiser la zone aveugle du test.
 - **Calcul de taille d’échantillon** : inverser la formule pour trouver le N requis afin de détecter un δ donné à puissance voulue.
-

2.5 — Comparaisons multiples & correction de Bonferroni

En une phrase

Tester m hypothèses gonfle le risque qu'au moins un faux positif survienne ; Bonferroni ramène le seuil de chaque test à α/m pour contrôler ce risque global.

Intuition

Sur 49 numéros testés à 95 %, voir « ~2–3 numéros hors bande » n'est pas une anomalie : **c'est exactement ce que le hasard produit**. Plus on multiplie les tests, plus on se donne d'occasions de tomber sur un faux positif. Bonferroni resserre la barre proportionnellement au nombre de tests, pour que le risque de se tromper **au moins une fois** reste maîtrisé.

Formalisation

Le problème. Pour m tests indépendants, chacun de niveau α , sous H_0 partout, la probabilité d'**au moins un** faux rejet (le *family-wise error rate*, FWER) est

$$\text{FWER} = 1 - (1 - \alpha)^m \xrightarrow{m \text{ grand}} 1.$$

Pour $m = 49$ et $\alpha = 0,05$: $\text{FWER} = 1 - 0,95^{49} \approx 0,92$ — il est **quasi certain** d'avoir au moins un « significatif » par pur hasard. Le nombre attendu de faux positifs est $m\alpha = 49 \times 0,05 \approx 2,45$ (les ~2–3 annoncés).

La correction de Bonferroni. On teste chaque hypothèse au seuil α/m . Par l'inégalité de Boole (sous-additivité), quel que soit le schéma de dépendance,

$$\text{FWER} = P\left(\bigcup_{i=1}^m \{p_i < \alpha/m\}\right) \leq \sum_{i=1}^m P(p_i < \alpha/m) = m \cdot \frac{\alpha}{m} = \alpha.$$

Le FWER est donc **borné par α** , sans hypothèse d'indépendance — d'où sa robustesse. Pour T1 : seuil par numéro $0,05/49 \approx 0,00102$.

Le coût : le conservatisme. Bonferroni est **prudent** (il contrôle le pire cas) ; quand les tests sont corrélés ou nombreux, il sacrifie de la puissance (§2.4) — le biais minimal détectable augmente. D'où des alternatives moins strictes.

Dans iAlexMG

- **T1** : test binomial exact par numéro, comparé au seuil de Bonferroni $\alpha/49$; sans cela, les 2–3 numéros « hors bande » seraient sur-interprétés.
- **T3 (main chaude)** : binomial exact par longueur de série k , corrigé pour le nombre de longueurs testées.

- C'est le garde-fou direct contre l'**illusion de motif** (§7.3) née de la multiplicité.

Pièges & malentendus

- **Ne pas corriger du tout** : ~2–3 faux positifs « garantis » sur 49 numéros.
- **Bonferroni partout, aveuglement** : trop conservateur pour de très nombreux tests corrélés ; envisager Holm ou FDR.
- **Confondre FWER et FDR** : contrôler « au moins un faux positif » (FWER) n'est pas contrôler « la proportion de faux positifs parmi les rejets » (FDR).

Pour vérifier ta compréhension

1. Sur 49 tests à $\alpha = 0,05$ sous H_0 , quel est le nombre attendu de faux positifs ? Et la probabilité d'en avoir au moins un ?
2. Quel seuil par numéro impose Bonferroni pour garder un $\text{FWER} \leq 0,05$ sur 49 tests ?
3. Pourquoi Bonferroni réduit-il la puissance ?

(Réponses [à la fin.](#))

Pour aller plus loin

- **Procédure de Holm** : Bonferroni séquentiel, uniformément plus puissant, même contrôle du FWER.
- **FDR de Benjamini-Hochberg** : contrôle la proportion attendue de faux positifs parmi les rejets ; bien plus puissant quand m est grand.
- **Tests corrélés** : la borne de Boole est lâche sous forte corrélation (cf. les 49 comptes corrélés à $-1/48$) ; des méthodes par permutation calibrent un seuil exact.

2.6 — Test du χ^2 d'adéquation

En une phrase

Le χ^2 d'adéquation compare des **comptes observés** à des **comptes attendus** sous H_0 via $X^2 = \sum (O - E)^2 / E$; c'est un test **omnibus** de la forme globale d'une distribution.

Intuition

On découpe les données en catégories (les 49 numéros, ou les valeurs possibles de la somme, ou les comptes de pairs), on calcule combien on en attend dans chaque case sous le hasard, et on mesure l'écart global. Le χ^2 additionne les écarts normalisés : un grand total signale que « la forme ne colle pas ». C'est puissant pour détecter **n'importe quelle** déformation, mais au prix d'une puissance **diluée** sur toutes les cases — il ne sait pas où regarder.

Formalisation

Pour c catégories d'effectifs observés O_i et attendus $E_i = Np_i$ sous H_0 :

$$\chi^2 = \sum_{i=1}^c \frac{(O_i - E_i)^2}{E_i}.$$

Sous H_0 et pour des effectifs suffisants, χ^2 suit approximativement une loi du χ^2 à ν **degrés de liberté** :

$$\nu = c - 1 - (\text{nombre de paramètres estimés depuis les données}).$$

Le -1 vient de la contrainte $\sum_i O_i = N$ (les comptes ne sont pas libres). Pour les 49 numéros sans paramètre estimé, $\nu = 48$.

Conditions de validité. Approximation correcte si les E_i ne sont pas trop petits (règle usuelle $E_i \geq 5$). Sinon, regrouper des cases ou passer par Monte-Carlo (§2.8).

Correction « population finie ». Le tirage **sans remise** (§0.3) introduit des corrélations $-1/48$ entre comptes et une contrainte de moyenne nulle (somme fixée). La loi du χ^2 asymptotique standard suppose des comptes (quasi) indépendants ; pour des catégories issues d'un même tirage, la p-value théorique peut être biaisée. Le projet **calibre alors la loi nulle par Monte-Carlo** en rejouant de vrais tirages sans remise.

Omnibus vs ciblé. Le χ^2 répartit sa puissance sur ν directions. Face à un effet **monotone** (la somme penche vers le haut), un z-test ciblé sur la moyenne (§1.4) est bien plus puissant : il projette tout le signal sur une seule direction. Le χ^2 peut **rater** un effet que le z-test détecte (c'est exactement le cas du penchant $z \approx 3,2$ en T5).

Dans iAlexMG

- **T1** : χ^2 d'uniformité des 49 numéros ($\nu = 48$), avec **p-value Monte-Carlo** pour intégrer le sans-remise.
- **T5** : χ^2 sur la **forme de la somme** (vs distribution exacte, §1.5) et sur la **parité** (vs hypergéométrique, §1.3). Le χ^2 sur la somme ne détecte pas le léger penchant — d'où l'ajout du z-test ciblé.

Pièges & malentendus

- **Mauvais degrés de liberté.** Oublier le -1 (contrainte de somme) ou les paramètres estimés fausse la p-value.
- **Petits E_i .** L'approximation χ^2 s'effondre ; regrouper ou simuler.
- **Tout attendre d'un omnibus.** Un χ^2 non significatif n'exclut pas un effet directionnel précis (utiliser un test ciblé en complément).
- **Ignorer le sans-remise.** Appliquer la loi χ^2 standard à des comptes corrélés d'un même tirage → p-value biaisée.

Pour vérifier ta compréhension

1. Pour les 49 numéros, combien de degrés de liberté a le χ^2 d'uniformité ? Pourquoi pas 49 ?
2. Pourquoi la p-value du χ^2 de T1 est-elle obtenue par Monte-Carlo plutôt que par la table du χ^2 ?
3. Le χ^2 sur la somme ne rejette pas, mais le z-test sur la moyenne, oui. Contradiction ? Explique.

(Réponses [à la fin.](#))

Pour aller plus loin

- **χ^2 d'indépendance** (tables de contingence) vs d'adéquation : même statistique, usages distincts.
- **Test du rapport de vraisemblance (G^2)** : alternative asymptotiquement équivalente, parfois préférable pour petits effectifs.
- **Décomposition des résidus** $(O_i - E_i)/\sqrt{E_i}$: localise *quelles* cases contribuent à l'écart.

2.7 — Intervalle de confiance

En une phrase

Un intervalle de confiance à 95 % est construit pour contenir le vrai paramètre dans 95 % des **répétitions** de l'expérience — c'est une affirmation sur la **procédure**, pas sur ce paramètre-ci.

Intuition

Imagine répéter l'histoire des 4 377 tirages des milliers de fois ; à chaque fois tu fabriques un intervalle. La promesse « 95 % » dit que **95 % de ces intervalles** contiendraient la vraie valeur. Pour *ton* intervalle particulier, la vérité y est ou n'y est pas — il n'y a pas de probabilité « 95 % » attachée à lui. C'est la

nuance fréquentiste, souvent mal comprise (et c'est précisément ce que l'intervalle **crédible** bayésien, §3.3, dit *vraiment*).

Formalisation

Un IC de niveau $1 - \alpha$ pour un paramètre θ est une paire de bornes aléatoires $[L(X), U(X)]$ (fonctions des données) telles que, **avant** observation,

$$P_{\theta}(L(X) \leq \theta \leq U(X)) = 1 - \alpha \quad \text{pour tout } \theta.$$

La probabilité porte sur les **données** X (donc sur les bornes), pas sur θ (fixe). Une fois les données observées, l'intervalle est numérique et ne « contient θ » qu'au sens de la procédure.

Méthodes pour une proportion :

- **Wald (asymptotique)** : $\hat{p} \pm z_{1-\alpha/2} \sqrt{\hat{p}(1-\hat{p})/N}$. Simple, mais médiocre pour p extrême ou petit N (peut sortir de $[0,1]$).
- **Clopper-Pearson (exact)** : inverse le test binomial, bornes exprimées via des quantiles de la loi Beta. **Toujours valide** (couverture $\geq 1 - \alpha$), légèrement conservateur.

Lien avec les tests. Un IC à $1 - \alpha$ est l'ensemble des valeurs θ_0 non rejetées par un test bilatéral de niveau α : tester et estimer par intervalle sont les deux faces d'une même pièce.

Dans iAlexMG

- **Bandes de T1/T2/T3** : les bandes à 95 % autour de 6/49 (ou de la courbe géométrique) sont des IC ; un point hors bande = rejet local (à corriger pour la multiplicité, §2.5).
- Le projet **oppose explicitement** cet IC fréquentiste à l'**intervalle crédible** bayésien (§3.3) sur la figure des posteriors par numéro — même nombre, interprétations opposées.

Pièges & malentendus

- « **95 % de chance que θ soit dans cet intervalle-ci** ». Faux en fréquentiste : c'est l'interprétation **crédible** (bayésienne). L'IC parle de la procédure.
- **Wald pour des comptes extrêmes**. Mauvaise couverture ; préférer Clopper-Pearson ou Wilson.
- **Confondre largeur et certitude**. Un IC étroit reflète beaucoup de données, pas une vérité « plus sûre » au sens probabiliste sur θ .

Pour vérifier ta compréhension

1. Reformule correctement : « le 7 sort dans $[0,118,0,127]$ avec 95 % de confiance ». Que signifie *exactement* le « 95 % » ?

2. Pourquoi préférer Clopper-Pearson à Wald pour un numéro à très faible effectif ?
3. En quoi un IC à 95 % et un test bilatéral à $\alpha = 0,05$ sont-ils équivalents ?

(Réponses [à la fin.](#))

Pour aller plus loin

- **Intervalle de Wilson** : bon compromis couverture/largeur pour une proportion.
 - **Dualité test-intervalle** : construire un IC en inversant n'importe quel test.
 - **Opposition fréquentiste/bayésien** : à lire avec §3.3 (crédible) pour saisir la différence d'objet (procédure vs croyance).
-

2.8 — Monte-Carlo (loi nulle empirique)

En une phrase

Quand la loi de la statistique sous H_0 est trop compliquée à calculer, on la **simule** : on génère des milliers de jeux de données sous H_0 et on lit où tombe l'observé.

Intuition

« Si je ne sais pas calculer la probabilité, je rejoue le hasard. » On fabrique des Lottos virtuels parfaitement aléatoires (sans remise, comme le vrai jeu), on calcule la statistique de test sur chacun, et on obtient ainsi la **distribution de référence** empirique. La p-value devient une simple proportion : « dans quelle fraction des univers simulés la statistique est-elle au moins aussi extrême que dans le vrai ? ».

Formalisation

Soit T la statistique et t_{obs} sa valeur observée. On simule B jeux sous H_0 , donnant $T^{(1)}, \dots, T^{(B)}$. La p-value Monte-Carlo (unilatérale) est

$$\hat{p} = \frac{1 + \#\{b: T^{(b)} \geq t_{\text{obs}}\}}{B + 1}.$$

(Le « +1 » au numérateur et au dénominateur — règle de l'observé compté comme une permutation/simulation — évite une p-value nulle et garde le test valide.)

Erreur de Monte-Carlo. $\hat{p}$ estime la vraie p-value p ; son écart-type est

$$SE(\hat{p}) \approx \sqrt{\frac{p(1-p)}{B}} \propto \frac{1}{\sqrt{B}}$$

Pour resserrer l'estimation d'un facteur 2, il faut **4 fois plus** de simulations. Choisir B grand quand la décision se joue près du seuil.

Reproductibilité. Le générateur pseudo-aléatoire doit être **seedé** (graine fixée) pour que la p-value soit rejouable à l'identique — exigence de rigueur du projet.

Dans iAlexMG

- **T1** : la p-value du χ^2 d'uniformité est obtenue par **Monte-Carlo** — on simule des historiques de 4 377 tirages **sans remise** (6 parmi 49), ce que la loi du χ^2 asymptotique ne capture pas exactement (corrélations $-1/48$, §0.3, §2.6).
- Les seeds sont fixés (numpy default_rng) pour la reproductibilité (§8.4).

Pièges & malentendus

- **Simuler une mauvaise H_0 .** Si la simulation n'imité pas fidèlement le mécanisme (oublier le sans-remise, p. ex.), la loi nulle est fausse → p-value fausse.
- **B trop petit.** Une p-value Monte-Carlo a sa propre incertitude en $1/\sqrt{B}$; conclure « $p = 0,04$ » avec $B = 200$ est hasardeux.
- **Oublier le seed.** Résultats non reproductibles.
- **p-value nulle.** Sans le « +1 », un observé jamais dépassé donne $\hat{p} = 0$, ce qui surestime la significativité.

Pour vérifier ta compréhension

1. Avec $B = 10\,000$ et une vraie p-value $\approx 0,05$, quel est l'ordre de grandeur de l'erreur de Monte-Carlo sur $\hat{p}$?
2. Pourquoi simuler **sans remise** plutôt que tirer 6 numéros indépendants avec probabilité 6/49 chacun ?
3. À quoi sert le « +1 » dans la formule de $\hat{p}$?

(Réponses [à la fin.](#))

Pour aller plus loin

- **Échantillonnage d'importance** : réduire la variance quand on cible des événements rares (queues).

- **MCMC** : simuler des lois complexes par chaînes de Markov (utile côté bayésien, document 04, même si la conjugaison Beta y rend la simulation inutile).
 - **Test de permutation** (§2.9) : un cas particulier où la « simulation » est un remélange des données réelles.
-

2.9 — Test de permutation

En une phrase

On obtient la loi nulle en **remélangeant** les données d’une façon qui préserve ce qui n’est pas testé mais détruit la structure testée — ici, casser l’ordre temporel de chaque numéro.

Intuition

« Et si le temps n’avait aucune importance ? » Si l’ordre des tirages ne portait aucune information, alors remélanger cet ordre ne devrait rien changer. On rebat donc les cartes du temps des milliers de fois, on recalcule la statistique, et on regarde si l’observé (ordre réel) ressort comme banal ou extraordinaire par rapport à ces versions « temps aboli ». C’est un Monte-Carlo qui simule à partir des **vraies** données plutôt que d’un modèle.

Formalisation

Soit une statistique T sensible à la structure testée (p. ex. la fréquence de motifs n -grammes). On génère B **permutations** π_b de l’axe testé (ici l’ordre temporel de la séquence binaire de chaque numéro), on calcule $T^{(b)} = T(\pi_b(\text{données}))$, et

$$\hat{p} = \frac{1 + \#\{b: T^{(b)} \geq t_{\text{obs}}\}}{B + 1}.$$

Ce que la permutation préserve vs détruit. Permuter l’ordre temporel **préserve la marge** (le nombre total de 1, donc la fréquence $\hat{p}$ de chaque numéro) mais **détruit toute dépendance temporelle** (autocorrélation, motifs). La loi nulle ainsi construite est exactement « même fréquence, mais aucune mémoire » — l’hypothèse qu’on veut tester.

Pourquoi elle bat un χ^2 naïf sur comptes corrélés. Les fréquences de n -grammes sont comptées sur **fenêtres chevauchantes** (§1.7), donc fortement **corrélées** : un χ^2 qui suppose des comptes indépendants donnerait une p -value fausse. La permutation, elle, **n’a besoin d’aucune hypothèse** sur ces corrélations : elle reconstruit la vraie loi nulle de T , chevauchement compris. Validité **exacte** (à la résolution $1/(B + 1)$) sous la seule hypothèse d’échangeabilité sous H_0 .

Dans iAlexMG

- **Étape 2.5 (cascade n-grammes, document 08)** : la p-value des fréquences de motifs est obtenue par **permutation de l'ordre temporel**, précisément parce que le chevauchement des fenêtres rend le χ^2 inadapté.
- **Figure 11a** : motifs observés indiscernables de leurs versions permutées, $p > 0,05$ partout → aucune structure temporelle.

Pièges & malentendus

- **Permuter la mauvaise chose.** Il faut permuter l'axe qui encode l'hypothèse testée (le temps) en préservant le reste (la fréquence). Mélanger autre chose teste une autre hypothèse.
- **Confondre permutation et bootstrap.** Le bootstrap rééchantillonne **avec remise** (pour estimer une variabilité) ; la permutation **réordonne sans remise** (pour tester une hypothèse de non-effet).
- **Trop peu de permutations** près du seuil : même limite $1/\sqrt{B}$ qu'en Monte-Carlo.

Pour vérifier ta compréhension

1. En permutant l'ordre temporel de la séquence d'un numéro, qu'est-ce qui reste inchangé ? Qu'est-ce qui est détruit ?
2. Pourquoi le test de permutation est-il préférable à un χ^2 pour des n-grammes à fenêtres chevauchantes ?
3. Permutation ou bootstrap pour tester « l'ordre des tirages n'a pas d'effet » ? Pourquoi ?

(Réponses [à la fin.](#))

Pour aller plus loin

- **Tests de permutation exacts** : énumérer toutes les permutations (faisable seulement pour de petits échantillons) donne une p-value exacte sans simulation.
- **Échangeabilité** : l'hypothèse précise qui légitime la permutation ; à vérifier avant de l'appliquer.
- **Permutations structurées** (par blocs) : préservent une dépendance qu'on ne veut pas détruire tout en testant une autre.

2.10 — Bruit blanc & indépendance temporelle

En une phrase

Un bruit blanc est une série de moyenne et variance constantes, à **autocorrélation nulle** pour tout décalage non nul ; l'indépendance des tirages l'implique pour toute série dérivée.

Intuition

« Aucune mémoire » : la valeur d'aujourd'hui ne dit rien de celle de demain. Si le Lotto est sans mémoire, alors n'importe quelle série qu'on en tire (la somme par tirage, le nombre de pairs, ...) doit ressembler à du bruit blanc : pas de tendance, pas de cycle, pas de corrélation d'un tirage au suivant. Tester l'indépendance temporelle, c'est chercher la moindre trace de mémoire dans ces séries.

Formalisation

Une série (Y_t) est un **bruit blanc** (faible) si, pour tout t et tout décalage $k \neq 0$:

$$\mathbb{E}[Y_t] = \mu, \quad \text{Var}(Y_t) = \sigma^2, \quad \rho(k) = \text{Corr}(Y_t, Y_{t+k}) = 0.$$

L'indépendance des tirages (H-indép, §0.1) **implique** $\rho(k) = 0$ pour toute série dérivée — la réciproque est fautive (corrélation nulle n'est pas indépendance), mais pour détecter une mémoire, l'autocorrélation est le premier filet.

Trois instruments complémentaires :

1. **Fonction d'autocorrélation (ACF).** Estimateur $\hat{\rho}(k) = \frac{\sum_t (Y_t - \bar{Y})(Y_{t+k} - \bar{Y})}{\sum_t (Y_t - \bar{Y})^2}$. Sous bruit blanc, $\hat{\rho}(k) \approx \mathcal{N}(0, 1/N)$, d'où une **bande de significativité** $\pm 1,96/\sqrt{N}$. Pour $N = 4\,377$: $\pm 1,96/\sqrt{4377} \approx \pm 0,0296$. Des $\hat{\rho}(k)$ dans la bande = compatibles avec l'absence de corrélation.
2. **Test des runs.** Compte les **séquences** de valeurs au-dessus/au-dessous de la médiane (les « plages »). Trop peu de runs $\rightarrow$ persistance ; trop $\rightarrow$ alternance. Teste les **signes**, complémentaire de l'ACF qui teste la **corrélation linéaire**.
3. **Statistique de Ljung-Box.** Agrège les premières autocorrélations en un seul test :

$$Q = N(N+2) \sum_{k=1}^h \frac{\hat{\rho}(k)^2}{N-k} \stackrel{H_0}{\sim} \chi_h^2.$$

Un Q grand (p-value faible) signale une autocorrélation globale sur les h premiers décalages.

Dans iAlexMG

- **T4 (indépendance temporelle)** applique ACF + runs + Ljung-Box aux séries dérivées : la **somme** des 6 numéros et la **parité** par tirage.
- Verdict : autocorrélations dans la bande $\pm 1,96/\sqrt{N}$, runs conformes, Ljung-Box non significatif $\rightarrow$ **aucune mémoire inter-tirages** détectable, confirmant (H-indép).

Pièges & malentendus

- **Corrélation nulle = indépendance.** Faux en général : l'ACF ne capte que les dépendances **linéaires** ; d'où le runs test (signes) en complément.
- **Oublier la multiplicité des décalages.** Lire 40 valeurs d'ACF et pointer « celle qui dépasse » = comparaisons multiples (§2.5) ; Ljung-Box agrège proprement.
- **Confondre bruit blanc et i.i.d. gaussien.** Le bruit blanc faible ne suppose ni indépendance complète ni normalité, seulement les trois conditions ci-dessus.

Pour vérifier ta compréhension

1. Pour $N = 4\,377$, quelle est la demi-largeur de la bande de significativité de l'ACF ?
2. Pourquoi compléter l'ACF par un test des runs ?
3. À quoi sert Ljung-Box plutôt que de regarder chaque $\hat{\rho}(k)$ séparément ?

(Réponses [à la fin.](#))

Pour aller plus loin

- **Densité spectrale** : vision « fréquences » du bruit blanc (spectre plat) ; un pic révélerait un cycle.
- **Tests de stationnarité** (ADF, KPSS) : vérifient μ, σ^2 constants avant de parler d'autocorrélation.
- **Lien permutation** : sous bruit blanc, permuter le temps ne change pas la loi des statistiques — fondement du test de permutation (§2.9).

Réponses aux exercices

2.1

1. H_0 : la probabilité de sortie est 6/49 **indépendamment de l'âge** (du retard) du numéro (sans mémoire) ; H_1 : $P(\text{sort} \mid \text{âge})$ augmente avec l'âge.
2. Parce qu'une infinité d'alternatives sont quasi indiscernables de H_0 avec un N fini (un biais infinitésimal échappe à tout test) : on ne peut qu'échouer à la rejeter, jamais la prouver.
3. La **puissance** du test (§2.4) : le biais minimal détectable. Un non-rejet n'est rassurant que si le test aurait su voir un effet d'intérêt.

2.2

1. $P(p < 0,01) = 0,01$ et $P(p < 0,05) = 0,05$: sous H_0 , la p-value est **uniforme** sur $[0,1]$, donc $P(p < \alpha) = \alpha$.
2. Nombre attendu = $49 \times 0,05 = 2,45$, soit **~2–3** faux positifs, alors même que H_0 est vraie partout.
3. La p-value est $P(\text{données} \mid H_0)$, pas $P(H_0 \mid \text{données})$. « $p = 0,03$ » signifie : si le tirage était honnête, on observerait un écart aussi extrême 3 % du temps — pas « 97 % de chances qu'il soit truqué ».

2.3

1. β **augmente** et la puissance $1 - \beta$ **diminue** (juge plus exigeant $\rightarrow$ plus de vrais effets ratés), à N constant.
2. Il ne rejette jamais $\rightarrow$ aucun faux positif possible ($\alpha = 0$), mais il ne détecte jamais un vrai effet non plus $\rightarrow$ puissance = 0.
- 3.

(a) = **type I** (rejeter H_0 vraie) ; (b) = **type II** (ne pas rejeter H_0 fausse).

2.4

1. **Quadrupler** N : le biais détectable est en $1/\sqrt{N}$, donc $\sqrt{4} = 2$.
2. Non. On peut conclure : « aucun biais grossier (de l'ordre de $\geq \sim 10\text{--}17\%$ relatif par numéro) n'est présent » ; des biais plus petits restent possibles et non détectés.
3. Elle abaisse le seuil par test à α/m , ce qui **augmente** $z_{1-\alpha/2}$ dans la formule de $\delta \rightarrow$ effet détectable plus grand.

2.5

1. Attendu = $49 \times 0,05 \approx 2,45$; au moins un : $1 - 0,95^{49} \approx 0,92$ ($\approx 92\%$).
2. $\alpha/m = 0,05/49 \approx 0,00102$ par numéro.
3. Parce qu'un seuil plus strict (α/m) augmente β (et le biais minimal détectable) : c'est le prix du contrôle du FWER.

2.6

1. $\nu = 49 - 1 = 48$. Le -1 vient de la contrainte $\sum_i O_i = N$ (les 49 comptes ne sont pas libres).

2. Parce que le tirage **sans remise** corréle les comptes ($-1/48$) et impose une somme fixe ; la loi du χ^2 standard (comptes indépendants) biaiserait la p-value. Monte-Carlo rejoue de vrais tirages et donne la vraie loi nulle.
3. Pas de contradiction : le χ^2 est **omnibus** (puissance diluée sur 48 directions) et rate un effet **monotone** que le z-test **ciblé** sur la moyenne capte pleinement.

2.7

1. Le « 95 % » porte sur la **procédure** : si l'on répétait l'expérience, 95 % des intervalles ainsi construits contiendraient la vraie probabilité du 7. Pour **cet** intervalle précis, la vérité y est ou n'y est pas (pas de probabilité attachée).
2. Wald a une **mauvaise couverture** à faible effectif (peut sortir de $[0,1]$, trop étroit) ; Clopper-Pearson est exact (couverture garantie $\geq 95\%$).
3. L'IC à 95 % = ensemble des θ_0 qu'un test bilatéral à $\alpha = 0,05$ ne rejette pas : dualité test-intervalle.

2.8

1. $SE \approx \sqrt{0,05 \times 0,95 / 10\,000} \approx 0,0022$ (~0,2 point de pourcentage).
2. Parce que le vrai mécanisme est sans remise (6 numéros **distincts**) : tirer 6 indicatrices indépendantes à 6/49 produirait parfois des doublons et de mauvaises corrélations → mauvaise loi nulle.
3. Il évite une p-value nulle (observé jamais dépassé) et rend le test **valide** en comptant l'observé comme une réalisation de référence.

2.9

1. **Inchangé** : la fréquence marginale de sorties du numéro (le nombre total de 1). **Détruit** : toute structure temporelle (autocorrélation, motifs n-grammes).
2. Parce que les fenêtres chevauchantes rendent les comptes **corrélés**, ce qui invalide le χ^2 ; la permutation reconstruit la loi nulle exacte sans hypothèse sur ces corrélations.
3. **Permutation** : on teste une hypothèse de **non-effet** de l'ordre en réordonnant sans remise. Le bootstrap (avec remise) sert à estimer une variabilité, pas à tester cette hypothèse.

2.10

1. $\pm 1,96 / \sqrt{4377} \approx \pm 0,0296$.

2. L'ACF ne détecte que les dépendances **linéaires** ; le runs test capte des structures de **signe** (persistance/alternance) qu'une corrélation linéaire nulle pourrait masquer.
3. Ljung-Box **agrège** les h premières autocorrélations en un seul test, évitant le problème de comparaisons multiples qu'on aurait en inspectant chaque $\hat{\rho}(k)$ isolément. ``