

05 — Biais cognitifs démontés

Table des matieres

[7.1 — Le mythe du numéro en retard](#)

[7.2 — Le mythe du numéro en avance](#)

[7.3 — Illusion de motif & sur-interprétation](#)

[Réponses aux exercices](#)

Niveau : base → intermédiaire (traité en profondeur). **Prérequis** : 02_lois_de_probabilite.md (§1.1 binomiale, §1.2 géométrique & propriété sans mémoire), 03_inference_frequentiste.md (§2.5 comparaisons multiples). **Couvre les fiches source** : 7.1 à 7.3 de concepts_FR.md. **Renvois avant** (regroupement par section) : §7.1 s'appuie sur **§6.4** (convergence ≠ rappel, document 08) ; §7.3 sur **§5.14** (le « mirage » du sur-apprentissage, document 07). Les idées essentielles sont rappelées ici ; le traitement complet est dans ces docs.

Idée directrice. Les mathématiques du hasard (documents 01–04) ne servent à rien si l'intuition humaine les contredit en silence. Ce document démonte trois illusions qui font perdre de l'argent au loto et faussent l'analyse de données : croire qu'un numéro « en retard » est dû (**mythe du numéro en retard**), qu'un numéro « en avance » continue (**mythe du numéro en avance**), et — plus insidieux — **voir des motifs dans le bruit** (illusion de motif), y compris à travers des modèles puissants. Chacune est réfutée empiriquement par la Phase 1 (document 06) ou la Phase 2 (document 07).

7.1 — Le mythe du numéro en retard

En une phrase

Le mythe du numéro en retard est la croyance qu'un événement « en retard » devient plus probable — faux, car le hasard est **sans mémoire**.

Intuition

Après cinq « rouge » à la roulette, beaucoup parient « noir » : il *doit* bien finir par sortir, le hasard se *corrige*. C'est une erreur. La bille n'a aucun souvenir des cinq tours précédents. De même au loto : un numéro absent depuis 30 tirages n'est pas « dû ». La racine de l'illusion est de confondre deux énoncés vrais — *à long terme les proportions s'équilibrent* — avec un énoncé faux — *donc le hasard rembourse les retards à court terme*.

Formalisation

H₀ : $P(\text{sort} \mid \text{absent depuis } m) = p = 6/49$ pour tout m (sans mémoire). **H₁ (le mythe)** : $P(\text{sort} \mid \text{absent depuis } m)$ **croît** avec l'âge m (le numéro « en retard » est « dû »).

Le mythe affirme $P(\text{sort au tirage } t \mid \text{absent depuis } m \text{ tirages}) > p$. Or, sous le processus de Bernoulli (§0.1), les tirages sont indépendants, donc

$$P(X_t = 1 \mid X_{t-1} = 0, \dots, X_{t-m} = 0) = P(X_t = 1) = p = \frac{6}{49}.$$

L'âge m n'a **aucun** effet. C'est une conséquence directe de la **propriété sans mémoire** de la loi géométrique des écarts (§1.2) :

$$P(T > m + n \mid T > m) = P(T > n).$$

La racine du mal : convergence ≠ remboursement. La loi des grands nombres fait converger la **proportion** $\hat{p} = Y/N$ vers p (le dénominateur grandit), mais **pas les compteurs** : l'écart absolu $|Y - Np|$ *grandit* en $\sqrt{N}$ (§0.4). Un déficit n'est jamais « remboursé » ; il est **dilué**. Ce point — *la moyenne se dilue, elle ne se corrige pas* — est formalisé en **§6.4** (document 08) et constitue le cœur mathématique de la réfutation.

Racine psychologique. Le biais découle de l'**heuristique de représentativité** (Kahneman & Tversky) : on attend d'une courte séquence aléatoire qu'elle « ait l'air aléatoire » localement (la « loi des petits nombres »). Une série 0 0 0 0 0 paraît « non représentative » du hasard, donc on anticipe un 1 correctif — alors que toute séquence précise est également probable.

Dans iAlexMG

Le mythe est réfuté de **trois façons convergentes** :

- **T2 (gaps, §4.2)** : sur **26 213 écarts**, gap moyen observé **8,15** vs **8,17** théorique ; la géométrie n'est pas rejetée (χ^2 $p = 0,63$) ; surtout $P(\text{sort} \mid \text{âge})$ reste **plate autour de** $6/49$, tous les IC contenant cette valeur.
- **Coefficient gap** ≈ 0 de la régression logistique (§5.10) : l'ancienneté n'a aucun pouvoir prédictif.
- **Cascade n-grammes (§6.3)** : la règle « déficit $\Rightarrow$ dû », formalisée puis mesurée, **dégrade** la prédiction hors-échantillon.

Pièges & malentendus

- « **Mais à la fin tout s'équilibre !** » Oui pour la *proportion*, non pour les *comptes*. L'équilibrage est une dilution, pas une compensation (§6.4).
- **Confondre indépendance et compensation.** L'indépendance interdit précisément toute compensation.

- **L'inverse du mythe.** Croire qu'un numéro « en retard » ne sortira **jamais** est l'erreur symétrique : sa probabilité reste $6/49$, ni plus, ni moins.

Pour vérifier ta compréhension

1. Un numéro est absent depuis 40 tirages. Quelle est sa probabilité de sortir au prochain ?
2. « Sur 10 000 tirages, ce numéro a 50 sorties de retard sur la moyenne ; il va rattraper. » Où est l'erreur, et que dit réellement la loi des grands nombres ?
3. Quelle propriété de la loi géométrique formalise l'absence d'effet de l'âge ?

(Réponses [à la fin.](#))

Pour aller plus loin

- **Martingales** : formalisent « aucune stratégie basée sur le passé ne change l'espérance » (§6.4).
- **Loi des petits nombres** (Tversky & Kahneman) : la source cognitive du biais.
- **Roulette de Monte-Carlo, 1913** : 26 rouges d'affilée, fortunes perdues à parier noir — l'exemple historique éponyme.

7.2 — Le mythe du numéro en avance

En une phrase

Le mythe du numéro en avance est la croyance qu'une série de succès se prolonge (« il est lancé ») — réfutée au loto par l'absence de dépendance entre tirages.

Intuition

Au basket, un joueur qui vient de marquer trois paniers « sent » qu'il va marquer le suivant ; le public y croit aussi. Transposée au loto : un numéro sorti plusieurs fois récemment serait « en avance ». C'est le miroir du mythe du numéro en retard — au lieu d'attendre un renversement, on attend une continuation. Les deux supposent une **mémoire** que le tirage n'a pas.

Formalisation

H_0 : $P(\text{sort} \mid \text{série de } k) = p = 6/49$ pour tout k (une série n'annonce rien). H_1 (**le mythe du numéro en avance**) : $P(\text{sort} \mid \text{série de } k) > p$ (le numéro « en avance » continue).

Le mythe du numéro en avance affirme $P(\text{sort} \mid \text{série de } k \text{ apparitions}) > p$. Sous indépendance (§0.1), à nouveau

$$P(X_t = 1 \mid X_{t-1} = 1, \dots, X_{t-k} = 1) = p = \frac{6}{49},$$

indépendamment de k . Le mythe du numéro en avance correspondrait à une **autocorrélation positive** de la série (persistance), exactement ce que le test d'indépendance temporelle (§2.10, §4.4) cherche — et ne trouve pas.

Subtilité statistique (le piège de Miller-Sanjurjo). Dans les données *finies*, estimer $P(\text{succès} \mid \text{série de succès})$ par la fréquence empirique introduit un biais de **sélection négatif** : conditionner sur « venir de réussir » sous-échantillonne mécaniquement les succès suivants. Ce biais a longtemps fait croire que l'effet de série au basket était « réfuté » alors qu'un petit effet réel (lié au talent/à la confiance) pourrait exister. **Au loto, la question est tranchée net** : il n'y a ni talent ni agentivité, donc aucune source possible de dépendance — toute continuation de série y est strictement nulle.

Dans iAlexMG

- **T3 (§4.3)** : pour chaque longueur de série $k = 1$ à 4, test binomial exact de $P(\text{sort} \mid \text{série de } k)$ contre $6/49$, avec correction de Bonferroni (§2.5). De $k = 1$ à 4, les probabilités restent proches de 0,12. La série de 4 monte à **0,189**, mais sur $n = 37$ seulement, avec un IC **[0,08 ; 0,35]** qui contient $6/49$: du **bruit**. Aucune série n'est significative.

Pièges & malentendus

- **Lire le bruit comme un signal.** Les grands k sont rares (n petit) → IC larges → des estimations ponctuelles élevées (0,189) sans aucune significativité. Confondre l'estimation ponctuelle et l'incertitude est l'erreur centrale.
- **Transposer le débat sportif au loto.** Au sport la question reste discutée (effet réel possible, biais de mesure) ; au loto, l'absence de mécanisme la rend triviale.
- **Symétrie.** Le numéro « en avance » (continuation) et le numéro « en retard » (renversement) sont deux croyances opposées, toutes deux fausses pour la même raison : pas de mémoire.

Pour vérifier ta compréhension

1. Pourquoi l'estimation $P(\text{sort} \mid \text{série de } 4) = 0,189$ ne prouve-t-elle rien ?
2. Quelle signature aurait le mythe du numéro en avance dans une analyse d'autocorrélation (§2.10) ?
3. Pourquoi le loto tranche-t-il plus nettement que le basket sur le mythe du numéro en avance ?

(Réponses [à la fin.](#))

Pour aller plus loin

- **Gilovich, Vallone & Tversky (1985)** : l'étude fondatrice sur l'effet de série (« hot hand ») au basket.
- **Miller & Sanjurjo (2018)** : le biais de sélection qui a relancé le débat.
- **Lien §4.4** : le mythe du numéro en avance au loto = autocorrélation positive ; son absence est confirmée par runs/ACF/Ljung-Box.

7.3 — Illusion de motif & sur-interprétation

En une phrase

L'illusion de motif (apophénie) est la tendance à voir des structures dans le bruit — et les modèles puissants peuvent l'amplifier au lieu de la corriger.

Intuition

Le cerveau est une machine à détecter des régularités ; il en trouve même là où il n'y en a pas — visages dans les nuages, « tendances » dans des suites aléatoires. En analyse de données, cette pulsion prend deux formes dangereuses : (1) **tester beaucoup** et ne retenir que ce qui « ressort » (faux positifs, §2.5) ; (2) faire confiance à un **modèle complexe** qui « voit » un motif — alors qu'il a simplement **mémorisé du bruit**. Le mirage du LSTM (§5.14) est précisément l'illusion de motif, version machine.

Formalisation

Trois mécanismes nourrissent l'illusion :

1. **Multiplicité des tests.** Sous H_0 , la p-value est uniforme (§2.2) : sur m tests, on attend $m\alpha$ « découvertes » fortuites. Chercher « le » numéro « en avance » parmi 49, ou « le » motif parmi des dizaines, **garantit** des faux positifs si l'on ne corrige pas (§2.5). Les survivants de ce tamis racontent une belle histoire — fausse.
2. **Survivance des faux positifs.** On publie/retient le test qui a « marché », on oublie les dizaines qui n'ont rien donné (biais de publication). Le motif « significatif » est un artefact de sélection.
3. **Sur-apprentissage (le mirage machine).** Un modèle à forte capacité fait baisser la perte **in-sample** sous le plancher d'entropie (§5.5) en épousant le bruit, sans baisser la perte **out-of-sample** — il *mémorise* sans *généraliser*. L'écart in/out **est** la signature de l'illusion. C'est formalisé en **§5.14** (document 07).

La parade : déclarer les tests à l'avance, corriger pour la multiplicité (§2.5), et juger tout modèle **hors-échantillon** contre une barre honnête (plancher d'entropie, §5.5). La rigueur fréquentiste et l'évaluation OOS sont les antidotes à l'apophénie.

Dans iAlexMG

L'illusion de motif est le **fil rouge narratif** qui relie les deux phases :

- **Phase 1** : les 4 numéros « hors bande » de T1 (§4.1) sont l'illusion de motif à l'échelle d'un test simple — dissoute par Bonferroni.
- **Phase 2** : le **mirage du LSTM** (§5.14, figure 9) est la même illusion à l'échelle d'un réseau profond — un modèle qui « apprend » des motifs inexistants in-sample et s'effondre hors-échantillon.

Le projet entier est, à sa manière, une **leçon d'humilité épistémique** : la structure qu'on croit voir dans le hasard est presque toujours dans l'œil (ou le modèle), pas dans les données.

Pièges & malentendus

- « **Le modèle a trouvé un motif, donc il existe.** » Non, tant qu'il n'est pas confirmé **hors-échantillon**. In-sample, n'importe quel motif est « trouvable ».
- **Storytelling trompeur**. Une explication séduisante *a posteriori* d'un faux positif est d'autant plus dangereuse qu'elle est convaincante.
- **Oublier les tests « ratés »**. Sans le dénominateur (tout ce qu'on a essayé), un succès isolé est ininterprétable.

Pour vérifier ta compréhension

1. Pourquoi trouver « le numéro le plus en avance » parmi 49 n'est-il pas une découverte ?
2. Quel est l'équivalent, pour un réseau de neurones, du « voir un motif dans le bruit » ? Comment le détecte-t-on ?
3. Cite deux parades méthodologiques contre l'illusion de motif.

(Réponses [à la fin.](#))

Pour aller plus loin

- **Apophénie & paréidolie** : les mécanismes perceptifs sous-jacents.
 - **Biais de publication & p-hacking** : versions institutionnelles de la survivance des faux positifs.
 - **Lien §5.14** : le mirage du sur-apprentissage comme illustration ultime, mesurée, de l'illusion de motif.
-

Réponses aux exercices

7.1

1. $6/49 \approx 12,24\%$, exactement comme toujours : le tirage est sans mémoire, l'âge n'a aucun effet.
2. L'erreur est de croire que le déficit de comptes sera « rattrapé ». La loi des grands nombres fait converger la **proportion** (car le dénominateur N grandit), mais l'**écart absolu** $|Y - Np|$ tend même à *croître* (en $\sqrt{N}$) : le retard est **dilué**, pas remboursé (§6.4).
3. La **propriété sans mémoire** $P(T > m + n \mid T > m) = P(T > n)$: l'attente déjà écoulée n'informe pas sur l'attente restante.

7.2

1. Parce qu'elle repose sur $n = 37$ observations seulement : l'IC **[0,08 ; 0,35]** contient $6/49$. L'estimation ponctuelle élevée est du bruit, non significatif.
2. Une **autocorrélation positive** (persistance) de la série binaire du numéro : $\hat{\rho}(k) > 0$ hors de la bande $\pm 1,96/\sqrt{N}$. T4 n'en trouve pas.
3. Parce qu'au loto il n'y a ni talent, ni confiance, ni fatigue — aucun mécanisme physique ne peut créer de dépendance, contrairement au basket où un petit effet réel reste plausible.

7.3

1. Parce qu'avec 49 candidats, sous H_0 , certains sortiront « hors bande » par pur hasard ($\sim 2-3$ attendus, §2.5) ; sélectionner le plus extrême a posteriori est un faux positif garanti, pas une découverte.
2. C'est le **sur-apprentissage** : le réseau fait baisser la perte **in-sample** (sous le plancher) en mémorisant le bruit, sans baisser la perte **out-of-sample**. On le détecte par l'**écart in/out** (§5.14).
3.
 - (i) Déclarer les tests à l'avance et **corriger la multiplicité** (Bonferroni/FDR, §2.5) ;
 - (ii) juger tout modèle **hors-échantillon** contre une barre honnête (plancher d'entropie, §5.5). ``