

## 05 — Biais cognitifs démontés

### Table des matieres

[7.1 — Le sophisme du joueur](#)

[7.2 — La main chaude](#)

[7.3 — Illusion de motif & sur-interprétation](#)

[Réponses aux exercices](#)

**Niveau** : base → intermédiaire (traité en profondeur). **Prérequis** : 02\_lois\_de\_probabilite.md (§1.1 binomiale, §1.2 géométrique & propriété sans mémoire), 03\_inference\_frequentiste.md (§2.5 comparaisons multiples). **Couvre les fiches source** : 7.1 à 7.3 de concepts\_FR.md. **Renvois avant** (regroupement par section) : §7.1 s'appuie sur **§6.4** (convergence ≠ rappel, document 08) ; §7.3 sur **§5.14** (le « mirage » du sur-apprentissage, document 07). Les idées essentielles sont rappelées ici ; le traitement complet est dans ces docs.

**Idée directrice.** Les mathématiques du hasard (documents 01–04) ne servent à rien si l'intuition humaine les contredit en silence. Ce document démonte trois illusions qui font perdre de l'argent au loto et faussent l'analyse de données : croire qu'un numéro « en retard » est dû (**sophisme du joueur**), qu'un numéro « chaud » continue (**main chaude**), et — plus insidieux — **voir des motifs dans le bruit** (illusion de motif), y compris à travers des modèles puissants. Chacune est réfutée empiriquement par la Phase 1 (document 06) ou la Phase 2 (document 07).

---

### 7.1 — Le sophisme du joueur

#### En une phrase

Le sophisme du joueur est la croyance qu'un événement « en retard » devient plus probable — faux, car le hasard est **sans mémoire**.

#### Intuition

Après cinq « rouge » à la roulette, beaucoup parient « noir » : il *doit* bien finir par sortir, le hasard se *corrige*. C'est une erreur. La bille n'a aucun souvenir des cinq tours précédents. De même au loto : un numéro absent depuis 30 tirages n'est pas « dû ». La racine de l'illusion est de confondre deux énoncés vrais — *à long terme les proportions s'équilibrent* — avec un énoncé faux — *donc le hasard rembourse les retards à court terme*.

#### Formalisation

**H<sub>0</sub>** :  $P(\text{sort} \mid \text{absent depuis } m) = p = 6/49$  pour tout  $m$  (sans mémoire). **H<sub>1</sub> (le sophisme)** :  $P(\text{sort} \mid \text{absent depuis } m)$  **croît** avec l'âge  $m$  (le numéro « en retard » est « dû »).

Le sophisme affirme  $P(\text{sort au tirage } t \mid \text{absent depuis } m \text{ tirages}) > p$ . Or, sous le processus de Bernoulli (§0.1), les tirages sont indépendants, donc

$$P(X_t = 1 \mid X_{t-1} = 0, \dots, X_{t-m} = 0) = P(X_t = 1) = p = \frac{6}{49}.$$

L'âge  $m$  n'a **aucun** effet. C'est une conséquence directe de la **propriété sans mémoire** de la loi géométrique des écarts (§1.2) :

$$P(T > m + n \mid T > m) = P(T > n).$$

**La racine du mal : convergence ≠ remboursement.** La loi des grands nombres fait converger la **proportion**  $\hat{p} = Y/N$  vers  $p$  (le dénominateur grandit), mais **pas** les **compteurs** : l'écart absolu  $|Y - Np|$  *grandit* en  $\sqrt{N}$  (§0.4). Un déficit n'est jamais « remboursé » ; il est **dilué**. Ce point — *la moyenne se dilue, elle ne se corrige pas* — est formalisé en **§6.4** (document 08) et constitue le cœur mathématique de la réfutation.

**Racine psychologique.** Le biais découle de l'**heuristique de représentativité** (Kahneman & Tversky) : on attend d'une courte séquence aléatoire qu'elle « ait l'air aléatoire » localement (la « loi des petits nombres »). Une série 0 0 0 0 0 paraît « non représentative » du hasard, donc on anticipe un 1 correctif — alors que toute séquence précise est également probable.

## Dans iAlexMG

Le sophisme est réfuté de **trois façons convergentes** :

- **T2 (gaps, §4.2)** : sur **26 213 écarts**, gap moyen observé **8,15** vs **8,17** théorique ; la géométrie n'est pas rejetée ( $\chi^2$   $p = 0,63$ ) ; surtout  $P(\text{sort} \mid \text{âge})$  reste **plate autour de**  $6/49$ , tous les IC contenant cette valeur.
- **Coefficient gap**  $\approx 0$  de la régression logistique (§5.10) : l'ancienneté n'a aucun pouvoir prédictif.
- **Cascade n-grammes (§6.3)** : la règle « déficit  $\Rightarrow$  dû », formalisée puis mesurée, **dégrade** la prédiction hors-échantillon.

## Pièges & malentendus

- « **Mais à la fin tout s'équilibre !** » Oui pour la *proportion*, non pour les *comptes*. L'équilibrage est une dilution, pas une compensation (§6.4).
- **Confondre indépendance et compensation.** L'indépendance interdit précisément toute compensation.

- **L'inverse du sophisme.** Croire qu'un numéro « en retard » ne sortira **jamais** est l'erreur symétrique : sa probabilité reste  $6/49$ , ni plus, ni moins.

### Pour vérifier ta compréhension

1. Un numéro est absent depuis 40 tirages. Quelle est sa probabilité de sortir au prochain ?
2. « Sur 10 000 tirages, ce numéro a 50 sorties de retard sur la moyenne ; il va rattraper. » Où est l'erreur, et que dit réellement la loi des grands nombres ?
3. Quelle propriété de la loi géométrique formalise l'absence d'effet de l'âge ?

(Réponses [à la fin.](#))

### Pour aller plus loin

- **Martingales** : formalisent « aucune stratégie basée sur le passé ne change l'espérance » (§6.4).
- **Loi des petits nombres** (Tversky & Kahneman) : la source cognitive du biais.
- **Roulette de Monte-Carlo, 1913** : 26 rouges d'affilée, fortunes perdues à parier noir — l'exemple historique éponyme.

## 7.2 — La main chaude

### En une phrase

La main chaude est la croyance qu'une série de succès se prolonge (« il est chaud ») — réfutée au loto par l'absence de dépendance entre tirages.

### Intuition

Au basket, un joueur qui vient de marquer trois paniers « sent » qu'il va marquer le suivant ; le public y croit aussi. Transposée au loto : un numéro sorti plusieurs fois récemment serait « en forme ». C'est le miroir du sophisme du joueur — au lieu d'attendre un renversement, on attend une continuation. Les deux supposent une **mémoire** que le tirage n'a pas.

### Formalisation

$H_0$  :  $P(\text{sort} \mid \text{série de } k) = p = 6/49$  pour tout  $k$  (une série n'annonce rien).  **$H_1$  (la main chaude)** :  $P(\text{sort} \mid \text{série de } k) > p$  (le numéro « chaud » continue).

La main chaude affirme  $P(\text{sort} \mid \text{série de } k \text{ apparitions}) > p$ . Sous indépendance (§0.1), à nouveau

$$P(X_t = 1 \mid X_{t-1} = 1, \dots, X_{t-k} = 1) = p = \frac{6}{49},$$

indépendamment de  $k$ . La main chaude correspondrait à une **autocorrélation positive** de la série (persistance), exactement ce que le test d'indépendance temporelle (§2.10, §4.4) cherche — et ne trouve pas.

**Subtilité statistique (le piège de Miller-Sanjurjo).** Dans les données *finies*, estimer  $P(\text{succès} \mid \text{série de succès})$  par la fréquence empirique introduit un biais de **sélection négatif** : conditionner sur « venir de réussir » sous-échantillonne mécaniquement les succès suivants. Ce biais a longtemps fait croire que la main chaude était « réfutée » au basket alors qu'un petit effet réel (lié au talent/à la confiance) pourrait exister. **Au loto, la question est tranchée net** : il n'y a ni talent ni agentivité, donc aucune source possible de dépendance — la main chaude y est strictement nulle.

### Dans iAlexMG

- **T3 (§4.3)** : pour chaque longueur de série  $k = 1$  à 4, test binomial exact de  $P(\text{sort} \mid \text{série de } k)$  contre  $6/49$ , avec correction de Bonferroni (§2.5). De  $k = 1$  à 4, les probabilités restent proches de 0,12. La série de 4 monte à **0,189**, mais sur  $n = 37$  seulement, avec un IC **[0,08 ; 0,35]** qui contient  $6/49$  : du **bruit**. Aucune série n'est significative.

### Pièges & malentendus

- **Lire le bruit comme un signal.** Les grands  $k$  sont rares ( $n$  petit) → IC larges → des estimations ponctuelles élevées (0,189) sans aucune significativité. Confondre l'estimation ponctuelle et l'incertitude est l'erreur centrale.
- **Transposer le débat sportif au loto.** Au sport la question reste discutée (effet réel possible, biais de mesure) ; au loto, l'absence de mécanisme la rend triviale.
- **Symétrie avec le sophisme.** Main chaude (continuation) et sophisme (renversement) sont deux croyances opposées, toutes deux fausses pour la même raison : pas de mémoire.

### Pour vérifier ta compréhension

1. Pourquoi l'estimation  $P(\text{sort} \mid \text{série de } 4) = 0,189$  ne prouve-t-elle rien ?
2. Quelle signature aurait la main chaude dans une analyse d'autocorrélation (§2.10) ?
3. Pourquoi le loto tranche-t-il plus nettement que le basket sur la main chaude ?

(Réponses [à la fin.](#))

### Pour aller plus loin

- **Gilovich, Vallone & Tversky (1985)** : l'étude fondatrice « réfutant » la main chaude au basket.

- **Miller & Sanjurjo (2018)** : le biais de sélection qui a relancé le débat.
  - **Lien §4.4** : la main chaude au loto = autocorrélation positive ; son absence est confirmée par runs/ACF/Ljung-Box.
- 

## 7.3 — Illusion de motif & sur-interprétation

### En une phrase

L'illusion de motif (apophénie) est la tendance à voir des structures dans le bruit — et les modèles puissants peuvent l'amplifier au lieu de la corriger.

### Intuition

Le cerveau est une machine à détecter des régularités ; il en trouve même là où il n'y en a pas — visages dans les nuages, « tendances » dans des suites aléatoires. En analyse de données, cette pulsion prend deux formes dangereuses : (1) **tester beaucoup** et ne retenir que ce qui « ressort » (faux positifs, §2.5) ; (2) faire confiance à un **modèle complexe** qui « voit » un motif — alors qu'il a simplement **mémorisé du bruit**. Le mirage du LSTM (§5.14) est précisément l'illusion de motif, version machine.

### Formalisation

Trois mécanismes nourrissent l'illusion :

1. **Multiplicité des tests.** Sous  $H_0$ , la p-value est uniforme (§2.2) : sur  $m$  tests, on attend  $m\alpha$  « découvertes » fortuites. Chercher « le » numéro chaud parmi 49, ou « le » motif parmi des dizaines, **garantit** des faux positifs si l'on ne corrige pas (§2.5). Les survivants de ce tamis racontent une belle histoire — fausse.
2. **Survivance des faux positifs.** On publie/retient le test qui a « marché », on oublie les dizaines qui n'ont rien donné (biais de publication). Le motif « significatif » est un artefact de sélection.
3. **Sur-apprentissage (le mirage machine).** Un modèle à forte capacité fait baisser la perte **in-sample** sous le plancher d'entropie (§5.5) en épousant le bruit, sans baisser la perte **out-of-sample** — il *mémorise* sans *généraliser*. L'écart in/out **est** la signature de l'illusion. C'est formalisé en **§5.14** (document 07).

**La parade** : déclarer les tests à l'avance, corriger pour la multiplicité (§2.5), et juger tout modèle **hors-échantillon** contre une barre honnête (plancher d'entropie, §5.5). La rigueur fréquentiste et l'évaluation OOS sont les antidotes à l'apophénie.

Dans iAlexMG

L'illusion de motif est le **fil rouge narratif** qui relie les deux phases :

- **Phase 1** : les 4 numéros « hors bande » de T1 (§4.1) sont l'illusion de motif à l'échelle d'un test simple — dissoute par Bonferroni.
- **Phase 2** : le **mirage du LSTM** (§5.14, figure 9) est la même illusion à l'échelle d'un réseau profond — un modèle qui « apprend » des motifs inexistants in-sample et s'effondre hors-échantillon.

Le projet entier est, à sa manière, une **leçon d'humilité épistémique** : la structure qu'on croit voir dans le hasard est presque toujours dans l'œil (ou le modèle), pas dans les données.

### Pièges & malentendus

- « **Le modèle a trouvé un motif, donc il existe.** » Non, tant qu'il n'est pas confirmé **hors-échantillon**. In-sample, n'importe quel motif est « trouvable ».
- **Storytelling trompeur.** Une explication séduisante *a posteriori* d'un faux positif est d'autant plus dangereuse qu'elle est convaincante.
- **Oublier les tests « ratés ».** Sans le dénominateur (tout ce qu'on a essayé), un succès isolé est ininterprétable.

### Pour vérifier ta compréhension

1. Pourquoi trouver « le numéro le plus chaud » parmi 49 n'est-il pas une découverte ?
2. Quel est l'équivalent, pour un réseau de neurones, du « voir un motif dans le bruit » ? Comment le détecte-t-on ?
3. Cite deux parades méthodologiques contre l'illusion de motif.

(Réponses [à la fin.](#))

### Pour aller plus loin

- **Apophénie & paréidolie** : les mécanismes perceptifs sous-jacents.
- **Biais de publication & p-hacking** : versions institutionnelles de la survivance des faux positifs.
- **Lien §5.14** : le mirage du sur-apprentissage comme illustration ultime, mesurée, de l'illusion de motif.

---

### Réponses aux exercices

## 7.1

1.  $6/49 \approx 12,24\%$ , exactement comme toujours : le tirage est sans mémoire, l'âge n'a aucun effet.
2. L'erreur est de croire que le déficit de comptes sera « rattrapé ». La loi des grands nombres fait converger la **proportion** (car le dénominateur  $N$  grandit), mais l'**écart absolu**  $|Y - Np|$  tend même à *croître* (en  $\sqrt{N}$ ) : le retard est **dilué**, pas remboursé (§6.4).
3. La **propriété sans mémoire**  $P(T > m + n \mid T > m) = P(T > n)$  : l'attente déjà écoulée n'informe pas sur l'attente restante.

## 7.2

1. Parce qu'elle repose sur  $n = 37$  observations seulement : l'IC **[0,08 ; 0,35]** contient  $6/49$ . L'estimation ponctuelle élevée est du bruit, non significatif.
2. Une **autocorrélation positive** (persistance) de la série binaire du numéro :  $\hat{\rho}(k) > 0$  hors de la bande  $\pm 1,96/\sqrt{N}$ . T4 n'en trouve pas.
3. Parce qu'au loto il n'y a ni talent, ni confiance, ni fatigue — aucun mécanisme physique ne peut créer de dépendance, contrairement au basket où un petit effet réel reste plausible.

## 7.3

1. Parce qu'avec 49 candidats, sous  $H_0$ , certains sortiront « hors bande » par pur hasard (~2–3 attendus, §2.5) ; sélectionner le plus extrême a posteriori est un faux positif garanti, pas une découverte.
2. C'est le **sur-apprentissage** : le réseau fait baisser la perte **in-sample** (sous le plancher) en mémorisant le bruit, sans baisser la perte **out-of-sample**. On le détecte par l'**écart in/out** (§5.14).
3.
  - (i) Déclarer les tests à l'avance et **corriger la multiplicité** (Bonferroni/FDR, §2.5) ;
  - (ii) juger tout modèle **hors-échantillon** contre une barre honnête (plancher d'entropie, §5.5). ``