

Table des matières

Cours 01 — Le métier, les sources et le premier regard	1
Objectifs	2
1. Le métier : ingénieur de données	2
2. L'architecture de référence	3
3. Deux chemins : le froid et le chaud	4
4. Où s'arrête l'ingénieur de données, et ce qu'il livre	5
5. Le fil rouge : Véhicules Boréal inc.	7
6. DuckDB, pour regarder sans charger	9
7. Le type deviné	9
Points clés à retenir	10
Exercices	11

Cours 01 — Le métier, les sources et le premier regard

Théorie · Module 1/12 — Formation Data Engineering · ~35 min · débutant

Où vous êtes : **source** → ingestion → lac → entrepôt → restitution. Le Cours 01 pose la carte entière et le terrain de Boréal, puis jette un premier regard sur ce que les sources livrent, sans rien ranger encore.

En 30 secondes :

- L'ingénieur de données fait arriver la donnée, la range, la fait tourner à l'heure et prouve qu'elle est bonne. Il livre aux autres métiers de la donnée, rarement au décideur lui-même.
- L'architecture de référence a deux chemins : le froid, par lots, qui bâtit l'historique fiable, et le chaud, en continu, qui sert la réaction immédiate.
- Le fil rouge est un fabricant fictif de véhicules récréatifs, Véhicules Boréal inc. : un ERP, une usine instrumentée, des véhicules connectés, un portail des garanties, une documentation, et de la vraie météo publique.
- DuckDB interroge les fichiers là où ils sont, sans rien charger : on regarde avant de ranger.
- Un CSV ou un JSON ne transporte aucun type. Laisser un outil les deviner produit des erreurs qui ne plantent pas : une date devient un entier, un décalage horaire disparaît.

L'idée du cours. Avant le premier pipeline, on prend la mesure du métier et du terrain : ce que l'ingénieur de données promet, où il s'arrête, ce qu'il livre, les deux chemins que peut prendre une donnée, et l'entreprise dont vous allez tenir les tuyaux pendant douze cours. Puis on regarde, sans rien ranger encore. Au labo, DuckDB lit les sources telles quelles, et devine leurs types ; ce qu'il devine de travers, sans prévenir, est le constat sur lequel le Cours 02 bâtit sa règle.

Objectifs

- Situer l'ingénieur de données (*data engineer*) dans la chaîne : ce qu'il livre, et à qui.
- Nommer les cinq étapes de l'architecture de référence, et l'outil de la formation pour chacune.
- Distinguer le chemin froid du chemin chaud, et reconnaître ce qu'un besoin réclame vraiment.
- Situer la frontière entre cette formation et ses voisines, et nommer les produits qu'elle livre.
- Connaître le fil rouge, Véhicules Boréal inc., et ses six sources.
- Interroger des fichiers sur place avec DuckDB, sans rien charger.
- Reconnaître les pièges d'un type deviné, sur une date, un code et un horodatage.

1. Le métier : ingénieur de données

Une donnée ne sert à rien tant qu'elle n'est pas arrivée. Entre le capteur qui mesure la vibration d'un compresseur et l'analyste qui cherche pourquoi il a lâché, il y a un réseau, un serveur, un export, un fichier, un stockage, une planification. Chaque maillon peut casser : une zone de l'usine perd sa liaison pendant trois heures, un extrait arrive deux fois, un format change sans prévenir, le fichier de la nuit n'est jamais venu. Quelqu'un doit rendre ce trajet sûr. C'est l'ingénieur de données.

Son travail tient en quatre promesses faites à ceux qui consomment la donnée :

Promesse	Ce qu'elle veut dire	Ce qui la casse
Elle arrive	tout ce que la source a produit est là, rien n'est perdu	une coupure, un fichier manquant, une erreur avalée en silence
Elle est rangée	au bon endroit, dans un format que les autres savent lire	un dossier fourre-tout, un format propriétaire
Elle est à l'heure	disponible quand on en a besoin, et l'on sait de quand elle date	un traitement qui glisse, une panne que personne ne voit

Promesse	Ce qu'elle veut dire	Ce qui la casse
Elle est bonne	des contrôles prouvent qu'elle respecte ses règles	des doublons, des valeurs impossibles, un capteur figé

Une propriété tient les quatre ensemble : un traitement doit pouvoir se **rejouer** sans rien casser. Relancer l'ingestion d'hier, par erreur ou pour réparer, doit donner exactement le même résultat, sans doubler ni perdre une ligne. Cette propriété porte un nom, l'idempotence, et elle gouverne toute la formation à partir du Cours 03.

L'ingénieur de données livre rarement au décideur. Ses clients sont les autres métiers de la donnée :

Qui consomme	Ce qu'il attend de l'amont	Formation du parcours
l'ingénieur analytique	une couche RAW complète et à jour dans l'entrepôt	Analytics Engineering
l'analyste et les opérations	des tableaux de bord qui ne mentent pas, certains en direct	Business Intelligence
le scientifique de données	des séries longues et propres, qu'on peut rejouer pour réentraîner un modèle	Data Science
l'ingénieur ML	les mêmes données à l'entraînement et en production	Machine Learning Engineering
l'ingénieur IA	une documentation complète, dont on connaît la version	AI Engineering

Les trois rôles centraux de la chaîne (ingénieur de données, ingénieur analytique, analyste) sont présentés côte à côte au Cours 01 de la formation Analytics Engineering. Ici, on regarde la chaîne depuis l'amont.

Analogie — le pipeline est un ouvrage, pas un script. Un pont ne se dimensionne pas pour la pluie d'un mardi ordinaire, mais pour la crue centennale. Un pipeline non plus : le jour normal, n'importe quel script fonctionne. Ce qui distingue un ouvrage d'ingénierie, c'est son comportement le jour où la source envoie deux fois le même fichier, où le réseau coupe au milieu d'un transfert, où un capteur se met à répéter la même valeur. La formation passe plus de temps sur ces jours-là que sur les autres.

2. L'architecture de référence

Toute plateforme de données, de la plus modeste à la plus lourde, suit le même trajet :

source → ingestion → lac → entrepôt → restitution

Étape	Son rôle	Dans cette formation	Cours
Source	le système qui produit la donnée, et qu'on ne contrôle pas	l'ERP, le SCADA et son historien, la GMAO, le portail des garanties, les véhicules connectés, l'API météo	03, 04, 08, 09
Ingestion	aller chercher la donnée, ou la recevoir, sans la perdre ni la doubler	scripts Python, Airflow, MQTT, Kafka	03, 04, 06, 09
Lac	garder le brut à bas coût, dans des formats ouverts	Parquet, Iceberg	02, 10
Entrepôt	servir la donnée en SQL aux autres métiers	DuckDB : la couche RAW et les séries de l'usine	03, 08, 12
Restitution	la montrer à ceux qui décident ou qui opèrent	Grafana en direct ; les rapports, chez BI	12

Le lac et l'entrepôt se ressemblent, mais ne répondent pas au même besoin. Le lac (*data lake*) est un stockage de fichiers : tout y entre, dans n'importe quel format, pour presque rien, et l'on décide de la structure au moment de lire. L'entrepôt (*data warehouse*) est une base de tables : on y entre par un schéma défini d'avance, et l'on y gagne le SQL, les types et les droits. Depuis quelques années, les deux convergent dans ce qu'on appelle un lakehouse, des tables transactionnelles posées sur des fichiers ouverts. C'est le sujet du Cours 10.

Pour interroger le lac comme l'entrepôt, le moteur SQL de la formation est DuckDB (section 6). Il sert de référence à tout le parcours, sur votre poste, sans compte infonuagique. Snowflake et Databricks, les deux plateformes qu'on croise le plus souvent en entreprise, reçoivent une annexe là où elles changent le geste (Cours 03, 07 et 10) et un encadré là où elles ne changent qu'un concept. Snowflake a aussi sa propre formation.

3. Deux chemins : le froid et le chaud

Une même donnée peut emprunter deux chemins entre la source et son lecteur.

Le chemin froid (*cold path*) traite la donnée par lots : chaque nuit ou chaque heure, on ramasse ce qui s'est accumulé et on le range. Le chemin chaud (*hot path*) la traite en continu : chaque mesure circule dès qu'elle est produite, en quelques secondes.

	Chemin froid, par lots	Chemin chaud, en continu
Délai	des minutes aux heures	des secondes

	Chemin froid, par lots	Chemin chaud, en continu
Question type chez Boréal	« combien de motoneiges la ligne a-t-elle assemblées hier, et combien d'énergie l'usine a-t-elle consommée ? »	« le compresseur d'air 2 vibre-t-il trop, en ce moment ? »
Ce qui compte d'abord	la complétude, l'exactitude, la possibilité de rejouer	le délai, la disponibilité
Coût	faible : on calcule quand on veut, puis tout s'éteint	élevé : des services allumés jour et nuit
Outils de la formation	Airflow, Parquet, DuckDB, Spark	MQTT, Kafka, une base de séries temporelles, Grafana
Cours	03 à 07, 10	08, 09

Les deux chemins coexistent le plus souvent et lisent la même source, mais ils n'ont pas le même statut. Le chemin froid est la référence : c'est lui qu'on corrige, qu'on rejoue, qu'on audite. Le chemin chaud sert la réaction immédiate, et accepte d'être approximatif pour être rapide. Le Cours 09 montre les deux façons classiques de les organiser : l'architecture Lambda, qui les garde séparés, et Kappa, qui ne garde que le flux.

À retenir — la plupart des besoins dits « temps réel » sont des besoins horaires. Avant de bâtir un chemin chaud, demandez quelle décision sera prise dans la minute qui suit la mesure. Arrêter un compresseur qui s'emballe, oui. Préparer le rapport mensuel des ventes, non : un traitement par lots, lancé la nuit, le produit tout aussi bien, et coûte bien moins cher. Il calcule une fois, puis ses machines s'éteignent, alors qu'un chemin chaud garde un courtier, des consommateurs et une base allumés jour et nuit pour un rapport que personne ne lira avant la fin du mois.

4. Où s'arrête l'ingénieur de données, et ce qu'il livre

Labo : Labo_01.md, étape 1.

Le parcours des formations suit la chaîne de la donnée. La part de cette formation est en gras :

source → **Data Engineering** → **couche RAW** → Analytics Engineering → couche MARTS → Business Intelligence ou Data Science → Machine Learning Engineering

Cette formation couvre l'amont, couche RAW comprise : c'est elle qui la produit et la livre. La RAW garde le brut tel que la source l'a livré, complet, daté, avec la trace de son origine. La formation ne renomme pas les colonnes au goût du métier, ne décode pas les codes de l'ERP, ne construit pas d'étoile et ne calcule pas d'indicateur. Ce travail appartient à l'ingénieur analytique, qui prend le relais au STAGING, juste après la RAW.

Une exception, dite dès maintenant : les séries de terrain. Les mesures de l'historien et du compteur électrique arrivent avec des valeurs recopiées, des heures qui se répètent au changement d'heure et des codes de qualité. Les nettoyer demande de connaître la source, et c'est l'ingénieur de données qui la connaît. Il livre donc aussi ces séries nettoyées et ramenées à l'heure, dans un schéma à part de l'entrepôt, argent (Cours 08). Pour tout le reste (l'ERP, les garanties, la télémétrie), la RAW passe telle quelle à l'ingénieur analytique.

Formation	Ce qu'elle possède	Ce que Data Engineering en fait
SQL avancé	le langage	l'écrit, sans l'enseigner
Snowflake	la plateforme d'entrepôt	y livre dans ses annexes, sans l'administrer
Analytics Engineering	la transformation et la modélisation	lui livre la couche RAW et les séries de l'usine
Business Intelligence	la restitution	alimente le tableau de bord de l'usine, sans en concevoir la lecture
Data Science	la modélisation statistique	lui sert les séries, sans construire de modèle
Python, Linux	le langage et le système	les suppose acquis

Ce que la formation livre, au bout du Cours 12 :

Produit	Ce que c'est	Qui le consomme	Cours
La couche RAW	les tables livrées telles que reçues, avec la trace de leur origine	l'ingénieur analytique	03, 12
Les séries de l'usine	les mesures de l'historien et du compteur, nettoyées et ramenées à l'heure	l'ingénieur analytique, le scientifique de données	08
Le lac bronze et argent	les fichiers bruts et nettoyés, en formats ouverts	l'architecte	02, 10
La base de séries temporelles	les mesures en continu, pour le tableau de bord de l'usine	l'analyste BI	08, 09, 12
Les contrats de données	les règles que chaque livraison doit respecter	l'ingénieur analytique, l'architecte	11

Chaque produit est décrit dans un document de livraison que la formation écrit à partir du Cours 03 : ses tables, ses comptes attendus, et la commande qui le reconstruit pour qui commence le parcours ailleurs qu'ici.

Ce qui se reconstruit ne se versionne pas, et c'est pourquoi le code et les données ne vivent pas au même endroit. Votre dépôt Git, 01_de, ne contient que du code ; les sources et la plateforme (le lac, l'entrepôt, les services) vivent à côté, dans Projet_Boreal, et se reconstruisent en relançant le générateur et le code. C'est l'organisation d'une vraie équipe, où le code d'ingestion a son dépôt et la plateforme de données est partagée. Les formations suivantes du parcours y ajouteront chacune le leur, jusqu'à 07_archi.

Une notion qui appartient à une autre formation n'est pas réexpliquée ici : on la nomme, on dit où elle est enseignée, et l'on en donne seulement ce qu'il faut pour suivre.

Piège — nettoyer « un peu » au chargement. La tentation est forte : l'extrait de l'ERP arrive avec des dates en texte (20240531) et des codes obscurs, et l'on se dit qu'on rendra service en les convertissant au passage. C'est exactement ce qu'il ne faut pas faire. Une correction faite à l'ingestion n'est ni versionnée, ni testée, ni visible dans le lignage, et le jour où elle se trompe, le brut d'origine n'existe plus nulle part. On charge tel quel, et l'on corrige plus loin, dans du code relu. La raison de fond, garder le brut pour pouvoir tout rejouer, est au Cours 01 de la formation Analytics Engineering.

5. Le fil rouge : Véhicules Boréal inc.

Labo : Labo_01.md, étape 2.

Véhicules Boréal inc., « Boréal » ensuite, fabrique des motoneiges, des motomarines et des véhicules hors-route, et vend les pièces et accessoires qui vont avec. Il ne vend pas aux clients finaux : un réseau d'environ 150 concessionnaires, dans les dix provinces, commande à l'ERP, revend au détail, puis fait l'entretien et les réparations sous garantie. Les véhicules sortent d'une usine d'assemblage à Val-des-Aulnes, au Saguenay–Lac-Saint-Jean : trois lignes, une par gamme, une cabine de peinture, un banc d'essai, et les utilités qui font tourner le tout, dont l'air comprimé.

L'usine est pilotée par un SCADA (*Supervisory Control and Data Acquisition*) : le système qui lit les capteurs des équipements, affiche leur état en salle de contrôle et permet d'agir à distance. Le SCADA ne garde pas l'histoire. C'est le rôle de l'historien, une base spécialisée qui archive les mesures de chaque point pendant des années. Chaque point mesuré porte une étiquette (*tag*) qui dit où il se trouve et ce qu'il mesure : UTL.CMP2.VIBRATION est la vibration du compresseur d'air 2, dans la zone des utilités ; LMN.VIS.COUPLE, le couple du poste de vissage de la ligne des motoneiges. L'équipement lui-même porte un identifiant à tiret, UTL-CMP2, dans le registre des actifs comme dans la GMAO.

Vous arrivez chez Boréal comme ingénieur de données. Six sources vous attendent :

Source	Système d'origine	Ce que vous recevez	Ce qui la rend difficile	Cours
L'ERP	un ERP de type SAP	un extrait CSV par mois et par table, et une copie de la base pour PostgreSQL	des noms techniques en abréviations allemandes, des dates en texte, un extrait livré deux fois	03, 04
L'usine	le SCADA et son historien, le registre des actifs, la GMAO, la gestion de l'énergie	un CSV par jour pour l'historien ; les actifs et les étiquettes ; les bons de travail ; les relevés du compteur électrique aux 15 minutes	des points irréguliers, une heure locale sans fuseau, des trous, des doublons	01, 02, 08

Source	Système d'origine	Ce que vous recevez	Ce qui la rend difficile	Cours
Les garanties	le portail des garanties et de l'après-vente	un extrait par mois : clients, enregistrements, visites, consentements, réclamations en JSON	des données personnelles, une réclamation qui revient chaque fois que son statut change	03
La télémétrie	le module télématique des véhicules connectés	une archive quotidienne des résumés de sortie publiés en MQTT	des messages en double, en retard, et un format qui change	09, 10
La documentation	la documentation technique et commerciale	des manuels, des bulletins de service, des politiques de garantie, des procédures	des documents qui paraissent à leur date, deux versions d'une même politique	03
La météo	Environnement et Changement climatique Canada	des observations publiques, par une API REST	la pagination, les limites de débit, les reprises sur erreur	04

Cinq sources sont fabriquées par un générateur livré avec le dépôt des formations, que le guide d'installation du parcours lance une fois, à son étape 9. La sixième est réelle, et c'est voulu, pour deux raisons. Une API réelle a des comportements qu'aucune simulation n'imité bien. Et la vraie météo pilote le fictif : les motoneiges se vendent quand la neige est au sol, et la demande électrique de l'usine suit la température de la station voisine, Bagotville.

Une clé relie les sources entre elles : le numéro de série du véhicule (MN26000417, une motoneige de l'année-modèle 2026). L'ERP le donne à l'assemblage, la télémétrie le porte dans chaque message, le portail des garanties dans chaque réclamation. C'est lui qui fera traverser un même chiffre d'une formation à l'autre.

Ces données portent les deux cas d'usage que le parcours retrouvera plus loin. La demande électrique de l'usine suit la journée, la semaine et la saison : c'est la matière d'une prévision de la demande. Et la période contient des pannes de compresseurs et de robots, que les mesures annoncent plusieurs jours d'avance pour qui sait les lire : c'est la matière de la maintenance prédictive. L'une de ces pannes, à l'automne 2025, aura des suites jusque chez les clients, et les formations suivantes la suivront jusque-là. Cette formation ne construit ni prévision ni modèle. Elle garantit que la donnée qui les nourrit est complète, datée et juste.

Fictif à dessein. Véhicules Boréal inc. n'existe pas, pas plus que ses concessionnaires, ses modèles ou Val-des-Aulnes : les noms ont été vérifiés pour qu'aucune entreprise ni aucune marque du secteur ne les porte. L'univers reproduit les systèmes d'un fabricant québécois et les défauts qui vont avec, sans prétendre représenter une organisation réelle. Les clients sont entièrement synthétiques. Seule la météo est réelle.

Une règle du terrain, enfin, qui revient au Cours 08 : on ne branche jamais un pipeline de données directement sur le réseau qui commande les équipements. Le réseau de contrôle industriel est isolé du réseau de bureau pour des raisons de sécurité, et la donnée en sort par des points de passage prévus pour ça, l'historien en tête. L'ingénieur de données travaille de l'autre côté de cette frontière.

Le reste se trouve à trois endroits : le décor commun des formations du parcours dans `_univers/boreal/README.md`, le sens de chaque fichier et de chaque colonne dans `_univers/boreal/DICTIONNAIRE.md`, et le mandat propre à cette formation, cours par cours, dans `01_Boreal/Mise_en_situation_Boreal_01_DE.md`.

6. DuckDB, pour regarder sans charger

Labo : Labo_01.md, étape 2.

DuckDB est un moteur SQL analytique qui s'exécute à l'intérieur de votre programme, sans serveur à installer ni à démarrer. Il lit directement un fichier, ou tout un dossier de fichiers, et il reste rapide sur des volumes qui étoufferaient un tableur. Il est le moteur de référence des labos, et ne cède la place à Spark et à Kafka que dans les cours dont ils sont le sujet.

Au premier regard, il interroge les sources telles que Boréal les livre. Un motif comme `'sources/usine/historien/*.csv'` lit les 92 fichiers de l'historien d'un coup, sans rien copier : les fichiers restent où ils sont, et c'est la requête qui va à eux. Le Cours 02 lui fera écrire le lac.

Il donne aussi un type à chaque colonne d'un fichier qui n'en déclare pas. C'est commode pour regarder, et c'est là que commence le piège de la section suivante.

7. Le type deviné

Labo : Labo_01.md, étape 3.

Un CSV ne contient que du texte. Un JSON distingue les nombres, les chaînes et les booléens, mais ne connaît ni les dates ni les montants. Pour offrir des colonnes typées, un outil lit un échantillon et devine. Il devine juste la plupart du temps, et c'est ce qui rend ses erreurs dangereuses : rien ne les signale.

Quatre erreurs de ce genre, vues chez Boréal avec DuckDB :

Colonne	Ce que devine DuckDB	Ce qui casse, sans erreur
ERDAT de VBAK, une date SAP comme 20251231	un entier	<code>MAX(ERDAT) + 1</code> rend 20251232, une date qui n'existe pas
AEDAT de VBAK, la même sorte de date, vide à 00000000	du texte, à cause de ses zéros	deux colonnes de dates, deux types : les comparer demande deux conversions différentes

Colonne	Ce que devine DuckDB	Ce qui casse, sans erreur
VKORG et VTWEG, des codes (1000, 10)	des entiers	un code n'est pas un nombre : un code 01 deviendrait 1
recu_le, debut et fin de la télémétrie, comme 2025-12-15T00:25:22-05:00	des horodatages ramenés à UTC	2025-12-15 05:25:22 : le décalage disparaît, et avec lui le fuseau où roulait le véhicule

Un cinquième piège, lui, plante, mais loin de sa cause. Lue d'un seul motif, l'archive de la télémétrie devient une unique colonne json : ses 39 premiers jours sont vides, et la détection, qui échantillonne les premiers fichiers, n'y a rien trouvé à analyser. C'est la requête suivante qui échoue, sur une colonne message introuvable.

La parade tient en une règle, celle du bronze, qui ouvre le Cours 02 : on déclare les types, on ne les devine pas.

Recoupements — ce que ce cours partage avec ses voisines. - Analytics Engineering. Les métiers se partagent la même chaîne : l'ingénieur de données livre la couche RAW et les séries de l'usine, l'ingénieur analytique prend la suite au STAGING. Le Cours 01 d'AE possède la présentation des rôles et le passage de l'ETL à l'ELT ; ici, on ne regarde que l'amont. - Data Science. Le scientifique de données consomme ce que cette formation produit. Les séries de l'usine de Boréal nourriront ses cas de prévision de la demande électrique et de maintenance prédictive.

Points clés à retenir

- L'ingénieur de données promet que la donnée arrive, qu'elle est rangée, à l'heure et bonne. Une propriété tient le tout : un traitement doit se rejouer sans rien casser.
- Il livre aux autres métiers de la donnée : la couche RAW à l'ingénieur analytique, des séries au scientifique, des tableaux de bord aux opérations.
- L'architecture de référence : source → ingestion → lac → entrepôt → restitution.
- Deux chemins : le froid, par lots, qui fait référence et se rejoue ; le chaud, en continu, qui sert la réaction immédiate et coûte plus cher. La plupart des besoins « temps réel » sont horaires.
- La formation s'arrête à la couche RAW, livrée brute, et aux séries de terrain nettoyées, qu'elle seule sait nettoyer. On ne corrige rien à l'ingestion.
- Le fil rouge : Véhicules Boréal inc. et ses six sources (ERP, usine, garanties, télémétrie, documentation, météo), dont une seule est réelle. Le numéro de série les relie.
- DuckDB interroge les fichiers là où ils sont, sans serveur et sans rien charger : c'est l'outil du premier regard, et le moteur de référence des labos.
- Un type deviné se trompe en silence : une date SAP devient un entier, un horodatage perd son décalage, une archive aux premiers fichiers vides devient une seule colonne json.

Exercices

Les exercices de ce cours et leur corrigé vivent dans `Exercices_corriges_01.md`. Faites-les après le labo : plusieurs énoncés supposent que le premier regard a été fait.