

Table des matières

Cours 08 — Données de terrain : SCADA, historien et séries temporelles.....	1
Objectifs.....	2
1. La chaîne qui produit un point.....	3
2. OPC UA, la langue commune des équipements.....	3
3. La bande morte : ce que l'historien garde, et ce qu'il jette.....	4
4. La qualité d'un point, et ce qu'elle vaut.....	5
5. Les étiquettes et la hiérarchie des actifs.....	6
6. La frontière entre technologies opérationnelles et technologies de l'information.....	6
7. Les quatre pièges d'horloge.....	7
8. Le capteur figé, et son faux jumeau.....	8
9. Rendre la série régulière.....	9
10. Chaque nature de point a sa règle.....	10
11. Une base de séries temporelles, et ce qu'elle change.....	11
12. L'agrégat continu, et ce qu'il ne peut pas voir.....	11
Points clés à retenir.....	12
Exercices.....	13

Cours 08 — Données de terrain : SCADA, historien et séries temporelles

Théorie · Module 8/12 — Formation Data Engineering · ~45 min · intermédiaire

Où vous êtes : **source** → ingestion → **lac** → entrepôt → restitution. Les Cours 03 et 04 ont chargé des fichiers et des bases, où chaque ligne est un fait posé par un humain ou par une application. Ce cours-ci change de nature de donnée : une mesure prise par un appareil, toutes les deux minutes, pendant des années, sans que personne ne la relise. Elle arrive avec ses propres règles et ses propres mensonges, et aucun des réflexes de l'ERP n'y suffit.

En 30 secondes :

- Un point de terrain n'est pas une ligne de base. Il porte un horodatage, une valeur et un code de qualité, et sa seule clé est le couple de l'étiquette et de l'instant.

- L'historien ne garde pas tout. Il retient un point quand la valeur s'écarte assez de la dernière retenue, ce qui rend la série irrégulière par construction.
- Le volume de points est lui-même un signal. Chez Boréal, la pression du réseau d'air passe de 89 points par jour à 265 pendant la dérive du compresseur, sans qu'aucune valeur ne sorte des bornes.
- Un code de qualité mauvaise arrive sans valeur : 529 points sur 182 jours, et une moyenne qui les compte pour zéro est fausse sans prévenir.
- L'heure locale sans fuseau est le piège le plus coûteux du terrain. Le 2 novembre 2025, une heure se répète, 49 paires en double ; le 8 mars 2026, une heure n'existe pas.
- Un équipement à l'arrêt ressemble à un capteur figé. La seule façon de les distinguer est de croiser la mesure avec l'état de marche.

L'idée du cours. Les données de terrain sont le seul endroit du parcours où la donnée est produite par un appareil plutôt que par un système d'information, et c'est ce qui change tout. Un capteur n'a pas de contrainte d'intégrité, pas de transaction, pas de corbeille. Il envoie ce qu'il croit mesurer, y compris quand il ne mesure plus rien. Le travail de l'ingénieur de données commence donc plus tôt qu'ailleurs : avant de transformer quoi que ce soit, il faut savoir ce que les points valent, et le prouver en les comptant.

Objectifs

- Nommer la chaîne qui produit un point : le capteur, le transmetteur, l'automate, le SCADA, l'historien.
- Expliquer ce qu'est la bande morte, et pourquoi elle rend une série irrégulière.
- Lire une valeur de départ et un archivage de minuit pour ce qu'ils sont, et ne pas les compter deux fois.
- Interpréter un code de qualité OPC, et dire ce qu'une valeur manquante fait à une moyenne.
- Lire une étiquette et retrouver son équipement dans la hiérarchie des actifs.
- Dire pourquoi un pipeline ne se branche jamais sur le réseau de contrôle.
- Reconnaître les quatre pièges d'horloge d'une série de terrain : l'heure locale sans fuseau, le changement d'heure, l'horodatage de fin d'intervalle et la date en texte.
- Distinguer un capteur figé d'un équipement à l'arrêt, sur les données et non sur l'intuition.
- Rééchantillonner une série irrégulière à l'heure, en pondérant chaque point par sa durée.
- Donner à chaque nature de point sa règle : moyenne pondérée, fraction de temps, différence de cumuls, somme.
- Dire ce qu'une base de séries temporelles fait mieux qu'un entrepôt, et ce qu'elle fait moins bien.
- Expliquer pourquoi un agrégat continu ne peut pas pondérer seul, et ce qu'il faut lui préparer.

1. La chaîne qui produit un point

Labo : Labo_08.md, étape 1.

Entre la grandeur physique et la ligne d'un fichier, il y a quatre appareils, et chacun peut mentir à sa façon.

L'appareil	Ce qu'il fait	Ce qu'il peut vous faire
Le capteur	traduit une grandeur physique en signal : une vibration en millimètres par seconde, une pression en kilopascals	dériver avec le temps, se salir, se bloquer sur sa dernière valeur
Le transmetteur	met le signal en forme et l'envoie à l'automate	saturer aux bornes de sa plage, tomber en défaut
L'automate programmable	commande l'équipement et tient les valeurs courantes	rien, en général : il fait son travail, et ce n'est pas lui qu'on interroge
Le SCADA	lit les automates, affiche les états en salle de contrôle, permet d'agir à distance	ne garde pas l'histoire, ce n'est pas son rôle
L'historien	archive les mesures de chaque point, pendant des années	jeter ce qu'il juge inutile, selon des règles qu'il faut connaître

Le SCADA de Boréal lit chaque point aux deux minutes. Ce n'est pas la fréquence du capteur, qui mesure en continu, ni celle de l'automate, qui rafraîchit ses valeurs bien plus vite : c'est la cadence de la boucle de supervision. Déjà, à ce niveau, la donnée que vous recevrez n'est plus le phénomène, mais un échantillon du phénomène.

Rappel — l'usine de Val-des-Aulnes, vue au Cours 01. Six zones, dix-sept équipements, 58 points mesurés. Les utilités portent les trois compresseurs d'air, le sécheur, le collecteur du réseau et la chaudière ; trois zones portent les lignes d'assemblage ; une la peinture, une les essais de fin de ligne.

2. OPC UA, la langue commune des équipements

Labo : Labo_08.md, étape 1.

Un atelier achète ses équipements à des fabricants différents, sur trente ans. Chacun parle son protocole. OPC UA (*Open Platform Communications Unified Architecture*) est la norme qui leur donne une langue commune : un modèle d'information où chaque point est un nœud nommé, typé, horodaté, avec un code de qualité, et un protocole pour le lire, s'y abonner et le parcourir.

Ce qu'il faut en retenir pour ce cours tient en trois faits. Le nom du point est structuré, ce qui permet d'en tirer la hiérarchie des actifs sans dictionnaire séparé. L'horodatage et la qualité voyagent avec la valeur, et ne sont donc pas une invention de l'historien. Et la lecture se fait par abonnement, ce qui veut dire qu'un client reçoit les changements plutôt que d'interroger sans cesse.

Vous ne monterez pas de serveur OPC UA dans ce labo : Boréal vous livre des fichiers, comme la plupart des usines le font pour une équipe qui n'a pas accès au réseau de contrôle (section 6). Ce qui compte est de savoir d'où viennent les trois colonnes que vous allez manipuler, et pourquoi la qualité est une colonne à part entière plutôt qu'une note en bas de page.

3. La bande morte : ce que l'historien garde, et ce qu'il jette

Labo : Labo_08.md, étapes 4 et 7.

Un historien qui garderait toutes les lectures de 58 points aux deux minutes écrirait 15 millions de lignes par an pour une petite usine, dont l'immense majorité répéterait la précédente. Il applique donc une compression par bande morte : il ne retient un point que si sa valeur s'écarte de la dernière valeur retenue de plus d'un seuil propre à l'étiquette, et au moins un point par heure pour prouver que la mesure vit toujours.

Chez Boréal, `etiquettes.csv` donne la bande morte de chaque point : 1 kW pour une puissance, 0,5 °C pour une température de refoulement, 0 pour un état de marche, qui n'est retenu qu'à son changement.

Trois conséquences, et ce sont elles qui comptent :

- La série est irrégulière par construction. L'intervalle entre deux points n'a aucune raison d'être constant, et il n'est presque jamais de deux minutes. Toute la suite du cours découle de là : une moyenne simple sur des points irréguliers est fausse, et c'est l'objet du rééchantillonnage de la seconde séance.
- Le nombre de points est un signal. Un capteur dont la valeur bouge plus produit plus de points. Chez Boréal, la pression du réseau d'air tient autour de 89 points par jour en marche normale, et monte à 265 le 24 octobre 2025, pendant que le compresseur 2 dérive. Personne n'a changé de réglage : c'est la grandeur qui s'est mise à osciller. Le signal ne se voit qu'au grain de l'étiquette : la zone des utilités, elle, reste dans sa fourchette ordinaire de 1 200 à 1 500 points par jour ouvrable, et ne trahit rien.
- Ce qui n'a pas été retenu n'existe plus. Un historien n'est pas un enregistreur : la valeur entre deux points retenus est perdue, et la seule chose qu'on puisse en dire est qu'elle est restée dans la bande morte.

Deux mécanismes s'ajoutent à la bande morte, et tous deux produisent des lignes qu'il ne faut pas compter comme des mesures ordinaires.

Le mécanisme	Ce qu'il écrit	Chez Boréal, sur 182 jours
La valeur de départ	en tête de chaque fichier quotidien, la dernière valeur retenue la veille, avec son horodatage de la veille	10 556 lignes, exactement 58 par jour

Le mécanisme	Ce qu'il écrit	Chez Boréal, sur 182 jours
L'archivage de minuit	à minuit, la valeur de chaque étiquette, même si elle n'a pas bougé	10 525 points à 00:00:00, et non 10 556

L'écart de trente et un points entre les deux lignes du tableau n'est pas une erreur de comptage. Quatre jours ont moins de 58 points à minuit, parce qu'une coupure de communication touchait une zone entière à cet instant. L'archivage de minuit n'est donc pas une garantie : c'est une intention de l'historien, que la réalité du réseau contredit parfois.

Piège — la valeur de départ se compte deux fois si on ne la voit pas. Elle porte l'horodatage de la veille, mais elle vit dans le fichier du jour. Qui charge les fichiers un par un sans y prendre garde obtient 10 556 doublons parfaits, chacun présent dans deux fichiers voisins. Le remède est d'écarter les lignes dont la date de l'horodatage n'est pas celle du fichier, et c'est exactement ce que le partitionnement par jour du bronze rend facile à écrire.

4. La qualité d'un point, et ce qu'elle vaut

Labo : Labo_08.md, étape 6.

OPC définit un code de qualité qui accompagne chaque valeur. Trois valent la peine d'être connues, et ce sont celles que l'historien de Boréal écrit.

Code	Sens	Ce que la valeur vaut
192	bonne	la mesure est utilisable
64	douteuse	la mesure est là, mais l'appareil signale qu'il n'en répond pas
0	mauvaise	il n'y a pas de mesure : le champ de la valeur est vide

Sur les 182 jours de l'historien de Boréal, valeurs de départ exclues, cela donne 538 938 points de qualité bonne, 64 de qualité douteuse et 529 de qualité mauvaise. Les proportions sont caractéristiques d'une usine qui va bien : le défaut est rare, mais il n'est pas nul, et il ne s'annonce pas.

Deux comportements méritent d'être vus une fois pour toutes, parce qu'ils décident de la façon dont on écrit les filtres :

- Une qualité mauvaise arrive sans valeur. Les 529 points n'ont aucune valeur, pas même un zéro. Un moteur qui lit ce fichier en met NULL, et une moyenne qui ne filtre pas la qualité les ignore silencieusement, ce qui est le bon résultat par accident. Mais une somme, un compte ou un remplissage par zéro donneraient un chiffre faux, et personne ne le verrait.
- Une coupure touche une zone entière. Les 529 points mauvais se répartissent sur 44 jours et, à chaque fois, sur un nombre de points qui vaut le nombre d'étiquettes d'une zone : 18 pour les utilités, 11 pour une ligne d'assemblage, 9 pour la peinture, 7 pour la ligne des motomarines, 2 pour les essais. Ce n'est pas un capteur qui tombe, c'est un lien de communication.

La qualité douteuse, elle, porte une valeur, et c'est ce qui la rend dangereuse : 64 points sur 33 étiquettes et 55 jours, au milieu de mesures normales. Les garder ou les écarter est une décision de métier, pas une décision technique, et la seule faute serait de ne pas la prendre.

5. Les étiquettes et la hiérarchie des actifs

Labo : Labo_08.md, étape 1.

Une étiquette dit en trois morceaux où se trouve le point et ce qu'il mesure. UTL.CMP2.VIBRATION est la vibration du compresseur d'air 2, dans la zone des utilités. L'équipement, lui, porte un identifiant à tiret, UTL-CMP2, et c'est celui-là que la GMAO emploie dans ses bons de travail. Les deux conventions cohabitent, et il faut savoir passer de l'une à l'autre : c'est la première jointure du labo.

Le fichier	Ce qu'il porte	Chez Boréal
actifs.csv	les zones et les équipements, chacun avec son parent, sa mise en service et sa puissance	23 lignes : 6 zones et 17 équipements
etiquettes.csv	les points mesurés, avec leur actif, leur grandeur, leur unité, leur bande morte et leur plage	58 lignes
bons_travail.csv	les interventions, préventives et correctives, par équipement	825 bons depuis 2022

La hiérarchie compte plus qu'il n'y paraît. Elle permet de remonter d'un point à son équipement, de l'équipement à sa zone, et de la zone à la ligne d'assemblage de l'ERP, parce que trois zones portent le poste de travail qui leur correspond. C'est ce chemin qui reliera plus tard une vibration anormale à des véhicules assemblés, et c'est pour cela qu'un référentiel d'actifs vaut d'être chargé avec autant de soin que les mesures elles-mêmes.

Pourquoi — un référentiel d'actifs n'est pas une table de référence ordinaire. Il change lentement, mais il change : un équipement remplacé, une zone réorganisée, un point ajouté. Le Cours 11 reviendra sur ce qu'un contrat doit exiger de lui. Pour l'instant, retenir qu'une mesure sans référentiel est un nombre sans objet.

6. La frontière entre technologies opérationnelles et technologies de l'information

Labo : Labo_08.md, étape 1.

Les appareils qui font marcher l'usine forment ce qu'on appelle les technologies opérationnelles, et les systèmes qui font marcher l'entreprise, les technologies de l'information. Les deux mondes sont séparés par une frontière qui n'est pas négociable, et un ingénieur de données doit savoir pourquoi avant de demander un accès.

Le réseau de contrôle porte des équipements dont une interruption arrête la production, ou pire : une soupape, un four, un robot. Il tourne souvent sur des systèmes anciens qu'on ne corrige pas, parce que les corriger demanderait de les arrêter. Une requête maladroite, un balayage de ports, un client qui ouvre trop

de connexions peuvent suffire à perturber un automate. La règle qui en découle est simple : on ne branche jamais un pipeline de données sur le réseau de contrôle.

Ce qu'on fait à la place, par ordre de préférence :

La voie	Ce que c'est	Ce qu'elle coûte
L'export de l'historien	ce que Boréal fait : un fichier par jour, déposé dans un dossier que l'équipe des données lit	le délai, et rien d'autre
Une réplique en lecture de l'historien	une copie du serveur, côté information	une licence, et une machine
Une passerelle unidirectionnelle	un appareil qui ne laisse passer les données que dans un sens	cher, et réservé aux sites qui l'exigent
Un accès direct au serveur OPC UA du réseau de contrôle	ce que personne ne devrait vous accorder	le risque, entièrement porté par la production

Cette frontière explique la forme des données de ce cours, et pas seulement leur sécurité. Si l'historien livre des fichiers quotidiens, c'est parce qu'un humain a décidé de ce qu'il exporte et quand. La fraîcheur des données de terrain n'est donc pas une propriété technique : c'est une entente.

7. Les quatre pièges d'horloge

Labo : Labo_08.md, étapes 2, 3 et 5.

Rien ne coûte plus cher, sur une série de terrain, qu'un horodatage mal compris. Les quatre pièges ci-dessous sont tous présents dans les données de Boréal, et tous les quatre viennent de systèmes différents, ce qui est exactement la situation réelle.

Le premier est l'heure locale sans fuseau. L'historien écrit 2025-11-02 01:30:00, sans dire s'il s'agit de l'heure avancée ou de l'heure normale. Tant que rien ne change, cela se supporte. Deux fois par an, cela casse :

Le jour	Ce qui arrive	Ce que les données montrent
2025-11-02, retour à l'heure normale	l'heure de 1 h à 2 h est vécue deux fois	141 points entre 01:00 et 02:00, dont 49 paires d'étiquette et d'horodatage strictement identiques
2026-03-08, passage à l'heure avancée	l'heure de 2 h à 3 h n'existe pas	aucun point entre 02:00 et 03:00, contre 79 le dimanche précédent

Les 49 doublons ne sont pas des doublons de livraison, comme l'extrait de l'ERP livré deux fois au Cours 03. Ce sont deux mesures différentes, prises à une heure d'intervalle, que l'horloge a rendues indistinguables. Les dédoublonner serait perdre une heure de données ; les garder telles quelles fait échouer toute clé qui suppose un horodatage unique par étiquette. La seule issue est de reconstruire le moment absolu, et la seconde séance s'en charge.

Le deuxième piège est l’horodatage de fin d’intervalle. Le compteur électrique de Boréal écrit un relevé aux quinze minutes, horodaté à la fin de l’intervalle : le relevé de 08:15 couvre de 08:00 à 08:15. Trois conséquences se suivent. Le dernier quart d’heure d’un mois finit à minuit, donc il est dans le fichier du mois suivant. L’énergie d’une année dépend de la convention retenue : sur les mêmes relevés, 2022 pèse 4 995 612 kWh si l’intervalle appartient à l’année où il finit, et 4 995 732 kWh s’il appartient à l’année où il commence. Et un graphique qui aligne ces relevés sur un autre signal sans corriger le décalage montre une cause qui suit son effet.

Le troisième piège est plus discret : le compteur électrique, lui, porte son décalage à UTC, -05:00 en heure normale et -04:00 en heure avancée. C’est la bonne façon de faire, et elle crée tout de même un piège, parce qu’un moteur qui lit ces relevés les ramène au fuseau de sa session. Sur les 148 891 relevés de Boréal, 27 116 changent de jour selon qu’on les lit en heure locale ou en temps universel : près d’un cinquième des relevés, et donc un total quotidien faux pour qui ne s’en aperçoit pas.

Le quatrième piège n’a rien d’industriel, mais il vient du même dossier : la GMAO écrit ses dates en texte, au format JJ/MM/AAAA HH:MM. Un moteur les lit comme des chaînes de caractères, les trie comme telles, et rend le 01/02/2024 pour la plus petite et le 31/12/2024 pour la plus grande, sur des bons qui vont de 2022 à 2026. Le tri alphabétique d’une date en texte ne veut rien dire, et c’est le genre de faute qui traverse un tableau de bord sans que personne ne la voie.

À retenir — un horodatage se qualifie avant d’être employé. Trois questions, toujours les mêmes : quel fuseau, et est-il écrit ; l’horodatage marque-t-il le début ou la fin de ce qu’il décrit ; et quel type le moteur a-t-il vraiment donné à la colonne. Les trois se répondent en une requête, et aucune ne se devine.

8. Le capteur figé, et son faux jumeau

Labo : Labo_08.md, étape 6.

Un capteur qui se bloque ne lève aucune alarme : il continue d’envoyer une valeur plausible, avec une qualité bonne, et l’historien l’archive consciencieusement à chaque heure. C’est la panne la plus sournoise du terrain, parce qu’elle ne ressemble pas à une panne.

La détection paraît facile : chercher les plages où la valeur ne change pas pendant longtemps. Sur les 182 jours de Boréal, cette requête rend d’abord le convoyeur de la ligne des motomarines, figé à zéro pendant 790 heures. Et c’est un faux positif : la ligne des motomarines ne tourne pas de la mi-décembre à la mi-janvier, parce que la saison des motoneiges occupe l’usine. Un équipement à l’arrêt donne exactement la signature d’un capteur mort.

Ce qui sépare les deux, c’est le contexte, et il est dans les données :

Le cas	La signature	Ce qui tranche
L’équipement est arrêté	valeur constante, souvent zéro, sur des plages qui suivent le calendrier de production	l’état de marche du même équipement vaut 0
Le capteur est figé	valeur constante non nulle, qualité bonne, pendant que l’équipement tourne	l’état de marche vaut 1, et les autres points du même équipement bougent

Chez Boréal, le seul vrai cas est l’humidité de la cabine de peinture, figée à 54,52 % du 7 octobre 2025 à 10:10 au 9 octobre à 12:00, soit 49,8 heures et 51 points, pendant que la cabine travaillait. Elle passe tous les contrôles de plage, de type et de qualité : seule la constance, croisée avec la marche, la révèle.

Le second candidat de la liste est un piège, et il vaut d’être vu. La vibration du compresseur d’air 1 tient 0,01 pendant vingt-quatre heures au tournant de l’année, ce qui ressemble beaucoup au cas précédent. Mais l’état de marche de la machine vaut 0 sur toute la plage, sa puissance vaut 0, et 0,01 est justement ce que ce capteur écrit quand le compresseur est arrêté. C’est un arrêt du jour de l’An, pas une panne. Écarter les valeurs nulles ne l’aurait pas éliminé, parce que sa valeur d’arrêt n’est pas zéro : seul le croisement avec l’état de marche tranche, et c’est pour cela qu’il n’est pas optionnel.

9. Rendre la série régulière

Labo : Labo_08.md, étapes 9, 10 et 11.

Personne ne consomme une série irrégulière. Un tableau de bord veut un point par heure, un modèle veut une matrice, un rapport veut une colonne par mois. Le rééchantillonnage est le geste qui transforme des points quand-ça-bouge en une grille régulière, et c’est le cœur de ce que Data Engineering livre à ses voisines.

Trois décisions le composent, et chacune se prend une fois pour toutes.

Le pas, d’abord. Une heure convient à Boréal : c’est le pas du tarif électrique, celui des rapports de production, et il laisse voir une dérive de treize jours sans noyer personne sous 500 000 lignes. Un pas plus fin se justifie par un usage, jamais par précaution.

L’instant absolu, ensuite. Une grille d’heures locales n’existe pas deux jours par an : celle de Boréal se construit en instants absolus, et les 25 heures du retour à l’heure normale comme les 23 du passage à l’heure avancée s’y rangent sans discussion. La conversion se fait une fois, à l’entrée, et le reste du pipeline ne connaît plus que des instants.

La pondération, enfin, et c’est la décision que tout le monde rate. Une moyenne simple des points d’une heure donne le même poids à une valeur qui a tenu deux minutes et à une qui a tenu quarante-cinq. Sur une série à bande morte, ces deux cas sont la règle, pas l’exception. La moyenne juste est pondérée par le temps : chaque point compte pour la durée pendant laquelle il valait.

L’heure du 2025-10-28 à 10 h, sur la vibration du compresseur 2	Ce qu’elle rend
Moyenne simple des neuf valeurs qui couvrent l’heure	8,040
Moyenne pondérée par la durée de validité	6,669

Neuf valeurs, et non neuf points : huit points sont horodatés dans cette heure-là, et la neuvième valeur est celle du point précédent, encore valide quand l’heure commence. Une heure se couvre toujours ainsi, et c’est déjà le découpage que la section 12 rendra explicite.

L’écart de 1,371 n’est pas une subtilité : le compresseur a déclenché à 10 h 44, et la valeur est tombée à zéro pour le dernier quart de l’heure. La moyenne simple compte cet arrêt pour une ligne parmi neuf ; la pondérée le compte pour le temps qu’il a duré. Sur les 239 816 heures de l’usine, les deux méthodes divergent de plus d’un millième sur 86 521, soit plus d’une heure sur trois.

Ce compte demande un soin. 398 heures tombent pile à un millième d’écart : une vibration à 0,00 pendant 24 minutes et à 0,01 pendant 36 donne 0,005 en moyenne simple et 0,006 en pondérée. Sur ces heures-là, seul le bruit des additions flottantes décide de quel côté du seuil l’écart tombe, et le même fichier

chargé deux fois rend deux comptes, de 86 690 à 86 700 d'un chargement à l'autre. L'écart s'arrondit donc à six décimales avant d'être comparé : assez pour effacer un bruit d'un milliardième, trop peu pour toucher un vrai écart, dont le plus petit au-dessus du seuil vaut 0,00103. Le Cours 07 a rencontré la même arithmétique sur ses moyennes.

Deux pièges accompagnent le calcul, et tous deux coupent la série par les bouts. Le dernier point d'une étiquette n'a pas de suivant : sans borne de fin, sa dernière journée disparaît du résultat. Et un point de qualité mauvaise n'a pas de valeur : il ne se moyenne pas, mais il doit fermer la validité de celui qui le précède, sans quoi la dernière bonne valeur traverse la coupure comme si de rien n'était.

À retenir — la couverture accompagne la valeur. Chaque heure de l'argent de Boréal porte le nombre de secondes réellement couvertes par une mesure. Une heure à 3 600 secondes est pleine ; une heure à 900 dit que la moyenne ne porte que sur un quart d'heure, le reste n'ayant pas été mesuré ; une heure à zéro n'a pas de valeur du tout. Sans cette colonne, les trois se ressemblent, et c'est ainsi qu'un modèle apprend sur du vide.

10. Chaque nature de point a sa règle

Labo : Labo_08.md, étapes 10, 11 et 12.

Rééchantillonner suppose de savoir ce qu'on rééchantillonne. Les 58 étiquettes de Boréal se rangent en trois natures, que le référentiel donne et qu'aucune heuristique ne devinerait.

Nature	Étiquettes	La règle horaire	Pourquoi
Mesure	45 : pressions, températures, vibrations, puissances, débits	moyenne pondérée par le temps	la grandeur existe à chaque instant, et son niveau moyen a un sens
État	10 : les marches d'équipement	la même moyenne pondérée, qui donne la fraction d'heure en marche	un 0 ou un 1 pondéré par le temps rend une disponibilité, ce que le dernier état de l'heure ne dit pas
Compteur	3 : les compteurs de véhicules des convoyeurs	la différence des cumuls, remise à zéro à minuit	la valeur est un cumul : sa moyenne ne veut rien dire, seule sa croissance en dit quelque chose

La deuxième ligne mérite qu'on s'y arrête, parce qu'elle simplifie beaucoup de code. Un état de marche vaut 0 ou 1 ; sa moyenne pondérée par le temps est exactement la part de l'heure passée en marche. Mesures et états se traitent donc par la même formule, et seule l'interprétation change.

La troisième nature, elle, ne se plie à aucune moyenne. Le compteur du convoyeur des motoneiges monte de 1 à 24 dans la journée et repart de zéro à minuit : sa production horaire est la différence entre son cumul de fin d'heure et celui de l'heure précédente, et celle de la première heure du jour est le cumul lui-même. Le contrôle qui suit tombe tout seul : la somme des productions d'une journée doit égaler le dernier cumul de cette journée.

Le compteur électrique, qui vient d'un autre système, n'a aucun de ces problèmes. Il livre déjà un relevé par quart d'heure, horodaté avec son fuseau : l'énergie d'une heure est la somme de ses quatre relevés, et la seule précaution est de retirer les quinze minutes du décalage de fin d'intervalle avant de grouper. Sa série traverse les deux changements d'heure sans une égratignure, là où l'historien en perd deux jours par an. La différence tient à une colonne.

11. Une base de séries temporelles, et ce qu'elle change

Labo : Labo_08.md, étape 13.

Un entrepôt analytique lit vite ce qu'on lui a préparé. Une base de séries temporelles est bâtie pour autre chose : recevoir des points en continu, les ranger par tranche de temps, et répondre à « les vingt-quatre dernières heures de cette étiquette » pendant que l'écriture continue. TimescaleDB, qui sert ici, est une extension de PostgreSQL : c'est le même serveur, le même SQL, les mêmes pilotes, avec trois mécaniques de plus.

La mécanique	Ce qu'elle fait	Ce qu'elle coûte
L'hypertable	découpe la table en tranches de temps, ici sept jours, et n'ouvre que les tranches utiles	rien de visible : la table s'interroge comme une table
L'agrégat continu	tient à jour une vue matérialisée par seau de temps, sans tout recalculer	une politique de rafraîchissement à régler, et un décalage assumé sur le présent
La rétention et la compression	jettent ou compriment les vieux morceaux selon une règle	un choix à faire, que le Cours 11 rouvrira côté contrats

Ce qu'elle fait mieux qu'un entrepôt de fichiers : écrire en continu pendant qu'on lit, répondre sur une fenêtre récente sans balayer l'historique, et tenir un tableau de bord qui se rafraîchit tout seul. Ce qu'elle fait moins bien : le balayage complet d'années de données pour un calcul analytique, où un moteur en colonnes sur du Parquet la dépasse largement, comme le Cours 07 l'a mesuré sur un autre couple d'outils.

Parce qu'elle reste un PostgreSQL, elle demande aussi un geste que l'entrepôt n'a pas : après un chargement en masse, `VACUUM ANALYZE`. `ANALYZE` donne au planificateur les statistiques de la table neuve, sans lesquelles il choisit ses plans à l'aveugle. `VACUUM` rend les pages vides qu'un chargement laisse derrière lui, parce que PostgreSQL agrandit une table par blocs pendant un `COPY`. Sur l'usine de Boréal, l'hypertable pèse 63 Mo juste après le chargement sur une base neuve, et 59 Mo après le `VACUUM`, qui tronque la fin de 18 de ses 27 tranches. Sans lui, l'autovacuum finit par faire le même travail, à un moment que rien ne fixe, et la taille lue dépend alors de l'heure à laquelle on la lit.

Chez Boréal, les deux cohabitent sans se marcher dessus. L'entrepôt et le lac portent l'argent, que les formations suivantes consomment par lots ; la base de séries temporelles porte la même série pour le chemin chaud et pour le tableau de bord de l'usine, que Business Intelligence concevra. Le Cours 09 la branchera sur un flux, et le capstone y mettra l'alerte de vibration.

12. L'agrégat continu, et ce qu'il ne peut pas voir

Labo : Labo_08.md, étape 14.

Un agrégat continu est une vue matérialisée qui sait quelles tranches de temps ont changé, et ne recalcule que celles-là. C'est ce qui permet de garder une moyenne horaire à jour sur des années de points sans repasser sur le passé.

Sa limite vient de la même mécanique : il agrège chaque seau indépendamment, et il ne voit jamais la ligne suivante. Il ne peut donc ni calculer la durée de validité d'un point, ni découper un intervalle qui traverse la frontière d'un seau. Un `AVG()` dans un agrégat continu est nécessairement une moyenne simple, avec l'écart que la section 9 a mesuré.

La parade est une décision d'architecture, et elle vaut bien au-delà de TimescaleDB : ce que l'agrégat ne peut pas calculer se calcule à l'ingestion. On livre à la base des morceaux qui ne traversent aucune frontière d'heure, chacun avec sa durée, et l'agrégat n'a plus qu'à sommer deux colonnes. La moyenne pondérée devient alors $\text{sum}(\text{valeur} * \text{secondes}) / \text{sum}(\text{secondes})$, que tout agrégat sait faire, et le résultat égale au millième près celui du moteur analytique.

Pourquoi — le travail se déplace vers l'écriture. Une série se lit mille fois et s'écrit une fois. Tout ce qu'on peut préparer à l'écriture, durée de validité, découpage, qualité, est payé une seule fois et épargné à chaque lecture. C'est le même raisonnement que le partitionnement du lac au Cours 02, appliqué au temps plutôt qu'aux fichiers.

Recoupements — ce que ce cours partage avec ses voisines.

- SQL avancé : le Cours 09 possède les séries temporelles et la jointure as-of, celle qui rattache une mesure au dernier état connu. Ici, on s'en sert sans l'enseigner, pour lire la vibration du compresseur pendant qu'il tourne.
- Analytics Engineering : elle reçoit les séries horaires que la seconde séance produira, et ne touchera jamais aux points bruts. La frontière est nette : le nettoyage d'une série de terrain appartient à qui connaît la source.
- Data Science : la maintenance prédictive et la prévision de la demande électrique partent de ces mêmes séries. Ce cours décide de ce qu'elles vaudront.
- Business Intelligence : le tableau de bord de l'usine lira la base de séries temporelles montée à la seconde séance ; sa conception appartient à BI.

Points clés à retenir

- Un point de terrain porte trois choses, une valeur, un horodatage et une qualité, et les trois se vérifient avant d'être employées.
- La bande morte rend la série irrégulière : il n'y a pas d'intervalle constant, et le nombre de points est un signal en soi.
- La valeur de départ et l'archivage de minuit sont des lignes techniques, pas des mesures. La première se compte deux fois si on l'ignore, la seconde manque quand la communication est coupée.
- Une qualité mauvaise arrive sans valeur ; une qualité douteuse arrive avec. La première se filtre, la seconde se décide.
- Une coupure touche une zone entière, au même instant : le compte des points mauvais vaut le nombre d'étiquettes de la zone.
- Un horodatage se qualifie avant usage : son fuseau, sa convention de bornage, son type réel.

- L'heure locale sans fuseau casse deux fois par an, dans un sens puis dans l'autre.
- Un capteur figé et un équipement à l'arrêt ont la même signature. Seul l'état de marche les sépare.
- On ne branche jamais un pipeline sur le réseau de contrôle, et c'est pour cela que les données de terrain arrivent en fichiers.
- Une moyenne horaire se pondère par le temps. Sur l'usine de Boréal, la moyenne simple s'en écarte sur plus d'une heure sur trois.
- Chaque nature de point a sa règle, et le référentiel est le seul à la connaître : moyenne pour une mesure, fraction de temps pour un état, différence de cumuls pour un compteur.
- La couverture accompagne la valeur : sans elle, une heure pleine, une heure à moitié mesurée et une heure vide se ressemblent.
- Un agrégat continu ne voit jamais la ligne suivante. Ce qu'il ne peut pas calculer se prépare à l'ingestion, une fois, et la lecture n'a plus qu'à sommer.

Exercices

Les énoncés et leur corrigé sont dans `Exercices_corrige_08.md`. Faites le labo avant : plusieurs questions portent sur des chiffres que vous aurez mesurés vous-même.