Table des matières

Cours 00 — Générer les données sources 1
Ce que vous allez faire 1
Avant de commencer 1
Étape 1 — Générer les sources · Sources 2
Étape 2 — Ce que vous avez maintenant · Sources 3
À retenir 3

Cours 00 — Générer les données sources

Cours de départ · La Brûlerie — Formation Data Engineering

Sources	**Ingestion**	**RAW**
d'où vient la donnée	aller la chercher, et la charger	la déposer, la ranger, la traiter
✓ ici		

Ce que vous allez faire

L'ingénieur de données est le premier de la chaîne, mais il ne part pas de rien : il reçoit ce que les systèmes de l'entreprise produisent. Pour La Brûlerie du Passage, un café de quartier fictif à Montréal, ce sont des fichiers : les exports de sa caisse, les traces de son torréfacteur, et quelques autres que les formations suivantes liront. En entreprise, ces fichiers arrivent seuls, chaque soir, dans un dossier de dépôt. Ici, un mois entier, juin 2025, est livré d'un coup.

Ce cours met ce mois dans votre projet. Un script le génère s'il manque, et garde vos sources si elles sont déjà là, parce que vous avez commencé par Analytics Engineering. Rien ne s'écrit à la main.

le mois livré → votre projet, `Projet_Brulerie\sources`

Avant de commencer

Deux fenêtres servent aux cours : l'Anaconda Prompt pour les commandes, et le notebook de DuckDB, dans le navigateur, pour les requêtes SQL. Ce cours n'a besoin que de l'Anaconda Prompt, placée dans `Data_Domain`, le dossier du parcours :

© 2026 iAlexMG. Tous droits réservés.

```
conda activate formations
REM Attendu : (formations) au début de l'invite.
python --version
REM Attendu : une version 3.11 de Python.
duckdb --version
REM Attendu : v1.5.5 ou plus récent.
git --version
REM Attendu : git version 2.51 ou plus récent.
pytest --version
REM Attendu : pytest 9.1 ou plus récent.
```

Ce sont les quatre outils des cours : Python pour les scripts, DuckDB pour lire et charger, Git pour garder le code, et `pytest` pour le tester, au cours 05. Si l'un d'eux manque, le guide d'installation du parcours, `00_Installation/Guide_installation.md`, le monte.

Étape 1 — Générer les sources · Sources

Le mois livré vit dans `_univers\brulerie\mini_cas\sources`, et on n'y travaille jamais : chaque formation lit sa copie, dans `Projet_Brulerie\sources`. `Projet_Brulerie` est votre projet. Il n'appartient qu'à vous, et le dépôt du parcours ne le versionne pas.

Le script de départ, `preparer_sources.py`, crée le projet et y copie le mois livré s'ils manquent. Il vérifie ensuite chaque fichier, les vôtres compris : il les compare à la liste des fichiers livrés avec le mois, et à leur empreinte, une signature de leur contenu. Vos sources sont lues, jamais modifiées.

1.1 Lancer le script, depuis `Data_Domain`.

```
python 01_Data_Engineering\01_Brulerie_facile\Paquet_de_depart\preparer_sources.py
REM Attendu : le bilan des dossiers, puis Conforme : les 101 fichiers livrés sont là, intacts.
```

Sur un projet neuf, le bilan se lit ainsi :

```
Sources : copiées du mini-cas, 101 fichiers

Dossier        Fichiers  Attendu  Empreintes
caisse               63       63  identiques
catalogue             3        3  identiques
documents            13       13  identiques
fidelite              3        3  identiques
graines               4        4  identiques
meteo                 2        2  identiques
torrefaction         10       10  identiques
(racine)              3        3  identiques

Conforme : les 101 fichiers livrés sont là, intacts, dans Projet_Brulerie\sources
```


© 2026 iAlexMG. Tous droits réservés.

Si vous avez commencé par Analytics Engineering, son cours 00 a déjà copié le mois : la première ligne devient `Sources : déjà là, 101 fichiers`. Il a aussi déposé le dépôt de Data Engineering, `01_de`, tiré du corrigé, et chargé la `RAW` dans l'entrepôt que les deux formations partagent. Le script les tasse, sans toucher au travail d'Analytics Engineering : il range ce `01_de` dans `000-OLD`, puisque vous allez écrire le vôtre, et vide de l'entrepôt les seules tables de Data Engineering, que votre chargeur remplira au cours 03. Deux lignes l'annoncent juste avant `Conforme`. Les vues d'Analytics Engineering revoient juin au complet dès votre cours 03 : même code, mêmes sources, même `RAW`.

Si le script s'arrête, son dernier message dit pourquoi :

Message	**Ce qui se passe**	**Quoi faire**
`1 écart(s) : les sources de Projet_Brulerie ne sont pas celles du mini-cas`, ou plus d'un	un fichier de `Projet_Brulerie\sources` a changé, manque ou s'est ajouté ; au-dessus du message, une ligne par écart le nomme, `modifié`, `manquant` ou `en trop`	mettre le dossier de côté, `move Projet_Brulerie\sources Projet_Brulerie\sources_avant`, puis relancer : le script recopie le mois livré

Étape 2 — Ce que vous avez maintenant · Sources

2.1 Lister le projet.

```
dir /b Projet_Brulerie
REM Attendu : sources, plus ce qu'Analytics Engineering y a laissé, si vous l'avez fait.
```

Les sources du café sont en place. Le cours 01 les ouvre et les lit, sans rien charger : c'est là que commence le travail d'un ingénieur de données.

À retenir

- L'ingénieur de données reçoit des fichiers qu'il ne modifie jamais : ils sont le point de départ de la chaîne.
- Les sources de départ se génèrent à zéro, ou se gardent quand elles sont déjà là et intactes.

© 2026 iAlexMG. Tous droits réservés.