Table des matières

Cours 01 — Les codes 1

Cours 01 — Les codes

Cours 1/12 · La Brûlerie — Formation Data Engineering

Sources	Ingestion	RAW
d'où vient la donnée	aller la chercher, et la charger	la déposer, la ranger, la traiter
✓ ici		

À ouvrir après avoir essayé. Chaque requête garde les commentaires numérotés du cours, pour comparer ligne par ligne. Elles se tapent dans le notebook de DuckDB (`duckdb -ui`, lancé depuis `Projet_Brulerie`), une par cellule.

2.2 Les premiers tickets du 1er juin

```sql
-- 1. quatre colonnes des cinq premiers tickets du 1er juin
SELECT ticket_id, horodatage, statut, total
FROM read_csv('sources/caisse/2025-06/tickets_2025-06-01_*.csv')
LIMIT 5;
```

2.3 Les types devinés

```sql
-- 1. les colonnes et les types devinés, tous les fichiers de tickets confondus
DESCRIBE SELECT * FROM read_csv('sources/caisse/*/tickets_*.csv');
```

2.4 L'encaissé du mois

```sql
-- 1. la somme de l'encaissé, tous les exports du mois
SELECT SUM(encaisse) AS encaisse
FROM read_csv('sources/caisse/*/tickets_*.csv');
```

3.1 Les lignes et les tickets distincts

```sql
-- 1. les lignes, puis les numéros de tickets distincts
SELECT COUNT(*) AS lignes, COUNT(DISTINCT ticket_id) AS tickets
FROM read_csv('sources/caisse/*/tickets_*.csv');
```


© 2026 iAlexMG. Tous droits réservés.

3.2 Le jour exporté plus d'une fois

```sql
-- 1. tirer le jour du nom de chaque fichier
SELECT REGEXP_EXTRACT(filename, 'tickets_(\d{4}-\d{2}-\d{2})_', 1) AS jour,
-- 2. compter les fichiers distincts (les exports), les lignes et les tickets distincts
       COUNT(DISTINCT filename) AS exports,
       COUNT(*) AS lignes,
       COUNT(DISTINCT ticket_id) AS tickets
FROM read_csv('sources/caisse/*/tickets_*.csv', filename = true)
GROUP BY jour
-- 3. ne garder que les jours exportés plus d'une fois
HAVING COUNT(DISTINCT filename) > 1;
```

3.3 Les deux exports du 12 juin

```sql
-- 1. pour chaque export du 12 juin : son nom, ses tickets, le premier et le dernier
SELECT PARSE_FILENAME(filename) AS fichier, COUNT(*) AS tickets,
       MIN(horodatage) AS premier, MAX(horodatage) AS dernier
FROM read_csv('sources/caisse/2025-06/tickets_2025-06-12_*.csv', filename = true)
GROUP BY fichier
ORDER BY fichier;
```

4.1 Les lots du journal

```sql
-- 1. les lots du journal, avec le premier et le dernier début
SELECT COUNT(*) AS lots, MIN(debut) AS premier, MAX(debut) AS dernier
FROM read_csv('sources/torrefaction/lots.csv');
```

4.2 Ce que couvrent les courbes

```sql
-- 1. les fichiers de courbes (les jours), les lots qu'ils couvrent, et leurs lectures
SELECT COUNT(DISTINCT filename) AS jours, COUNT(DISTINCT lot_id) AS lots, COUNT(*) AS lectures
FROM read_csv('sources/torrefaction/courbes/*/courbe_*.csv', filename = true);
```

4.3 Les moments marqués d'un lot

```sql
-- 1. les lectures du lot L-2025-0214 qui portent un événement
SELECT lot_id, seconde, temp_grain, evenement
FROM read_csv('sources/torrefaction/courbes/2025-06/courbe_2025-06-03.csv')
WHERE lot_id = 'L-2025-0214' AND evenement IS NOT NULL;
```


© 2026 iAlexMG. Tous droits réservés.