Table des matières

Cours 02 — Les codes 1

Cours 02 — Les codes

Cours 2/12 · La Brûlerie — Formation Data Engineering

Sources	Ingestion	RAW
d'où vient la donnée	aller la chercher, et la charger	la déposer, la ranger, la traiter
		✓ ici

À ouvrir après avoir essayé. Le code garde les commentaires numérotés du cours, pour comparer ligne par ligne.

01_de/.gitignore

```
# Fichiers compilés par Python
__pycache__/
```

01_de/sql/bronze.sql

```
-- 01_de/sql/bronze.sql : les tickets de la caisse en Parquet, typés, un dossier par jour livré
COPY (
    -- 1. chaque export avec son chemin, les types déclarés, les montants en DECIMAL ; le jour livré
    SELECT *, CAST(REGEXP_EXTRACT(filename, 'tickets_(\d{4}-\d{2}-\d{2})_', 1) AS DATE) AS jour
    FROM read_csv('sources/caisse/*/tickets_*.csv', filename = true, columns = {
        'ticket_id': 'INTEGER', 'horodatage': 'TIMESTAMP', 'type_ticket': 'VARCHAR',
        'statut': 'VARCHAR', 'ticket_origine': 'INTEGER', 'membre_id': 'VARCHAR',
        'sous_total': 'DECIMAL(10,2)', 'tps': 'DECIMAL(10,2)', 'tvq': 'DECIMAL(10,2)',
        'total': 'DECIMAL(10,2)', 'mode_paiement': 'VARCHAR', 'arrondi': 'DECIMAL(10,2)',
        'encaisse': 'DECIMAL(10,2)'})
    -- 2. d'un jour exporté deux fois, ne garder que le dernier export : il fait foi
    QUALIFY filename = MAX(filename) OVER (PARTITION BY jour)
-- 3. un dossier par jour livré ; OVERWRITE vide le bronze, qui se refait en entier
) TO 'plateforme/lac/bronze/tickets' (FORMAT parquet, PARTITION_BY (jour), OVERWRITE);

-- 4. le contrôle : les tickets distincts de la source, contre les lignes du bronze
SELECT (SELECT COUNT(DISTINCT ticket_id) FROM read_csv('sources/caisse/*/tickets_*.csv')) AS source,
       (SELECT COUNT(*) FROM read_parquet('plateforme/lac/bronze/tickets/*/*.parquet')) AS bronze;
```


© 2026 iAlexMG. Tous droits réservés.

4.2 Le bronze jour par jour, contre la source

```sql
-- 1. par jour livré, les tickets distincts de la source, puis les lignes du bronze
WITH source AS (
    SELECT CAST(REGEXP_EXTRACT(filename, 'tickets_(\d{4}-\d{2}-\d{2})_', 1) AS DATE) AS jour,
           COUNT(DISTINCT ticket_id) AS tickets
    FROM read_csv('sources/caisse/*/tickets_*.csv', filename = true)
    GROUP BY jour
),
bronze AS (
    SELECT jour, COUNT(*) AS tickets
    FROM read_parquet('plateforme/lac/bronze/tickets/*/*.parquet')
    GROUP BY jour
)
-- 2. un jour d'un seul côté, ou deux comptes qui diffèrent, est un écart
SELECT COUNT(*) AS jours, SUM(CASE WHEN s.tickets = b.tickets THEN 0 ELSE 1 END) AS ecarts
FROM source AS s
FULL OUTER JOIN bronze AS b ON b.jour = s.jour;
```

4.3 Le 12 juin dans le bronze

```sql
-- 1. le fichier d'où viennent les tickets du 12 juin, leur nombre, le premier et le dernier
SELECT PARSE_FILENAME(filename) AS fichier, COUNT(*) AS tickets,
       MIN(horodatage) AS premier, MAX(horodatage) AS dernier
FROM read_parquet('plateforme/lac/bronze/tickets/*/*.parquet')
WHERE jour = '2025-06-12'
GROUP BY fichier;
```


© 2026 iAlexMG. Tous droits réservés.