Table des matières

Cours 03 — Les codes 1

Cours 03 — Les codes

Cours 3/12 · La Brûlerie — Formation Data Engineering

Sources	Ingestion	RAW
d'où vient la donnée	aller la chercher, et la charger	la déposer, la ranger, la traiter
	✓ ici	

À ouvrir après avoir essayé. Le code garde les commentaires numérotés du cours, pour comparer ligne par ligne. Le `.gitignore` du dépôt est au `Codes_02_DE.md`.

01_de/charger.py

```python
# 01_de/charger.py : charger dans la RAW ce qui est arrivé jusqu'à un jour donné
import hashlib
import sys
from pathlib import Path
import duckdb

LIVRAISONS = {"tickets": "caisse/*/tickets_*.csv", "lignes": "caisse/*/lignes_*.csv",
              "produits": "catalogue/produits.csv", "modifications": "catalogue/modifications.csv",
              "membres": "fidelite/membres.csv", "consentements": "fidelite/consentements.csv",
              "lots": "torrefaction/lots.csv", "courbes": "torrefaction/courbes/*/courbe_*.csv"}
LECTURE = "SELECT * FROM read_csv(?, all_varchar = true, filename = true)"

def charger(con, jusqua):
    con.execute("CREATE TABLE IF NOT EXISTS journal (fichier TEXT, empreinte TEXT, charge_le TIMESTAMP)")
    for table, motif in LIVRAISONS.items():
        for fichier in sorted(Path("sources").glob(motif)):
            # 1. le jour d'arrivée, en fin de nom ; 2. sauter ce qui n'est pas arrivé, ou déjà au journal
            arrive = fichier.stem.split("_")[-1].replace("-", "")[:8]
            empreinte = hashlib.sha256(fichier.read_bytes()).hexdigest()
            deja = con.execute("SELECT 1 FROM journal WHERE empreinte = ?", [empreinte]).fetchone()
            if (arrive.isdigit() and arrive > jusqua.replace("-", "")) or deja:
                continue
```


© 2026 iAlexMG. Tous droits réservés.

```
            # 3. dans raw_<table>, tout en texte, avec le chemin ; 4. noter le fichier au journal
            con.execute(f"CREATE TABLE IF NOT EXISTS raw_{table} AS {LECTURE} LIMIT 0", [str(fichier)])
            con.execute(f"INSERT INTO raw_{table} {LECTURE}", [str(fichier)])
            con.execute("INSERT INTO journal VALUES (?, ?, now())", [fichier.name, empreinte])

if __name__ == "__main__":
    with duckdb.connect("plateforme/entrepot/brulerie.duckdb") as con:
        charger(con, sys.argv[1])
```


© 2026 iAlexMG. Tous droits réservés.