Table des matières

Cours 07 — Les codes 1

Cours 07 — Les codes

Cours 7/12 · La Brûlerie — Formation Data Engineering

Sources	**Ingestion**	**RAW**
d'où vient la donnée	aller la chercher, et la charger	la déposer, la ranger, la traiter
		✓ ici

À ouvrir après avoir essayé. Chaque requête garde les commentaires numérotés du cours, pour comparer ligne par ligne. Elles se tapent dans le notebook de DuckDB (`duckdb -ui`, lancé depuis `Projet_Brulerie`), une par cellule, sous la cellule qui attache l'entrepôt.

1.2 Le nombre de fils

```
SELECT current_setting('threads') AS fils;
```

1.3 Le plan de l'agrégat des courbes

```
-- 1. exécuter l'agrégat, et rendre son plan avec ce que chaque opérateur a rendu
EXPLAIN ANALYZE
SELECT lot_id, COUNT(*) AS lectures, MAX(CAST(temp_grain AS DECIMAL(5, 1))) AS temp_max
FROM entrepot.raw_courbes
GROUP BY lot_id;
```

2.1 Le gros volume, en mémoire

```
-- 1. chaque lecture mille fois, une par torréfacteur, typée une fois pour toutes
CREATE OR REPLACE TABLE gros AS
SELECT t.range AS torrefacteur, c.lot_id, CAST(c.seconde AS INTEGER) AS seconde,
       CAST(c.temp_grain AS DECIMAL(5, 1)) AS temp_grain
FROM entrepot.raw_courbes AS c
CROSS JOIN range(1000) AS t;
```

2.2 Le plan du même agrégat, sur le gros volume

© 2026 iAlexMG. Tous droits réservés.

```
-- 1. le même agrégat par lot, sur le gros volume, déjà typé
EXPLAIN ANALYZE
SELECT lot_id, COUNT(*) AS lectures, MAX(temp_grain) AS temp_max
FROM gros
GROUP BY lot_id;
```

3.2 Un seul fil

```
-- 1. un seul fil pour toutes les cellules qui suivent
SET threads = 1;
```

3.3 Les fils rendus

```
RESET threads;
```

4.1 Un fichier par fil

```
-- 1. le gros volume dans plateforme/lac/essai, chaque fil dans son fichier
COPY gros TO 'plateforme/lac/essai' (FORMAT parquet, PER_THREAD_OUTPUT);
```

4.2 Les lectures de chaque fichier

```
-- 1. chaque fichier écrit, et ses lectures
SELECT PARSE_FILENAME(filename) AS fichier, COUNT(*) AS lectures
FROM read_parquet('plateforme/lac/essai/*.parquet', filename = true)
GROUP BY fichier
ORDER BY fichier;
```

4.3 Le poids du dossier

```
SELECT COUNT(*) AS fichiers, SUM(size) AS octets FROM read_blob('plateforme/lac/essai/*.parquet');
```


© 2026 iAlexMG. Tous droits réservés.