Table des matières

Mise en situation — La Brûlerie du Passage 1
Le décor 1
La boîte 1
Les cours 2
Ce que le cas démontre 4

Mise en situation — La Brûlerie du Passage

Formation Data Engineering — le cas d'étude pour apprendre · douze cours

La Brûlerie est le cas qui vous apprend le métier. En douze cours courts, vous montez le pipeline d'un petit café, du fichier livré jusqu'au contrôle qui prouve les chiffres, en écrivant vous-même chaque fichier à partir d'un pseudocode. Boréal intermédiaire (le cas d'étude à l'échelle d'une entreprise) refait chaque cours au même rang, en profondeur, pour qui veut aller plus loin. Cette mise en situation reprend, de celle du parcours (`Mises_en_situation/Mise_en_situation_La_Brulerie.md`), ce qui concerne l'ingénieur de données.

Le décor

La Brûlerie du Passage est un café de quartier à Montréal. Elle torréfie son café sur place, sert au comptoir et n'a qu'une caisse. Une trentaine de produits, des boissons chaudes aux sacs de café en grains.

La caisse exporte ses tickets chaque soir, un fichier par jour, et le torréfacteur garde le journal de ses lots et une courbe de température par jour de torréfaction. Les fichiers s'empilent dans un dossier, et personne ne les a jamais chargés nulle part. On vous demande un pipeline qui les prenne chaque matin, qui ne compte jamais un jour deux fois quand la caisse l'a exporté deux fois, qui tire des courbes une ligne par lot, et qui s'arrête quand un chiffre ne retombe plus juste. La météo du jour, que les formations suivantes mettront à côté des ventes, se tire d'une API publique, celle d'Environnement et Changement climatique Canada.

Le mois est petit à dessein : 1 527 tickets et 47 lots. Un ticket se suit de tête, du fichier jusqu'au lac, et chaque total se recompte d'une requête.

La boîte

Volet	Détail
Intrants	Le mois de juin 2025, figé dans `_univers/brulerie/mini_cas/sources/` : les exports quotidiens de la caisse, le journal et les courbes du torréfacteur, la

© 2026 iAlexMG. Tous droits réservés.

Volet	Détail
	météo du mois telle que l'API l'a rendue, et le dictionnaire des colonnes. Le cours 00 le met dans votre projet ; le cours 04 tire aussi la météo de l'API.
Extrants	Le bronze de la caisse en Parquet, un dossier par jour, puis en table Iceberg ; la `RAW` de tout ce qui est livré, pour Data Engineering comme pour Analytics Engineering, avec son journal des chargements ; la météo tirée de l'API ; une table des lots du torréfacteur ; une alerte levée sur les courbes en direct ; quatre règles de la qualité, jugées à chaque passage ; une commande qui rebâtit tout de zéro.
Ressources	Python, DuckDB, `pytest`, la bibliothèque PyIceberg et Git : l'Anaconda Prompt pour les commandes, et le notebook de DuckDB, dans le navigateur, pour les requêtes. Aucun Docker. Un dépôt, `Projet_Brulerie/01_de`, et un entrepôt, `Projet_Brulerie/plateforme/entrepot/brulerie.duckdb`, partagé avec Analytics Engineering.
Contrôles	Le 12 juin compte 65 tickets, et non 123. Relancer le pipeline ne double rien, et rattraper le mois jour par jour donne la même chose que le charger d'un bloc. Quatre règles jugent chaque passage et l'arrêtent quand il le faut : la caisse a livré le jour demandé, le bronze égale la source, un seul export par jour, l'argent égal au journal des lots. Rebâti de zéro, le projet égale celui d'avant, et les ventes payées retombent sur celles de la caisse au cent près : 1 511 ventes, 16 718,00 $ avant taxes. La météo de l'API se compare, jour par jour, à celle qui est livrée.
Livrable	Le dépôt `01_de`, étiqueté `v1.0` : une quinzaine de fichiers courts, qui se rejouent de zéro en une commande.

Les cours

Un cours de départ, le 00, met le mois livré dans votre projet ; douze cours en font un pipeline. Chaque cours explique en quelques phrases, puis fait faire tout de suite. Le fichier à écrire se donne en pseudocode, et son code complet vit à part, dans le `Codes_NN_DE.md` du cours, à ouvrir après avoir essayé.

Chaque cours porte le numéro et le nom du cours de Boréal qu'il refait en petit, dans la même couche, celle de la carte du site. Les trois couches de l'ingénieur de données :

© 2026 iAlexMG. Tous droits réservés.

Couche	Son rôle
Sources	d'où vient la donnée
Ingestion	aller la chercher, et la charger
`RAW`	la déposer, la ranger, la traiter

Les cours 00, 01 et 08 restent dans les sources : ce qui est livré, puis le terrain du torréfacteur. Les cours 03, 04 et 09 vont chercher la donnée : les fichiers, l'API, puis le direct. Les cours 02, 07 et 10 la rangent et la traitent : le bronze, le travail d'une seule machine, la table qui garde ses versions. Les cours 05, 06 et 11 tiennent le pipeline à travers les trois couches, et le 12 le monte de bout en bout. Chaque cours le rappelle en tête, et chacune de ses étapes porte sa couche.

Couche	Cours	Ce qu'il apprend	Les fichiers écrits	Chez Boréal
Sources	00 Générer les données sources	générer les sources de départ, ou garder celles qui sont là	aucun : un script fourni	Cours 00
Sources	01 Analyser les sources	lire les fichiers sans les charger, douter des types devinés	aucun	Cours 01
`RAW`	02 Ranger les fichiers en bronze	Parquet, types déclarés, un dossier par jour, le dernier export qui fait foi	`sql/bronze.sql`	Cours 02
Ingestion	03 Charger la `RAW`	charger tel quel, et relancer sans rien doubler	`charger.py`	Cours 03
Ingestion	04 Extraire d'une base ou d'une API	tirer une API page par page, et la comparer à ce qui est livré	`meteo.py`	Cours 04
Tenir le pipeline	05 Rendre le pipeline robuste	la porte d'entrée du pipeline, son code de sortie, et un test qui prouve que relancer ne double rien	`pipeline.py`, `pytest.ini`, `tests/test_charger.py`	Cours 05
Tenir le pipeline	06 Orchestrer et rattraper	le jour logique, rattraper un mois jour par jour, et prouver	`rattraper.py`	Cours 06

© 2026 iAlexMG. Tous droits réservés.

Couche	Cours	Ce qu'il apprend	Les fichiers écrits	Chez Boréal
		que c'est la même chose qu'un chargement d'un bloc		
RAW	07 Traiter un gros volume	le plan d'exécution, le travail réparti sur les cœurs, ce qu'un moteur écrit en parallèle	aucun	Cours 07
Sources	08 Lire des séries temporelles	une série aux 10 secondes, lue comme un historien, ramenée à une ligne par lot	`sql/argent_torrefaction.sql`	Cours 08
Ingestion	09 Ingérer un flux d'événements	un flux de messages gardé dans un journal, le décalage du lecteur, les doublons, une alerte	`consommer.py`	Cours 09
RAW	10 Passer à un format de table ouvert	une table qui garde ses versions, et le 12 juin revu avant son second export	`iceberg.py`	Cours 10
Tenir le pipeline	11 Contrôler la qualité	une règle, un nombre d'écarts, et ce qu'elle déclenche : bloquer ou avertir	`sql/controles.sql`, `controler.py`	Cours 11
De bout en bout	12 Rebâtir le pipeline de bout en bout	tout refaire de zéro en une commande, le prouver, et retomber sur la caisse	`reconstruire.cmd`, `README.md`	Cours 12

Ce que le cas démontre

Que vous savez monter un pipeline complet, petit mais vrai : partir d'un dossier vide, charger ce qui est livré sans rien perdre ni rien doubler, ranger la caisse au lac, tirer une API et une mesure du terrain, rattraper un mois et prouver que tout retombe sur la caisse. Deux décisions y sont les vôtres : quel export fait foi quand la caisse en a livré deux pour le même jour, et quand un lot du torréfacteur se contrôle, alors que son journal connaît tout le mois d'avance.

© 2026 iAlexMG. Tous droits réservés.

C’est aussi l’échelle où un défaut se voit à l’œil nu. Un jour compté deux fois s’y trahit par 58 numéros de tickets répétés. Boréal refait chaque geste au même rang, sur une entreprise entière, avec les outils que son volume et son temps réel demandent : Airflow, Spark, MQTT et Kafka.

© 2026 iAlexMG. Tous droits réservés.