Table des matières

Cours 00 — Générer les données sources 1
Ce que vous allez faire 1
Avant de commencer 1
Étape 1 — Générer les sources · Sources 2
Étape 2 — Ce que vous avez maintenant · Sources 3
À retenir 3

Cours 00 — Générer les données sources

Cours de départ · Boréal — Formation Data Engineering

Sources	**Ingestion**	**RAW**
d'où vient la donnée	aller la chercher, et la charger	la déposer, la ranger, la traiter
✓ ici		

Ce que vous allez faire

L'ingénieur de données est le premier de la chaîne, mais il ne part pas de rien : il reçoit ce que les systèmes de l'entreprise produisent. Pour Véhicules Boréal inc., le fabricant fictif de motoneiges, de motomarines et de véhicules hors-route que suivent les cours, ce sont six sources : l'usine, le progiciel de gestion, le portail des garanties, la télémétrie des véhicules connectés, la météo et un corpus de documents. En entreprise, elles arrivent seules, chaque jour ou chaque mois. Ici, quatre ans, de janvier 2022 à décembre 2025, se génèrent d'un coup.

Ce cours crée votre projet, `Projet_Boreal`, et y génère tout ce que Boréal livre. Un script fait tout, et rien ne s'écrit à la main.

le générateur de Boréal → votre projet, `Projet_Boreal\sources`

Avant de commencer

Deux fenêtres servent aux cours : l'Anaconda Prompt pour les commandes, et le carnet de DuckDB, dans le navigateur, pour les requêtes SQL. Ce cours n'a besoin que de l'Anaconda Prompt, placée dans `Data_Domain`, le dossier du parcours :

© 2026 iAlexMG. Tous droits réservés.

```
conda activate formations
REM Attendu : (formations) au début de l'invite.
python --version
REM Attendu : une version 3.11 de Python.
duckdb --version
REM Attendu : v1.5.5 ou plus récent.
git --version
REM Attendu : git version 2.51 ou plus récent.
```

Les lignes `REM` sont des commentaires : l'Anaconda Prompt les ignore. Python fait tourner le générateur, DuckDB lit les sources dès le cours 01, et Git garde votre code, à partir du Labo 01. Si l'un d'eux manque, le guide d'installation du parcours, `00_Installation/Guide_installation.md`, le monte.

Étape 1 — Générer les sources · Sources

Les sources de Boréal ne se copient pas : un script les génère, `_univers/boreal/generer_boreal.py`. Elles sont les mêmes chez tout le monde, au fichier près, et chaque chiffre des cours se retrouve donc chez vous. `Projet_Boreal` est votre projet : il n'appartient qu'à vous, et le dépôt du parcours ne le versionne pas. Le générateur écrit dans un projet qui existe : on le crée d'abord.

1.1 Créer le projet, depuis `Data_Domain`.

```
mkdir Projet_Boreal
```

1.2 Lancer le générateur.

```
python _univers/boreal/generer_boreal.py --projet Projet_Boreal
REM Attendu, en un peu plus d'une minute : 1 763 fichiers, puis Conforme à la référence des cours.
```

La sortie se lit ainsi. Le chemin et la durée changent d'un poste à l'autre, le reste jamais :

```
Génération de Véhicules Boréal inc., du 2022-01-01 au 2025-12-31...
  meteo/        11 stations, 17061 jours, 37068 heures
  erp/          48 extraits mensuels (et 2023-03_bis), 25 483 commandes, 77 732 postes, 27 775 véhicules à l'état du 2025-12-31
  usine/        historien 92 jours, 275 436 lignes, 58 étiquettes ; 779 bons de travail ; 140 255 relevés du compteur
  garanties/    48 extraits mensuels : 26 732 enregistrements, 53 865 visites, 5 623 lignes de réclamations
  telemetrie/   884 jours, 158 146 messages reçus de 6 759 véhicules, dont 2 303 doublons
  corpus/       33 documents publiés sur 34 au catalogue, 16 126 mots

Écrit dans …\Data_Domain\Projet_Boreal\sources
  1 763 fichiers, 138,4 Mo, empreinte globale 37521016091c44da...
Durée : 70.9 s.
Conforme à la référence des cours (la génération par défaut).
```


© 2026 iAlexMG. Tous droits réservés.

L’empreinte globale est une signature du contenu de tous les fichiers : deux générations identiques donnent la même. La dernière ligne compare la vôtre à celle dont les cours tirent leurs chiffres.

Si le script s’arrête, ou si `mkdir` refuse, le message dit pourquoi :

Message	Ce qui se passe	Quoi faire
`Le dossier du projet n'existe pas`	`mkdir Projet_Boreal` a été sauté, ou le dossier porte un autre nom	le créer, exactement sous ce nom, dans `Data_Domain`, puis relancer le générateur
`python: can't open file` sur `generer_boreal.py`	l’Anaconda Prompt n’est pas dans `Data_Domain`	s’y placer, puis relancer
`mkdir` répond que `Projet_Boreal` existe déjà	c’est le projet d’un passage précédent	`python _univers/remise/remettre_a_zero.py --cas boreal --formation DE` montre ce qui partirait dans `000-OLD/`, et `--go` l’y range ; puis reprendre l’étape 1

Étape 2 — Ce que vous avez maintenant · Sources

2.1 Se placer dans le projet, et lister les sources.

```
cd Projet_Boreal
dir sources
REM Attendu : six dossiers, corpus, erp, garanties, meteo, telemetrie et usine.
```

Les sources de Boréal sont en place. L’Anaconda Prompt reste dans `Projet_Boreal` : le cours 01 y crée votre dépôt de code, puis ouvre chaque source et la lit, sans rien charger. C’est là que commence le travail d’un ingénieur de données.

À retenir

- L’ingénieur de données reçoit ce que les systèmes de l’entreprise produisent, et ne le modifie jamais : c’est le point de départ de la chaîne.
- Les sources de Boréal se génèrent, les mêmes chez tout le monde : un chiffre des cours qui ne se retrouve pas se règle en relançant le générateur.

© 2026 iAlexMG. Tous droits réservés.