

Table des matières

Exercices 01 — Le métier, les sources et le premier regard	1
Questions courtes	1
Questions pratiques	2
Diagnostics	3
Questions à développer	4
Mises en situation	4

Exercices 01 — Le métier, les sources et le premier regard

Comment travailler ces exercices. Répondez seul, puis vérifiez avec le corrigé. Les exercices marqués [labo] portent sur ce que vous venez de faire au labo ; les autres vérifient que le cours est clair dans votre tête. Tout vient de la Théorie 01 et du Labo 01.

Le corrigé est dans `Corrige_01.md`. Répondez à l'énoncé en entier avant de l'ouvrir : c'est en butant sur une question qu'on découvre ce qu'on avait lu sans le comprendre.

Questions courtes

1. Les quatre promesses. Nommez ce que l'ingénieur de données promet à ceux qui consomment sa donnée, puis la propriété qui tient ces promesses ensemble.
2. À qui il livre. Nommez trois métiers qui consomment le travail de l'ingénieur de données, et ce que chacun attend de l'amont.
3. L'architecture de référence. Donnez les cinq étapes, dans l'ordre, avec un outil ou un système de la formation pour chacune.
4. Lac et entrepôt. En une phrase chacun, ce qui distingue un lac d'un entrepôt.
5. Froid ou chaud. Classez chaque besoin : (a) l'énergie consommée par l'usine le mois dernier ;
(b) l'alerte quand la vibration d'un compresseur dépasse un seuil ; (c) la prévision de la demande électrique de la semaine prochaine ; (d) l'état de marche des compresseurs affiché en salle de contrôle.
6. Le coût du chaud. À volume égal, pourquoi un chemin chaud coûte-t-il plus cher qu'un chemin froid ?

7. La phrase honnête. Que veut dire « la plupart des besoins dits temps réel sont des besoins horaires » ? Quelle question poser avant de bâtir un chemin chaud ?
8. La frontière. À quelle couche l'ingénieur de données s'arrête-t-il, et qui prend la suite ? Quelle exception la formation fait-elle, et pourquoi ?
9. Rendre service. Un collègue propose de convertir les dates de l'ERP en vraies dates et de décoder ses codes au moment de l'ingestion, « pour rendre service ». Quelle règle enfreint-il ?
10. Les sources de Boréal. Nommez les six sources, et le système d'où vient chacune.
11. Lire une étiquette. Que désigne `UTL.CMP2.TEMP_REFOULEMENT` ? Et `UTL-CMP2` ? D'où vient la différence d'écriture ?
12. Les codes de qualité. Que signifient 192, 64 et 0 dans la colonne `Quality` de l'historien ?
13. La seule vraie source. Laquelle des six sources n'est pas générée ? Donnez deux raisons de ce choix.
14. Le choix de DuckDB. Donnez deux raisons de faire les labos avec DuckDB plutôt qu'avec un serveur de base de données.
15. [labo] Où vit quoi. Dans quel dépôt Git vit `generer_boreal.py` ? Et `sources/` ? Et le code que vous écrivez dans ce cours ?
16. [labo] Relancer le générateur. Que se passe-t-il si vous relancez `generer_boreal.py` ? Comment le prouver en une seule comparaison, et quelle propriété de la formation ce comportement illustre-t-il déjà ?
17. [labo] Compter. Combien de lignes compte l'historien sur les 92 jours, et combien d'étiquettes ?
18. [labo] Le fuseau. Qu'est-ce qui manque à la colonne `Timestamp` ? Quel jour de la période cela va-t-il poser un problème concret, et lequel ?
19. Deviner juste. Pourquoi un outil qui devine juste la plupart du temps est-il plus dangereux qu'un outil qui ne devine jamais ?
 1. Le lendemain du 31 décembre. Pourquoi `MAX(ERDAT) + 1` rend-il 20251232, et comment obtenir le vrai lendemain ?
 2. Deux dates, deux types. Pourquoi DuckDB fait-il de `ERDAT` un entier et de `AEDAT` du texte, alors que les deux sont des dates SAP ?
 3. Le décalage perdu. Que perd-on quand `2025-12-15T00:25:22-05:00` devient `2025-12-15 05:25:22` ? Pourquoi est-ce plus grave pour `debut` que pour `recu_1e` ?

Questions pratiques

Ici on écrit vraiment : des commandes, du SQL. Tapez votre réponse avant de la comparer. Une requête qu'on croit connaître et qu'on n'a jamais écrite de mémoire n'est pas acquise.

P1. Le décompte par qualité. Écrivez la requête DuckDB qui compte les lignes de l'historien par code de qualité, du meilleur au pire.

P2. Les étiquettes bavardes. Écrivez la requête qui donne les cinq étiquettes qui ont le plus de points, puis celle qui donne l'étiquette qui en a le moins. Expliquez l'écart en une phrase.

P3. Ce que l'historien jette. Le SCADA lit chaque point toutes les deux minutes. Combien de lectures cela fait-il par étiquette sur 92 jours ? Comparez avec les 27 661 points de ESS.BANC.TEMP_REFROIDISSEMENT et avec les 210 points de UTL.CMP3.MARCHE. Que concluez-vous ?

P4. Le .gitignore. Écrivez le .gitignore de Projet_Boreal/01_de, avec un commentaire par entrée qui justifie l'exclusion. Dites aussi pourquoi sources/ n'y figure pas.

P5. Un compresseur à l'œil. Écrivez la requête qui affiche, pour le compresseur d'air 2, la vibration maximale de chaque jour, en ne gardant que les points de bonne qualité, triée par date. Exécutez-la. Qu'observez-vous dans la seconde moitié d'octobre ? Allez ensuite voir usine/gmao/bons_travail.csv : quels bons de travail correspondent ?

P6. Les extraits ne sont pas la base. Les extraits de l'ERP contiennent 26 538 lignes d'en-têtes de commande, pour 25 483 commandes distinctes. Écrivez la requête qui retrouve le nombre de lignes lues en trop à cause de l'extrait livré deux fois, puis expliquez d'où vient le reste de l'écart.

P7. Déclarer plutôt que deviner. Écrivez la requête qui lit sources/erp/extraits/2024-05/VBAK.csv avec toutes ses colonnes en texte, et qui donne le nombre d'en-têtes, puis la première et la dernière date de création, converties en vraies dates. Expliquez pourquoi un extrait de mai contient des commandes créées en avril.

P8. Le délai de livraison, juste. Écrivez la requête qui donne le plus court et le plus long délai entre la création d'une commande (ERDAT) et la date de livraison souhaitée (VDATU), en jours, sur tous les extraits, avec des dates correctement converties.

Diagnostics

On vous montre quelque chose qui ne va pas. Dites ce qui cloche, pourquoi, et donnez le correctif. Ces situations sont toutes arrivées à quelqu'un.

E1. Pour produire le rapport mensuel de l'énergie consommée par l'usine, un collègue a monté un flux Kafka et un tableau de bord rafraîchi à la seconde. Le rapport sort juste, mais trois services tournent jour et nuit pour un document lu une fois par mois.

E2. Un pipeline charge chaque mois tous les dossiers de erp/extraits/ et ajoute leurs lignes à celles du mois précédent. Depuis mars 2023, les ventes de ce mois-là sont doublées dans tous les rapports, et personne n'a vu d'erreur.

E3. Un apprenant a copié sources/ dans son dépôt 01_de « pour avoir une sauvegarde », et l'a versionné. Après quelques générations, dont une avec --historien complet, son dépôt a nettement gonflé, chaque clone en transporte tout l'historique, et le moindre git push traîne. Il efface le dossier et committe : le dépôt ne maigrit pas.

E4. Un collègue calcule le délai de livraison des commandes par VDATU - ERDAT, directement sur les extraits de l'ERP lus par DuckDB. La plupart des délais sont plausibles, mais 13 109 lignes dépassent 60 jours, et la commande 0010005407 affiche un délai de 8 984 jours.

Questions à développer

Ces questions ne se répondent pas en un mot : on veut un court paragraphe de raisonnement. Rédigez votre réponse avant d'ouvrir le corrigé.

A. Le métier, en vos mots. Situez l'ingénieur de données par rapport à l'ingénieur analytique, puis expliquez pourquoi la propriété « un traitement se rejoue sans rien casser » tient ensemble les quatre promesses.

B. Deux chemins pour une vibration. Décrivez ce que le chemin froid et le chemin chaud feraient, chacun, des mesures de vibration des compresseurs de Boréal. Expliquez pourquoi on garde les deux, et lequel fait référence.

C. Le brut intact. L'historien contient des lignes de qualité mauvaise sans valeur et des valeurs de qualité douteuse ; les extraits de l'ERP contiennent un mois livré deux fois. Expliquez pourquoi on charge tout cela tel quel plutôt que de le nettoyer à l'ingestion. Appuyez-vous sur au moins deux exemples tirés de Boréal.

Mises en situation

Le format le plus proche du travail réel. On vous décrit un organisme, ses données et ses contraintes ; à vous de décider et de justifier. Il n'y a pas une seule bonne réponse, mais il y a des réponses indéfendables. Le corrigé donne une solution défendable et dit ce qui serait acceptable aussi.

M1. Transport collectif des Deux-Rives. Une société de transport fictive, 240 autobus. Trois sources : les boîtiers GPS des autobus, qui transmettent leur position toutes les 10 secondes par le réseau cellulaire ; le système de perception, qui exporte chaque nuit les validations de cartes ; et les horaires planifiés, publiés chaque semaine dans un fichier standard. Trois demandes : afficher aux arrêts le retard des prochains passages ; calculer l'achalandage par ligne et par heure pour la planification ; prévoir l'achalandage de la rentrée scolaire.

Pour chaque demande, dites quel chemin elle réclame, quelles sources elle mobilise, et ce que l'ingénieur de données livre exactement. Dites aussi où s'arrête son travail.

M2. Coopérative électrique de la Rivière-aux-Saules. Une coopérative d'électricité fictive, 18 000 clients équipés de compteurs intelligents. Les compteurs mesurent la consommation toutes les 15 minutes, mais le système qui les collecte ne transmet ses lectures qu'une fois par nuit, en lot. Les douze postes de distribution, eux, sont surveillés par un SCADA. Le directeur général veut « un tableau de bord de la consommation en temps réel ».

Répondez-lui : ce qui est possible, ce qui ne l'est pas, et ce que vous proposez. Dites ce qui vous ferait changer d'avis.

M3. (avancé) L'usine de traitement. L'usine de traitement d'eau d'une grande ville veut alimenter son nouveau lac de données. Pour éviter le délai des exports de l'historien, l'équipe informatique propose de brancher le pipeline directement sur les automates des filtres et des pompes, par leur protocole industriel.

Donnez votre avis motivé, et proposez une solution qui réponde au vrai besoin, celui d'avoir la donnée plus vite.