

Table des matières

Exercices 02 — Les formats de fichiers et le lac bronze	1
Questions courtes	1
Questions pratiques	2
Diagnostics	3
Questions à développer	3
Mises en situation	3

Exercices 02 — Les formats de fichiers et le lac bronze

Comment travailler ces exercices. Répondez seul, puis vérifiez avec le corrigé. Les exercices marqués [labo] portent sur ce que vous venez de faire au labo ; les autres vérifient que le cours est clair dans votre tête. Tout vient de la Théorie 02 et du Labo 02.

Le corrigé est dans `Corrige_02.md`. Répondez à l'énoncé en entier avant de l'ouvrir : c'est en butant sur une question qu'on découvre ce qu'on avait lu sans le comprendre.

Questions courtes

1. Ligne ou colonne. Pour chaque usage, dites quel stockage convient : (a) l'ERP qui enregistre une commande ; (b) la vibration moyenne par étiquette sur deux ans ; (c) le portail qui met à jour le statut d'une réclamation ; (d) le total des ventes par gamme et par mois.
2. Deux colonnes sur quatre. Une requête ne lit que `TagName` et `Value`. Donnez deux raisons pour lesquelles elle va plus vite sur un format en colonnes.
3. Échange ou stockage. Pourquoi le CSV reste-t-il le format d'export de tant de systèmes, alors qu'il fait un mauvais format de lac ?
4. Avro ou Parquet. Lequel convient à un flux d'événements écrits un à un, lequel à un lac analytique, et pourquoi ?
5. Les trois niveaux. Nommez les trois niveaux d'un fichier Parquet, et dites à quoi sert chacun.
6. Le pied de page. Que contient le pied de page d'un fichier Parquet, et pourquoi un moteur le lit-il avant le reste ?
7. Encodage et compression. Quelle est la différence ? Donnez un exemple de chacun sur l'historien.
8. Snappy ou zstd. Sur l'historien en un seul fichier, snappy donne 1,8 Mo et zstd 1,2 Mo. Qu'est-ce qui pourrait faire choisir snappy malgré tout ?

9. Projection et prédicat poussé. Définissez l'un et l'autre en une phrase.
 10. Des statistiques inutiles. Pourquoi le minimum et le maximum de `TagName` ne font-ils sauter aucun groupe de lignes dans un fichier quotidien de l'historien ? Que faudrait-il changer ?
 11. La règle du bronze. Énoncez-la en une phrase. Quel type reçoivent `Timestamp` dans l'historien et `recu_1e` dans la télémétrie, et pourquoi pas le même ?
 12. Le montant. Pourquoi un montant ne se range-t-il jamais en `DOUBLE` ?
 13. Le stockage objet. Nommez deux différences entre un stockage objet et un disque qui changent la façon de ranger un lac.
 14. L'élagage. Qu'est-ce que l'élagage des partitions, et en quoi va-t-il plus loin que le prédicat poussé ?
 15. La clé de partition. Donnez les trois critères du choix d'une clé, et appliquez-les à l'historien de Boréal.
 16. Les petits fichiers. Pourquoi 843 fichiers de 13 Ko se lisent-ils plus lentement qu'un seul fichier de même contenu ? Comment s'appelle le remède ?
 17. [labo] Le jour livré. Dans quelle partition du bronze vivent les valeurs de départ datées du 30 septembre 2025 ? Pourquoi ce choix prépare-t-il le Cours 03 ?
 18. [labo] Les dossiers. Que répond DuckDB si `plateforme/lac/bronze/usine/` n'existe pas au moment du `COPY`, et que faut-il en retenir ?
 19. [labo] Relancer. Que se passe-t-il si vous relancez `bronze_historien.sql` ? Et si vous retirez `OVERWRITE` avant de le relancer ?
 20. [labo] Les mesures. Donnez la taille de l'historien en CSV et dans le bronze, et le nombre de fichiers que lit une requête filtrée sur `jour = DATE '2025-10-28'`.
1. [labo] Une seule colonne json. Pourquoi `read_json('sources/telemetry/*.jsonl')` ne donne-t-il qu'une colonne json, et quelles sont les deux façons de l'éviter ?
 2. [labo] Deux températures. Pourquoi le bronze de la télémétrie garde-t-il `temp_moteur_max` et `temperature_moteur_max` en deux colonnes, au lieu de les réunir ?

Questions pratiques

Ici on écrit vraiment : des commandes, du SQL. Tapez votre réponse avant de la comparer. Une requête qu'on croit connaître et qu'on n'a jamais écrite de mémoire n'est pas acquise.

P1. Le pied de page d'un jour. Écrivez la requête qui affiche, pour la partition du 2025-10-28, le nombre de lignes du groupe et le minimum et le maximum de `Timestamp`, sans lire les données. Expliquez le minimum.

P2. Le poids de chaque colonne. Pour la même partition, écrivez la requête qui donne la taille compressée et non compressée de chaque colonne. Quelle colonne pèse le plus, laquelle le moins, et pourquoi ?

P3. Filtrer sur la partition ou sur l'horodatage. Écrivez deux requêtes `EXPLAIN ANALYZE` qui comptent les lignes du 1er octobre 2025 dans le bronze de l'historien : l'une filtre jour, l'autre filtre `Timestamp`. Combien de fichiers chacune lit-elle ? Les deux rendent 3 714 lignes : sont-ce les mêmes ? Prouvez-le par une requête.

P4. Trier pour que les statistiques servent. Créez un dossier `essais` dans `Projet_Boreal`, puis écrivez le `COPY` qui range tout le bronze de l'historien dans un seul fichier `zstd, essais/historien_trie.parquet`, trié par étiquette puis par horodatage. Lisez les statistiques de `TagName` dans ses groupes de lignes : combien de groupes une requête sur `UTL.CMP2.VIBRATION` doit-elle lire ? Comparez la taille du fichier à celle d'un fichier non trié (1,2 Mo, Théorie 02) et expliquez l'écart.

P5. Compacter la télémétrie. Écrivez le `COPY` qui compacte le bronze de la télémétrie dans un seul fichier `zstd, essais/telemetry_compacte.parquet`. Comparez sa taille à celle des 843 fichiers, puis le temps d'un `COUNT(DISTINCT message.sennr)` sur l'un et sur l'autre.

Diagnostics

On vous montre quelque chose qui ne va pas. Dites ce qui cloche, pourquoi, et donnez le correctif. Ces situations sont toutes arrivées à quelqu'un.

E1. Un script d'équipe régénère les sources avec `--historien complet` pour préparer une étude annuelle, puis lance l'étude sur le bronze de l'historien. Aucune erreur. L'étude ne montre pourtant que trois mois.

E2. Pour « tout rendre filtrable », une collègue partitionne le bronze de l'historien par étiquette et par jour : `etiquette=.../jour=.../`. Le lac compte maintenant des milliers de fichiers minuscules, et une requête sur un mois entier est devenue plus lente qu'avant.

Questions à développer

Ces questions ne se répondent pas en un mot : on veut un court paragraphe de raisonnement. Rédigez votre réponse avant d'ouvrir le corrigé.

A. D'où vient la vitesse. Sur l'historien, la même requête prend environ 3 secondes sur les CSV aux types devinés, 0,6 seconde aux types déclarés, et 0,016 seconde sur le bronze. Expliquez ce que chaque écart doit à la détection des types, à la lecture en texte et au format en colonnes.

B. Défendre la règle du bronze. Un collègue veut « tout typer dès le bronze pour faciliter la vie de l'ingénieur analytique » : dates SAP converties, horodatages ramenés à UTC, codes en entiers. Répondez-lui, avec au moins deux exemples tirés de Boréal.

C. Une partition pour les extraits de l'ERP. Les extraits mensuels de l'ERP seront chargés au Cours 03. Proposez une façon de les ranger s'ils passaient par le bronze, en appliquant les trois critères du choix d'une clé, et dites ce que devient l'extrait `2023-03_bis`.

Mises en situation

Le format le plus proche du travail réel. On vous décrit un organisme, ses données et ses contraintes ; à vous de décider et de justifier. Il n'y a pas une seule bonne réponse, mais il y a des réponses indéfendables. Le corrigé donne une solution défendable et dit ce qui serait acceptable aussi.

M1. Transport collectif des Deux-Rives, le bronze. Les 240 autobus de la société transmettent leur position toutes les 10 secondes, en JSON : jusqu'à deux millions de messages par jour, qu'un service écrit toutes les cinq minutes dans un nouveau fichier. Les analystes interrogent surtout par date et par ligne d'autobus ; la planification relit une année entière chaque automne.

Choisissez le format, la compression, la clé de partition et la taille des fichiers du bronze, et dites ce qu'il faut faire des fichiers écrits toutes les cinq minutes.

M2. Coopérative électrique de la Rivière-aux-Saules, le bronze. Chaque nuit, le système de collecte livre un CSV des lectures de la veille : 18 000 compteurs, une lecture aux 15 minutes, l'heure de fin d'intervalle avec son décalage à UTC, l'énergie en kWh avec trois décimales, et un code de qualité (R réel, E estimé).

Décrivez le bronze de ces lectures : le type de chaque colonne, la clé de partition, et ce qui pourrait mal tourner si l'on laissait l'outil deviner.

M3. (avancé) Le lac de Boréal dans le nuage. La direction de Boréal veut déplacer le lac dans un stockage objet, facturé à la requête et à l'octet lu. Le bronze compte aujourd'hui 92 fichiers pour l'historien et 843 pour la télémétrie, et la télémétrie grossit d'un fichier par jour. Les analystes lisent surtout les trente derniers jours ; la science des données relit tout chaque semaine.

Proposez une organisation du bronze qui tienne compte du coût, et un plan de compactage. Dites ce qui vous ferait changer d'avis.