

Table des matières

Exercices 03 — Charger des fichiers dans la couche RAW.....	1
Questions courtes	1
Questions pratiques	2
Diagnostics	2
Questions à développer	3
Mises en situation.....	3

Exercices 03 — Charger des fichiers dans la couche RAW

Comment travailler ces exercices. Répondez seul, puis vérifiez avec le corrigé. Les exercices marqués [labo] portent sur la RAW que vous venez de charger ; les autres vérifient que le cours est clair dans votre tête. Tout vient de la Théorie 03 et du Labo 03.

Le corrigé est dans `Corrige_03.md`. Répondez à l'énoncé en entier avant de l'ouvrir : c'est en butant sur une question qu'on découvre ce qu'on avait lu sans le comprendre.

Questions courtes

1. Les trois voies. Nommez les trois façons d'extraire vues au cours, avec la source de Boréal qui sert d'exemple à chacune.
2. Complet ou incrémental. Donnez un avantage et un inconvénient de chaque forme de chargement.
3. Un extrait n'est pas la base. Pourquoi les extraits de l'ERP comptent-ils 26 538 en-têtes de commande alors que la base en compte 25 483 ?
4. Les données maîtres. Les extraits livrent KNA1 en entier chaque mois. Pourquoi la RAW en garde-t-elle 7 481 lignes plutôt que 156 ?
5. Idempotence. Définissez-la en une phrase, et dites pourquoi un pipeline en a besoin plus qu'un script lancé une seule fois.
6. Trois stratégies. Remplacer, fusionner, tenir un journal : donnez un cas de Boréal pour chacune.
7. L'empreinte. À quoi sert le SHA-256 dans le journal des chargements, et que se passe-t-il quand un fichier revient avec la même empreinte ?
8. Le fichier corrigé. Un export complet revient sous le même nom, avec un contenu différent. Que fait le chargeur, étape par étape ?
9. La transaction. Pourquoi le chargement d'un fichier et sa ligne au journal s'écrivent-ils dans la même transaction ?

10. Le lot. Que vaut `_lot` pour un extrait de l'ERP, pour un jour de télémétrie et pour la GMAO ?
11. Trois colonnes de lignage. Nommez-les et donnez, pour chacune, une question à laquelle elle permet de répondre.
12. Tout en texte. Donnez deux colonnes de Boréal qu'un type deviné abîmerait, et dites ce qu'elles deviennent dans la RAW.
13. Le champ vide. Que devient un champ vide d'un CSV dans la RAW, et pourquoi ce choix plutôt que la chaîne vide ?
14. Bronze et RAW. Les deux gardent le brut. Qu'est-ce qui les distingue, et où vit la télémétrie ?
15. [labo] Le second passage. Qu'affiche le chargeur quand on le relance sans rien changer, et pourquoi ?
16. [labo] Le verrou. Que répond le chargeur si la ligne de commande DuckDB est encore ouverte, et pourquoi cette règle existe.
17. [labo] Le corpus. Pourquoi les documents se déposent-ils tels quels dans le bronze au lieu d'entrer dans des tables, et que devient le catalogue ?

Questions pratiques

Ici on écrit vraiment : des requêtes, des commandes. Tapez votre réponse avant de la comparer. La RAW doit être chargée ; les requêtes DuckDB se lancent depuis `Projet_Boreal`, après `ATTACH IF NOT EXISTS 'plateforme/entrepot/boreal.duckdb' AS entrepot (READ_ONLY); USE entrepot;`

- P1. Le journal d'un mois. Écrivez la requête qui donne, pour le lot 2024-05, la liste des fichiers chargés avec leur nombre de lignes, triée par table. Combien de fichiers, et combien de lignes en tout ?
- P2. Les lots d'une table. Écrivez la requête qui compte les lots de `raw.garanties_clients`, donne le premier et le dernier, et le nombre de lignes du lot 2025-09.
- P3. L'état courant des clients. Écrivez la requête qui garde, pour chaque `client_id`, sa version du lot le plus récent, et qui compte les clients obtenus. Comparez ce nombre au nombre de lignes de la table, et expliquez l'écart.
- P4. Le doublon de mars 2023. Écrivez la requête qui prouve que les lignes du lot 2023-03_bis sont exactement celles du lot 2023-03, colonnes de lignage exclues.
- P5. Les doublons de la télémétrie. Écrivez la requête qui compte les identifiants de message reçus plus d'une fois, et le nombre de messages en trop. Retrouvez-vous les 2 303 doublons annoncés par le générateur ?
- P6. Les tables les plus lourdes. Écrivez la requête qui donne les cinq tables de la RAW qui comptent le plus de lignes, d'après le journal des chargements.

Diagnostics

On vous montre quelque chose qui ne va pas. Dites ce qui cloche, pourquoi, et donnez le correctif. Ces situations sont toutes arrivées à quelqu'un.

E1. Un collègue charge les extraits sans journal, avec un `INSERT` par fichier lancé depuis un script qu'il relance quand il a un doute. `raw.erp_vbak` compte 53 076 lignes pour 25 483 commandes, et les rapports de ventes donnent le double du chiffre d'affaires réel.

E2. Une collègue trouve que le journal devrait reconnaître un fichier à son empreinte plutôt qu'à son chemin, pour attraper `2023-03_bis`. Elle change le chargeur en ce sens. Le chargement passe, mais `raw.erp_t005u` ne compte plus que 20 lignes, toutes au lot `2022-01`, et l'ingénieur analytique signale que sa table des régions est vide quand il filtre sur le dernier lot.

Questions à développer

Ces questions ne se répondent pas en un mot : on veut un court paragraphe de raisonnement. Rédigez votre réponse avant d'ouvrir le corrigé.

A. Défendre le doublon. Le responsable des ventes découvre que la RAW contient deux fois les commandes de mars 2023 et demande qu'on les retire « à la source ». Répondez-lui : ce que la RAW garantit, ce qui arrive si on la corrige, et qui règle le problème, où.

Mises en situation

Le format le plus proche du travail réel. On vous décrit un organisme, ses données et ses contraintes ; à vous de décider et de justifier. Il n'y a pas une seule bonne réponse, mais il y a des réponses indéfendables. Le corrigé donne une solution défendable et dit ce qui serait acceptable aussi.

M1. Coopérative forestière des Hautes-Terres. Chaque nuit, six scieries déposent sur un serveur de fichiers un export de leur production de la veille, nommé `production_<scierie>_AAAA-MM-JJ.csv`. Il arrive qu'une scierie redépose un fichier corrigé le lendemain, sous le même nom, et qu'une autre dépose deux fois le même fichier sous deux noms, avec un suffixe `_v2`. Les analystes veulent l'état juste de chaque journée, et la direction veut savoir ce qui a été corrigé.

Décrivez le chargement : la clé du journal, la règle du lot, ce qui entre dans la RAW, et le contrôle qui signale les redépôts.