

Table des matières

Exercices 04 — Lire une base et une API	1
Questions courtes	1
Questions pratiques	2
Diagnostics	2
Questions à développer	2
Mises en situation	3

Exercices 04 — Lire une base et une API

Comment travailler ces exercices. Répondez seul, puis vérifiez avec le corrigé. Les questions courtes vérifient que le cours est clair dans votre tête ; les questions pratiques se font sur la base de l'ERP démarrée et sur la RAW du Cours 03. Tout vient de la Théorie 04 et du Labo 04.

Le corrigé est dans `Corrige_04.md`. Répondez à l'énoncé en entier avant de l'ouvrir : c'est en butant sur une question qu'on découvre ce qu'on avait lu sans le comprendre.

Questions courtes

1. Tirer ou recevoir. Qu'est-ce qui distingue une source qui pousse d'une source qu'on tire, et quelle responsabilité chacune laisse au pipeline ?
2. ODBC. Nommez les quatre pièces qui se passent une requête, de votre script jusqu'à la base.
3. Le pilote comme contrat. Qu'est-ce qui change dans votre code si la base passe de PostgreSQL à SQL Server ?
4. Lire sans nuire. Donnez trois précautions à prendre avant d'extraire d'une base de production.
5. Le filigrane. Qu'est-ce qu'un filigrane, et pourquoi AEDAT seul ne suffit-il pas chez Boréal ?
6. Les angles morts. Citez deux choses qu'une capture par filigrane ne voit pas, et ce qu'on fait pour chacune.
7. Les documents de modification. Que gardent CDHDR et CDPOS que la table KNA1 ne garde pas ?
8. Le journal de la base. Qu'apporte la capture par journal que les deux autres méthodes n'ont pas, et que demande-t-elle en retour ?
9. La pagination. Dites ce que valent `numberMatched` et `numberReturned` dans une réponse de l'API d'ECCC, et comment on sait qu'il reste des pages.

10. Réessayer ou pas. Pour chacun de ces codes, dites s'il faut réessayer : 400, 429, 500, et une coupure du réseau sans code.

11. La temporisation exponentielle. Expliquez le principe, et dites pourquoi on borne le nombre d'essais.

Questions pratiques

Ici on écrit vraiment : des requêtes, des commandes. Tapez votre réponse avant de la comparer. Les requêtes DuckDB se lancent depuis `Projet_Boreal`, après `ATTACH IF NOT EXISTS 'plateforme/entrepot/boreal.duckdb' AS entrepot (READ_ONLY); USE entrepot; ;` celles de la base, dans `psql` ; le script de l'API, depuis `01_de`.

P1. Le filigrane de juillet 2024. Écrivez la requête qui compte, dans l'état reconstruit de VBAK, les commandes créées ou modifiées en juillet 2024, puis celle qui compte les lignes du lot 2024-07. Les deux nombres doivent concorder.

P2. Une requête sur la base. Dans `psql`, écrivez la requête qui donne, pour chaque concessionnaire fermé (LOEVM non vide), son numéro, son nom et sa province. Combien y en a-t-il ?

P3. Les paliers révisés. Dans `psql`, écrivez la requête qui compte les concessionnaires par ancien et par nouveau palier, pour la révision du 2024-07-01 : le champ KUKLA de `sap.cdpos`, daté par `sap.cdhdr`. Combien sont montés d'un palier, combien sont descendus ? Le dictionnaire de Boréal donne le sens des codes.

P4. La taille de page. Dans `extraire_meteo_api.py`, passez PAGE de 50 à 100, relancez le script, puis remettez 50. Combien de pages le script lit-il, et le fichier du bronze change-t-il ? Pourquoi ne pas toujours demander la plus grande page que l'API accepte ?

Diagnostics

On vous montre quelque chose qui ne va pas. Dites ce qui cloche, pourquoi, et donnez le correctif. Ces situations sont toutes arrivées à quelqu'un.

E1. Un pipeline extrait chaque nuit les commandes modifiées depuis la veille, avec le filtre `aedat >= <filigrane>`. Les rapports mensuels tombent juste, mais le tableau de bord des nouvelles commandes reste désespérément vide.

E2. Un script d'extraction ODBC lit une table de 40 millions de lignes avec `fetchall()`, puis écrit le résultat dans un CSV. Il tourne sur le poste d'un collègue, où il finit par échouer avec une erreur de mémoire ; sur le serveur, il fait tomber les temps de réponse de l'ERP pendant vingt minutes.

Questions à développer

Ces questions ne se répondent pas en un mot : on veut un court paragraphe de raisonnement. Rédigez votre réponse avant d'ouvrir le corrigé.

A. Choisir une capture de changements. Pour chacune de ces trois sources, dites quelle méthode de capture vous retiendriez et pourquoi : les commandes de l'ERP, les fiches des concessionnaires, et une table de stocks mise à jour toutes les minutes par un automate, où les lignes se suppriment.

B. Le coût d'une extraction. Un collègue propose de remplacer les extraits mensuels de l'ERP par une extraction ODBC complète chaque nuit, « pour avoir toujours l'état courant ». Évaluez la proposition : ce qu'elle apporte, ce qu'elle coûte, ce qu'elle perd.

Mises en situation

Le format le plus proche du travail réel. On vous décrit un organisme, ses données et ses contraintes ; à vous de décider et de justifier. Il n'y a pas une seule bonne réponse, mais il y a des réponses indéfendables. Le corrigé donne une solution défendable et dit ce qui serait acceptable aussi.

M1. Portail des permis de la Ville de Rivière-Blanche. La ville publie une API REST des permis émis, paginée par curseur (chaque réponse porte un jeton suivant), plafonnée à 500 permis par page et limitée à 1 000 requêtes par heure, avec une réponse 429 au-delà. L'historique compte 900 000 permis, et 300 s'ajoutent chaque jour.

Décrivez l'extraction initiale, puis l'extraction quotidienne : ce que vous gardez entre deux exécutions, comment vous respectez la limite, et comment vous prouvez qu'il ne manque rien.

M2. (avancé) Assurances Val-Perdu. Leur base de polices, dans Oracle, pèse 400 Go, dont une table de mouvements de 2 milliards de lignes. La fenêtre d'extraction nocturne est de deux heures, les polices résiliées sont supprimées de la table des polices, et l'équipe d'exploitation refuse tout accès au journal de transactions « pour des raisons de sécurité ».

Proposez une stratégie d'ingestion complète : méthode de capture, fréquence, ce que vous demandez à l'équipe de l'ERP, et ce que vous faites des suppressions. Dites ce qui vous ferait changer d'avis.