

Table des matières

Exercices 06 — Orchestration avec Airflow	1
Questions courtes	1
Questions pratiques	2
Diagnostics	3
Questions à développer	3
Mises en situation	3

Exercices 06 — Orchestration avec Airflow

Comment travailler ces exercices. Répondez seul, puis vérifiez avec le corrigé. Les exercices marqués [labo] portent sur les deux DAG et sur la fenêtre que vous venez d'écrire ; les autres vérifient que le cours est clair dans votre tête. Tout vient de la Théorie 06 et du Labo 06.

Le corrigé est dans `Corrige_06.md`. Répondez à l'énoncé en entier avant de l'ouvrir : c'est en butant sur une question qu'on découvre ce qu'on avait lu sans le comprendre.

Questions courtes

1. Le partage du travail. Nommez trois choses qu'un ordonnanceur fait, et deux qu'il ne fait pas.
2. Sans cycle. Pourquoi un graphe de tâches doit-il être acyclique ? Que ne pourrait-on plus faire si une flèche revenait en arrière ?
3. Ce qu'une flèche dit. Une flèche va de `bronze` vers `raw`. Donnez deux affirmations qu'elle garantit, et deux qu'on lui prête à tort.
4. Les deux temps. Une exécution du DAG mensuel porte la date du premier février 2026 et tourne le 16 septembre 2026. Lequel des deux est l'intervalle de données, et lequel n'a aucune importance pour le contenu chargé ?
5. `{{ ds }}`. Que vaut cette valeur pour l'exécution du 15 mars du DAG quotidien, rejouée aujourd'hui ?
6. Trois mois de retard. Un DAG mensuel démarre avec une date de début remontant à trois mois. Combien d'exécutions l'ordonnanceur crée-t-il, et dans quel ordre les lance-t-il ?
7. La borne de fin. Un DAG mensuel doit couvrir janvier, février et mars 2026. À quelle date faut-il poser sa borne de fin, et qu'arrive-t-il si on la pose au premier avril ?

8. Deux filtres. La fenêtre et le journal des chargements écartent tous deux des fichiers. Qu'est-ce que chacun regarde, et pourquoi la fenêtre passe-t-elle en premier ?
9. Ce qui n'a pas de date. Le lot d'un export livré en entier vaut « complet ». Pourquoi la fenêtre le laisse-t-elle passer dans toutes les tranches, plutôt que de l'écarter ?
10. Une relivraison. Le lot 2023-03_bis tombe-t-il dans une fenêtre du mois de mars 2023 ? Pourquoi ce choix, plutôt que l'inverse ?
11. Trois idempotences. Nommez les trois mécaniques qui rendent le pipeline de Boréal rejouable, et dites ce que chacune garantit.
12. Le bronze non fenêtré. Pourquoi l'étape bronze reconstruit-elle tout à chaque passage au lieu de se limiter à la journée de l'exécution ?
13. Rater, tarder, attendre. Associez chacune de ces trois situations à sa réponse : la nouvelle tentative, l'alerte de retard, le capteur.
14. Les SLA. Un tutoriel trouvé en ligne montre `sla=timedelta(minutes=30)` sur une tâche. Que faut-il en faire avec Airflow 3, et par quoi se remplace-t-il ?
15. Le pool. Qu'est-ce qu'un pool protège, que le nombre d'exécutions simultanées d'un DAG ne protège pas ?
16. La tâche vide. `dbt_build` ne fait rien. Donnez deux raisons de la poser quand même.

Questions pratiques

1. [labo] Une seule journée. Écrivez la commande qui charge la télémétrie du 2 février 2026, et rien d'autre. Dites combien de fichiers vous attendez.
1. [labo] Un trimestre d'un coup. Écrivez la commande qui charge l'ERP et les garanties du premier trimestre 2026 en une seule exécution, sans passer par Airflow.
2. [labo] Le profil des exécutions. Écrivez la requête qui donne, pour chaque lot de 2026, le nombre de fichiers chargés et le total des lignes, du plus ancien au plus récent.
3. [labo] La preuve, retournée. Sans relancer le pipeline, écrivez la requête qui vérifie qu'aucun fichier n'a été chargé deux fois sous la même empreinte dans la table des chargements.
4. [labo] Un DAG hebdomadaire. Écrivez la déclaration d'un DAG qui tournerait chaque lundi sur la semaine écoulée, avec la fenêtre correspondante. Les deux bornes doivent venir de la date logique de l'exécution.
5. [labo] La météo fenêtrée. L'étape `meteo` ignore la fenêtre et lit ses dates dans `config.toml`. Décrivez le changement qui la brancherait sur la fenêtre, et ce qu'il faudrait vérifier avant.
6. [labo] Un capteur. Le DAG mensuel ne devrait démarrer que si l'extrait `VBAK.csv` du mois est déposé. Nommez la tâche qui ferait cette attente, et dites où elle se placerait dans le graphe.

7. [labo] Le pool en action. Sans toucher aux DAG, écrivez la commande qui montre que le pool entrepot n'a qu'une place, puis celle qui lui en donnerait deux. Dites ce qui se passerait alors.

Diagnostics

1. Une collègue écrit `bash_command="python -m pipeline raw --depuis $(date +%F) --jusqua $(date +%F)"`. Le DAG tourne, ne rate jamais, et pourtant le rattrapage des trois mois a tout mis dans le même lot. Que s'est-il passé ?
2. Un DAG mensuel a `catchup=True` et une date de début au premier janvier 2022. À la première mise en route, l'ordonnanceur crée cinquante et une exécutions qui se bousculent. Deux choses sont à corriger, lesquelles ?
3. La tâche `raw` du DAG quotidien échoue une fois sur trois avec `Could not set lock on file ... Conflicting lock is held`. Elle passe toujours au second essai. Pourquoi la nouvelle tentative ne suffit-elle pas comme réponse ?
4. Un DAG n'apparaît pas dans l'interface, et le dossier `dags/` contient bien son fichier. L'auteur jure que le fichier est correct. Où regardez-vous, et dans quel ordre ?
5. Après avoir ajouté `--livraisons erp,garanties` au DAG mensuel, un ingénieur constate que la télémétrie de 2026 n'est plus chargée du tout. Il en conclut que la fenêtre est cassée. Où est l'erreur de raisonnement ?
6. Le DAG quotidien met cinq minutes de plus que d'habitude, et se termine vert. Les journaux de la tâche `corpus` ne montrent rien d'anormal. Où est passée la différence ?

Questions à développer

- A. L'intervalle de données est présenté comme la notion la plus mal comprise d'Airflow. Expliquez pourquoi l'erreur qu'il cause est plus dangereuse qu'une panne, et proposez deux habitudes de travail qui la rendent improbable.
- B. Le rattrapage est vérifié dans ce cours par une comparaison ligne par ligne avec un chargement d'un bloc. Un collègue trouve cela excessif, et propose de comparer seulement les comptes de lignes. Qu'est-ce que sa méthode laisserait passer ? Construisez un cas concret.
- C. Le pipeline de Boréal porte trois mécaniques d'idempotence. Un architecte propose de n'en garder qu'une, la fenêtre, « pour simplifier ». Défendez ou attaquez cette proposition, en disant ce qu'on perdrait précisément dans chaque cas.

Mises en situation

1. Chez Boréal, l'équipe de l'usine veut son propre DAG, qui écrira dans l'entrepôt toutes les quinze minutes. On vous demande votre avis avant qu'ils l'écrivent. Que soulevez-vous, et que proposez-vous ?

2. Une panne de trois jours a arrêté les conteneurs. À la reprise, on vous demande s'il faut recharger à la main ou laisser l'ordonnanceur faire. Que répondez-vous, et sur quoi vous appuyez-vous pour en être sûr ?
3. Un ingénieur d'une équipe voisine vous montre son DAG : quinze tâches, toutes en ligne, une flèche entre chacune. Il trouve que « ça se lit bien ». Que regardez-vous avant de lui répondre, et que lui dites-vous ?
4. La direction demande une alerte « dès que le chargement est en retard ». Le chargement quotidien prend d'ordinaire huit minutes, mais il a déjà pris quarante minutes un lundi de mars sans conséquence. Comment choisissez-vous le délai, et que répondez-vous si on vous demande de le mettre à dix minutes ?
5. Six mois après ce cours, la formation Analytics Engineering est terminée et la tâche `dbt_build` doit être remplie. On vous demande si elle doit rester dans le DAG quotidien ou vivre dans un DAG à elle. Donnez les deux options, leurs conséquences, et votre recommandation.