

Table des matières

Exercices corrigés 08 — Données de terrain : SCADA, historien et séries temporelles	1
Questions courtes	1
Questions pratiques	2
Diagnostics	3
Questions à développer	3
Mises en situation	4
Corrigé	5

Exercices corrigés 08 — Données de terrain : SCADA, historien et séries temporelles

Comment travailler ces exercices. Répondez seul, puis vérifiez avec le corrigé. Les exercices marqués [labo] portent sur les requêtes que vous venez d'écrire et sur les chiffres que vous avez sous les yeux ; les autres vérifient que le cours est clair dans votre tête. Tout vient de la Théorie 08 et du Labo 08.

Les chiffres à retrouver. Plusieurs énoncés demandent une mesure faite pendant le labo. Le script `01_de/sql/diagnostic_usine.sql` les rejoue tous d'un trait, depuis `Projet_Boreal` : lancez-le plutôt que de refaire les requêtes une à une.

Le corrigé suit les énoncés, en fin de document. Répondez à l'énoncé en entier avant d'y passer : c'est en butant sur une question qu'on découvre ce qu'on avait lu sans le comprendre.

Questions courtes

1. La bande morte. Expliquez en deux phrases ce qu'elle fait, puis dites pourquoi elle rend impossible le calcul d'une moyenne horaire par une moyenne simple des points.
2. La valeur de départ. Dites ce qu'elle est, où elle se trouve, et ce qui arrive à qui charge tous les fichiers quotidiens sans la reconnaître.
3. Trente et un. L'historien devrait porter 10 556 points d'archivage de minuit et n'en porte que 10 525. Expliquez l'écart, et dites ce qu'il apprend sur la fiabilité de ce mécanisme.
4. Les trois codes. Donnez le sens de 192, 64 et 0, et dites lequel arrive sans valeur.
5. Dix-huit. Une coupure de communication chez Boréal fait perdre 18 points au même instant. D'où vient ce nombre, et qu'est-ce qu'il vous dit sur la nature de la panne ?

6. Deux jours par an. Dites ce qui arrive aux horodatages de l'historien le premier dimanche de novembre et le deuxième dimanche de mars, et pourquoi les deux cas demandent des remèdes différents.
7. Fin d'intervalle. Le compteur horodate ses relevés à la fin de l'intervalle mesuré. Donnez trois conséquences concrètes de cette convention.
8. La frontière. Dites pourquoi un pipeline de données ne se branche pas sur le réseau de contrôle, et nommez deux façons d'obtenir quand même les données.
9. Pondérer. Expliquez en deux phrases pourquoi une moyenne simple est fautive sur une série à bande morte, et dites par quoi on pondère.
10. Trois natures. Donnez la règle horaire d'une mesure, d'un état de marche et d'un compteur cumulatif, et dites d'où vient l'information qui permet de les distinguer.
11. La couverture. Une heure de l'argent porte 900 secondes de couverture. Dites ce que cela signifie, et ce qu'un consommateur de la série doit en faire.
12. L'agrégat continu. Dites pourquoi il ne peut pas calculer lui-même une moyenne pondérée par le temps, et ce qu'il faut lui préparer pour qu'il y arrive.

Questions pratiques

1. [labo] Les points qui comptent. Écrivez la requête qui donne, pour le 2025-10-28, le nombre de points de mesure par zone, valeurs de départ exclues. Dites ce que vous attendez comme ordre de grandeur, et pourquoi ce jour-là n'est pas un jour comme les autres.
2. [labo] Les zones aveugles. Écrivez la requête qui liste les instants où une zone entière a perdu ses points, avec le nom de la zone et le nombre de points perdus, triés du plus grave au moins grave.
3. [labo] Une heure sans rien. Écrivez la requête qui rend, pour l'étiquette UTL.AIR.PRESSION, les heures du mois d'octobre 2025 qui ne portent aucun point. Dites ce que vous attendez, sachant que l'historien garantit au moins un point par heure.
4. [labo] La maintenance, dans l'ordre. Écrivez la requête qui donne les dix derniers bons correctifs, du plus récent au plus ancien, avec leur équipement et leur durée d'intervention en heures. Attention au type des deux colonnes de dates.
5. [labo] La facture du mois. Écrivez la requête qui donne l'énergie consommée en octobre 2025, selon les deux conventions de bornage, et l'écart entre les deux.
6. [labo] L'autre compresseur. Reprenez la requête de la vibration en marche, et appliquez-la au compresseur 1 sur la même période. Dites ce que la comparaison des deux séries apporte au diagnostic.
7. [labo] La disponibilité du compresseur. Écrivez la requête qui donne, sur l'argent, la part d'heure en marche du compresseur 2, jour par jour, du 20 au 31 octobre 2025. Dites ce que la colonne valeur d'un état de marche représente.
1. [labo] Les heures de pointe. Écrivez la requête qui donne les dix heures où l'usine a le plus consommé, avec leur énergie et le jour de la semaine, et dites ce que le résultat apprend.

2. [labo] Le contrôle qui manquerait. Écrivez la requête qui vérifie que chaque étiquette de l'argent porte bien 4 368 heures, ni plus ni moins, et expliquez pourquoi ce compte-là est le bon malgré les deux changements d'heure.

Diagnostics

1. Un collègue charge les 182 fichiers de l'historien dans une table et annonce fièrement « 550 087 mesures sur la période ». Son tableau de bord affiche une moyenne de vibration par étiquette. Qu'est-ce qui est faux, et de combien ?
2. Un contrôle de complétude vérifie que chaque étiquette porte au moins 24 points par jour, un par heure. Il passe toute l'année, sauf un dimanche de mars où il lève une alerte sur les 58 étiquettes. Expliquez, puis proposez un contrôle qui ne se trompe pas.
3. Une analyste calcule la disponibilité d'un équipement en remplaçant par zéro les valeurs manquantes de son état de marche. Dites ce que son chiffre vaut, et ce qu'elle aurait dû faire des 529 points de qualité mauvaise.
4. Une ingénieure déclare une clé primaire sur (TagName, Timestamp) dans la table cible, et son chargement échoue une fois par an. Expliquez, et donnez deux façons de régler le problème, avec ce que chacune coûte.
5. Un détecteur de capteurs figés tourne chaque semaine et ne signale rien pendant onze mois. En janvier, il signale cinq capteurs morts sur la ligne des motomarines. Personne n'a touché à l'usine. Que s'est-il passé, et comment corrigez-vous le détecteur ?
6. Une ingénieure calcule la moyenne horaire avec `AVG(valeur)` dans un agrégat continu, et compare son résultat au vôtre. Les deux diffèrent sur un tiers des heures, et l'écart monte à plusieurs milliers sur le régime du banc d'essai. Elle conclut que votre calcul a un défaut. Que répondez-vous, et comment le prouvez-vous en une requête ?
7. Un collègue écrit le rééchantillonnage sans borner le dernier point de chaque étiquette. Les comptes tombent justes sur les cinq premiers mois, et la dernière journée manque 180 heures sur les 22 étiquettes les plus lentes. Expliquez, puis donnez la correction et ce qu'elle suppose.

Questions à développer

- A. L'historien jette des données à l'écriture, et personne ne peut les récupérer ensuite. Défendez ce choix d'ingénierie, puis dites ce qu'il coûte à qui doit analyser ces séries dix ans plus tard, et ce qu'on peut faire pour en limiter le prix.
- B. Un fournisseur vous propose de brancher votre pipeline directement sur le serveur OPC UA de l'usine, ce qui vous ferait gagner une journée de délai sur les données. Écrivez la réponse que vous donneriez à votre directeur, en nommant ce que vous protégez et ce que vous proposez à la place.
- C. Le labo montre que le nombre de points d'une étiquette est un signal en soi : la pression passe de 89 points par jour à 265 pendant la dérive. Expliquez le mécanisme, dites ce qu'on peut en faire en surveillance, et donnez deux cas où ce signal induirait en erreur.
- D. Le cours calcule la même série horaire deux fois, dans un entrepôt analytique et dans une base de séries temporelles, et montre qu'elles coïncident. Défendez cette redondance auprès d'un chef de projet qui veut n'en garder qu'une, puis dites à quelles conditions il aurait raison.

Mises en situation

1. Embouteillage de Saint-Zotique vous livre un historien de six ans, en heure locale sans fuseau, et vous demande un tableau de bord de consommation d'énergie à l'heure. Vous découvrez que les six changements d'heure d'automne portent chacun leurs doublons. Décrivez ce que vous faites, dans l'ordre, et ce que vous écrivez au client avant de commencer.
2. L'aluminerie de Pointe-du-Lac veut réunir dans un même entrepôt les données de son SCADA, de sa GMAO et de son compteur électrique. Les trois systèmes horodatent différemment : l'un en heure locale sans fuseau, l'autre en texte au format jour-mois-année, le troisième en heure locale avec décalage. Proposez la règle que vous poserez pour l'entrepôt, et dites ce que vous faites de chaque source pour y arriver.
3. (avancé) Un chef d'usine vous montre un rapport annuel d'énergie produit par son fournisseur et un autre produit par votre équipe. Ils diffèrent de 0,002 %. Il veut savoir lequel est le bon. Dites ce que vous vérifiez, dans quel ordre, et ce que vous répondez si les deux méthodes se révèlent défendables.

Corrigé

Les chiffres cités sont ceux de la génération du cours, jusqu'à 2026-03, historien de 182 jours. Le script `01_de/sql/diagnostic_usine.sql` les rejoue.

Questions courtes

1. La bande morte. L'historien ne retient un point que si sa valeur s'écarte de la dernière valeur retenue de plus d'un seuil propre à l'étiquette, plus un point par heure au minimum. Il jette donc tout ce qui reste dans le seuil, et ce qui est jeté est perdu. L'intervalle entre deux points n'a par conséquent aucune raison d'être constant : une moyenne simple des points donne autant de poids à une valeur qui a duré deux minutes qu'à une valeur qui a duré une heure. Il faut pondérer par le temps, ce que la seconde séance fera.

Théorie : Theorie_08.md, section 3.

2. La valeur de départ. C'est la dernière valeur retenue la veille, recopiée en tête du fichier du lendemain, avec son horodatage de la veille : elle dit d'où part chaque point pour qui ne lit qu'un fichier. Elle existe donc deux fois, dans le fichier de la veille à sa place, et dans celui du lendemain en tête. Qui charge tous les fichiers sans la reconnaître obtient 10 556 doublons parfaits sur les 182 jours, soit 58 par jour, et gonfle ses comptes de 2 %.

Théorie : Theorie_08.md, section 3.

3. Trente et un. Quatre jours portent moins de 58 points à minuit, parce qu'une coupure de communication touchait une zone entière à cet instant : le 2025-10-28 (47 points), le 2025-12-03 (56), le 2025-12-20 (51) et le 2026-01-29 (47). Les manques valent 11, 2, 7 et 11, soit des tailles de zones. La leçon : l'archivage de minuit est une intention de l'historien, pas une garantie. Un contrôle qui suppose 58 points par jour à minuit lèvera de vraies alertes, mais un calcul qui s'appuie sur leur présence sera faux sans le dire.

Théorie : Theorie_08.md, section 3.

4. Les trois codes. 192 signifie une qualité bonne, 64 une qualité douteuse, 0 une qualité mauvaise. C'est le code 0 qui arrive sans valeur : les 529 points concernés ont un champ de valeur vide, et un moteur les lit en NULL. Le code 64, lui, porte une valeur, et c'est ce qui le rend dangereux : elle est là, elle est plausible, et l'appareil dit qu'il n'en répond pas.

Théorie : Theorie_08.md, section 4.

5. Dix-huit. C'est le nombre d'étiquettes de la zone des utilités. Quand 18 points passent en qualité mauvaise au même instant, ce n'est pas un capteur qui tombe, c'est le lien de communication de la zone qui se coupe. Le même raisonnement vaut pour 11 (une ligne d'assemblage), 9 (la peinture), 7 (la ligne des motomarines) et 2 (les essais). Compter les points perdus par instant et les comparer à la taille des zones classe la panne sans rien savoir d'autre.

Théorie : Theorie_08.md, section 4.

6. Deux jours par an. Au retour à l'heure normale, le 2025-11-02, l'heure de 1 h à 2 h est vécue deux fois : 141 points tombent dans cette plage, dont 49 paires d'étiquette et d'horodatage strictement identiques, avec des valeurs différentes. Au passage à l'heure avancée, le 2026-03-08, l'heure de 2 h à 3 h

n'existe pas : aucun point, contre 79 le dimanche précédent. Les remèdes diffèrent parce que les problèmes sont inverses. Dans le premier cas, il faut distinguer deux instants que l'écriture a confondus, ce qui demande de reconstruire le moment absolu. Dans le second, il n'y a rien à reconstruire : il faut seulement que les contrôles de complétude acceptent une journée de 23 heures.

Théorie : Theorie_08.md, section 7.

7. Fin d'intervalle. Premièrement, le dernier quart d'heure d'un mois finit à minuit le premier du mois suivant, donc il se trouve dans le fichier du mois suivant. Deuxièmement, le total d'une période dépend de la convention : octobre 2025 pèse 340 102 kWh si l'on prend le fichier du mois, et 340 129 kWh si l'on prend les intervalles qui commencent dans le mois, pour le même nombre de relevés. Troisièmement, un graphique qui aligne ces relevés sur une autre série sans corriger le décalage de quinze minutes montre une cause qui suit son effet.

Théorie : Theorie_08.md, section 7.

8. La frontière. Le réseau de contrôle porte des équipements dont une perturbation arrête la production ou met des personnes en danger, souvent sur des systèmes anciens qu'on ne corrige pas. Une requête maladroite ou un client trop bavard peuvent suffire à déranger un automate. Les deux voies raisonnables : l'export de l'historien vers un dossier que l'équipe des données lit, ce que Boréal fait, et une réplique en lecture de l'historien côté technologies de l'information. Une passerelle unidirectionnelle existe aussi, pour les sites qui l'exigent.

Théorie : Theorie_08.md, section 6.

9. Pondérer. Sur une série à bande morte, l'intervalle entre deux points n'est pas constant : une valeur peut tenir deux minutes et la suivante quarante-cinq. Une moyenne simple leur donne le même poids, donc elle mesure la fréquence d'écriture de l'historien plutôt que la grandeur. On pondère par la durée de validité de chaque point, c'est-à-dire par le temps qui le sépare du suivant.

Théorie : Theorie_08.md, section 9.

10. Trois natures. Une mesure se moyenne, pondérée par le temps. Un état de marche se moyenne de la même façon, et le résultat est la part de l'heure passée en marche. Un compteur cumulatif ne se moyenne pas : sa valeur horaire est la différence entre son cumul de fin d'heure et celui de l'heure précédente, et la première heure du jour vaut le cumul lui-même, puisqu'il repart de zéro à minuit. L'information qui permet de distinguer les trois est dans le référentiel des étiquettes, et nulle part ailleurs : aucune heuristique ne reconnaît un cumul d'une mesure qui monte.

Théorie : Theorie_08.md, section 10.

11. La couverture. Neuf cents secondes sur 3 600 veulent dire qu'un quart de l'heure seulement était couvert par une mesure valable, et que le reste est un trou, coupure de communication ou qualité mauvaise. La valeur reste calculable, mais elle ne porte que sur ce quart d'heure. Un consommateur doit en tenir compte : écarter l'heure, la marquer, ou la pondérer à son tour selon ce qu'il en fait. Sans cette colonne, une heure pleine et une heure à peine mesurée se ressemblent.

Théorie : Theorie_08.md, section 9.

12. L'agrégat continu. Il agrège chaque seau de temps indépendamment et ne voit jamais la ligne suivante : il ne peut donc ni calculer la durée de validité d'un point, ni découper un intervalle qui traverse la frontière d'un seau. Pour qu'il y arrive, on lui livre des morceaux déjà découpés aux frontières, chacun avec sa durée en colonne ; la moyenne pondérée devient alors $\text{sum}(\text{valeur} * \text{secondes}) / \text{sum}(\text{secondes})$, que tout agrégat sait faire.

Théorie : Theorie_08.md, section 12.

Questions pratiques

1. [labo] Les points qui comptent.

-- Attendu : UTL 1 447, LMN 777, LHR 633, ESS 510, PEI 434, LMM 247, soit 4 048 points.

```
SELECT SPLIT_PART(TagName, '.', 1) AS zone, count(*) AS points
FROM points
WHERE jour = DATE '2025-10-28'
GROUP BY zone
ORDER BY points DESC;
```

La vue points écarte déjà les valeurs de départ, puisqu'elle ne garde que les lignes dont l'horodatage tombe le jour du fichier. Le 28 octobre est le jour où le compresseur 2 a déclenché, à 10 h 44, et pourtant le compte par zone ne le montre pas : les utilités portent 1 447 points, soit le milieu de leur fourchette ordinaire, et le total de la journée, 4 048 points, vaut celui d'un jeudi calme, 3 949. C'est la leçon de la question : le volume de points est un signal, mais au grain de l'étiquette. Sur UTL.AIR.PRESSION seule, il passe de 89 points un jour normal à 265 le 24 octobre.

Théorie : Theorie_08.md, section 3.

2. [labo] Les zones aveugles.

-- Attendu : des coupures de 18 points sur UTL, la plus ancienne le 2025-10-05 à 14:46.

```
SELECT SPLIT_PART(TagName, '.', 1) AS zone, min(Timestamp) AS instant, count(*) AS points_perdus
FROM points
WHERE Quality = 0
GROUP BY zone, jour, DATE_TRUNC('minute', Timestamp)
ORDER BY points_perdus DESC, instant;
```

Grouper par minute suffit ici, parce qu'une coupure frappe toutes les étiquettes d'une zone au même horodatage. Sur une usine où les points ne seraient pas synchronisés, il faudrait grouper par fenêtre de quelques minutes.

Théorie : Theorie_08.md, section 4.

3. [labo] Une heure sans rien.

-- Attendu : 5 heures, toutes le 2025-10-05, de 15:00 à 19:00.

```
WITH heures AS (
  SELECT UNNEST(GENERATE_SERIES(TIMESTAMP '2025-10-01 00:00:00',
                                TIMESTAMP '2025-10-31 23:00:00',
```

Page 7 sur 14

```

INTERVAL 1 HOUR)) AS heure
), vues AS (
  SELECT DATE_TRUNC('hour', Timestamp) AS heure
  FROM points
  WHERE TagName = 'UTL.AIR.PRESSION'
  GROUP BY heure
)
SELECT h.heure
FROM heures h
LEFT JOIN vues v ON v.heure = h.heure
WHERE v.heure IS NULL
ORDER BY h.heure;

```

Les cinq heures se suivent, et elles suivent la coupure de 14 h 46 du même jour. La garantie d'un point par heure ne vaut donc que tant que la communication tient : pendant une coupure, l'historien n'écrit rien, pas même un point de qualité mauvaise. Un trou ne se trouve pas dans les données, il se trouve en les comparant à une série d'heures qu'on fabrique.

Théorie : Theorie_08.md, section 3.

4. [labo] La maintenance, dans l'ordre.

```

-- Attendu : BT-2026-00820 (LMM-CNV, 3,7 h), BT-2026-00819 (UTL-SEC, 4,7 h),
-- BT-2026-00818 (LMN-CNV, 4,8 h), puis les suivants.
SELECT no_bt, actif_id,
  STRPTIME(ouvert_le, '%d/%m/%Y %H:%M') AS ouvert,
  ROUND(DATE_DIFF('minute', STRPTIME(ouvert_le, '%d/%m/%Y %H:%M'),
    STRPTIME(ferme_le, '%d/%m/%Y %H:%M')) / 60.0, 1) AS heures
FROM read_csv('sources/usine/gmao/bons_travail.csv')
WHERE type_bt = 'CORR' AND ferme_le IS NOT NULL
ORDER BY ouvert DESC
LIMIT 10;

```

Les deux colonnes sont du texte, et les deux demandent STRPTIME. Trier sur ouvert_le tel quel donnerait un classement par jour du mois, et soustraire deux chaînes de caractères ne donnerait rien du tout. Le filtre sur ferme_le écarte les quatre bons encore ouverts, qui n'ont pas de durée.

Théorie : Theorie_08.md, section 7.

5. [labo] La facture du mois.

```

-- Attendu : 340 102 kWh pour le fichier du mois, 340 129 pour les intervalles commencés en
-- octobre, 27 kWh d'écart, et 2 976 relevés dans les deux cas.
SELECT ROUND(SUM(energie_kwh)) AS kwh_du_fichier
FROM read_csv('sources/usine/compteur/relevés_2025-10.csv');

```



```
SELECT ROUND(SUM(energie_kwh)) AS kwh_commences_en_octobre
FROM read_csv('sources/usine/compteur/relevés_*.csv')
WHERE YEAR(fin_intervalle - INTERVAL 15 MINUTE) = 2025
      AND MONTH(fin_intervalle - INTERVAL 15 MINUTE) = 10;
```

Les deux comptent 2 976 relevés, et ce ne sont pas les mêmes : le premier prend l'intervalle qui finit le 1er octobre à minuit, le second celui qui finit le 1er novembre à minuit. Vingt-sept kilowattheures d'écart, soit 0,008 %, que personne ne verra et que personne ne saura réconcilier dans six mois. La règle est d'écrire la convention à côté du chiffre.

Théorie : Theorie_08.md, section 7.

6. [labo] L'autre compresseur.

```
-- Attendu : Le compresseur 1 tient entre 2,45 et 2,56 du 20 au 28 octobre.
WITH vibration AS (
  SELECT Timestamp, Value FROM points
  WHERE TagName = 'UTL.CMP1.VIBRATION' AND Quality = 192
), marche AS (
  SELECT Timestamp, Value AS etat FROM points
  WHERE TagName = 'UTL.CMP1.MARCHE' AND Quality = 192
)
SELECT CAST(v.Timestamp AS DATE) AS jour, ROUND(AVG(v.Value), 2) AS vibration_en_marche
FROM vibration v ASOF JOIN marche m ON v.Timestamp >= m.Timestamp
WHERE m.etat = 1 AND CAST(v.Timestamp AS DATE) BETWEEN DATE '2025-10-20' AND DATE '2025-10-28'
GROUP BY jour
ORDER BY jour;
```

Le compresseur 1 sert de témoin. Pendant que le 2 passe de 3,39 à 8,93, le 1 reste plat. Cela écarte d'un coup trois explications qu'il aurait fallu vérifier autrement : un défaut de la chaîne de mesure, un changement de réglage de l'historien, ou une cause commune aux deux machines comme la température ambiante. Un témoin vaut mieux qu'un seuil.

Labo : Labo_08.md, étape 7.

7. [labo] La disponibilité du compresseur.

```
-- Attendu : 0,397 Le 27 octobre, 0,197 Le 28, 0 Le 29, 0,078 Le 30, 0,396 Le 31.
SELECT CAST(heure AT TIME ZONE 'America/Toronto' AS DATE) AS jour,
       ROUND(SUM(valeur * couverture_s) / SUM(couverture_s), 3) AS part_en_marche
FROM entrepot.argent.usine_horaire
WHERE etiquette = 'UTL.CMP2.MARCHE'
      AND CAST(heure AT TIME ZONE 'America/Toronto' AS DATE)
```

```
BETWEEN DATE '2025-10-27' AND DATE '2025-10-31'  
GROUP BY jour ORDER BY jour;
```

La colonne valeur d'un état de marche est la part de l'heure passée en marche, entre 0 et 1, parce qu'une moyenne pondérée par le temps sur une grandeur qui vaut 0 ou 1 donne exactement cela. Le 29 octobre à zéro et le 30 à 0,078 racontent la réparation : le compresseur revient en service en fin de journée le 30.

Théorie : Theorie_08.md, section 10.

8. [labo] Les heures de pointe.

```
-- Attendu : La pointe est Le 2025-01-21 à 07 h, 1 878,22 kwh, puis deux heures du 2023-02-03.  
SELECT heure, energie_kwh, DAYNAME(heure AT TIME ZONE 'America/Toronto') AS jour_semaine  
FROM entrepot.argent.energie_horaire  
ORDER BY energie_kwh DESC  
LIMIT 10;
```

Les dix heures les plus chargées sont des matinées de semaine en janvier et février : le chauffage électrique de l'usine suit la température extérieure, et il pèse plus que les lignes d'assemblage. C'est ce que Data Science reprendra pour la prévision de la demande.

Théorie : Theorie_08.md, section 10.

9. [labo] Le contrôle qui manquerait.

```
-- Attendu : 0 étiquette hors du compte.  
SELECT count(*) AS etiquettes_hors_compte FROM (  
  SELECT etiquette, count(*) AS heures  
  FROM entrepot.argent.usine_horaire  
  GROUP BY etiquette  
  HAVING count(*) <> 4368);
```

Le compte est le bon parce que la grille est bâtie en instants absolus : 182 jours font 4 368 heures, et les deux changements d'heure ne changent rien à ce total. Ils en déplacent la répartition sur le calendrier local, une journée de 25 heures en novembre et une de 23 en mars, mais un instant absolu ne connaît pas ces accidents.

Théorie : Theorie_08.md, section 9.

Diagnostics

1. Deux erreurs, et la seconde est pire que la première. Les 550 087 lignes comprennent 10 556 valeurs de départ, qui sont des recopies : il n'y a que 539 531 points de mesure, et le compte annoncé est gonflé de 2 %. Surtout, sa moyenne de vibration mélange les périodes de marche et d'arrêt, où la valeur tombe à 0,01. Le compresseur 2 rend 2,57 en marche le 14 octobre, et 0,02 en moyenne quotidienne le 18 : le tableau de bord montre une machine

saine pendant qu'elle dérive. Le remède tient en deux gestes, écarter les lignes dont l'horodatage n'est pas du jour du fichier, et croiser avec l'état de marche.

Théorie : Theorie_08.md, sections 3 et 8.

2. Le dimanche en question est celui du passage à l'heure avancée, le 2026-03-08 : l'heure de 2 h à 3 h n'a pas existé, et aucune étiquette ne peut porter de point dedans. L'alerte est donc fausse, et elle reviendra chaque année. Un contrôle juste compte les heures attendues plutôt que de supposer 24 : il génère la série des heures du jour dans le fuseau local, ce qui en donne 23 ce jour-là et 25 au retour à l'heure normale, puis compare. Tant qu'on y est, le vrai contrôle de complétude est celui de la question pratique 3 : chercher les heures sans aucun point, qui trouvent les coupures réelles.

Théorie : Theorie_08.md, section 7.

3. Son chiffre est faux, et il est faux dans le sens rassurant. Les 529 points de qualité mauvaise n'ont pas de valeur parce qu'il n'y avait pas de mesure : les remplacer par zéro revient à déclarer l'équipement à l'arrêt pendant une coupure de communication, ce qui abaisse la disponibilité sans raison, ou l'augmente selon le sens du calcul. Ce qu'il fallait faire : écarter ces points du calcul et les compter à part, puis dire dans le résultat sur quelle fraction du temps la mesure était disponible. Une disponibilité de 97 % mesurée sur 99 % du temps n'est pas la même chose qu'une disponibilité de 97 % tout court.

Théorie : Theorie_08.md, section 4.

4. Une fois par an, au retour à l'heure normale, deux mesures différentes portent le même couple d'étiquette et d'horodatage : 49 paires le 2025-11-02. La clé les refuse. Première façon de régler le problème, la bonne : convertir l'horodatage en instant absolu à l'entrée, en tenant compte du fuseau et de l'ordre d'arrivée des lignes, et poser la clé sur cet instant. Elle coûte une passe de nettoyage et une règle à écrire. Seconde façon, acceptable si le bronze doit rester tel quel : garder la clé technique du fichier, ajouter un numéro d'ordre dans la seconde, et ne poser la contrainte qu'en aval. Ce qu'il ne faut pas faire, c'est dédoublonner : ce serait perdre une heure de production réelle.

Théorie : Theorie_08.md, section 7.

5. Rien n'est tombé en panne : la ligne des motomarines s'est arrêtée pour la saison, du 17 décembre au 19 janvier, et cinq de ses sept points sont restés à zéro, de 768 à 790 heures selon l'étiquette. Le détecteur confond un équipement à l'arrêt avec un capteur figé, parce qu'il ne regarde que la constance de la valeur. Deux corrections, à faire ensemble. Écarter les plages dont la valeur est nulle ne suffit pas : le compresseur 1 de la même usine s'arrête à 0,01 et traverse ce filtre, et sur une grandeur qui vaut légitimement zéro en marche, le filtre cacherait le vrai cas. Il faut croiser avec l'état de marche de l'équipement, et ne lever une alerte que sur une valeur constante pendant que la machine tourne. Et le filtre se pose après le découpage en plages, jamais avant, sans quoi les périodes de marche se soudent entre elles et le détecteur annonce des gels de 4 344 heures.

Théorie : Theorie_08.md, section 8.

6. Son calcul n'a pas de défaut, et le vôtre non plus : les deux ne mesurent pas la même chose. $AVG(valeur)$ donne le même poids à chaque ligne, donc il mesure la cadence d'écriture de l'historien autant que la grandeur ; votre moyenne pondère chaque valeur par le temps pendant lequel elle valait. L'écart maximal tombe sur le régime du banc d'essai parce que sa grandeur varie de zéro à plusieurs milliers de tours par minute, et qu'une seule ligne à l'arrêt suffit à tirer la moyenne simple. La preuve tient dans l'agrégat lui-même, qui porte les deux :

```
SELECT count(*) FILTER (WHERE abs(moyenne_simple - somme_ponderee / secondes_totales) > 0.001)
      AS heures_en_ecart,
      ROUND(MAX(abs(moyenne_simple - somme_ponderee / secondes_totales))::numeric, 2) AS ecart_max
FROM usine_horaire;
```

Attendu : 86 700 heures sur 239 816, et 9 141,44 d'écart maximal. Ce compte-là est celui de l'agrégat continu : le même calcul refait dans DuckDB en rend 86 695, parce qu'un seuil au millième fait basculer cinq heures selon l'ordre des additions flottantes. C'est la leçon des contrôles à tolérance du Cours 07, et elle ne change rien à la conclusion. Reste à choisir : pour un tableau de bord d'exploitation, la pondérée ; pour compter des événements, la simple.

Théorie : Theorie_08.md, sections 9 et 12.

7. Le dernier point de chaque étiquette n'a pas de suivant, donc LEAD rend NULL et son intervalle disparaît avec lui. Les étiquettes les plus lentes sont les plus touchées : leur dernier point date parfois de plusieurs heures avant la fin de l'export, et c'est toute la fin de leur journée qui manque. La correction est de fermer le dernier intervalle à une borne, la fin de la dernière heure livrée :

```
COALESCE(LEAD(instant) OVER (PARTITION BY etiquette ORDER BY instant),
      (SELECT TIME_BUCKET(INTERVAL 1 HOUR, max(instant)) + INTERVAL 1 HOUR
      FROM points_dates)) AS fin
```

Ce que cela suppose est à dire : que la valeur a tenu jusqu'à cette borne. C'est raisonnable sur un export qui s'arrête à minuit, et ce le serait beaucoup moins sur un flux interrompu en plein milieu, où la bonne réponse serait plutôt de ne pas publier la dernière heure.

Théorie : Theorie_08.md, section 9.

Questions à développer

A. La défense du choix tient en trois arguments. Le volume d'abord : 58 points lus aux deux minutes font 15 millions de lignes par an, dont l'immense majorité répéterait la précédente, et une usine moyenne porte des milliers de points, pas des dizaines. Le coût de stockage ensuite, qui se paie sur dix à vingt ans de rétention réglementaire. Et la lecture enfin : une série compressée se parcourt plus vite, et l'opérateur qui cherche un incident dans une courbe de trois ans n'attend pas.

Ce que cela coûte à l'analyse, dix ans plus tard : la série est irrégulière, donc toute moyenne demande une pondération par le temps ; la valeur entre deux points est inconnue, donc une interpolation est une hypothèse et non une mesure ; et un phénomène plus rapide que la bande morte est invisible pour toujours, ce qui peut cacher exactement le défaut qu'on cherche.

Ce qu'on peut faire pour en limiter le prix : régler la bande morte point par point, en fonction de ce qu'on veut pouvoir détecter, et non d'un pourcentage uniforme ; garder une rétention fine sur les points critiques, quitte à compresser le reste plus fort ; et documenter la bande morte à côté de la série, ce que le référentiel des étiquettes de Boréal fait, pour qu'un analyste sache ce qu'il ne verra jamais.

Théorie : Theorie_08.md, section 3.

B. La réponse doit commencer par ce qu'on protège, et non par ce qu'on refuse. Le réseau de contrôle porte des équipements dont une perturbation arrête la production ou blesse quelqu'un. Un pipeline de données est un client de plus, avec ses reprises, ses montées en charge et ses erreurs de code, sur des automates qui n'ont pas été conçus pour en supporter. Le gain proposé, une journée de délai, se met en face du risque : une heure d'arrêt de la ligne des motoneiges vaut plus cher que la fraîcheur d'un tableau de bord.

Ce qu'on propose à la place, dans l'ordre : augmenter la fréquence d'export de l'historien, qui ne coûte presque rien et règle souvent tout ; monter une réplique en lecture de l'historien du côté des technologies de l'information ; et, si la fraîcheur à la minute est vraiment nécessaire, une passerelle unidirectionnelle, budgétée et portée par la production, pas par l'équipe des données. La conclusion s'écrit en une ligne : ce n'est pas un refus, c'est un choix de chemin.

Théorie : Theorie_08.md, section 6.

C. Le mécanisme est celui de la bande morte. L'historien retient un point quand la valeur s'écarte assez de la dernière retenue ; une grandeur qui se met à osciller franchit ce seuil bien plus souvent, donc produit plus de lignes, sans qu'aucune valeur ne sorte de sa plage. La pression du réseau d'air de Boréal passe de 89 points par jour à 265 pendant la dérive du compresseur, et son minimum ne descend jamais sous le seuil de 500 kPa qui aurait déclenché quelque chose.

En surveillance, cela donne un indicateur qui ne coûte presque rien : compter les points par étiquette et par jour, et alerter sur un écart au profil habituel. Il détecte l'instabilité, qui précède souvent la panne, alors qu'un seuil sur la valeur ne détecte que le dépassement.

Deux cas où ce signal trompe. Un changement de réglage de la bande morte, ou une mise à jour de l'automate, fait bouger le nombre de points sans que rien de physique n'ait changé : d'où l'importance de versionner le référentiel des étiquettes. Et un arrêt de production fait chuter le nombre de points pour une raison parfaitement normale, ce qui produirait une alerte tous les samedis si on ne croise pas avec l'état de marche.

Théorie : Theorie_08.md, sections 3 et 8.

D. La redondance n'en est pas une : les deux copies servent des usages que rien ne réunit. Le lac et l'entrepôt portent l'argent pour la consommation par lots, celle d'Analytics Engineering et de Data Science, qui balaient des mois de données d'un coup et pour qui un moteur en colonnes est des ordres de grandeur plus rapide. La base de séries temporelles porte la même série pour le chemin chaud : l'écriture en continu, la fenêtre récente, le tableau de bord qui se rafraîchit tout seul, l'alerte. Demander à l'un de faire le travail de l'autre coûte cher dans les deux sens. S'ajoute un argument qui n'est pas technique : les deux se comparent, et cette comparaison est le meilleur contrôle de qualité du pipeline. Elle a déjà servi à trouver le point non borné.

Le chef de projet aurait raison dans deux cas. Si le tableau de bord n'a pas besoin de temps réel et se contente d'une actualisation quotidienne, la base de séries temporelles ne sert plus à rien et le Parquet suffit. Et si le volume devenait tel qu'entretenir deux chemins coûterait plus que la latence gagnée, il faudrait trancher. Ni l'un ni l'autre n'est le cas de Boréal, dont l'usine produit 550 087 points par semestre.

Théorie : Theorie_08.md, section 11.

Mises en situation

1. Embouteillage de Saint-Zotique. Ce qu'on fait, dans l'ordre. D'abord, mesurer l'ampleur : compter les paires d'étiquette et d'horodatage en double, année par année, et vérifier que chaque occurrence tombe bien dans l'heure répétée du premier dimanche de novembre. Ensuite, décider de la règle d'interprétation, qui est une décision de client et non une décision technique : dans l'ordre du fichier, la première occurrence est en heure avancée et la

seconde en heure normale, et c'est cet ordre qui permet de reconstruire l'instant absolu. Puis convertir toute la série en instants absolus, une fois, à l'entrée du pipeline, et ne plus jamais raisonner en heure locale ailleurs que pour l'affichage. Enfin, vérifier : sur les six automnes, le nombre de points de l'heure doublée doit se répartir en deux heures plausibles, et le total annuel ne doit pas bouger.

Ce qu'on écrit au client avant de commencer : que six heures de données portent une ambiguïté d'horodatage que seule une convention peut lever, quelle convention on propose, et ce qu'elle change sur les chiffres déjà publiés. Un rapport d'énergie recalculé qui ne coïncide plus avec l'ancien doit s'expliquer avant d'être livré, pas après.

Théorie : Theorie_08.md, section 7.

2. L'aluminerie de Pointe-du-Lac. La règle de l'entrepôt tient en une phrase : tout horodatage est stocké en instant absolu, avec son fuseau d'origine conservé à côté pour l'affichage, et aucune source n'entre sans que sa convention ait été écrite. Ce qu'on fait de chaque source : le SCADA, en heure locale sans fuseau, se convertit à l'entrée en nommant le fuseau et en traitant les deux transitions annuelles, avec la règle d'ordre pour l'heure doublée ; la GMAO, en texte jour-mois-année, se type dès le staging par un format déclaré, et son fuseau se documente auprès du fournisseur plutôt que de se deviner ; le compteur, qui porte déjà son décalage, se charge tel quel, et c'est le seul dont on n'a rien à reconstruire, ce qui en fait le modèle à citer quand on demandera aux deux autres de changer.

On ajoute une précision qui évitera une réunion : les trois systèmes n'ont pas la même granularité ni la même convention de bornage, et l'entrepôt doit porter, pour chaque série, ce que son horodatage désigne, un instant ou la fin d'un intervalle.

Théorie : Theorie_08.md, section 7.

3. (avancé) Deux rapports à 0,002 %. Ce qu'on vérifie, dans l'ordre. La période d'abord : les deux rapports couvrent-ils les mêmes intervalles, et chacun compte-t-il l'intervalle de minuit dans la même année. C'est de loin la cause la plus probable, et elle explique à elle seule des écarts de cet ordre : sur Boréal, la même année pèse 4 995 612 ou 4 995 732 kWh selon la convention, soit 0,002 %. Le périmètre ensuite : les relevés estimés sont-ils comptés des deux côtés, et le fournisseur a-t-il remplacé certains d'entre eux par des valeurs corrigées après coup. L'arrondi enfin, qui pèse peu mais qu'il faut écarter : additionner des flottants dans un ordre différent ne donne pas exactement le même total, et un rapport qui arrondit chaque mois avant de sommer n'égale pas celui qui somme puis arrondit.

Ce qu'on répond si les deux méthodes se révèlent défendables : qu'aucun des deux n'est faux, que l'écart vient d'une convention et non d'une erreur, et qu'il faut en choisir une et l'écrire, de préférence celle du fournisseur, parce que c'est elle qui fait foi sur la facture. On ajoute que l'écart doit être reproductible : si l'on peut retrouver le chiffre du fournisseur à partir des mêmes relevés, le débat est clos, et c'est ce contrôle-là qu'on met en place.

Théorie : Theorie_08.md, section 7.