

Table des matières

Mise en situation — Véhicules Boréal inc., l’amont de la chaîne	1
Le décor	1
La boîte	2
Les sources	3
La synchronisation avec les cours	3
À remettre	5

Mise en situation — Véhicules Boréal inc., l’amont de la chaîne

Formation Data Engineering — le fil rouge, ce que vous bâtissez · fil des Labo_NN

Boréal est votre chantier : le pipeline que vous montez cours après cours, du premier extrait reçu jusqu’au tableau de bord de l’usine en direct. La théorie l’explique, les labos le bâtissent. Pas de notes ni d’examens, la cible est un livrable professionnel. Le décor commun aux sept formations du parcours est dans `_univers/boreal/README.md` ; cette mise en situation raconte ce que Boréal attend de son ingénieur de données. À lire avant le Cours 01, puis à garder ouvert.

Le décor

Véhicules Boréal inc. fabrique des motoneiges, des motomarines et des véhicules hors-route à Val-des-Aulnes, au Saguenay–Lac-Saint-Jean, et les vend à un réseau de concessionnaires canadiens. Ses systèmes produisent beaucoup de données, et presque aucune ne sert au-delà du système qui la produit. L’ERP exporte un extrait par mois, que chacun ouvre dans un tableur. L’historien de l’usine produit un fichier par jour, qu’un technicien copie à la main quand on le lui demande. Le portail des garanties livre ses extraits à l’après-vente, et la télémétrie des véhicules connectés s’accumule dans une archive que personne ne lit. Personne ne peut relier une réclamation au véhicule qui l’a causée et à la semaine où il a été assemblé, ni une panne de compresseur aux mesures qui l’ont précédée.

Les sigles du décor. Un ERP est un progiciel de gestion intégré : le logiciel unique où passent les commandes, les articles, les clients et les livraisons d’une entreprise. Celui de Boréal vient de SAP, l’éditeur allemand le plus répandu du secteur, dont les noms de tables sont des abréviations allemandes des années 1970. La GMAO est la gestion de la maintenance assistée par ordinateur, le logiciel où l’usine ouvre et ferme ses bons de travail. MQTT est un protocole de publication et abonnement, taillé pour des machines qui envoient de petits messages en continu. ODBC est une interface de connexion à une base de données, que presque tous les langages savent employer. Un DAG, enfin, est un graphe orienté acyclique : les étapes d’un traitement et l’ordre dans lequel elles doivent passer, sans jamais boucler.

La direction veut que ça change. Cinq besoins sont sur la table :

- l’usine veut être prévenue quand un compresseur ou un robot dérive, avant qu’il déclenche ;

- la maintenance veut relier chaque bon de travail aux mesures qui l'ont précédé, pour savoir quelles pannes s'annonçaient ;
- l'après-vente veut suivre chaque réclamation jusqu'au véhicule, à sa production et à ses sorties ;
- la gestion de l'énergie veut prévoir la demande électrique de l'usine ;
- la direction veut des rapports mensuels fiables : ventes, production, réclamations.

Vous arrivez comme ingénieur de données. Votre mandat n'est pas de répondre vous-même à ces cinq demandes : c'est de faire en sorte que la donnée qui y répond arrive complète, à l'heure et prouvée bonne. Aux ingénieurs analytiques, qui bâtiront les étoiles et les rapports ; aux scientifiques de données, qui bâtiront la prévision et la détection des pannes ; et à l'usine, qui recevra les alertes.

La boîte

Le mandat, réduit à ses quatre faces.

Volet	Détail
Intrants	Les six sources de Boréal, telles que ses systèmes les livrent : les extraits mensuels de l'ERP et la copie de sa base ; l'historien, le registre des actifs, la GMAO et le compteur électrique de l'usine ; les extraits du portail des garanties ; l'archive de la télémétrie, puis son flux en direct au Cours 09 ; la documentation ; la météo publique d'Environnement et Changement climatique Canada. Des noms techniques en abréviations allemandes, des dates en texte, une heure locale sans fuseau, des points irréguliers, des codes de qualité, des doublons, un extrait livré deux fois.
Extrants	La couche RAW dans l'entrepôt DuckDB ; les séries de l'usine nettoyées, dans le schéma argent ; un lac en Parquet, puis en Iceberg, organisé en bronze et argent ; un chemin chaud qui alerte en quelques secondes, et son tableau de bord Grafana ; des contrats de données ; un pipeline orchestré, testé et surveillé ; le dépôt 01_de, la pièce de portfolio.
Ressources	Python, DuckDB, Docker dans l'Ubuntu de WSL 2, PostgreSQL, Airflow, Spark, Mosquitto, Kafka, TimescaleDB, Iceberg, Grafana, Git ; un poste de travail ordinaire, aucun compte infonuagique ; et vous, l'ingénieur de données.

Volet	Détail
Contrôles	L'idempotence (rejouer ne casse rien), le brut conservé intact, les contrats de données, la frontière entre le réseau de contrôle de l'usine et le réseau de bureau, aucun secret ni aucune donnée dans le dépôt.

Les deux chemins. Le froid : ERP, historien, garanties, télémétrie archivée → ingestion → lac (bronze, argent) → couche RAW et schéma argent → Analytics Engineering et Data Science. Le chaud, en parallèle : usine et véhicules → MQTT → Kafka → base de séries temporelles → Grafana.

Les sources

Source	Ce qui arrive dans <code>Projet_Boreal/sources/</code>	Exploitée d'abord au
L'ERP	<code>erp/extraits/AAAA-MM/</code> , un CSV par table SAP ; <code>erp/postgresql/</code> , la copie de la base	Cours 03 et 04
L'usine	<code>usine/historien/</code> , <code>usine/referentiel/</code> , <code>usine/gmao/</code> , <code>usine/compteur/</code>	Cours 01, 02 et 08
Les garanties	<code>garanties/AAAA-MM/</code> , dont les réclamations en JSON	Cours 03
La télémétrie	<code>telemetrie/sorties_AAAA-MM-JJ.jsonl</code>	Cours 01, 02 et 09
La documentation	<code>corpus/</code> , et son catalogue <code>index.csv</code>	Cours 03
La météo	<code>meteo/</code> , l'instantané figé ; la vraie API au Cours 04	Cours 03 et 04

Le sens de chaque fichier, de chaque colonne et de chaque code est dans `_univers/boreal/DICTIONNAIRE.md`. Les exemples et les chiffres des labos sortent du générateur : tout le monde obtient les mêmes.

La synchronisation avec les cours

Chaque labo ajoute une pièce au pipeline, sur votre machine. À la fin, `Projet_Boreal/01_de/` est un dépôt Git complet. Le poste de travail et les sources de Boréal se montent avant le premier cours, une seule fois, avec `Data_Domain/GUIDE_INSTALLATION.md`.

Cours	Ce que vous livrez	Étape
01	votre dépôt 01_de, un premier regard en SQL sur les six sources, et le constat de ce que coûte un type deviné	le premier regard
02	l'historien et la télémétrie rangés en Parquet, partitionnés par jour ; la mesure de ce que le format change	le stockage
03	l'ingestion idempotente des fichiers livrés : les extraits de l'ERP et des garanties, la télémétrie archivée, la documentation ; la couche RAW	la couche RAW
04	la base de l'ERP lue par ODBC, et prouvée égale aux extraits ; la météo tirée de l'API REST	la base et l'API
05	le code des ingestions devenu pipeline : configuration, secrets, journalisation, tests, conteneur	la robustesse
06	des DAG Airflow qui orchestrent les ingestions quotidiennes et mensuelles, et rattrapent les mois manqués	l'orchestration
07	deux ans d'historien : ce que DuckDB tient encore, et le même traitement en Spark	le volume
08	l'historien apprivoisé : valeurs de départ, heure locale, qualité, rééchantillonnage ; les séries de l'usine dans le schéma argent, et une base de séries temporelles	les données de terrain
09	le chemin chaud : l'usine et les véhicules rejoués en MQTT, un pont vers Kafka, une alerte de vibration	le temps réel
10	le lac en Iceberg, organisé en bronze et argent, et un format de télémétrie qui change	le lakehouse

Cours	Ce que vous livrez	Étape
11	les contrats et les contrôles : doublons, clés orphelines, plages physiques, capteur figé	la qualité
12	les deux chemins de bout en bout, Grafana en direct, une couche RAW livrée	la livraison

Après le Cours 12, une synthèse refait l'arc de la formation d'un bloc, sur d'autres données : Comptoir Aurore, une boutique en ligne. La Brûlerie, un café de quartier, en est le premier pas, un mini-cas à petite échelle.

À remettre

- `Projet_Boreal/01_de/` : le code des ingestions, les DAG, le lac en couches, le chemin chaud, les contrats, tout sous Git.
- Au Cours 12 : un pipeline qui se reconstruit de zéro, un tableau de bord Grafana en direct, une couche RAW et des séries de l'usine qu'un ingénieur analytique peut reprendre telles quelles, et le document de livraison qui les décrit.
- Au bout : un dépôt public, la pièce de portfolio.

Ce qui distingue un livrable fini d'un script qui tourne :

- chaque ingestion se rejoue sans doubler ni perdre une ligne ;
- le brut est conservé intact, et chaque correction vit dans du code relu ;
- des contrôles bloquent la donnée fausse avant qu'elle n'atteigne un consommateur ;
- aucun secret dans le dépôt, aucune donnée non plus.