

## Table des matières

|                                                              |    |
|--------------------------------------------------------------|----|
| Data Engineering — plan des modules .....                    | 1  |
| 1. Ce que cette formation est, et ce qu'elle n'est pas ..... | 1  |
| 2. Ce qui entre, ce qui sort .....                           | 2  |
| 3. La pile et le poste de travail .....                      | 4  |
| 4. Le projet de l'apprenant .....                            | 7  |
| 5. Les recoupements .....                                    | 7  |
| 6. Les douze cours .....                                     | 9  |
| 7. Le capstone .....                                         | 20 |
| 8. La synthèse, et le mini-cas .....                         | 21 |
| 9. Le kit 02 .....                                           | 22 |

## Data Engineering — plan des modules

*Écrit le 2026-08-31, amendé le 2026-09-11 pour les données industrielles, révisé le 2026-09-15. Ce fichier n'est pas un support de cours : c'est le plan de la formation, ce qu'elle promet, ce qu'elle livre et dans quel ordre. Il se lit pour juger la conception plutôt que pour apprendre.*

Ce qui change à la révision. Les onze modules, leurs frontières, les quatre supports par cours et l'encadré de recoupements restent. Le fil rouge passe de la Régie du Val-Clair à Véhicules Boréal inc. La formation livre des produits nommés (la couche RAW, les séries de l'usine) que les formations suivantes consomment. Chaque cours dit ses données, ses événements plantés et ses variantes Snowflake et Databricks. Un capstone, une synthèse et le kit 02 ferment la formation.

Les chemins sont relatifs à Portfolio/Formations/Data\_Domain/. Les numéros D renvoient au mandat, les numéros E aux événements plantés de \_univers/boreal/README.md. Les chiffres cités sont la sortie réelle du générateur, lue dans \_univers/boreal/CHIFFRES\_ATTENDUS.md.

---

### 1. Ce que cette formation est, et ce qu'elle n'est pas

Elle couvre l'amont de la chaîne : faire arriver la donnée, la ranger, la faire tourner à l'heure, et prouver qu'elle est bonne. Elle s'arrête là où commence la transformation métier : à la couche RAW comprise pour les sources relationnelles et les événements, aux séries nettoyées pour les données de terrain (D32).

| Formation                    | Ce qu'elle possède                   | Frontière avec Data Engineering                                                                                                                             |
|------------------------------|--------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------|
| SQL avancé                   | le langage                           | DE écrit du SQL sans l'enseigner ; chaque notion SQL reçoit un renvoi nommé                                                                                 |
| Snowflake                    | la plateforme d'entrepôt             | DE y livre dans ses annexes, sans l'administrer                                                                                                             |
| Analytics Engineering        | la transformation et la modélisation | DE livre la RAW et les séries de l'usine ; AE commence au STAGING. DE ne décode pas les codes SAP, ne dédouble pas les clients et ne joint pas deux sources |
| Business Intelligence        | la restitution                       | DE monte Grafana sur la base de séries temporelles et y branche l'alerte ; la lecture du tableau de bord appartient à BI                                    |
| Data Science                 | la modélisation statistique          | DE sert les séries longues de l'usine et la météo, sans construire de modèle                                                                                |
| Machine Learning Engineering | le pipeline de modèle                | MLE réemploie les conteneurs et Airflow de DE ; DE ne sert aucun modèle                                                                                     |
| AI Engineering               | la récupération augmentée            | DE dépose le corpus tel quel dans le lac ; le découpage et l'indexation appartiennent à AI                                                                  |
| Architecture et Gouvernance  | les règles et la cible               | DE écrit et exécute les contrats techniques ; Archi en fait des engagements entre équipes                                                                   |
| Linux, Python                | le système, le langage               | DE suppose le terminal et la syntaxe acquis                                                                                                                 |

La règle des renvois de `_commun/STYLE.md`, section 5, s'applique : une notion qui appartient à une autre formation n'est pas réexpliquée, elle est renvoyée nommément.

## 2. Ce qui entre, ce qui sort

### 2.1 Les entrées

Les six sources de Boréal, telles que ses systèmes les livrent, fabriquées par `_univers/boreal/generer_boreal.py` dans `Projet_Boreal/sources/`. DE ne consomme le produit d'aucune autre formation : le générateur lui suffit, et aucune porte d'entrée n'est à écrire (D12).

| Source     | Ce qui arrive dans sources/                                                                             | Défauts qui servent DE                                                                                                                                                                                                                                                                | Cours                  |
|------------|---------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------|
| ERP        | erp/extraits/AAAA-MM/, un CSV par table SAP ; erp/postgresql/, la copie de la base et charger_erp.sql   | l'extrait de mars 2023 livré deux fois (E6), une commande avant la fiche de son concessionnaire (E7), des textes NUMC à zéros de tête et des dates DATS à 00000000, les documents de modification (E8), les mois de 2026 (E17)                                                        | 01, 03, 04, 06, 11     |
| Usine      | usine/historien/, un CSV par jour ; usine/referentiel/ ; usine/gmao/ ; usine/compteur/, un CSV par mois | valeurs de départ, archivage forcé de minuit, heure locale sans fuseau et collisions (E1), capteur figé (E2), coupures et valeurs aberrantes (E3), dérives et pannes (E4, E5), dates JJ/MM/AAAA HH:MM, compteur horodaté en fin d'intervalle avec son décalage à UTC, relevés estimés | 01, 02, 07, 08, 09, 11 |
| Garanties  | garanties/AAAA-MM/ : clients, enregistrements, visites et consentements en CSV, réclamations en JSON    | données personnelles, une réclamation qui revient à chaque changement de statut, un effacement (E14)                                                                                                                                                                                  | 03, 11                 |
| Télémetrie | telemetrie/sorties_AAAA-MM-JJ.jsonl, ce qu'écrit l'abonné du courtier MQTT                              | doublons de la qualité de service 1, messages en retard (E12), un champ ajouté et un champ renommé (E11)                                                                                                                                                                              | 01, 02, 03, 09, 10, 11 |
| Corpus     | corpus/ : documents HTML et Markdown, catalogue index.csv                                               | des documents qui paraissent à leur date                                                                                                                                                                                                                                              | 03                     |
| Météo      | meteo/, l'instantané figé d'ECCE ; la vraie API au Cours 04                                             | trous et drapeaux de qualité de la vraie donnée                                                                                                                                                                                                                                       | 03, 04                 |

## 2.2 Les sorties

| Produit                                            | Forme                                                                                  | Où                                                              | Consommé par                                                                        | Kit                                |
|----------------------------------------------------|----------------------------------------------------------------------------------------|-----------------------------------------------------------------|-------------------------------------------------------------------------------------|------------------------------------|
| La couche RAW                                      | une table par fichier livré, en texte, avec ses colonnes de lignage (D60)              | schéma raw de l'entrepôt DuckDB, et une copie Parquet par table | AE, cours du STAGING ; Archi                                                        | 02                                 |
| Les séries de l'usine                              | les étiquettes de l'historien et l'énergie du compteur, nettoyées et rééchantillonnées | plateforme/lac/argent/, et schéma argent de l'entrepôt (D61)    | AE (étoile de l'usine) ; DS (maintenance prédictive, prévision de la demande) ; MLE | 02, et 04 avec l'historien complet |
| Le lac bronze et argent                            | Parquet partitionné, puis tables Iceberg                                               | plateforme/lac/                                                 | Archi, Cours 01                                                                     | 07                                 |
| La base de séries temporelles et le flux rejouable | TimescaleDB chargée, le rejoueur MQTT de _univers/rejoueurs/                           | le docker compose du Solution/ de DE                            | BI, son cours Grafana                                                               | 03                                 |
| Le corpus déposé tel quel                          | les fichiers, et raw.corpus_index                                                      | plateforme/lac/bronze/corpus/                                   | AI, Cours 02                                                                        | 06                                 |
| Les contrats de données                            | YAML et requêtes de contrôle                                                           | le dépôt 01_de                                                  | AE (ses tests prennent le relais) ; Archi, Cours 05                                 | 07                                 |
| Le DAG et les conteneurs                           | DAG Airflow, Dockerfile, docker compose                                                | Cours/Solution/                                                 | MLE, Cours 01 et 04                                                                 | aucun : de l'outillage             |

Chaque produit est décrit dans Cours/Solution/LIVRAISON.md : ses tables, ses colonnes de lignage, ses comptes attendus, le cours qui le fabrique et la commande du kit qui le reconstruit. C'est le document que les formations suivantes citent quand elles nomment ce qu'elles reçoivent (D12). Il commence au Cours 03 et se complète au Cours 12.

### 3. La pile et le poste de travail

#### 3.1 La pile

Python et des outils ouverts, en local (D13). DuckDB est le moteur de référence des labos : il lit CSV, JSON, Parquet et Iceberg sans serveur. Les services tournent en conteneurs. Spark et Kafka ne sortent que dans les cours dont ils sont le sujet, et rien n'oblige à ouvrir un compte infonuagique.

| Outil                                       | Rôle                               | Où il tourne                                                                                                          | Dès le cours |
|---------------------------------------------|------------------------------------|-----------------------------------------------------------------------------------------------------------------------|--------------|
| Python 3.11, environnement conda formations | le code du pipeline                | Windows                                                                                                               | 01           |
| DuckDB, paquet et ligne de commande         | le SQL des labos, l'entrepôt local | Windows                                                                                                               | 01           |
| Git                                         | le dépôt 01_de                     | Windows                                                                                                               | 01           |
| Docker Engine, docker compose               | les services                       | l'Ubuntu de WSL 2 (D59)                                                                                               | 04           |
| PostgreSQL 18                               | la base de l'ERP de Boréal         | conteneur, port 5433 : le 5432 reste à un PostgreSQL déjà installé, celui de la formation SQL avancé par exemple      | 04           |
| psqlODBC, pyodbc                            | l'extraction par ODBC              | Windows                                                                                                               | 04           |
| Airflow 3                                   | l'orchestration                    | conteneurs                                                                                                            | 06           |
| Spark 4                                     | le traitement distribué            | conteneur : sous Windows, Spark demande une version de Java précise et des utilitaires Hadoop (à révéifier à l'essai) | 07           |
| TimescaleDB                                 | la base de séries temporelles      | conteneur                                                                                                             | 08           |
| Mosquitto, Kafka en mode KRaft              | le chemin chaud                    | conteneurs                                                                                                            | 09           |
| Pylceberg, deltalake                        | les formats de table ouverts       | Windows                                                                                                               | 10           |
| Grafana                                     | le tableau de bord du chemin chaud | conteneur                                                                                                             | 12           |

### 3.2 Le poste de l'auteur, constaté le 2026-09-15

| Élément | État                                                      |
|---------|-----------------------------------------------------------|
| Windows | 10 Famille, 22H2 (build 19045)                            |
| Mémoire | 32 Go, dont 15 Go laissés à WSL 2                         |
| WSL 2   | version 2.7, Ubuntu 26.04 LTS, systemd actif, sans Docker |

| Élément    | État                                                                                                                          |
|------------|-------------------------------------------------------------------------------------------------------------------------------|
| Docker     | absent ; des restes d'un Docker Desktop désinstallé (la distribution docker-desktop de WSL et deux dossiers de configuration) |
| PostgreSQL | 18, installé en natif                                                                                                         |
| DuckDB     | 1.5.5, paquet et ligne de commande                                                                                            |
| Java       | 23                                                                                                                            |

Faits vérifiés le 2026-09-15 : Airflow ne tourne pas nativement sous Windows (WSL 2 ou conteneurs, selon sa documentation) ; Kafka non plus, en pratique ; Docker ne soutient Docker Desktop que sur les versions de Windows encore dans le calendrier de service de Microsoft, que Windows 10 a quitté le 2025-10-14, et sa page d'installation ne nomme que les éditions Pro, Entreprise et Éducation.

### 3.3 Les variantes Snowflake et Databricks

Reprises de la charte commune du parcours. Une annexe quand le lecteur fait autre chose, un encadré quand la plateforme change un concept sans changer le geste. Les faits de chaque plateforme se revérifient avant d'écrire, aucun script ne porte d'identifiant de compte, et c'est vous qui les exécutez.

| Cours                                | Snowflake                                                                                                                                    | Databricks                                                 | Forme                                |
|--------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------|--------------------------------------|
| 02 Formats de fichiers et lac bronze | micro-partitions                                                                                                                             | fichiers Delta                                             | encadré                              |
| 03 Charger des fichiers dans la RAW  | stage interne, COPY INTO, Snowpipe, schéma transient ; les quatre remarques de relecture d'AE sur le stage, le schéma transient et les rôles | volume Unity Catalog, COPY INTO, Auto Loader               | annexe                               |
| 06 Orchestration                     | tâches                                                                                                                                       | Jobs                                                       | encadré                              |
| 07 Spark                             | Snowpark                                                                                                                                     | Spark serverless de Free Edition, le terrain même du cours | annexe Databricks, encadré Snowflake |
| 09 Streaming                         | Snowpipe Streaming, Streams et Tasks                                                                                                         | Structured Streaming                                       | encadré                              |
| 10 Formats de table ouverts          | tables Iceberg                                                                                                                               | Delta, Unity Catalog ; encadré Fabric                      | annexe                               |
| 11 Qualité                           | fonctions de mesure de la qualité                                                                                                            | attentes des pipelines déclaratifs                         | encadré                              |

## 4. Le projet de l'apprenant

Décision D33 : un seul dossier `Projet_Boreal/`, ignoré par le dépôt des formations, qui porte une plateforme partagée et un dépôt Git par formation.

| Dossier                                                                     | Contenu                                                                                                                                                          | Qui l'écrit                    |
|-----------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------|
| <code>Projet_Boreal/sources/</code>                                         | la sortie du générateur                                                                                                                                          | <code>generer_boreal.py</code> |
| <code>Projet_Boreal/plateforme/lac/bronze/</code> ,<br><code>argent/</code> | Parquet, puis Iceberg                                                                                                                                            | DE                             |
| <code>Projet_Boreal/plateforme/entrepot/</code>                             | l'entrepôt DuckDB en un seul fichier,<br><code>boreal.duckdb</code> (D67), schémas <code>raw</code> et <code>argent</code> ; les autres viendront avec AE et MLE | DE                             |
| <code>Projet_Boreal/01_de/</code>                                           | votre dépôt : le code du pipeline, les DAG, le <code>docker-compose.yml</code> , les contrats, les tests                                                         | vous                           |

La ligne de commande DuckDB se lance depuis `Projet_Boreal/`, et le code depuis `01_de/` (D62). Les synthèses suivent la même forme dans `Projet_Brulerie/` et `Projet_Aurore/`, eux aussi ignorés par Git.

## 5. Les recoupements

Décision prise avec vous le 2026-08-31 : chaque théorie se termine par un encadré court, une ligne par formation voisine, qui dit ce qui est commun et qui possède la matière. Le contenu de chaque encadré est fixé ici.

| Cours | Recoupe       | Ce que l'encadré doit dire                                                                                                                                                       |
|-------|---------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 01    | AE, DS        | Les métiers se partagent la même chaîne. DE livre la RAW et les séries de l'usine ; AE prend la suite au STAGING, DS consomme les séries.                                        |
| 02    | Snowflake     | Les micro-partitions de Snowflake sont le partitionnement d'un lac, appliqué en interne.                                                                                         |
| 03    | AE, Snowflake | COPY INTO et Snowpipe se voient côté plateforme dans la formation Snowflake ; ici, la mécanique générale. Les codes SAP que la RAW garde tels quels se décodent au STAGING d'AE. |

| Cours | Recoupe       | Ce que l'encadré doit dire                                                                                                                                                                                          |
|-------|---------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 04    | SQL           | Les Cours 10 et 11 de SQL possèdent le plan de requête et l'index, la lecture longue et les versions de lignes ; ici, ce qu'ils changent pour qui extrait d'une base.                                               |
| 05    | Python, Linux | Le langage et le terminal appartiennent aux deux autres formations ; ici, seulement ce qui rend un pipeline rejouable.                                                                                              |
| 06    | AE, MLE       | dbt build dans un DAG est le point de couture avec AE. Le DAG d'entraînement de MLE réemploie l'outil.                                                                                                              |
| 07    | SQL           | Le plan d'exécution de Spark et celui d'un moteur SQL résolvent le même problème. Renvoi au Cours 10 de SQL.                                                                                                        |
| 08    | SQL, DS       | Le Cours 09 de SQL possède les séries temporelles et les jointures as-of ; ici, d'où viennent les points et ce qu'ils valent. DS s'en sert pour la maintenance prédictive et la prévision de la demande électrique. |
| 09    | BI, Archi     | Le chemin chaud finit dans Grafana, dont la lecture appartient à BI. Lambda et Kappa reviennent au Cours 01 d'Archi, comme choix d'architecture.                                                                    |
| 10    | AE, Archi     | Bronze, argent et or recourent RAW, STAGING et MARTS ; le parcours donne l'argent des séries de terrain à DE (D32). Archi reprend le débat du lac et de l'entrepôt (Cours 01) et le choix de la pile (Cours 03).    |
| 11    | AE, Archi     | Les tests dbt sont la version aval des contrats posés ici. Archi fait du contrat un engagement, avec un propriétaire et un recours.                                                                                 |

| Cours | Recoupe    | Ce que l'encadré doit dire                                                                                                         |
|-------|------------|------------------------------------------------------------------------------------------------------------------------------------|
| 12    | AE, BI, DS | La RAW du capstone est ce que le kit 02 livre à AE ; le tableau de bord Grafana passe à BI ; les séries de l'usine nourrissent DS. |

## 6. Les douze cours

La formation compte douze cours numérotés 01 à 12, sans Cours 00 (D99). Les anciens Cours 01 et 02 se sont coupés chacun en deux le 2026-09-18, à la charnière que leurs fiches rappellent, et tout ce qui suivait a reculé de deux rangs. Un cours se numérote par sa place dans la formation, jamais par son histoire.

| Avant la coupe      | Numéro | Titre                                                       | Dossier                                                          | Coupure nommée                          |
|---------------------|--------|-------------------------------------------------------------|------------------------------------------------------------------|-----------------------------------------|
| 01, première moitié | 01     | Le métier, les sources et le premier regard                 | Cours_01_Le_metier_les_sources_et_le_premier_regard              |                                         |
| 01, seconde moitié  | 02     | Les formats de fichiers et le lac bronze                    | Cours_02_Les_formats_de_fichiers_et_le_lac_bronze                |                                         |
| 02, première moitié | 03     | Charger des fichiers dans la couche RAW                     | Cours_03_Charger_des_fichiers_dans_la_couche_RAW                 |                                         |
| 02, seconde moitié  | 04     | Lire une base et une API                                    | Cours_04_Lire_une_base_et_une_API                                |                                         |
| 03                  | 05     | Le code d'un pipeline robuste                               | Cours_05_Le_code_d_un_pipeline_robuste                           |                                         |
| 04                  | 06     | Orchestration avec Airflow                                  | Cours_06_Orchestration_avec_Airflow                              | après l'étape 5                         |
| 05                  | 07     | Traitement distribué avec Spark                             | Cours_07_Traitement_distribue_avec_Spark                         |                                         |
| 06                  | 08     | Données de terrain : SCADA, historien et séries temporelles | Cours_08_Donnees_de_terrain_SCADA_historien_et_serie_temporelles | le terrain et ses pièges, puis l'argent |

| Avant la coupe | Numéro | Titre                                            | Dossier                                                          | Coupure nommée   |
|----------------|--------|--------------------------------------------------|------------------------------------------------------------------|------------------|
| 07             | 09     | Streaming et événements : MQTT et Kafka          | Cours_09_Streaming_et_ev<br>enements_MQTT_et_Kafka               | MQTT, puis Kafka |
| 08             | 10     | Formats de table ouverts, lakehouse et médaillon | Cours_10_Formats_de_tabl<br>e_ouverts_lakehouse_et_m<br>edaillon |                  |
| 09             | 11     | Qualité, contrats et observabilité               | Cours_11_Qualite_contrat<br>s_et_observabilite                   |                  |
| 10             | 12     | Capstone : un pipeline de bout en bout           | Cours_12_Capstone_pipeli<br>ne_de_bout_en_bout                   |                  |

Les quatre titres neufs disent chacun la charnière de leur coupe : regarder puis écrire, fichiers puis base et API. Les cours qui n'ont pas de coupure nommée ici annoncent leurs séances quand ils s'écrivent ou se relisent, mesurées sur la frappe (D93). Le sous-titre des supports dit Module N/12.

Pour chaque cours : trois supports (Theorie\_NN, Labo\_NN, Exercices\_corriges\_NN), cinq familles d'exercices et environ 40 exercices, comme chez AE ; un Labo\_NN.sql généré ; aucune image (D21). Chaque labo se termine par un tableau d'état du pipeline (tables, lignes, contrôles), le même que le kit 02 affiche. Chaque cours ajoute sa part au Solution/ de la formation, et ses chiffres sortent de l'exécution de ce Solution/ sur une génération fraîche.

### L'installation, hors de la formation

Il n'y a plus de Cours 00 depuis le 2026-09-18 (D97). Le socle du poste vit dans Data\_Domain/GUIDE\_INSTALLATION.md, commun au parcours : l'environnement conda et les paquets, Git, la ligne de commande DuckDB, Docker Engine dans l'Ubuntu de WSL 2, le pilote psqLODBC, et la génération de Boréal (1 763 fichiers, 138 Mo, un peu plus d'une minute). Ce que la formation allume elle-même ouvre le cours qui s'en sert, dans une section ## Avant de commencer :

| Ce qui s'allume                   | Où           | Ce que ça monte                                                                                                      |
|-----------------------------------|--------------|----------------------------------------------------------------------------------------------------------------------|
| la plateforme et la base de l'ERP | Cours 04     | les fichiers de _univers/plateforme/ copiés (D91), la base démarrée et chargée par charger_erp.sql, 25 483 commandes |
| Airflow                           | Cours 06     | l'image construite et les cinq services sains, avec le pool entrepot                                                 |
| Spark, Grafana                    | Cours 07, 12 | à écrire avec leur cours                                                                                             |

| Ce qui s'allume  | Où       | Ce que ça monte                                                                                                             |
|------------------|----------|-----------------------------------------------------------------------------------------------------------------------------|
| TimescaleDB      | Cours 08 | à écrire avec son cours ; il ne sert qu'à la seconde séance, et son bloc peut l'attendre, comme celui d'Airflow au Cours 06 |
| Mosquitto, Kafka | Cours 09 | à écrire avec son cours ; Mosquitto dès l'ouverture, Kafka seulement à la seconde séance                                    |

## Cours 01 — Le métier, les sources et le premier regard

Le métier, ce qu'il produit, à qui il le livre. L'architecture de référence (source, ingestion, lac, entrepôt, restitution) et ses deux chemins, le froid et le chaud. La chaîne du parcours et les produits que cette formation y livre. Boréal et ses six sources, vus depuis l'amont. DuckDB, qui interroge un fichier sur place, sans serveur et sans rien charger. Et le piège qui ne plante pas : un type deviné. Lu sans précaution, un extrait de l'ERP garde ses numéros en texte, mais sa date de création ERDAT devient un entier (20240531), comme le mandant MANDT, alors que AEDAT, où traîne la date vide 00000000, reste du texte : deux colonnes de dates, deux types, et aucune erreur ne l'annonce.

| Élément       | Détail                                                                                                                                                                                                                                                                                                                                                                                                         |
|---------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Données       | le premier regard en SQL : l'historien (275 436 lignes ; qualités 192, 64 et 0 pour 275 080, 35 et 321 lignes, valeurs de départ comprises), les extraits de l'ERP (26 538 en-têtes de commande lus dans les extraits, pour 25 483 dans la base : un extrait n'est pas la base), la télémétrie (158 146 messages) ; le poids de ce qui est arrivé ; un VBAK d'extrait lu avec des types devinés, puis en texte |
| Événements    | E6 se voit dans la liste des dossiers (2023-03_bis), sans être traité                                                                                                                                                                                                                                                                                                                                          |
| Le labo livre | le dépôt 01_de et son .gitignore ; les premières requêtes ; le poids des sources, 13,7 Mo d'historien et 70,6 Mo de télémétrie ; le type deviné, constaté sur l'ERP et la télémétrie                                                                                                                                                                                                                           |
| Contrôle      | aucun : rien ne s'écrit                                                                                                                                                                                                                                                                                                                                                                                        |
| Variantes     | aucune                                                                                                                                                                                                                                                                                                                                                                                                         |
| CIMA+         | chemin chaud et chemin froid, posés ; DuckDB                                                                                                                                                                                                                                                                                                                                                                   |

## Cours 02 — Les formats de fichiers et le lac bronze

Le lac : ligne contre colonne. CSV, JSON, Avro, Parquet, ORC : ce que chacun coûte et ce qu'il rend. Compression, schéma embarqué, prédicat poussé à la lecture. La règle du bronze, qui répond au type deviné du Cours 01. Le stockage objet, le partitionnement par chemin et le piège des petits fichiers. DuckDB pour écrire et interroger du Parquet sur place.

| Élément             | Détail                                                                                                                                                                                             |
|---------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Données             | l'historien de 92 jours converti de CSV en Parquet partitionné par jour ; la télémétrie de JSON lines en Parquet imbriqué, et ses 884 fichiers quotidiens face au piège des petits fichiers        |
| Le labo livre       | les deux scripts de <code>01_de/sql/</code> ; le bronze de l'historien et de la télémétrie dans <code>plateforme/lac/bronze/</code> , la mesure de ce que le format change en taille et en vitesse |
| Règle du bronze     | chaque ligne et chaque valeur telles que reçues ; un type déclaré quand la conversion ne perd rien, du texte ailleurs ; compression zstd, un dossier par jour livré                                |
| Contrôle qui échoue | les lignes du CSV contre celles du Parquet ; une date DATS qui doit rester du texte                                                                                                                |
| Variantes           | encadrés Snowflake et Databricks                                                                                                                                                                   |
| CIMA+               | DuckDB et Parquet                                                                                                                                                                                  |

Les Cours 01 et 02 viennent de la coupe de l'ancien Cours 01, le 2026-09-18, à la charnière « regarder, puis écrire » (D99). Le premier finit sur un constat mesuré, le type deviné, sans rien écrire dans le lac ; le second ouvre sur la règle qui en découle, et écrit le bronze.

### Cours 03 — Charger des fichiers dans la couche RAW

Extraire d'un dépôt de fichiers, la voie la plus répandue : les extraits mensuels de l'ERP et des garanties, l'archive de la télémétrie, les exports de l'usine, l'instantané de la météo. Chargement complet contre chargement incrémental. La propriété qui gouverne tout, l'idempotence : un journal des chargements, et rejouer un extrait ne double rien. La couche RAW et ses règles. Et ce qui se dépose tel quel sans devenir une table : la documentation.

| Élément | Détail                                                                                                                                                                    |
|---------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Données | les extraits de 2022-01 à 2025-12, puis de 2026-01 à 2026-03 (E17) ; la télémétrie archivée ; le référentiel et la GMAO de l'usine ; l'instantané de la météo ; le corpus |

| Élément                    | Détail                                                                                                                                                                                                                                                                                |
|----------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Le piège qui ne plante pas | 2023-03_bis porte un autre nom que 2023-03 : le journal des chargements le laisse passer, et 609 commandes arrivent deux fois. Le cours le montre, le contrat du Cours 11 l'attrape, et la RAW le garde marqué de son lot pour que le test d'unicité d'AE ait quelque chose à prouver |
| Le labo livre              | la RAW : 22 tables (9 de l'ERP, 5 des garanties, 3 du référentiel et de la GMAO, 3 de la météo, la télémétrie, le catalogue du corpus) ; le corpus déposé dans le bronze ; LIVRAISON.md commencé                                                                                      |
| Contrôle                   | charger deux fois le même extrait ne change aucun compte                                                                                                                                                                                                                              |
| Poste                      | Windows seul : l'Anaconda Prompt et DuckDB                                                                                                                                                                                                                                            |
| Variantes                  | annexe Snowflake, annexe Databricks                                                                                                                                                                                                                                                   |

## Cours 04 — Lire une base et une API

Extraire d'une base relationnelle par ODBC : la base de l'ERP, dans son conteneur PostgreSQL ; le pilote comme contrat, et pourquoi on ne lit pas une base de production à l'heure de pointe. D'une API REST : la vraie API d'ECCC (`api.weather.gc.ca`), sa pagination, sa limitation de débit, la reprise sur erreur, comparée à l'instantané figé. Filigrane sur la date de modification des commandes (AEDAT) ; capture de changements par requête, sur les documents de modification CDHDR et CDPOS, et la capture par journal annoncée (la synthèse Aurore la fait). MQTT, REST et ODBC comparés : qui pousse, qui tire, ce que chacun garantit ; MQTT est traité au Cours 09.

| Élément       | Détail                                                                                                                                                                               |
|---------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Données       | la base au 2025-12-31 (25 483 commandes), puis au 2026-03-31 (27 185) ; les 49 documents de modification du palier du 2024-07-01 (E8) ; la vraie API d'ECCC                          |
| Le labo livre | la plateforme reçue et la base de l'ERP montée ; ses neuf tables tirées par ODBC, à 0 écart de la RAW ; le filigrane de décembre égal à l'extrait ; 92 jours de météo tirés de l'API |
| Contrôle      | l'état reconstruit depuis les extraits égale la base sur les neuf tables                                                                                                             |
| Poste         | Ubuntu et Docker pour la base, le pilote ODBC, Internet pour l'API                                                                                                                   |
| Variantes     | aucune                                                                                                                                                                               |

| Élément        | Détail                                                                                                                                                                                                                                                                        |
|----------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Avant d'écrire | le correctif de <code>verifier_sql.py</code> (D24) ; l'essai de <code>lancer_depuis</code> hors de la formation et d'un <code>.sql</code> à deux moteurs ; l'essai d'ODBC depuis Windows vers le conteneur de WSL 2 ; les faits des plateformes et de l'API d'ECCC revérifiés |
| CIMA+          | REST, ODBC, et MQTT, REST et ODBC comparés                                                                                                                                                                                                                                    |

Les Cours 03 et 04 viennent de la coupe de l'ancien Cours 02, le 2026-09-18, à la charnière « fichiers, puis base et API » (D99) : le lecteur finit le premier sans avoir ouvert Ubuntu.

### Cours 05 — Le code d'un pipeline robuste

Ce qui sépare un script d'un pipeline : la configuration hors du code, les secrets hors du dépôt (le mot de passe de la base de l'ERP), une journalisation exploitable, les reprises avec temporisation exponentielle (l'API d'ECCC), les tests d'une transformation, l'empaquetage et l'exécution en conteneur. Le langage Python lui-même reste à la formation Python.

Une règle de conception sert tout le parcours : le pipeline a une seule porte d'entrée en ligne de commande, que le DAG du Cours 06 appelle et que le kit 02 rejoue sans Airflow. Le chemin que rejoue le kit n'importe que DuckDB et la bibliothèque standard.

| Élément       | Détail                                                                                                                                                                                                                                                                                                                        |
|---------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Données       | les ingestions des Cours 02 à 04, reprises en paquet Python dans <code>01_de/</code>                                                                                                                                                                                                                                          |
| Le labo livre | la configuration, le <code>.env</code> hors du dépôt, les journaux, les reprises, des tests <code>pytest</code> (le journal refuse un extrait déjà chargé, la conversion garde le compte des lignes, la reprise s'arrête après le nombre d'essais prévu), une image Docker du pipeline lancée sur <code>sources/</code> monté |
| Variantes     | aucune                                                                                                                                                                                                                                                                                                                        |

### Cours 06 — Orchestration avec Airflow

Le graphe acyclique dirigé comme façon de penser. Tâches, dépendances, planification, intervalle de données, rattrapage, nouvelle tentative, capteurs, alertes de retard. Ce qui rend un DAG rejouable, et pourquoi un DAG qui n'est pas idempotent est une bombe à retardement. La couture avec `dbt build`.

| Élément | Détail                                                                                                           |
|---------|------------------------------------------------------------------------------------------------------------------|
| Données | un DAG quotidien (historien, télémétrie, météo) et un DAG mensuel (extraits de l'ERP et des garanties, compteur) |

| Élément        | Détail                                                                                                                                                                                                                |
|----------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Événements     | les mois de 2026 (E17) : régénérer avec --jusqua 2026-03, laisser Airflow rattraper trois mois, et constater que l'état égale un chargement d'un bloc                                                                 |
| Le labo livre  | les deux DAG dans 01_de/, Airflow 3 en conteneurs ; la tâche qui lancera dbt build, posée en attente : AE la remplit                                                                                                  |
| Variantes      | encadrés Snowflake et Databricks                                                                                                                                                                                      |
| Avant d'écrire | fait le 2026-09-16 : la pile tient, l'entrepôt de Windows s'écrit depuis un conteneur, le rattrapage égale le bloc, et les SLA d'Airflow 2 sont devenus les Deadline Alerts. Restent quatre choix de forme à trancher |

## Cours 07 — Traitement distribué avec Spark

Quand une machine ne suffit plus, et surtout quand elle suffit encore. Partitions, évaluation paresseuse, brassage, l'API DataFrame. Lire le plan d'exécution. Les pièges classiques : le brassage inutile, la partition déséquilibrée, le `collect` qui ramène tout au pilote.

| Élément                 | Détail                                                                                                                                                                                                                                                    |
|-------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Données                 | l'historien complet (731 jours, 2 133 145 lignes, 106 Mo, --historien complet) et la télémétrie : le même traitement en DuckDB et en Spark (conversion en Parquet partitionné, agrégats quotidiens par étiquette, messages dédoublonnés par jour), mesuré |
| Ce que le cours conclut | DuckDB suffit à Boréal. Le cours dit d'où viendrait le besoin (des dizaines d'usines, des années de points bruts), sans le simuler                                                                                                                        |
| Partition déséquilibrée | les étiquettes qui bougent sans cesse contre les états de marche, qui ne gardent presque aucun point                                                                                                                                                      |
| Variantes               | annexe Databricks, encadré Snowpark                                                                                                                                                                                                                       |
| Avant d'écrire          | fait le 2026-09-16 : Spark 4.2.0 en conteneur rend les mêmes chiffres que DuckDB, 27 à 120 fois plus lentement, et les limites de Free Edition sont revérifiées. Restent deux choix de forme à trancher                                                   |
| CIMA+                   | Databricks, repris                                                                                                                                                                                                                                        |

## Cours 08 — Données de terrain : SCADA, historien et séries temporelles

D'où vient la donnée industrielle : le capteur, l'automate, le SCADA qui supervise et commande, OPC UA comme langue commune des équipements. L'historien, qui archive les points à haute fréquence : compression par bande morte, qualité du point, étiquettes et hiérarchie des actifs. Les bases de séries temporelles ouvertes : ce qu'elles font mieux qu'un entrepôt, et moins bien. Les pièges du terrain : trous, horloges, heure locale, rééchantillonnage, unités. Et la frontière qui gouverne tout : on ne branche jamais un pipeline sur le réseau de contrôle ; la séparation des technologies opérationnelles et des technologies de l'information existe pour la sécurité.

| Élément             | Détail                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                               |
|---------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Données             | l'usine de Val-des-Aulnes : 6 zones, 17 équipements, 58 étiquettes ; l'historien de 182 jours que le Cours 07 laisse (550 087 lignes), le référentiel, la GMAO (825 bons), le compteur (148 891 relevés)                                                                                                                                                                                                                                                                                                                                                                                                             |
| Les pièges, un à un | les valeurs de départ (10 556 lignes, 58 par jour) ; l'archivage forcé de minuit (10 525 points, et non 10 556 : quatre jours en perdent 31) ; le retour à l'heure normale du 2025-11-02 (E1, 49 paires en double) et le passage à l'heure avancée du 2026-03-08, qui laisse une heure vide ; l'humidité de la cabine de peinture figée 49,8 heures à qualité bonne (E2), et son faux jumeau, la ligne des motomarines à l'arrêt 790 heures ; 529 points de qualité mauvaise, sans valeur, et 64 de qualité douteuse (E3) ; le compteur horodaté en fin d'intervalle avec son décalage à UTC, et 247 relevés estimés |
| L'argent            | les points dédoublonnés, l'horodatage résolu en UTC, la qualité portée ; le rééchantillonnage horaire (moyenne pondérée par le temps pour une mesure, dernier état pour une marche, différence pour un compteur) ; l'énergie horaire du compteur. Le grain exact se fixe au cours                                                                                                                                                                                                                                                                                                                                    |
| L'incident          | UTL . CMP2 . VIBRATION monte dès le 2025-10-15 ; le compresseur 2 déclenche le 2025-10-28 à 10 h 44 (bon BT-2025-00742)                                                                                                                                                                                                                                                                                                                                                                                                                                                                                              |
| Le labo livre       | plateforme/lac/argent/usine/, le schéma argent, TimescaleDB chargée (hypertable, agrégat continu horaire), comparée à DuckDB                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         |
| Variantes           | aucune                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                               |
| Avant d'écrire      | l'essai de TimescaleDB et de Grafana alimentés par un rejoueur MQTT (essai à faire avant d'écrire le cours)                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          |
| CIMA+               | SCADA et historien, base de séries temporelles                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                       |

La charnière, posée le 2026-09-18 avant l'écriture (D93, D99) : d'où viennent les points, puis ce qu'on en sert. La formation compte douze cours, et celui-ci reste un seul cours : la charnière y pose une coupure nommée entre deux séances d'environ deux heures et demie, comme le Labo 06 après son étape 5. Chaque séance se tient seule. La première finit sur des pièges comptés, la seconde sur une série horaire prouvée.

|                  | Première séance : le terrain et ses pièges                                                                                                                                                                                                                                                    | Seconde séance : l'argent et la base de séries temporelles                                                                                                                                                                                          |
|------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Théorie          | le capteur, l'automate, le SCADA et OPC UA ; l'historien, la bande morte, la qualité du point, les étiquettes et la hiérarchie des actifs ; la frontière entre technologies opérationnelles et technologies de l'information ; les pièges du terrain, trous, horloges, heure locale et unités | le nettoyage : points dédoublonnés, heure résolue en UTC, qualité portée ; le rééchantillonnage selon la nature du point ; les bases de séries temporelles, ce qu'elles font mieux qu'un entrepôt et moins bien, et la licence de l'agrégat continu |
| Labo             | le référentiel, la GMAO et le compteur ; les six pièges de la ligne « Les pièges, un à un », mesurés sur le bronze de l'historien et sur le compteur ; l'incident, lu dans les points et dans le bon de travail                                                                               | l'argent de l'usine dans plateforme/lac/argent/usine/ et dans le schéma argent ; l'énergie horaire du compteur ; TimescaleDB chargée, avec son hypertable et son agrégat continu                                                                    |
| Fin de la séance | chaque piège compté, au chiffre de la fiche                                                                                                                                                                                                                                                   | l'agrégat continu égale le rééchantillonnage de DuckDB                                                                                                                                                                                              |
| Service          | aucun                                                                                                                                                                                                                                                                                         | TimescaleDB                                                                                                                                                                                                                                         |

## Cours 09 — Streaming et événements : MQTT et Kafka

Le contraste avec le lot : ce que le temps réel apporte, ce qu'il coûte. MQTT, le protocole léger du terrain : un courtier, la publication et l'abonnement, des sujets hiérarchiques, trois niveaux de qualité de service, le message retenu. Kafka, quand le flux doit être conservé et relu : sujets, partitions, clés, décalages, groupes de consommateurs. Le pont entre les deux. Sémantique de livraison, fenêtrage, données en retard. L'architecture Lambda, qui garde les deux chemins séparés, et Kappa, qui ne garde que le flux. Et la question honnête : la plupart des besoins dits « temps réel » sont des besoins horaires.

| Élément | Détail                                                                                                                                                                                                                                        |
|---------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Données | les rejoueurs de _univers/rejoueurs/, écrits à la séance de ce cours : l'usine (les points de l'historien d'une fenêtre choisie, en accéléré) et la télémétrie (boreal/vehicules/<numéro de série>/sorties, avec ses retards et ses doublons) |

| Élément                      | Détail                                                                                                                                                                                                                                     |
|------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Événements                   | 2 303 doublons de la qualité de service 1 ; 5 581 messages reçus plus d'une heure après la fin de leur sortie (E12) ; la dérive du compresseur 2 (E5)                                                                                      |
| Le labo livre                | l'abonnement, le pont MQTT vers Kafka, un consommateur qui écrit dans TimescaleDB, une fenêtre de 15 minutes sur la vibration du compresseur 2 et son alerte : la date où elle se lève pendant la dérive, et l'avance sur le déclenchement |
| Ce que le cours montre aussi | l'archive quotidienne de la télémétrie est ce qu'écrit un abonné : le chemin froid la ramasse le lendemain                                                                                                                                 |
| Variantes                    | encadrés Snowflake et Databricks                                                                                                                                                                                                           |
| Avant d'écrire               | les rejeuteurs écrits et prouvés (les messages publiés égalent l'archive) ; Kafka en mode KRaft dans son image officielle, revérifié                                                                                                       |
| CIMA+                        | MQTT ; chemin chaud et chemin froid, Lambda et Kappa                                                                                                                                                                                       |

La charnière, posée le 2026-09-18 avant l'écriture (D93, D99) : le terrain qui publie, puis le flux qu'on garde et qu'on relit. Comme au Cours 08, un seul cours et une coupure nommée entre deux séances. La première finit quand un abonné reçoit ce que les rejeuteurs publient, doublons et retards compris ; la seconde garde le flux dans Kafka, le relit par fenêtres et en tire l'alerte.

|         | Première séance : MQTT, le terrain qui publie                                                                                                                                                                                                                       | Seconde séance : Kafka, le flux qu'on garde                                                                                                              |
|---------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------|
| Théorie | ce que le temps réel apporte et ce qu'il coûte, et la question honnête des besoins horaires ; MQTT : le courtier, la publication et l'abonnement, les sujets hiérarchiques, les trois niveaux de qualité de service, le message retenu ; la sémantique de livraison | Kafka : sujets, partitions, clés, décalages, groupes de consommateurs ; le pont entre les deux ; le fenêtrage et les données en retard ; Lambda et Kappa |
| Labo    | les rejeuteurs de l'usine et de la télémétrie ; l'abonnement ; les doublons de la qualité de service 1 et les messages en retard, vus à la réception ; l'archive quotidienne reconnue comme ce qu'écrit un abonné                                                   | le pont MQTT vers Kafka ; le consommateur qui écrit dans TimescaleDB ; la fenêtre de 15 minutes sur la vibration du compresseur 2, et son alerte         |

|                  | Première séance : MQTT, le terrain qui publie | Seconde séance : Kafka, le flux qu'on garde                            |
|------------------|-----------------------------------------------|------------------------------------------------------------------------|
| Fin de la séance | les messages publiés égalent l'archive        | l'alerte datée pendant la dérive, avec son avance sur le déclenchement |
| Service          | Mosquitto                                     | Kafka en mode KRaft                                                    |

## Cours 10 — Formats de table ouverts, lakehouse et médaillon

Iceberg et Delta : des transactions ACID sur des fichiers. Évolution de schéma, voyage dans le temps, compactage. L'architecture médaillon : le bronze garde la donnée telle que reçue, l'argent la nettoie et la rend conforme, l'or la prépare pour la consommation. La correspondance avec RAW, STAGING et MARTS, l'endroit où elle cloche, et la réponse du parcours : DE tient l'argent des séries de terrain, et les sources relationnelles passent de la RAW au STAGING d'AE (D32). La convergence du lac et de l'entrepôt, et les lakehouses clés en main.

| Élément        | Détail                                                                                                                                                                                                                                                                                                                                                                                                      |
|----------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Données        | la télémétrie du bronze en Iceberg : le micrologiciel 2.0 (E11, dès le 2025-05-01, 68 469 messages) ajoute heures_moteur et renomme temp_moteur_max en temperature_moteur_max, ce qui en fait un cas d'évolution de schéma ; les mois de 2026 en nouveaux instantanés, et le voyage dans le temps vers l'état au 2025-12-31 ; le compactage des 884 fichiers quotidiens ; les séries de l'argent en Iceberg |
| Le labo livre  | le lac en tables Iceberg, lues par DuckDB ; la même table en Delta, pour comparer                                                                                                                                                                                                                                                                                                                           |
| Variantes      | annexe Snowflake, annexe Databricks, encadré Fabric                                                                                                                                                                                                                                                                                                                                                         |
| Avant d'écrire | l'essai de Pylceberg avec un catalogue SQL local et de la lecture par DuckDB                                                                                                                                                                                                                                                                                                                                |
| CIMA+          | médaille, formats de table ouverts, Fabric                                                                                                                                                                                                                                                                                                                                                                  |

## Cours 11 — Qualité, contrats et observabilité

Le contrat de données entre producteur et consommateur. Valider à l'entrée plutôt que déboguer en aval. Fraîcheur, volume, distribution, unicité, et pour un capteur, la plage physiquement possible. Bloquer ou avertir, et pourquoi ce n'est pas le même choix pour chaque contrat. Lignage, alerte utile contre alerte ignorée, conduite d'un incident de données. La parenté avec les tests dbt, dite explicitement.

| Élément                       | Détail                                                                                                                                                                                                                                                                                                                                                                                                                |
|-------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Données                       | un contrat par produit livré, qui porte ses attendus (D64)                                                                                                                                                                                                                                                                                                                                                            |
| Ce que les contrats attrapent | l'extrait 2023-03_bis identique à 2023-03 (E6) ; la commande 0010015405 d'un concessionnaire absent de l'extrait 2024-05 (E7) ; le champ renommé du micrologiciel 2.0 (E11) ; le capteur figé (E2) ; les valeurs hors de la plage de etiquettes.csv et les coupures (E3) ; la pression instable du réseau d'air pendant la dérive du compresseur 2, par un contrôle de distribution sur les heures de production (E5) |
| Le labo livre                 | les contrats, leur exécution dans le DAG, le compte des alertes vraies et fausses, le post-mortem d'un incident de données                                                                                                                                                                                                                                                                                            |
| Variantes                     | encadrés Snowflake et Databricks                                                                                                                                                                                                                                                                                                                                                                                      |
| Avant d'écrire                | le contrôle de la pression bâti sur la vraie sortie, et ses fausses alertes comptées hors de la dérive                                                                                                                                                                                                                                                                                                                |

## Cours 12 — Capstone : un pipeline de bout en bout

Détail en section 7.

### 7. Le capstone

Il boucle le projet Boréal de la formation (D14) : les deux chemins, de bout en bout, sur les sources générées jusqu'au 2026-03-31.

| Chemin | Ce qui tourne                                                                                                                                                                                                                                                  | Ce qui le prouve                                                                                     |
|--------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------|
| Froid  | Airflow orchestre l'ERP par ses extraits et l'extraction ODBC qui retrouve la même base, l'historien, la GMAO, le compteur, les garanties, la météo par l'API, la télémétrie archivée et le corpus ; le bronze, l'argent et la RAW ; les contrats qui bloquent | le projet se reconstruit de zéro ; l'état final égale LIVRAISON.md ; chaque contrat rend son attendu |
| Chaud  | les rejoueurs de l'usine et de la télémétrie, Mosquitto, le pont, Kafka, TimescaleDB, Grafana et l'alerte de vibration                                                                                                                                         | l'alerte se lève pendant la dérive, à la date calculée au Cours 09                                   |

Ce que le capstone livre : le dépôt 01\_de complet, la pièce de portfolio ; LIVRAISON.md complet ; le tableau de bord Grafana de l'usine (état du réseau d'air, vibration et température du compresseur 2, alerte), que BI reprend pour en concevoir la lecture ; le Solution/ que rejouent le kit 02 et, au lot 7, le kit 03 (TimescaleDB chargée et rejoueur). L'incident vu depuis l'amont tient en trois faits : la date de l'alerte, le contrat qui a vu la pression instable, et une RAW où AE retrouvera la plage des motoneiges touchées.

8. La synthèse, et le mini-cas

D96 n'en garde qu'une par formation, la plus avancée : Aurore. Elle suit le capstone (D14), repart des données brutes générées (D15) et suit le modèle d'AE (D16) : une mise en situation, un document unique qui refait l'arc de la formation d'un bloc, un dossier Solution/ rejouable, sans notes ni examens.

La Brûlerie change de rôle : elle devient le mini-cas figé du premier pas, et non plus une synthèse (D96, D110). Ses données ne se génèrent plus chez le lecteur : la sortie de --extrait mois de juin 2025, avec graines/ et ses empreintes, est versionnée, et le générateur quitte son chemin. La section 8.1 ci-dessous décrit encore l'ancienne synthèse ; elle se réécrit à la séance qui l'écrira, pas avant.

8.1 La Brûlerie, l'ancienne synthèse, à refaire en mini-cas figé

Synthese\_La\_Brulerie\_facile/ : Mise\_en\_situation\_La\_Brulerie\_01\_DE.md (D126), Synthese\_brulerie.md, Solution/. Données : le mini-cas figé, \_univers/brulerie/mini\_cas/sources/, un mois de caisse versionné, 100 fichiers et 0,9 Mo (A5.10). Le lecteur ne génère rien, et l'arc se refait sur ce mois-là.

| Arc refait                     | Sur La Brûlerie                                                                                                                                       |
|--------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------|
| Formats, ingestion idempotente | les exports quotidiens de la caisse, en bronze Parquet partitionné par jour ; l'export repris du 2025-06-12 (L5) : garder le dernier export d'un jour |
| La RAW                         | le catalogue, la fidélité et la météo de Montréal                                                                                                     |
| Terrain et continu             | le torréfacteur du mois, rejoué en MQTT                                                                                                               |
| Orchestration                  | un DAG quotidien sur les journées du mois                                                                                                             |
| Contrat                        | la caisse recomptée : les totaux de preuves/totaux_mensuels.sql, que le générateur écrit lui-même dans preuves/totaux_attendus.csv (A5.20)            |
| Ce qu'on n'installe pas        | ni Spark, ni Kafka, ni Iceberg : un petit commerce n'en a pas besoin, et la synthèse le dit                                                           |

8.2 Aurore, avancée

Synthese\_Aurore\_avancee/ : Mise\_en\_situation\_Aurore\_01\_DE.md (D126), Synthese\_aurore.md, Solution/. Données : \_univers/aurore/generer\_aurore.py (40 Mo, 305 Mo décompressés), puis --jusqua 2026-03.

| Arc refait                         | Sur Aurore                                                                                                                                                                                                                                                              |
|------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Capture de changements par journal | la copie de la base chargée dans PostgreSQL, puis le journal au format de Debezium rejoué jusqu'à la RAW : l'instantané initial, les opérations, la ligne avant réduite à la clé en REPLICA IDENTITY DEFAULT, les décimaux en texte, les dates en jours depuis 1970     |
| Idempotence                        | les sept heures republiées au redémarrage du connecteur, le 2024-10-08 (A5)                                                                                                                                                                                             |
| Évolution de schéma                | la colonne ajoutée à la table des commandes le 2025-01-20 (A6)                                                                                                                                                                                                          |
| Preuve                             | le journal rejoué égale la copie de la base (preuves/verifier_journal.py)                                                                                                                                                                                               |
| Continu                            | les 408 074 événements web rejoués dans Kafka : fenêtres, retards, doublons ; la version 2 du format (A7, 2025-06-02) attrapée par un contrat ; le robot du 2024-09-09 au 2024-09-20 (A8) signalé sans être retiré, parce que l'écarter est une décision de BI et de DS |
| La RAW                             | les tables de l'application, les événements web, les taux de change réels de la Banque du Canada                                                                                                                                                                        |

Les rejoueurs de `_univers/rejoueurs/` couvrent les quatre flux (usine, télémétrie, torréfacteur, web) par un seul script, qui lit un flux généré et le publie sur MQTT ou sur Kafka. Il dépend de paquets déclarés, comme le permet la règle des générateurs.

## 9. Le kit 02

La sortie de DE devient l'entrée d'AE (D10, D11, D35) : le kit reconstruit ce que DE aurait livré, en rejouant le `Solution/` de DE.

| Élément       | Détail                                                                                                                                                                                                                                                                                                                                                                                                               |
|---------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Commande      | <code>python _univers/kits/demarrer.py --formation 02 --projet Projet_Boreal</code>                                                                                                                                                                                                                                                                                                                                  |
| Ce qu'il fait | génère les sources si elles manquent, ou vérifie leurs empreintes ; rejoue le chemin froid du <code>Solution/</code> par sa ligne de commande, sans Airflow, Kafka, Spark ni Docker ; écrit <code>raw</code> et <code>argent</code> dans l'entrepôt, le lac bronze et argent, une copie Parquet de chaque table livrée ; affiche l'état, le compare aux attendus et passe les contrôles de <code>LIVRAISON.md</code> |

| Élément     | Détail                                                                                                                                                                                |
|-------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Options     | --jusqua 2026-03 ; --historien complet, pour le kit 04 ; --verifier, qui passe les contrôles de DE sur le projet d'un apprenant (M3) ; --catalogue, le catalogue du script Databricks |
| Dépendances | duckdb seulement                                                                                                                                                                      |
| Durée       | 2 minutes visées ; la durée mesurée, génération comprise, est dans _univers/kits/README.md                                                                                            |
| Plateformes | un script de chargement généré pour Snowflake, un pour Databricks, sans identifiant de compte ; vous les exécutez                                                                     |
| Preuve      | deux exécutions sur une copie jetable du projet, mêmes comptes et mêmes sommes de contrôle, l'heure de chargement exclue ; le chargement sur Databricks Free Edition, fait par vous   |