

Table des matières

Data Engineering — plan des modules	1
1. Ce que cette formation est, et ce qu'elle n'est pas	1
2. Ce qui entre, ce qui sort	2
3. La pile et le poste de travail	4
4. Le projet de l'apprenant	7
5. Les recoupements	7
6. Les douze cours	9
7. Le capstone	20
8. La synthèse, et le mini-cas	21
9. Le kit 02	22

Data Engineering — plan des modules

Écrit le 2026-08-31, amendé le 2026-09-11 pour les données industrielles, révisé le 2026-09-15. Ce fichier n'est pas un support de cours : c'est le plan de la formation, ce qu'elle promet, ce qu'elle livre et dans quel ordre. Il se lit pour juger la conception plutôt que pour apprendre.

Ce qui change à la révision. Les onze modules, leurs frontières, les quatre supports par cours et l'encadré de recoupements restent. Le fil rouge passe de la Régie du Val-Clair à Véhicules Boréal inc. La formation livre des produits nommés (la couche RAW, les séries de l'usine) que les formations suivantes consomment. Chaque cours dit ses données, ses événements plantés et ses variantes Snowflake et Databricks. Un capstone, une synthèse et le kit 02 ferment la formation.

Les chemins sont relatifs à la racine du parcours. Les numéros D désignent une décision de conception, les numéros E un événement planté dans les données du fil rouge : ce sont des références internes, citées ici pour que chaque choix soit traçable. Les chiffres cités sont la sortie réelle du générateur de données, jamais une estimation.

1. Ce que cette formation est, et ce qu'elle n'est pas

Elle couvre l'amont de la chaîne : faire arriver la donnée, la ranger, la faire tourner à l'heure, et prouver qu'elle est bonne. Elle s'arrête là où commence la transformation métier : à la couche RAW comprise pour les sources relationnelles et les événements, aux séries nettoyées pour les données de terrain (D32).

Formation	Ce qu'elle possède	Frontière avec Data Engineering
SQL avancé	le langage	DE écrit du SQL sans l'enseigner ; chaque notion SQL reçoit un renvoi nommé
Snowflake	la plateforme d'entrepôt	DE y livre dans ses annexes, sans l'administrer
Analytics Engineering	la transformation et la modélisation	DE livre la RAW et les séries de l'usine ; AE commence au STAGING. DE ne décode pas les codes SAP, ne dédouble pas les clients et ne joint pas deux sources
Business Intelligence	la restitution	DE monte Grafana sur la base de séries temporelles et y branche l'alerte ; la lecture du tableau de bord appartient à BI
Data Science	la modélisation statistique	DE sert les séries longues de l'usine et la météo, sans construire de modèle
Machine Learning Engineering	le pipeline de modèle	MLE réemploie les conteneurs et Airflow de DE ; DE ne sert aucun modèle
AI Engineering	la récupération augmentée	DE dépose le corpus tel quel dans le lac ; le découpage et l'indexation appartiennent à AI
Architecture et Gouvernance	les règles et la cible	DE écrit et exécute les contrats techniques ; Archi en fait des engagements entre équipes
Linux, Python	le système, le langage	DE suppose le terminal et la syntaxe acquis

La règle des renvois de `_commun/STYLE.md`, section 5, s'applique : une notion qui appartient à une autre formation n'est pas réexpliquée, elle est renvoyée nommément.

2. Ce qui entre, ce qui sort

2.1 Les entrées

Les six sources de Boréal, telles que ses systèmes les livrent, fabriquées par `_univers/boreal/generer_boreal.py` dans `Projet_Boreal/sources/`. DE ne consomme le produit d'aucune autre formation : le générateur lui suffit, et aucune porte d'entrée n'est à écrire (D12).

Source	Ce qui arrive dans sources/	Défauts qui servent DE	Cours
ERP	erp/extraits/AAAA-MM/, un CSV par table SAP ; erp/postgresql/, la copie de la base et charger_erp.sql	l'extrait de mars 2023 livré deux fois (E6), une commande avant la fiche de son concessionnaire (E7), des textes NUMC à zéros de tête et des dates DATS à 00000000, les documents de modification (E8), les mois de 2026 (E17)	01, 03, 04, 06, 11
Usine	usine/historien/, un CSV par jour ; usine/referentiel/ ; usine/gmao/ ; usine/compteur/, un CSV par mois	valeurs de départ, archivage forcé de minuit, heure locale sans fuseau et collisions (E1), capteur figé (E2), coupures et valeurs aberrantes (E3), dérives et pannes (E4, E5), dates JJ/MM/AAAA HH:MM, compteur horodaté en fin d'intervalle avec son décalage à UTC, relevés estimés	01, 02, 07, 08, 09, 11
Garanties	garanties/AAAA-MM/ : clients, enregistrements, visites et consentements en CSV, réclamations en JSON	données personnelles, une réclamation qui revient à chaque changement de statut, un effacement (E14)	03, 11
Télémetrie	telemetrie/sorties_AAAA-MM-JJ.jsonl, ce qu'écrit l'abonné du courtier MQTT	doublons de la qualité de service 1, messages en retard (E12), un champ ajouté et un champ renommé (E11)	01, 02, 03, 09, 10, 11
Corpus	corpus/ : documents HTML et Markdown, catalogue index.csv	des documents qui paraissent à leur date	03
Météo	meteo/, l'instantané figé d'ECCE ; la vraie API au Cours 04	trous et drapeaux de qualité de la vraie donnée	03, 04

2.2 Les sorties

Produit	Forme	Où	Consommé par	Kit
La couche RAW	une table par fichier livré, en texte, avec ses colonnes de lignage (D60)	schéma raw de l'entrepôt DuckDB, et une copie Parquet par table	AE, cours du STAGING ; Archi	02
Les séries de l'usine	les étiquettes de l'historien et l'énergie du compteur, nettoyées et rééchantillonnées	plateforme/lac/argent/, et schéma argent de l'entrepôt (D61)	AE (étoile de l'usine) ; DS (maintenance prédictive, prévision de la demande) ; MLE	02, et 04 avec l'historien complet
Le lac bronze et argent	Parquet partitionné, puis tables Iceberg	plateforme/lac/	Archi, Cours 01	07
La base de séries temporelles et le flux rejouable	TimescaleDB chargée, le rejoueur MQTT de _univers/rejoueurs/	le docker compose du Solution/ de DE	BI, son cours Grafana	03
Le corpus déposé tel quel	les fichiers, et raw.corpus_index	plateforme/lac/bronze/corpus/	AI, Cours 02	06
Les contrats de données	YAML et requêtes de contrôle	le dépôt 01_de	AE (ses tests prennent le relais) ; Archi, Cours 05	07
Le DAG et les conteneurs	DAG Airflow, Dockerfile, docker compose	Cours/Solution/	MLE, Cours 01 et 04	aucun : de l'outillage

Chaque produit est décrit dans Cours/Solution/LIVRAISON.md : ses tables, ses colonnes de lignage, ses comptes attendus, le cours qui le fabrique et la commande du kit qui le reconstruit. C'est le document que les formations suivantes citent quand elles nomment ce qu'elles reçoivent (D12). Il commence au Cours 03 et se complète au Cours 12.

3. La pile et le poste de travail

3.1 La pile

Python et des outils ouverts, en local (D13). DuckDB est le moteur de référence des labos : il lit CSV, JSON, Parquet et Iceberg sans serveur. Les services tournent en conteneurs. Spark et Kafka ne sortent que dans les cours dont ils sont le sujet, et rien n'oblige à ouvrir un compte infonuagique.

Outil	Rôle	Où il tourne	Dès le cours
Python 3.11, environnement conda formations	le code du pipeline	Windows	01
DuckDB, paquet et ligne de commande	le SQL des labos, l'entrepôt local	Windows	01
Git	le dépôt 01_de	Windows	01
Docker Engine, docker compose	les services	l'Ubuntu de WSL 2 (D59)	04
PostgreSQL 18	la base de l'ERP de Boréal	conteneur, port 5433 : le 5432 reste à un PostgreSQL déjà installé, celui de la formation SQL avancé par exemple	04
psqlODBC, pyodbc	l'extraction par ODBC	Windows	04
Airflow 3	l'orchestration	conteneurs	06
Spark 4	le traitement distribué	conteneur : sous Windows, Spark demande une version de Java précise et des utilitaires Hadoop (à révéifier à l'essai)	07
TimescaleDB	la base de séries temporelles	conteneur	08
Mosquitto, Kafka en mode KRaft	le chemin chaud	conteneurs	09
Pylceberg, deltalake	les formats de table ouverts	Windows	10
Grafana	le tableau de bord du chemin chaud	conteneur	12

3.2 Le poste de l'auteur, constaté le 2026-09-15

Élément	État
Windows	10 Famille, 22H2 (build 19045)
Mémoire	32 Go, dont 15 Go laissés à WSL 2
WSL 2	version 2.7, Ubuntu 26.04 LTS, systemd actif, sans Docker

Élément	État
Docker	absent ; des restes d'un Docker Desktop désinstallé (la distribution docker-desktop de WSL et deux dossiers de configuration)
PostgreSQL	18, installé en natif
DuckDB	1.5.5, paquet et ligne de commande
Java	23

Faits vérifiés le 2026-09-15 : Airflow ne tourne pas nativement sous Windows (WSL 2 ou conteneurs, selon sa documentation) ; Kafka non plus, en pratique ; Docker ne soutient Docker Desktop que sur les versions de Windows encore dans le calendrier de service de Microsoft, que Windows 10 a quitté le 2025-10-14, et sa page d'installation ne nomme que les éditions Pro, Entreprise et Éducation.

3.3 Les variantes Snowflake et Databricks

Reprises de la charte commune du parcours. Une annexe quand le lecteur fait autre chose, un encadré quand la plateforme change un concept sans changer le geste. Les faits de chaque plateforme se revérifient avant d'écrire, aucun script ne porte d'identifiant de compte, et c'est vous qui les exécutez.

Cours	Snowflake	Databricks	Forme
02 Formats de fichiers et lac bronze	micro-partitions	fichiers Delta	encadré
03 Charger des fichiers dans la RAW	stage interne, COPY INTO, Snowpipe, schéma transient ; les quatre remarques de relecture d'AE sur le stage, le schéma transient et les rôles	volume Unity Catalog, COPY INTO, Auto Loader	annexe
06 Orchestration	tâches	Jobs	encadré
07 Spark	Snowpark	Spark serverless de Free Edition, le terrain même du cours	annexe Databricks, encadré Snowflake
09 Streaming	Snowpipe Streaming, Streams et Tasks	Structured Streaming	encadré
10 Formats de table ouverts	tables Iceberg	Delta, Unity Catalog ; encadré Fabric	annexe
11 Qualité	fonctions de mesure de la qualité	attentes des pipelines déclaratifs	encadré

4. Le projet de l'apprenant

Décision D33 : un seul dossier `Projet_Boreal/`, ignoré par le dépôt des formations, qui porte une plateforme partagée et un dépôt Git par formation.

Dossier	Contenu	Qui l'écrit
<code>Projet_Boreal/sources/</code>	la sortie du générateur	<code>generer_boreal.py</code>
<code>Projet_Boreal/plateforme/lac/bronze/</code> , <code>argent/</code>	Parquet, puis Iceberg	DE
<code>Projet_Boreal/plateforme/entrepot/</code>	l'entrepôt DuckDB en un seul fichier, <code>boreal.duckdb</code> (D67), schémas <code>raw</code> et <code>argent</code> ; les autres viendront avec AE et MLE	DE
<code>Projet_Boreal/01_de/</code>	votre dépôt : le code du pipeline, les DAG, le <code>docker-compose.yml</code> , les contrats, les tests	vous

La ligne de commande DuckDB se lance depuis `Projet_Boreal/`, et le code depuis `01_de/` (D62). Les synthèses suivent la même forme dans `Projet_Brulerie/` et `Projet_Aurore/`, eux aussi ignorés par Git.

5. Les recoupements

Décision prise avec vous le 2026-08-31 : chaque théorie se termine par un encadré court, une ligne par formation voisine, qui dit ce qui est commun et qui possède la matière. Le contenu de chaque encadré est fixé ici.

Cours	Recoupe	Ce que l'encadré doit dire
01	AE, DS	Les métiers se partagent la même chaîne. DE livre la RAW et les séries de l'usine ; AE prend la suite au STAGING, DS consomme les séries.
02	Snowflake	Les micro-partitions de Snowflake sont le partitionnement d'un lac, appliqué en interne.
03	AE, Snowflake	COPY INTO et Snowpipe se voient côté plateforme dans la formation Snowflake ; ici, la mécanique générale. Les codes SAP que la RAW garde tels quels se décodent au STAGING d'AE.

Cours	Recoupe	Ce que l'encadré doit dire
04	SQL	Les Cours 10 et 11 de SQL possèdent le plan de requête et l'index, la lecture longue et les versions de lignes ; ici, ce qu'ils changent pour qui extrait d'une base.
05	Python, Linux	Le langage et le terminal appartiennent aux deux autres formations ; ici, seulement ce qui rend un pipeline rejouable.
06	AE, MLE	dbt build dans un DAG est le point de couture avec AE. Le DAG d'entraînement de MLE réemploie l'outil.
07	SQL	Le plan d'exécution de Spark et celui d'un moteur SQL résolvent le même problème. Renvoi au Cours 10 de SQL.
08	SQL, DS	Le Cours 09 de SQL possède les séries temporelles et les jointures as-of ; ici, d'où viennent les points et ce qu'ils valent. DS s'en sert pour la maintenance prédictive et la prévision de la demande électrique.
09	BI, Archi	Le chemin chaud finit dans Grafana, dont la lecture appartient à BI. Lambda et Kappa reviennent au Cours 01 d'Archi, comme choix d'architecture.
10	AE, Archi	Bronze, argent et or recourent RAW, STAGING et MARTS ; le parcours donne l'argent des séries de terrain à DE (D32). Archi reprend le débat du lac et de l'entrepôt (Cours 01) et le choix de la pile (Cours 03).
11	AE, Archi	Les tests dbt sont la version aval des contrats posés ici. Archi fait du contrat un engagement, avec un propriétaire et un recours.

Cours	Recoupe	Ce que l'encadré doit dire
12	AE, BI, DS	La RAW du capstone est ce que le kit 02 livre à AE ; le tableau de bord Grafana passe à BI ; les séries de l'usine nourrissent DS.

6. Les douze cours

La formation compte douze cours numérotés 01 à 12, sans Cours 00 (D99). Les anciens Cours 01 et 02 se sont coupés chacun en deux le 2026-09-18, à la charnière que leurs fiches rappellent, et tout ce qui suivait a reculé de deux rangs. Un cours se numérote par sa place dans la formation, jamais par son histoire.

Avant la coupe	Numéro	Titre	Dossier	Coupure nommée
01, première moitié	01	Le métier, les sources et le premier regard	Cours_01_Le_metier_les_sources_et_le_premier_regard	
01, seconde moitié	02	Les formats de fichiers et le lac bronze	Cours_02_Les_formats_de_fichiers_et_le_lac_bronze	
02, première moitié	03	Charger des fichiers dans la couche RAW	Cours_03_Charger_des_fichiers_dans_la_couche_RAW	
02, seconde moitié	04	Lire une base et une API	Cours_04_Lire_une_base_et_une_API	
03	05	Le code d'un pipeline robuste	Cours_05_Le_code_d_un_pipeline_robuste	
04	06	Orchestration avec Airflow	Cours_06_Orchestration_avec_Airflow	après l'étape 5
05	07	Traitement distribué avec Spark	Cours_07_Traitement_distribue_avec_Spark	
06	08	Données de terrain : SCADA, historien et séries temporelles	Cours_08_Donnees_de_terrain_SCADA_historien_et_serie_temporelles	le terrain et ses pièges, puis l'argent

Avant la coupe	Numéro	Titre	Dossier	Coupure nommée
07	09	Streaming et événements : MQTT et Kafka	Cours_09_Streaming_et_ev enements_MQTT_et_Kafka	MQTT, puis Kafka
08	10	Formats de table ouverts, lakehouse et médaillon	Cours_10_Formats_de_tabl e_ouverts_lakehouse_et_m edaillon	
09	11	Qualité, contrats et observabilité	Cours_11_Qualite_contrat s_et_observabilite	
10	12	Capstone : un pipeline de bout en bout	Cours_12_Capstone_pipeli ne_de_bout_en_bout	

Les quatre titres neufs disent chacun la charnière de leur coupe : regarder puis écrire, fichiers puis base et API. Les cours qui n'ont pas de coupure nommée ici annoncent leurs séances quand ils s'écrivent ou se relisent, mesurées sur la frappe (D93). Le sous-titre des supports dit Module N/12.

Pour chaque cours : quatre supports (Theorie_NN, Labo_NN, Exercices_NN, Corrige_NN), cinq familles d'exercices et environ 40 exercices, comme chez AE ; un Labo_NN.sql généré ; aucune image (D21). Chaque labo se termine par un tableau d'état du pipeline (tables, lignes, contrôles), le même que le kit 02 affiche. Chaque cours ajoute sa part au Solution/ de la formation, et ses chiffres sortent de l'exécution de ce Solution/ sur une génération fraîche.

L'installation, hors de la formation

Il n'y a plus de Cours 00 depuis le 2026-09-18 (D97). Le socle du poste vit dans Data_Domain/GUIDE_INSTALLATION.md, commun au parcours : l'environnement conda et les paquets, Git, la ligne de commande DuckDB, Docker Engine dans l'Ubuntu de WSL 2, le pilote psqLODBC, et la génération de Boréal (1 763 fichiers, 138 Mo, un peu plus d'une minute). Ce que la formation allume elle-même ouvre le cours qui s'en sert, dans une section ## Avant de commencer :

Ce qui s'allume	Où	Ce que ça monte
la plateforme et la base de l'ERP	Cours 04	les fichiers de _univers/plateforme/ copiés (D91), la base démarrée et chargée par charger_erp.sql, 25 483 commandes
Airflow	Cours 06	l'image construite et les cinq services sains, avec le pool entrepot
Spark, Grafana	Cours 07, 12	à écrire avec leur cours

Ce qui s'allume	Où	Ce que ça monte
TimescaleDB	Cours 08	à écrire avec son cours ; il ne sert qu'à la seconde séance, et son bloc peut l'attendre, comme celui d'Airflow au Cours 06
Mosquitto, Kafka	Cours 09	à écrire avec son cours ; Mosquitto dès l'ouverture, Kafka seulement à la seconde séance

Cours 01 — Le métier, les sources et le premier regard

Le métier, ce qu'il produit, à qui il le livre. L'architecture de référence (source, ingestion, lac, entrepôt, restitution) et ses deux chemins, le froid et le chaud. La chaîne du parcours et les produits que cette formation y livre. Boréal et ses six sources, vus depuis l'amont. DuckDB, qui interroge un fichier sur place, sans serveur et sans rien charger. Et le piège qui ne plante pas : un type deviné. Lu sans précaution, un extrait de l'ERP garde ses numéros en texte, mais sa date de création ERDAT devient un entier (20240531), comme le mandant MANDT, alors que AEDAT, où traîne la date vide 00000000, reste du texte : deux colonnes de dates, deux types, et aucune erreur ne l'annonce.

Élément	Détail
Données	le premier regard en SQL : l'historien (275 436 lignes ; qualités 192, 64 et 0 pour 275 080, 35 et 321 lignes, valeurs de départ comprises), les extraits de l'ERP (26 538 en-têtes de commande lus dans les extraits, pour 25 483 dans la base : un extrait n'est pas la base), la télémétrie (158 146 messages) ; le poids de ce qui est arrivé ; un VBAK d'extrait lu avec des types devinés, puis en texte
Événements	E6 se voit dans la liste des dossiers (2023-03_bis), sans être traité
Le labo livre	le dépôt 01_de et son .gitignore ; les premières requêtes ; le poids des sources, 13,7 Mo d'historien et 70,6 Mo de télémétrie ; le type deviné, constaté sur l'ERP et la télémétrie
Contrôle	aucun : rien ne s'écrit
Variantes	aucune
CIMA+	chemin chaud et chemin froid, posés ; DuckDB

Cours 02 — Les formats de fichiers et le lac bronze

Le lac : ligne contre colonne. CSV, JSON, Avro, Parquet, ORC : ce que chacun coûte et ce qu'il rend. Compression, schéma embarqué, prédicat poussé à la lecture. La règle du bronze, qui répond au type deviné du Cours 01. Le stockage objet, le partitionnement par chemin et le piège des petits fichiers. DuckDB pour écrire et interroger du Parquet sur place.

Élément	Détail
Données	l'historien de 92 jours converti de CSV en Parquet partitionné par jour ; la télémétrie de JSON lines en Parquet imbriqué, et ses 884 fichiers quotidiens face au piège des petits fichiers
Le labo livre	les deux scripts de <code>01_de/sql/</code> ; le bronze de l'historien et de la télémétrie dans <code>plateforme/lac/bronze/</code> , la mesure de ce que le format change en taille et en vitesse
Règle du bronze	chaque ligne et chaque valeur telles que reçues ; un type déclaré quand la conversion ne perd rien, du texte ailleurs ; compression zstd, un dossier par jour livré
Contrôle qui échoue	les lignes du CSV contre celles du Parquet ; une date DATS qui doit rester du texte
Variantes	encadrés Snowflake et Databricks
CIMA+	DuckDB et Parquet

Les Cours 01 et 02 viennent de la coupe de l'ancien Cours 01, le 2026-09-18, à la charnière « regarder, puis écrire » (D99). Le premier finit sur un constat mesuré, le type deviné, sans rien écrire dans le lac ; le second ouvre sur la règle qui en découle, et écrit le bronze.

Cours 03 — Charger des fichiers dans la couche RAW

Extraire d'un dépôt de fichiers, la voie la plus répandue : les extraits mensuels de l'ERP et des garanties, l'archive de la télémétrie, les exports de l'usine, l'instantané de la météo. Chargement complet contre chargement incrémental. La propriété qui gouverne tout, l'idempotence : un journal des chargements, et rejouer un extrait ne double rien. La couche RAW et ses règles. Et ce qui se dépose tel quel sans devenir une table : la documentation.

Élément	Détail
Données	les extraits de 2022-01 à 2025-12, puis de 2026-01 à 2026-03 (E17) ; la télémétrie archivée ; le référentiel et la GMAO de l'usine ; l'instantané de la météo ; le corpus

Élément	Détail
Le piège qui ne plante pas	2023-03_bis porte un autre nom que 2023-03 : le journal des chargements le laisse passer, et 609 commandes arrivent deux fois. Le cours le montre, le contrat du Cours 11 l'attrape, et la RAW le garde marqué de son lot pour que le test d'unicité d'AE ait quelque chose à prouver
Le labo livre	la RAW : 22 tables (9 de l'ERP, 5 des garanties, 3 du référentiel et de la GMAO, 3 de la météo, la télémétrie, le catalogue du corpus) ; le corpus déposé dans le bronze ; LIVRAISON.md commencé
Contrôle	charger deux fois le même extrait ne change aucun compte
Poste	Windows seul : l'Anaconda Prompt et DuckDB
Variantes	annexe Snowflake, annexe Databricks

Cours 04 — Lire une base et une API

Extraire d'une base relationnelle par ODBC : la base de l'ERP, dans son conteneur PostgreSQL ; le pilote comme contrat, et pourquoi on ne lit pas une base de production à l'heure de pointe. D'une API REST : la vraie API d'ECCC (`api.weather.gc.ca`), sa pagination, sa limitation de débit, la reprise sur erreur, comparée à l'instantané figé. Filigrane sur la date de modification des commandes (AEDAT) ; capture de changements par requête, sur les documents de modification CDHDR et CDPOS, et la capture par journal annoncée (la synthèse Aurore la fait). MQTT, REST et ODBC comparés : qui pousse, qui tire, ce que chacun garantit ; MQTT est traité au Cours 09.

Élément	Détail
Données	la base au 2025-12-31 (25 483 commandes), puis au 2026-03-31 (27 185) ; les 49 documents de modification du palier du 2024-07-01 (E8) ; la vraie API d'ECCC
Le labo livre	la plateforme reçue et la base de l'ERP montée ; ses neuf tables tirées par ODBC, à 0 écart de la RAW ; le filigrane de décembre égal à l'extrait ; 92 jours de météo tirés de l'API
Contrôle	l'état reconstruit depuis les extraits égale la base sur les neuf tables
Poste	Ubuntu et Docker pour la base, le pilote ODBC, Internet pour l'API
Variantes	aucune

Élément	Détail
Avant d'écrire	le correctif de <code>verifier_sql.py</code> (D24) ; l'essai de <code>lancer_depuis</code> hors de la formation et d'un <code>.sql</code> à deux moteurs ; l'essai d'ODBC depuis Windows vers le conteneur de WSL 2 ; les faits des plateformes et de l'API d'ECCC revérifiés
CIMA+	REST, ODBC, et MQTT, REST et ODBC comparés

Les Cours 03 et 04 viennent de la coupe de l'ancien Cours 02, le 2026-09-18, à la charnière « fichiers, puis base et API » (D99) : le lecteur finit le premier sans avoir ouvert Ubuntu.

Cours 05 — Le code d'un pipeline robuste

Ce qui sépare un script d'un pipeline : la configuration hors du code, les secrets hors du dépôt (le mot de passe de la base de l'ERP), une journalisation exploitable, les reprises avec temporisation exponentielle (l'API d'ECCC), les tests d'une transformation, l'empaquetage et l'exécution en conteneur. Le langage Python lui-même reste à la formation Python.

Une règle de conception sert tout le parcours : le pipeline a une seule porte d'entrée en ligne de commande, que le DAG du Cours 06 appelle et que le kit 02 rejoue sans Airflow. Le chemin que rejoue le kit n'importe que DuckDB et la bibliothèque standard.

Élément	Détail
Données	les ingestions des Cours 02 à 04, reprises en paquet Python dans <code>01_de/</code>
Le labo livre	la configuration, le <code>.env</code> hors du dépôt, les journaux, les reprises, des tests <code>pytest</code> (le journal refuse un extrait déjà chargé, la conversion garde le compte des lignes, la reprise s'arrête après le nombre d'essais prévu), une image Docker du pipeline lancée sur <code>sources/</code> monté
Variantes	aucune

Cours 06 — Orchestration avec Airflow

Le graphe acyclique dirigé comme façon de penser. Tâches, dépendances, planification, intervalle de données, rattrapage, nouvelle tentative, capteurs, alertes de retard. Ce qui rend un DAG rejouable, et pourquoi un DAG qui n'est pas idempotent est une bombe à retardement. La couture avec `dbt build`.

Élément	Détail
Données	un DAG quotidien (historien, télémétrie, météo) et un DAG mensuel (extraits de l'ERP et des garanties, compteur)

Élément	Détail
Événements	les mois de 2026 (E17) : régénérer avec --jusqua 2026-03, laisser Airflow rattraper trois mois, et constater que l'état égale un chargement d'un bloc
Le labo livre	les deux DAG dans 01_de/, Airflow 3 en conteneurs ; la tâche qui lancera dbt build, posée en attente : AE la remplit
Variantes	encadrés Snowflake et Databricks
Avant d'écrire	fait le 2026-09-16 : la pile tient, l'entrepôt de Windows s'écrit depuis un conteneur, le rattrapage égale le bloc, et les SLA d'Airflow 2 sont devenus les Deadline Alerts. Restent quatre choix de forme à trancher

Cours 07 — Traitement distribué avec Spark

Quand une machine ne suffit plus, et surtout quand elle suffit encore. Partitions, évaluation paresseuse, brassage, l'API DataFrame. Lire le plan d'exécution. Les pièges classiques : le brassage inutile, la partition déséquilibrée, le `collect` qui ramène tout au pilote.

Élément	Détail
Données	l'historien complet (731 jours, 2 133 145 lignes, 106 Mo, --historien complet) et la télémétrie : le même traitement en DuckDB et en Spark (conversion en Parquet partitionné, agrégats quotidiens par étiquette, messages dédoublonnés par jour), mesuré
Ce que le cours conclut	DuckDB suffit à Boréal. Le cours dit d'où viendrait le besoin (des dizaines d'usines, des années de points bruts), sans le simuler
Partition déséquilibrée	les étiquettes qui bougent sans cesse contre les états de marche, qui ne gardent presque aucun point
Variantes	annexe Databricks, encadré Snowpark
Avant d'écrire	fait le 2026-09-16 : Spark 4.2.0 en conteneur rend les mêmes chiffres que DuckDB, 27 à 120 fois plus lentement, et les limites de Free Edition sont revérifiées. Restent deux choix de forme à trancher
CIMA+	Databricks, repris

Cours 08 — Données de terrain : SCADA, historien et séries temporelles

D'où vient la donnée industrielle : le capteur, l'automate, le SCADA qui supervise et commande, OPC UA comme langue commune des équipements. L'historien, qui archive les points à haute fréquence : compression par bande morte, qualité du point, étiquettes et hiérarchie des actifs. Les bases de séries temporelles ouvertes : ce qu'elles font mieux qu'un entrepôt, et moins bien. Les pièges du terrain : trous, horloges, heure locale, rééchantillonnage, unités. Et la frontière qui gouverne tout : on ne branche jamais un pipeline sur le réseau de contrôle ; la séparation des technologies opérationnelles et des technologies de l'information existe pour la sécurité.

Élément	Détail
Données	l'usine de Val-des-Aulnes : 6 zones, 17 équipements, 58 étiquettes ; l'historien de 182 jours que le Cours 07 laisse (550 087 lignes), le référentiel, la GMAO (825 bons), le compteur (148 891 relevés)
Les pièges, un à un	les valeurs de départ (10 556 lignes, 58 par jour) ; l'archivage forcé de minuit (10 525 points, et non 10 556 : quatre jours en perdent 31) ; le retour à l'heure normale du 2025-11-02 (E1, 49 paires en double) et le passage à l'heure avancée du 2026-03-08, qui laisse une heure vide ; l'humidité de la cabine de peinture figée 49,8 heures à qualité bonne (E2), et son faux jumeau, la ligne des motomarines à l'arrêt 790 heures ; 529 points de qualité mauvaise, sans valeur, et 64 de qualité douteuse (E3) ; le compteur horodaté en fin d'intervalle avec son décalage à UTC, et 247 relevés estimés
L'argent	les points dédoublonnés, l'horodatage résolu en UTC, la qualité portée ; le rééchantillonnage horaire (moyenne pondérée par le temps pour une mesure, dernier état pour une marche, différence pour un compteur) ; l'énergie horaire du compteur. Le grain exact se fixe au cours
L'incident	UTL . CMP2 . VIBRATION monte dès le 2025-10-15 ; le compresseur 2 déclenche le 2025-10-28 à 10 h 44 (bon BT-2025-00742)
Le labo livre	plateforme/lac/argent/usine/, le schéma argent, TimescaleDB chargée (hypertable, agrégat continu horaire), comparée à DuckDB
Variantes	aucune
Avant d'écrire	l'essai de TimescaleDB et de Grafana alimentés par un rejoueur MQTT (essai à faire avant d'écrire le cours)
CIMA+	SCADA et historien, base de séries temporelles

La charnière, posée le 2026-09-18 avant l'écriture (D93, D99) : d'où viennent les points, puis ce qu'on en sert. La formation compte douze cours, et celui-ci reste un seul cours : la charnière y pose une coupure nommée entre deux séances d'environ deux heures et demie, comme le Labo 06 après son étape 5. Chaque séance se tient seule. La première finit sur des pièges comptés, la seconde sur une série horaire prouvée.

	Première séance : le terrain et ses pièges	Seconde séance : l'argent et la base de séries temporelles
Théorie	le capteur, l'automate, le SCADA et OPC UA ; l'historien, la bande morte, la qualité du point, les étiquettes et la hiérarchie des actifs ; la frontière entre technologies opérationnelles et technologies de l'information ; les pièges du terrain, trous, horloges, heure locale et unités	le nettoyage : points dédoublonnés, heure résolue en UTC, qualité portée ; le rééchantillonnage selon la nature du point ; les bases de séries temporelles, ce qu'elles font mieux qu'un entrepôt et moins bien, et la licence de l'agrégat continu
Labo	le référentiel, la GMAO et le compteur ; les six pièges de la ligne « Les pièges, un à un », mesurés sur le bronze de l'historien et sur le compteur ; l'incident, lu dans les points et dans le bon de travail	l'argent de l'usine dans plateforme/lac/argent/usine/ et dans le schéma argent ; l'énergie horaire du compteur ; TimescaleDB chargée, avec son hypertable et son agrégat continu
Fin de la séance	chaque piège compté, au chiffre de la fiche	l'agrégat continu égale le rééchantillonnage de DuckDB
Service	aucun	TimescaleDB

Cours 09 — Streaming et événements : MQTT et Kafka

Le contraste avec le lot : ce que le temps réel apporte, ce qu'il coûte. MQTT, le protocole léger du terrain : un courtier, la publication et l'abonnement, des sujets hiérarchiques, trois niveaux de qualité de service, le message retenu. Kafka, quand le flux doit être conservé et relu : sujets, partitions, clés, décalages, groupes de consommateurs. Le pont entre les deux. Sémantique de livraison, fenêtrage, données en retard. L'architecture Lambda, qui garde les deux chemins séparés, et Kappa, qui ne garde que le flux. Et la question honnête : la plupart des besoins dits « temps réel » sont des besoins horaires.

Élément	Détail
Données	les rejoueurs de _univers/rejoueurs/, écrits à la séance de ce cours : l'usine (les points de l'historien d'une fenêtre choisie, en accéléré) et la télémétrie (boreal/vehicules/<numéro de série>/sorties, avec ses retards et ses doublons)

Élément	Détail
Événements	2 303 doublons de la qualité de service 1 ; 5 581 messages reçus plus d'une heure après la fin de leur sortie (E12) ; la dérive du compresseur 2 (E5)
Le labo livre	l'abonnement, le pont MQTT vers Kafka, un consommateur qui écrit dans TimescaleDB, une fenêtre de 15 minutes sur la vibration du compresseur 2 et son alerte : la date où elle se lève pendant la dérive, et l'avance sur le déclenchement
Ce que le cours montre aussi	l'archive quotidienne de la télémétrie est ce qu'écrit un abonné : le chemin froid la ramasse le lendemain
Variantes	encadrés Snowflake et Databricks
Avant d'écrire	les rejeuteurs écrits et prouvés (les messages publiés égalent l'archive) ; Kafka en mode KRaft dans son image officielle, revérifié
CIMA+	MQTT ; chemin chaud et chemin froid, Lambda et Kappa

La charnière, posée le 2026-09-18 avant l'écriture (D93, D99) : le terrain qui publie, puis le flux qu'on garde et qu'on relit. Comme au Cours 08, un seul cours et une coupure nommée entre deux séances. La première finit quand un abonné reçoit ce que les rejeuteurs publient, doublons et retards compris ; la seconde garde le flux dans Kafka, le relit par fenêtres et en tire l'alerte.

	Première séance : MQTT, le terrain qui publie	Seconde séance : Kafka, le flux qu'on garde
Théorie	ce que le temps réel apporte et ce qu'il coûte, et la question honnête des besoins horaires ; MQTT : le courtier, la publication et l'abonnement, les sujets hiérarchiques, les trois niveaux de qualité de service, le message retenu ; la sémantique de livraison	Kafka : sujets, partitions, clés, décalages, groupes de consommateurs ; le pont entre les deux ; le fenêtrage et les données en retard ; Lambda et Kappa
Labo	les rejeuteurs de l'usine et de la télémétrie ; l'abonnement ; les doublons de la qualité de service 1 et les messages en retard, vus à la réception ; l'archive quotidienne reconnue comme ce qu'écrit un abonné	le pont MQTT vers Kafka ; le consommateur qui écrit dans TimescaleDB ; la fenêtre de 15 minutes sur la vibration du compresseur 2, et son alerte

	Première séance : MQTT, le terrain qui publie	Seconde séance : Kafka, le flux qu'on garde
Fin de la séance	les messages publiés égalent l'archive	l'alerte datée pendant la dérive, avec son avance sur le déclenchement
Service	Mosquitto	Kafka en mode KRaft

Cours 10 — Formats de table ouverts, lakehouse et médaillon

Iceberg et Delta : des transactions ACID sur des fichiers. Évolution de schéma, voyage dans le temps, compactage. L'architecture médaillon : le bronze garde la donnée telle que reçue, l'argent la nettoie et la rend conforme, l'or la prépare pour la consommation. La correspondance avec RAW, STAGING et MARTS, l'endroit où elle cloche, et la réponse du parcours : DE tient l'argent des séries de terrain, et les sources relationnelles passent de la RAW au STAGING d'AE (D32). La convergence du lac et de l'entrepôt, et les lakehouses clés en main.

Élément	Détail
Données	la télémétrie du bronze en Iceberg : le micrologiciel 2.0 (E11, dès le 2025-05-01, 68 469 messages) ajoute heures_moteur et renomme temp_moteur_max en temperature_moteur_max, ce qui en fait un cas d'évolution de schéma ; les mois de 2026 en nouveaux instantanés, et le voyage dans le temps vers l'état au 2025-12-31 ; le compactage des 884 fichiers quotidiens ; les séries de l'argent en Iceberg
Le labo livre	le lac en tables Iceberg, lues par DuckDB ; la même table en Delta, pour comparer
Variantes	annexe Snowflake, annexe Databricks, encadré Fabric
Avant d'écrire	l'essai de Pylceberg avec un catalogue SQL local et de la lecture par DuckDB
CIMA+	médaille, formats de table ouverts, Fabric

Cours 11 — Qualité, contrats et observabilité

Le contrat de données entre producteur et consommateur. Valider à l'entrée plutôt que déboguer en aval. Fraîcheur, volume, distribution, unicité, et pour un capteur, la plage physiquement possible. Bloquer ou avertir, et pourquoi ce n'est pas le même choix pour chaque contrat. Lignage, alerte utile contre alerte ignorée, conduite d'un incident de données. La parenté avec les tests dbt, dite explicitement.

Élément	Détail
Données	un contrat par produit livré, qui porte ses attendus (D64)
Ce que les contrats attrapent	l'extrait 2023-03_bis identique à 2023-03 (E6) ; la commande 0010015405 d'un concessionnaire absent de l'extrait 2024-05 (E7) ; le champ renommé du micrologiciel 2.0 (E11) ; le capteur figé (E2) ; les valeurs hors de la plage de etiquettes.csv et les coupures (E3) ; la pression instable du réseau d'air pendant la dérive du compresseur 2, par un contrôle de distribution sur les heures de production (E5)
Le labo livre	les contrats, leur exécution dans le DAG, le compte des alertes vraies et fausses, le post-mortem d'un incident de données
Variantes	encadrés Snowflake et Databricks
Avant d'écrire	le contrôle de la pression bâti sur la vraie sortie, et ses fausses alertes comptées hors de la dérive

Cours 12 — Capstone : un pipeline de bout en bout

Détail en section 7.

7. Le capstone

Il boucle le projet Boréal de la formation (D14) : les deux chemins, de bout en bout, sur les sources générées jusqu'au 2026-03-31.

Chemin	Ce qui tourne	Ce qui le prouve
Froid	Airflow orchestre l'ERP par ses extraits et l'extraction ODBC qui retrouve la même base, l'historien, la GMAO, le compteur, les garanties, la météo par l'API, la télémétrie archivée et le corpus ; le bronze, l'argent et la RAW ; les contrats qui bloquent	le projet se reconstruit de zéro ; l'état final égale LIVRAISON.md ; chaque contrat rend son attendu
Chaud	les rejoueurs de l'usine et de la télémétrie, Mosquitto, le pont, Kafka, TimescaleDB, Grafana et l'alerte de vibration	l'alerte se lève pendant la dérive, à la date calculée au Cours 09

Ce que le capstone livre : le dépôt 01_de complet, la pièce de portfolio ; LIVRAISON.md complet ; le tableau de bord Grafana de l'usine (état du réseau d'air, vibration et température du compresseur 2, alerte), que BI reprend pour en concevoir la lecture ; le Solution/ que rejouent le kit 02 et, au lot 7, le kit 03 (TimescaleDB chargée et rejoueur). L'incident vu depuis l'amont tient en trois faits : la date de l'alerte, le contrat qui a vu la pression instable, et une RAW où AE retrouvera la plage des motoneiges touchées.

8. La synthèse, et le mini-cas

D96 n'en garde qu'une par formation, la plus avancée : Aurore. Elle suit le capstone (D14), repart des données brutes générées (D15) et suit le modèle d'AE (D16) : une mise en situation, un document unique qui refait l'arc de la formation d'un bloc, un dossier Solution/ rejouable, sans notes ni examens.

La Brûlerie change de rôle : elle devient le mini-cas figé du premier pas, et non plus une synthèse (D96, D110). Ses données ne se génèrent plus chez le lecteur : la sortie de --extrait mois de juin 2025, avec graines/ et ses empreintes, est versionnée, et le générateur quitte son chemin. La section 8.1 ci-dessous décrit encore l'ancienne synthèse ; elle se réécrit à la séance qui l'écrira, pas avant.

8.1 La Brûlerie, l'ancienne synthèse, à refaire en mini-cas figé

Synthese_La_Brulerie_facile/ : Mise_en_situation_La_Brulerie.md, Synthese_brulerie.md, Solution/. Données : le mini-cas figé, _univers/brulerie/mini_cas/sources/, un mois de caisse versionné, 100 fichiers et 0,9 Mo (A5.10). Le lecteur ne génère rien, et l'arc se refait sur ce mois-là.

Arc refait	Sur La Brûlerie
Formats, ingestion idempotente	les exports quotidiens de la caisse, en bronze Parquet partitionné par jour ; l'export repris du 2025-06-12 (L5) : garder le dernier export d'un jour
La RAW	le catalogue, la fidélité et la météo de Montréal
Terrain et continu	le torréfacteur du mois, rejoué en MQTT
Orchestration	un DAG quotidien sur les journées du mois
Contrat	la caisse recomptée : les totaux de preuves/totaux_mensuels.sql, que le générateur écrit lui-même dans preuves/totaux_attendus.csv (A5.20)
Ce qu'on n'installe pas	ni Spark, ni Kafka, ni Iceberg : un petit commerce n'en a pas besoin, et la synthèse le dit

8.2 Aurore, avancée

Synthese_Aurore_avancee/ : Mise_en_situation_Aurore.md, Synthese_aurore.md, Solution/. Données : _univers/aurore/generer_aurore.py (40 Mo, 305 Mo décompressés), puis --jusqua 2026-03.

Arc refait	Sur Aurore
Capture de changements par journal	la copie de la base chargée dans PostgreSQL, puis le journal au format de Debezium rejoué jusqu'à la RAW : l'instantané initial, les opérations, la ligne avant réduite à la clé en REPLICA IDENTITY DEFAULT, les décimaux en texte, les dates en jours depuis 1970
Idempotence	les sept heures republiées au redémarrage du connecteur, le 2024-10-08 (A5)
Évolution de schéma	la colonne ajoutée à la table des commandes le 2025-01-20 (A6)
Preuve	le journal rejoué égale la copie de la base (preuves/verifier_journal.py)
Continu	les 408 074 événements web rejoués dans Kafka : fenêtres, retards, doublons ; la version 2 du format (A7, 2025-06-02) attrapée par un contrat ; le robot du 2024-09-09 au 2024-09-20 (A8) signalé sans être retiré, parce que l'écartier est une décision de BI et de DS
La RAW	les tables de l'application, les événements web, les taux de change réels de la Banque du Canada

Les rejoueurs de `_univers/rejoueurs/` couvrent les quatre flux (usine, télémétrie, torréfacteur, web) par un seul script, qui lit un flux généré et le publie sur MQTT ou sur Kafka. Il dépend de paquets déclarés, comme le permet la règle des générateurs.

9. Le kit 02

La sortie de DE devient l'entrée d'AE (D10, D11, D35) : le kit reconstruit ce que DE aurait livré, en rejouant le `Solution/` de DE.

Élément	Détail
Commande	<code>python _univers/kits/demarrer.py --formation 02 --projet Projet_Boreal</code>
Ce qu'il fait	génère les sources si elles manquent, ou vérifie leurs empreintes ; rejoue le chemin froid du <code>Solution/</code> par sa ligne de commande, sans Airflow, Kafka, Spark ni Docker ; écrit <code>raw</code> et <code>argent</code> dans l'entrepôt, le lac bronze et argent, une copie Parquet de chaque table livrée ; affiche l'état et le compare aux attendus

Élément	Détail
Options	--jusqua 2026-03 ; --historien complet, pour le kit 04 ; --verifier, qui passe les contrôles de DE sur le projet d'un apprenant (M3)
Dépendances	duckdb seulement
Durée	2 minutes visées ; la génération seule prend un peu plus d'une minute, et l'écart se mesure à la séance du kit
Plateformes	un script de chargement généré pour Snowflake, un pour Databricks, sans identifiant de compte ; vous les exécutez
Preuve	deux exécutions sur une copie jetable du projet, mêmes comptes et mêmes sommes de contrôle, l'heure de chargement exclue ; le chargement sur Databricks Free Edition, fait à la main