

Table des matières

Data Engineering — Formation.....	1
Démarrage rapide	1
Les douze cours.....	2
Ce que contient le dossier.....	3
Prérequis	3
Place dans le parcours	4

Data Engineering — Formation

Formation d'ingénierie des données (*data engineering*), sous forme de supports Markdown. Elle couvre l'amont de la chaîne : faire arriver la donnée, la ranger, la faire tourner à l'heure, et prouver qu'elle est bonne. Elle va jusqu'à la couche RAW comprise, qu'elle produit et livre à la formation Analytics Engineering, et livre en plus les séries de terrain qu'elle seule sait nettoyer.

Le fil rouge est un fabricant fictif de véhicules récréatifs, Véhicules Boréal inc. : un ERP de type SAP, une usine instrumentée (SCADA, historien, GMAO, compteur électrique), des véhicules connectés en MQTT, un portail des garanties, une documentation, et de la vraie météo publique. Le même univers sert les sept formations du parcours. Douze cours, du premier regard au pipeline complet, par lots et en continu, puis une synthèse.

Les deux chemins, en une ligne chacun :

- le froid : ERP, historien, garanties, télémétrie archivée → ingestion → lac (bronze, argent) → couche RAW et séries de l'usine ;
- le chaud : usine et véhicules → MQTT → Kafka → base de séries temporelles → Grafana.

La pile est ouverte et locale : Python, DuckDB, Parquet, Iceberg, Docker dans l'Ubuntu de WSL 2, PostgreSQL, Airflow, Spark, MQTT, Kafka, TimescaleDB, Grafana. Rien n'oblige à ouvrir un compte infonuagique ; Snowflake et Databricks reçoivent des annexes là où ils changent le geste.

Démarrage rapide

```
conda create -n formations python=3.11 -y
conda activate formations
pip install -r requirements.txt
```

Puis Git, Docker Engine dans l'Ubuntu de WSL 2 et le pilote psycopg2. Le guide d'installation du parcours, `Data_Domain/GUIDE_INSTALLATION.md`, refait chacun de ces gestes en détail : commencez par lui. La plateforme de Boréal, elle, s'allume dans les cours qui s'en servent : la base de l'ERP au Cours 04, Airflow au Cours 06.

Les données se fabriquent. Depuis Data_Domain/, après avoir créé Projet_Boreal/ (guide d'installation, étape 1), python `_univers/boreal/generer_boreal.py --projet Projet_Boreal` produit les sources de Boréal dans `Projet_Boreal/sources/`, en un peu plus d'une minute. Seule la vraie API météo se consulte en ligne, au Cours 04 ; le générateur en lit un instantané figé.

Les douze cours

La formation compte douze cours, numérotés 01 à 12. L'installation n'en fait pas partie : le socle du poste se monte une seule fois pour tout le parcours, avec le guide d'installation.

Cours	Sujet	État
01	Le métier, les sources et le premier regard	rédigé
02	Les formats de fichiers et le lac bronze	rédigé
03	Charger des fichiers dans la couche RAW	rédigé
04	Lire une base et une API	rédigé
05	Le code d'un pipeline robuste	rédigé
06	Orchestration avec Airflow	rédigé
07	Traitement distribué avec Spark	rédigé
08	Données de terrain : SCADA, historien et séries temporelles	rédigé
09	Streaming et événements : MQTT et Kafka	à venir
10	Formats de table ouverts, lakehouse et médaillon	à venir
11	Qualité, contrats et observabilité	à venir
12	Capstone : un pipeline de bout en bout	à venir
Synthèse	Comptoir Aurore, plus le mini-cas figé de La Brûlerie en premier pas	à venir

Chaque cours compte trois supports : `Theorie_NN.md`, `Labo_NN.md` et `Exercices_corriges_NN.md`, qui porte les énoncés puis leur corrigé. Le plan détaillé des modules, et ce que la formation livre aux suivantes, est dans `PLAN_MODULES.md`.

Les huit cours rédigés forment un tout qui se suit et se rejoue : ils montent la couche RAW de Boréal, 22 tables et 513 857 lignes, et les séries de l'usine que le Cours 08 nettoie. Les quatre qui restent ajoutent le temps réel, les formats de table ouverts, la qualité et le capstone ; ils n'enlèvent rien à ce qui précède. Ce que la formation livre déjà à Analytics Engineering est décrit dans `Cours/Solution/LIVRAISON.md`, table par table.

Ce que contient le dossier

	Fichiers	À quoi ça sert
Pour suivre la formation	<code>Cours/</code> (les dossiers de cours et <code>Mise_en_situation_Boreal_01_DE.md</code>), <code>requirements.txt</code> ; la mise en situation du parcours dans <code>Data_Domain/Mises_en_situation/</code> ; les générateurs dans <code>Data_Domain/_univers/</code>	les supports, le mandat, la pile, les données
Pour comparer ou débloquent	<code>Cours/Solution/</code>	l'état de référence du dépôt 01_de, cours après cours, et la façon de le rejouer
Pour l'auteur	<code>PLAN_MODULES.md</code> , <code>STYLE.md</code> , <code>formation.json</code> , <code>lint_md.py</code> , <code>md_vers_docx.py</code>	le plan, la charte, la chaîne <code>.md</code> → <code>.docx</code> (outillage commun dans <code>Formations/_commun/</code>)

Un dossier que vous ne trouverez pas : `Data_Domain/Projet_Boreal/`. C'est la plateforme de données que vous bâtissez, avec votre propre dépôt Git, 01_de/. Le guide d'installation du parcours crée le dossier et les données, le Labo 01 votre dépôt.

À la première ouverture d'un `.docx`. Le sommaire et les numéros de page sont des champs Word : ils arrivent vides. Sélectionnez tout, Ctrl+A, puis appuyez sur F9 et choisissez « Mettre à jour toute la table ». Word les tient à jour ensuite, et les recalcule à chaque impression.

Prérequis

- Le SQL courant : `SELECT`, `WHERE`, `GROUP BY`, `JOIN`, une agrégation. On écrit du SQL ici, on ne l'enseigne pas. Ce que les labos empruntent au-delà du SQL courant est inventorié dans `Data_Domain/prerequis/RENVOIS_SQL.md`, avec le cours de SQL avancé qui l'enseigne.
- La syntaxe de Python : la formation enseigne ce qui rend un pipeline robuste, pas le langage. Chaque outil du langage qu'un labo fait taper reçoit sa glose d'une ligne à son premier emploi.
- Six gestes au terminal, et pas davantage : se déplacer (`cd`), créer un dossier (`mkdir`), lancer un conteneur (`docker`, `docker compose`), ouvrir l'Ubuntu de WSL 2 (`wsl`), lire la fin d'un fichier (`tail`), peser un dossier (`du`). Le guide d'installation du parcours monte tout le reste. La formation Linux n'est pas un prérequis : elle a deux cours écrits sur neuf.
- Un poste Windows capable de faire tourner WSL 2 (la virtualisation activée), ou un poste macOS ou Linux avec Docker.

- Aucune notion industrielle : le Cours 01 présente le SCADA et l'historien, le Cours 08 les creuse.

Place dans le parcours

Numéro 01 du parcours du domaine des données : le début de la chaîne, en amont d'Analytics Engineering, qui reprend la couche RAW. La carte complète, et la raison de cet ordre, est en tête du README.md des formations.