

Table des matières

Data Engineering — Formation.....	1
Démarrage rapide	1
Les douze cours.....	2
Ce que contient le dossier.....	3
Prérequis	3
Place dans le parcours	4

Data Engineering — Formation

Formation d'ingénierie des données (*data engineering*), sous forme de supports Markdown. Elle couvre l'amont de la chaîne : faire arriver la donnée, la ranger, la faire tourner à l'heure, et prouver qu'elle est bonne. Elle va jusqu'à la couche RAW comprise, qu'elle produit et livre à la formation Analytics Engineering, et livre en plus les séries de terrain qu'elle seule sait nettoyer.

Le fil rouge est un fabricant fictif de véhicules récréatifs, Véhicules Boréal inc. : un ERP de type SAP, une usine instrumentée (SCADA, historien, GMAO, compteur électrique), des véhicules connectés en MQTT, un portail des garanties, une documentation, et de la vraie météo publique. Le même univers sert les sept formations du parcours. Douze cours, du premier regard au pipeline complet, par lots et en continu, puis une synthèse.

Les deux chemins, en une ligne chacun :

- le froid : ERP, historien, garanties, télémétrie archivée → ingestion → lac (bronze, argent) → couche RAW et séries de l'usine ;
- le chaud : usine et véhicules → MQTT → Kafka → base de séries temporelles → Grafana.

La pile est ouverte et locale : Python, DuckDB, Parquet, Iceberg, Docker dans l'Ubuntu de WSL 2, PostgreSQL, Airflow, Spark, MQTT, Kafka, TimescaleDB, Grafana. Rien n'oblige à ouvrir un compte infonuagique ; Snowflake et Databricks reçoivent des annexes là où ils changent le geste.

Démarrage rapide

```
conda create -n formations python=3.11 -y
conda activate formations
pip install -r requirements.txt
```

Puis Git, Docker Engine dans l'Ubuntu de WSL 2 et le pilote psycopg2. Le guide d'installation du parcours, `Data_Domain/GUIDE_INSTALLATION.md`, refait chacun de ces gestes en détail : commencez par lui. La plateforme de Boréal, elle, s'allume dans les cours qui s'en servent : la base de l'ERP au Cours 04, Airflow au Cours 06, la base de séries temporelles au Cours 08, le courtier MQTT et Kafka au Cours 09.

Les données se fabriquent. Depuis Data_Domain/, après avoir créé Projet_Boreal/ (guide d'installation, étape 1), python `_univers/boreal/generer_boreal.py --projet Projet_Boreal` produit les sources de Boréal dans `Projet_Boreal/sources/`, en un peu plus d'une minute. Seule la vraie API météo se consulte en ligne, au Cours 04 ; le générateur en lit un instantané figé.

Les douze cours

La formation compte douze cours, numérotés 01 à 12. L'installation n'en fait pas partie : le socle du poste se monte une seule fois pour tout le parcours, avec le guide d'installation.

Cours	Sujet	État
01	Le métier, les sources et le premier regard	rédigé
02	Les formats de fichiers et le lac bronze	rédigé
03	Charger des fichiers dans la couche RAW	rédigé
04	Lire une base et une API	rédigé
05	Le code d'un pipeline robuste	rédigé
06	Orchestration avec Airflow	rédigé
07	Traitement distribué avec Spark	rédigé
08	Données de terrain : SCADA, historien et séries temporelles	rédigé
09	Streaming et événements : MQTT et Kafka	rédigé
10	Formats de table ouverts, lakehouse et médaillon	rédigé
11	Qualité, contrats et observabilité	rédigé
12	Capstone : un pipeline de bout en bout	rédigé
Mini-cas	La Brûlerie, un mois de caisse du fichier au contrat, le premier arc fait seul	rédigé
Synthèse	Comptoir Aurore, une base lue par son journal de capture, et un flux web qui livre en double et en retard	rédigé

Chaque cours compte trois supports : Theorie_NN.md, Labo_NN.md et Exercices_corrigees_NN.md, qui porte les énoncés puis leur corrigé. Le plan détaillé des modules, et ce que la formation livre aux suivantes, est dans PLAN_MODULES.md.

Les douze cours rédigés forment un tout qui se suit et se rejoue : ils montent la couche RAW de Boréal, 22 tables et 513 857 lignes, les séries de l'usine que le Cours 08 nettoie, le chemin chaud du Cours 09, du courtier MQTT à Kafka et à la base de séries temporelles, jusqu'à l'alerte de vibration, les tables Iceberg et Delta du Cours 10, qui posent sur le lac des transactions, un historique et un schéma qui évolue, et les contrats de données du Cours 11, qui jugent chaque livraison et disent à qui il faut quand elle ne tient pas sa promesse. Le dernier, le capstone, efface la plateforme, la refait de zéro par un seul DAG et prouve qu'elle est revenue identique ; il rejoue le chemin chaud, monte le tableau de bord de l'usine dans Grafana, et livre le dépôt 01_de avec son README.md et une étiquette v1.0. Ce que la formation livre à Analytics Engineering est décrit dans 01_Boreal/Solution/LIVRAISON.md, table par table.

Ce que contient le dossier

	Fichiers	À quoi ça sert
Pour suivre la formation	01_Boreal/ (les dossiers de cours et Mise_en_situation_Boreal_01_DE.md), 02_Brulerie_facile/, 03_Aurore_avancee/, requirements.txt ; la mise en situation du parcours dans Data_Domain/Mises_en_situation/ ; les générateurs dans Data_Domain/_univers/	les supports, le mandat, la pile, les données
Pour comparer ou débloquer	01_Boreal/Solution/, 02_Brulerie_facile/Solution/, 03_Aurore_avancee/Solution/	l'état de référence du dépôt 01_de, cours après cours, celui du mini-cas et celui de la synthèse, et la façon de les rejouer
Pour l'auteur	PLAN_MODULES.md, STYLE.md, formation.json, lint_md.py, md_vers_docx.py	le plan, la charte, la chaîne .md → .docx (outillage commun dans Formations/_commun/)

Un dossier que vous ne trouverez pas : Data_Domain/Projet_Boreal/. C'est la plateforme de données que vous bâtissez, avec votre propre dépôt Git, 01_de/. Le guide d'installation du parcours crée le dossier et les données, le Labo 01 votre dépôt.

À la première ouverture d'un .docx. Le sommaire et les numéros de page sont des champs Word : ils arrivent vides. Sélectionnez tout, Ctrl+A, puis appuyez sur F9 et choisissez « Mettre à jour toute la table ». Word les tient à jour ensuite, et les recalcule à chaque impression.

Prérequis

- Le SQL courant : SELECT, WHERE, GROUP BY, JOIN, une agrégation. On écrit du SQL ici, on ne l'enseigne pas. Ce que les labos empruntent au-delà du SQL courant est inventorié dans Data_Domain/prerequis/RENVOIS_SQL.md, avec le cours de SQL avancé qui l'enseigne.

- La syntaxe de Python : la formation enseigne ce qui rend un pipeline robuste, pas le langage. Chaque outil du langage qu'un labo fait taper reçoit sa glose d'une ligne à son premier emploi.
- Six gestes au terminal, et pas davantage : se déplacer (`cd`), créer un dossier (`mkdir`), lancer un conteneur (`docker`, `docker compose`), ouvrir l'Ubuntu de WSL 2 (`wsl`), lire la fin d'un fichier (`tail`), peser un dossier (`du`). Le guide d'installation du parcours monte tout le reste. La formation Linux n'est pas un prérequis : elle a deux cours écrits sur neuf.
- Un poste Windows capable de faire tourner WSL 2 (la virtualisation activée), ou un poste macOS ou Linux avec Docker.
- Aucune notion industrielle : le Cours 01 présente le SCADA et l'historien, le Cours 08 les creuse.

Place dans le parcours

Numéro 01 du parcours du domaine des données : le début de la chaîne, en amont d'Analytics Engineering, qui reprend la couche RAW. La carte complète, et la raison de cet ordre, est en tête du `README.md` des formations.