Table des matières

Data Engineering — Formation 1
Démarrage rapide 1
Les douze cours 2
Ce que contient le dossier 3
Prérequis 4
Place dans le parcours 6

Data Engineering — Formation

Formation d'ingénierie des données (*data engineering*), sous forme de supports Markdown. Elle couvre l'amont de la chaîne : faire arriver la donnée, la ranger, la faire tourner à l'heure, et prouver qu'elle est bonne. Elle va jusqu'à la couche `RAW` comprise, qu'elle produit et livre à la formation Analytics Engineering, et livre en plus les séries de terrain qu'elle seule sait nettoyer.

Le cas d'étude est un fabricant fictif de véhicules récréatifs, Véhicules Boréal inc. : un ERP de type SAP, une usine instrumentée (SCADA, historien, GMAO, compteur électrique), des véhicules connectés en MQTT, un portail des garanties, une documentation, et de la vraie météo publique. Le même univers sert les sept formations du parcours. Douze cours, du premier regard au pipeline complet, par lots et en continu, refaits à trois niveaux : La Brûlerie, un café de quartier, pour apprendre ; Boréal intermédiaire, pour approfondir ; Boréal avancé, le plus exigeant, à écrire.

Les deux chemins, en une ligne chacun :

- le froid : ERP, historien, garanties, télémétrie archivée → ingestion → lac (bronze, argent) → couche `RAW` et séries de l'usine ;
- le chaud : usine et véhicules → MQTT → Kafka → base de séries temporelles → Grafana.

La pile est ouverte et locale : Python, DuckDB, Parquet, Iceberg, Docker dans l'Ubuntu de WSL 2, PostgreSQL, Airflow, Spark, MQTT, Kafka, TimescaleDB, Grafana. Rien n'oblige à ouvrir un compte infonuagique ; Snowflake et Databricks reçoivent des annexes là où ils changent le geste.

Démarrage rapide

```
conda create -n formations python=3.11 -y
conda activate formations
pip install -r requirements.txt
```

Puis Git, Docker Engine dans l'Ubuntu de WSL 2 et le pilote psqlODBC. Le guide d'installation du parcours, `Data_Domain/00_Installation/Guide_installation.md`, refait chacun de ces gestes en détail : commencez par lui. La plateforme de Boréal, elle, s'allume

© 2026 iAlexMG. Tous droits réservés.

dans les cours qui s'en servent : la base de l'ERP au Cours 04, Airflow au Cours 06, la base de séries temporelles au Cours 08, le courtier MQTT et Kafka au Cours 09.

Les données se fabriquent au Cours 00 : depuis `Data_Domain/`, `mkdir Projet_Boreal_intermediaire` crée le projet, puis `python _univers/boreal/generer_boreal.py --projet Projet_Boreal_intermediaire` produit les sources de Boréal dans `Projet_Boreal_intermediaire/sources/`, en un peu plus d'une minute. Seule la vraie API météo se consulte en ligne, au Cours 04 ; le générateur en lit un instantané figé.

Les douze cours

La formation compte douze cours, numérotés 01 à 12, précédés d'un Cours 00 qui génère les données sources. L'installation n'en fait pas partie : le socle du poste se monte une seule fois pour tout le parcours, avec le guide d'installation.

Cours	Sujet	État
00	Générer les données sources	rédigé
01	Analyser les sources	rédigé
02	Ranger les fichiers en bronze	rédigé
03	Charger la `RAW`	rédigé
04	Extraire d'une base ou d'une API	rédigé
05	Rendre le pipeline robuste	rédigé
06	Orchestrer et rattraper	rédigé
07	Traiter un gros volume	rédigé
08	Lire des séries temporelles	rédigé
09	Ingérer un flux d'événements	rédigé
10	Passer à un format de table ouvert	rédigé
11	Contrôler la qualité	rédigé
12	Rebâtir le pipeline de bout en bout	rédigé

© 2026 iAlexMG. Tous droits réservés.

Cours	Sujet	État
La Brûlerie	les mêmes cours, 00 à 12, en petit, sur un mois de caisse figé : deux supports par cours	écrite : 00 à 12

Chaque cours compte trois supports : `Theorie_NN.md`, `Labo_NN.md` et `Exercices_corriges_NN.md`, qui porte les énoncés puis leur corrigé. Le plan détaillé des modules, et ce que la formation livre aux suivantes, est dans `PLAN_MODULES.md`.

Les douze cours rédigés forment un tout qui se suit et se rejoue : ils montent la couche `RAW` de Boréal, 22 tables et 513 857 lignes, les séries de l'usine que le Cours 08 nettoie, le chemin chaud du Cours 09, du courtier MQTT à Kafka et à la base de séries temporelles, jusqu'à l'alerte de vibration, les tables Iceberg et Delta du Cours 10, qui posent sur le lac des transactions, un historique et un schéma qui évolue, et les contrats de données du Cours 11, qui jugent chaque livraison et disent à qui il faut quand elle ne tient pas sa promesse. Le dernier, le capstone, efface la plateforme, la refait de zéro par un seul DAG et prouve qu'elle est revenue identique ; il rejoue le chemin chaud, monte le tableau de bord de l'usine dans Grafana, et livre le dépôt `01_de` avec son `README.md` et une étiquette `v1.0`. Ce que la formation livre à Analytics Engineering est décrit dans `02_Boreal_intermediaire/Solution/LIVRAISON.md`, table par table.

Ce que contient le dossier

	Fichiers	À quoi ça sert
Pour suivre la formation	`01_Brulerie_facile/`, `02_Boreal_intermediaire/` (les dossiers de cours et `Mise_en_situation_Boreal_01_DE.md`), `requirements.txt` ; la mise en situation du parcours dans `Data_Domain/Mises_en_situation/` ; les générateurs dans `Data_Domain/_univers/`	les supports, le mandat, la pile, les données
Pour comparer ou débloquer	`01_Brulerie_facile/Solution/`, `02_Boreal_intermediaire/Solution/`	l'état de référence du dépôt `01_de`, celui de La Brûlerie et celui de Boréal cours après cours, et la façon de les rejouer
Pour l'auteur	`PLAN_MODULES.md`, `STYLE.md`, `formation.json`, `lint_md.py`, `md_vers_docx.py`	le plan, la charte, la chaîne `.md → .docx` (outillage commun dans `Formations/_commun/`)

Un dossier que vous ne trouverez pas : `Data_Domain/Projet_Boreal_intermediaire/`. C'est la plateforme de données que vous bâtissez, avec votre propre dépôt Git, `01_de/`. Le Cours 00 crée le dossier et ses données, le Cours 01 votre dépôt.

À la première ouverture d'un `.docx`. Le sommaire et les numéros de page sont des champs Word : ils arrivent vides. Sélectionnez tout, Ctrl+A, puis appuyez sur F9 et choisissez « Mettre à jour toute la table ». Word les tient à jour ensuite, et les recalcule à chaque impression.

© 2026 iAlexMG. Tous droits réservés.

Prérequis

- Les Cours 01 et 02 de la formation SQL avancé : le modèle relationnel, les jointures, `NULL`, puis lire et calculer (filtres, `CASE`, types, texte, dates, agrégats). C'est le socle, exigé avant le Cours 01. On écrit du SQL ici, on ne l'enseigne pas : le reste du langage se prend au besoin, et chaque notion reçoit, à son premier emploi, une phrase et le cours de SQL avancé qui l'enseigne. La carte suit la liste.
- La syntaxe de Python : la formation enseigne ce qui rend un pipeline robuste, pas le langage. Chaque outil du langage qu'un labo fait taper reçoit sa glose d'une ligne à son premier emploi.
- Six gestes au terminal, et pas davantage : se déplacer (`cd`), créer un dossier (`mkdir`), lancer un conteneur (`docker`, `docker compose`), ouvrir l'Ubuntu de WSL 2 (`wsl`), lire la fin d'un fichier (`tail`), peser un dossier (`du`). Le guide d'installation du parcours monte tout le reste. La formation Linux n'est pas un prérequis : elle a deux cours écrits sur neuf.
- Un poste Windows capable de faire tourner WSL 2 (la virtualisation activée), ou un poste macOS ou Linux avec Docker.
- Aucune notion industrielle : le Cours 01 présente le SCADA et l'historien, le Cours 08 les creuse.

Ce que chaque cours emprunte à SQL avancé

Les cours qui renvoient à SQL avancé au-delà du socle, et vers quels cours. Qui veut prendre SQL au fil de l'eau fait, avant chaque cours, ceux de la dernière colonne qu'il n'a pas encore faits.

Cas	Cours	Ce qu'il emprunte au-delà du socle	Cours de SQL avancé
Boréal	Cours 01	les expressions de table communes, l'agrégat filtré (`FILTER`), `UNION ALL`	05, 06, 07
Boréal	Cours 02	le plan d'une requête (`EXPLAIN ANALYZE`), dans les exercices	10
Boréal	Cours 03	créer, remplacer et remplir une table, la transaction, les flèches du JSON ; `QUALIFY ROW_NUMBER()` et `EXCEPT`, dans les exercices	03, 04, 07, 08
Boréal	Cours 04	l'index et le plan d'une requête, `QUALIFY ROW_NUMBER()`, `EXCEPT`	04, 07, 10
Boréal	Cours 07	les plans d'un moteur SQL, à côté de ceux de Spark ; le fenêtrage	04, 10

© 2026 iAlexMG. Tous droits réservés.

Cas	Cours	Ce qu'il emprunte au-delà du socle	Cours de SQL avancé
Boréal	Cours 08	les vues, `LAG` et la somme cumulée, les îlots, `arg_max`, la jointure as-of, le fuseau d'une journée, `TIME_BUCKET`	03, 04, 09
Boréal	Cours 09	les contraintes et `ON CONFLICT`	03
Boréal	Cours 10	`UNNEST` et `LATERAL` sur un document JSON	07, 08
Boréal	Cours 11	`EXISTS`, les cadres de fenêtre, la médiane	04, 07, 09
Boréal	Cours 12	`STRING_AGG`	06
La Brûlerie	cours 01, 03 et 05	rien : le socle suffit	aucun
La Brûlerie	cours 02	le dernier export d'un jour par `MAX(…) OVER (PARTITION BY …)` et `QUALIFY` ; le contrôle jour par jour, en expressions de table communes (`WITH`)	04, 05
La Brûlerie	cours 04	rien de neuf : `WITH` revient du cours 02	aucun
La Brûlerie	cours 06	deux entrepôts comparés dans les deux sens par `EXCEPT ALL`, mis bout à bout par `UNION ALL`	07
La Brûlerie	cours 07	le plan d'une requête (`EXPLAIN ANALYZE`), une table née d'une requête (`CREATE OR REPLACE TABLE … AS`), une série sans table (`range`) collée par `CROSS JOIN`	03, 05, 10
La Brûlerie	cours 08	la ligne précédente (`LAG`), l'agrégat filtré (`FILTER`)	04, 06

© 2026 iAlexMG. Tous droits réservés.

Cas	Cours	Ce qu'il emprunte au-delà du socle	Cours de SQL avancé
La Brûlerie	cours 09	la clé primaire, et l'écriture qui ne double rien (`INSERT … ON CONFLICT DO NOTHING`)	03
La Brûlerie	cours 10	rien de neuf : `EXCEPT ALL` revient du cours 06 ; `SET VARIABLE` et les fonctions de l'extension `iceberg` s'expliquent sur place	aucun
La Brûlerie	cours 11	rien de neuf : `CASE`, `ABS` et `split_part` sont du socle, `UNION ALL` revient du cours 06	aucun
La Brûlerie	cours 12	rien de neuf : `EXCEPT ALL` revient du cours 06, `QUALIFY` du cours 02, `FILTER` du cours 08	aucun

Les fonctions de table de DuckDB (`read_csv`, `read_json`, `read_parquet`, `read_blob`), `ATTACH` et `COPY` ne sont pas des emprunts : la formation les explique là où elles servent. Le hachage (`md5`, `sha256`) et `COLUMNS(*)` n'ont pas de renvoi : SQL avancé les traite avec les patrons de la chaîne de données, dans un cours que sa refonte ajoute.

Place dans le parcours

Numéro 01 du parcours du domaine des données : le début de la chaîne, en amont d'Analytics Engineering, qui reprend la couche `RAW`. La carte complète, et la raison de cet ordre, est en tête du `README.md` des formations.

© 2026 iAlexMG. Tous droits réservés.