Table des matières

Data Engineering — Formation 1
Démarrage rapide 1
Les douze cours 2
Ce que contient le dossier 3
Prérequis 4
Place dans le parcours 5

Data Engineering — Formation

Formation d'ingénierie des données (*data engineering*), sous forme de supports Markdown. Elle couvre l'amont de la chaîne : faire arriver la donnée, la ranger, la faire tourner à l'heure, et prouver qu'elle est bonne. Elle va jusqu'à la couche `RAW` comprise, qu'elle produit et livre à la formation Analytics Engineering, et livre en plus les séries de terrain qu'elle seule sait nettoyer.

Le cas d'étude est un fabricant fictif de véhicules récréatifs, Véhicules Boréal inc. : un ERP de type SAP, une usine instrumentée (SCADA, historien, GMAO, compteur électrique), des véhicules connectés en MQTT, un portail des garanties, une documentation, et de la vraie météo publique. Le même univers sert les sept formations du parcours. Douze cours, du premier regard au pipeline complet, par lots et en continu, puis une synthèse.

Les deux chemins, en une ligne chacun :

- le froid : ERP, historien, garanties, télémétrie archivée → ingestion → lac (bronze, argent) → couche `RAW` et séries de l'usine ;
- le chaud : usine et véhicules → MQTT → Kafka → base de séries temporelles → Grafana.

La pile est ouverte et locale : Python, DuckDB, Parquet, Iceberg, Docker dans l'Ubuntu de WSL 2, PostgreSQL, Airflow, Spark, MQTT, Kafka, TimescaleDB, Grafana. Rien n'oblige à ouvrir un compte infonuagique ; Snowflake et Databricks reçoivent des annexes là où ils changent le geste.

Démarrage rapide

```
conda create -n formations python=3.11 -y
conda activate formations
pip install -r requirements.txt
```

Puis Git, Docker Engine dans l'Ubuntu de WSL 2 et le pilote psqlODBC. Le guide d'installation du parcours, `Data_Domain/00_Installation/Guide_installation.md`, refait chacun de ces gestes en détail : commencez par lui. La plateforme de Boréal, elle, s'allume

© 2026 iAlexMG. Tous droits réservés.

dans les cours qui s'en servent : la base de l'ERP au Cours 04, Airflow au Cours 06, la base de séries temporelles au Cours 08, le courtier MQTT et Kafka au Cours 09.

Les données se fabriquent, au début du Labo 01 : depuis `Data_Domain/`, `mkdir Projet_Boreal` crée le projet, puis `python _univers/boreal/generer_boreal.py --projet Projet_Boreal` produit les sources de Boréal dans `Projet_Boreal/sources/`, en un peu plus d'une minute. Seule la vraie API météo se consulte en ligne, au Cours 04 ; le générateur en lit un instantané figé.

Les douze cours

La formation compte douze cours, numérotés 01 à 12. L'installation n'en fait pas partie : le socle du poste se monte une seule fois pour tout le parcours, avec le guide d'installation.

Cours	Sujet	État
01	Le métier, les sources et le premier regard	rédigé
02	Les formats de fichiers et le lac bronze	rédigé
03	Charger des fichiers dans la couche RAW	rédigé
04	Lire une base et une API	rédigé
05	Le code d'un pipeline robuste	rédigé
06	Orchestration avec Airflow	rédigé
07	Traitement distribué avec Spark	rédigé
08	Données de terrain : SCADA, historien et séries temporelles	rédigé
09	Streaming et événements : MQTT et Kafka	rédigé
10	Formats de table ouverts, lakehouse et médaillon	rédigé
11	Qualité, contrats et observabilité	rédigé
12	Capstone : un pipeline de bout en bout	rédigé
Mini-cas	La Brûlerie, un mois de caisse du fichier au contrat, le premier arc fait seul	rédigé

© 2026 iAlexMG. Tous droits réservés.

Cours	Sujet	État
Synthèse	Comptoir Aurore, une base lue par son journal de capture, et un flux web qui livre en double et en retard	rédigé

Chaque cours compte trois supports : `Theorie_NN.md`, `Labo_NN.md` et `Exercices_corriges_NN.md`, qui porte les énoncés puis leur corrigé. Le plan détaillé des modules, et ce que la formation livre aux suivantes, est dans `PLAN_MODULES.md`.

Les douze cours rédigés forment un tout qui se suit et se rejoue : ils montent la couche `RAW` de Boréal, 22 tables et 513 857 lignes, les séries de l'usine que le Cours 08 nettoie, le chemin chaud du Cours 09, du courtier MQTT à Kafka et à la base de séries temporelles, jusqu'à l'alerte de vibration, les tables Iceberg et Delta du Cours 10, qui posent sur le lac des transactions, un historique et un schéma qui évolue, et les contrats de données du Cours 11, qui jugent chaque livraison et disent à qui il faut quand elle ne tient pas sa promesse. Le dernier, le capstone, efface la plateforme, la refait de zéro par un seul DAG et prouve qu'elle est revenue identique ; il rejoue le chemin chaud, monte le tableau de bord de l'usine dans Grafana, et livre le dépôt `01_de` avec son `README.md` et une étiquette `v1.0`. Ce que la formation livre à Analytics Engineering est décrit dans `01_Boreal/Solution/LIVRAISON.md`, table par table.

Ce que contient le dossier

	Fichiers	À quoi ça sert
Pour suivre la formation	`01_Boreal/` (les dossiers de cours et `Mise_en_situation_Boreal_01_DE.md`), `02_Brulerie_facile/`, `03_Aurore_avancee/`, `requirements.txt` ; la mise en situation du parcours dans `Data_Domain/Mises_en_situation/` ; les générateurs dans `Data_Domain/_univers/`	les supports, le mandat, la pile, les données
Pour comparer ou débloquer	`01_Boreal/Solution/`, `02_Brulerie_facile/Solution/`, `03_Aurore_avancee/Solution/`	l'état de référence du dépôt `01_de`, cours après cours, celui du mini-cas et celui de la synthèse, et la façon de les rejouer
Pour l'auteur	`PLAN_MODULES.md`, `STYLE.md`, `formation.json`, `lint_md.py`, `md_vers_docx.py`	le plan, la charte, la chaîne `.md → .docx` (outillage commun dans `Formations/_commun/`)

Un dossier que vous ne trouverez pas : `Data_Domain/Projet_Boreal/`. C'est la plateforme de données que vous bâtissez, avec votre propre dépôt Git, `01_de/`. Le Labo 01 crée le dossier, ses données et votre dépôt.

À la première ouverture d'un `.docx`. Le sommaire et les numéros de page sont des champs Word : ils arrivent vides. Sélectionnez tout, Ctrl+A, puis appuyez sur F9 et choisissez « Mettre à jour toute la table ». Word les tient à jour ensuite, et les recalcule à chaque impression.

© 2026 iAlexMG. Tous droits réservés.

Prérequis

- Les Cours 01 et 02 de la formation SQL avancé : le modèle relationnel, les jointures, `NULL`, puis lire et calculer (filtres, `CASE`, types, texte, dates, agrégats). C'est le socle, exigé avant le Cours 01. On écrit du SQL ici, on ne l'enseigne pas : le reste du langage se prend au besoin, et chaque notion reçoit, à son premier emploi, une phrase et le cours de SQL avancé qui l'enseigne. La carte suit la liste.
- La syntaxe de Python : la formation enseigne ce qui rend un pipeline robuste, pas le langage. Chaque outil du langage qu'un labo fait taper reçoit sa glose d'une ligne à son premier emploi.
- Six gestes au terminal, et pas davantage : se déplacer (`cd`), créer un dossier (`mkdir`), lancer un conteneur (`docker`, `docker compose`), ouvrir l'Ubuntu de WSL 2 (`wsl`), lire la fin d'un fichier (`tail`), peser un dossier (`du`). Le guide d'installation du parcours monte tout le reste. La formation Linux n'est pas un prérequis : elle a deux cours écrits sur neuf.
- Un poste Windows capable de faire tourner WSL 2 (la virtualisation activée), ou un poste macOS ou Linux avec Docker.
- Aucune notion industrielle : le Cours 01 présente le SCADA et l'historien, le Cours 08 les creuse.

Ce que chaque cours emprunte à SQL avancé

Les cours qui renvoient à SQL avancé au-delà du socle, et vers quels cours. Qui veut prendre SQL au fil de l'eau fait, avant chaque cours, ceux de la dernière colonne qu'il n'a pas encore faits.

Cas	Cours	Ce qu'il emprunte au-delà du socle	Cours de SQL avancé
Boréal	Cours 01	les expressions de table communes, l'agrégat filtré (`FILTER`), `UNION ALL`	05, 06, 07
Boréal	Cours 02	le plan d'une requête (`EXPLAIN ANALYZE`), dans les exercices	10
Boréal	Cours 03	créer, remplacer et remplir une table, la transaction, les flèches du JSON ; `QUALIFY ROW_NUMBER()` et `EXCEPT`, dans les exercices	03, 04, 07, 08
Boréal	Cours 04	l'index et le plan d'une requête, `QUALIFY ROW_NUMBER()`, `EXCEPT`	04, 07, 10
Boréal	Cours 07	les plans d'un moteur SQL, à côté de ceux de Spark ; le fenêtrage	04, 10

© 2026 iAlexMG. Tous droits réservés.

Cas	Cours	Ce qu'il emprunte au-delà du socle	Cours de SQL avancé
Boréal	Cours 08	les vues, `LAG` et la somme cumulée, les îlots, `arg_max`, la jointure as-of, le fuseau d'une journée, `TIME_BUCKET`	03, 04, 09
Boréal	Cours 09	les contraintes et `ON CONFLICT`	03
Boréal	Cours 10	`UNNEST` et `LATERAL` sur un document JSON	07, 08
Boréal	Cours 11	`EXISTS`, les cadres de fenêtre, la médiane	04, 07, 09
Boréal	Cours 12	`STRING_AGG`	06
La Brûlerie	leçons 01 et 02	rien : le socle suffit	aucun
Aurore	la synthèse	les flèches du JSON, les expressions de table communes, `QUALIFY ROW_NUMBER()`, `NOT EXISTS`, `UNION ALL`	04, 05, 07, 08

Les fonctions de table de DuckDB (`read_csv`, `read_json`, `read_parquet`, `read_blob`), `ATTACH` et `COPY` ne sont pas des emprunts : la formation les explique là où elles servent. Le hachage (`md5`, `sha256`) et `COLUMNS(*)` n'ont pas de renvoi : SQL avancé les traite avec les patrons de la chaîne de données, dans un cours que sa refonte ajoute.

Place dans le parcours

Numéro 01 du parcours du domaine des données : le début de la chaîne, en amont d'Analytics Engineering, qui reprend la couche `RAW`. La carte complète, et la raison de cet ordre, est en tête du `README.md` des formations.

© 2026 iAlexMG. Tous droits réservés.