

Table des matières

Cours 02 — Modélisation dimensionnelle et matrice de bus.....	1
Objectifs.....	2
1. Ce que la forme normalisée fait bien, et pourquoi elle gêne ici.....	2
2. La recette en quatre temps.....	3
3. Le grain.....	4
4. Les faits et leurs mesures.....	4
5. L'étoile et le flocon.....	5
6. La clé de substitution.....	5
7. Quand une dimension change.....	6
8. La dimension dégénérée.....	7
9. Les dimensions conformes.....	7
10. La matrice de bus.....	8
11. Les trois étoiles de Boréal.....	8
12. Le forage transversal.....	9
Points clés à retenir.....	9
Exercices.....	10

Cours 02 — Modélisation dimensionnelle et matrice de bus

Théorie · Module 2/9 — Formation Analytics Engineering · ~50 min · intermédiaire

Où vous êtes : RAW → STAGING → INTERMEDIATE → MARTS. Le Cours 02 conçoit la cible avant de bâtir quoi que ce soit, et n'ouvre aucun outil : la modélisation se fait sur papier, puis se vérifie en SQL.

En 30 secondes :

- Le modèle d'une application est fait pour écrire vite sans se contredire. Celui d'un entrepôt est fait pour répondre à des questions. Les deux ne peuvent pas être le même modèle.

- La recette tient en quatre temps, toujours dans cet ordre : le processus, le grain, les dimensions, les faits. Sauter le deuxième est la faute la plus coûteuse du métier.
- Le grain est la phrase qui dit ce qu'une ligne du fait représente. Il se déclare avant les colonnes, et ne se discute plus après.
- Une dimension décrit, un fait mesure. La clé de substitution sépare l'identité du modèle de l'identifiant du système source, et c'est elle qui rendra l'historique possible.
- Boréal n'a pas une étoile à concevoir, mais trois, et ce qu'elles partagent compte plus que ce qui les distingue.

L'idée du cours. Un entrepôt mal conçu ne se répare pas en écrivant du meilleur SQL : il se reconçoit, et tout ce qui en dépend se réécrit. C'est pourquoi ce cours vient avant dbt, avant les tests, avant tout. Vous allez apprendre à déclarer un grain, à distinguer une mesure additive d'une autre qui ne l'est pas, et à voir venir les changements d'une dimension avant qu'ils ne vous surprennent. Au labo, vous écrirez les prototypes en SQL pur, sans outil, pour que la conception reste la conception.

Objectifs

- Dire pourquoi la forme normalisée, faite pour une application, gêne l'analyse.
- Appliquer la recette de Kimball en quatre temps, dans l'ordre.
- Déclarer le grain d'un fait en une phrase, et reconnaître un grain mal déclaré.
- Distinguer une mesure additive, semi-additive et non additive, et dire ce qu'on a le droit de sommer.
- Distinguer une étoile d'un flocon, et dire ce qu'on gagne et perd à dénormaliser.
- Expliquer ce qu'une clé de substitution rend possible qu'une clé naturelle interdit.
- Choisir entre une dimension à évolution lente de type 1 et de type 2, en disant ce que chacune fait perdre.
- Reconnaître une dimension dégénérée et dire où elle vit.

Ce cours se lit en deux séances. La première va jusqu'à la fin de la section 7 : la recette, le grain, les mesures, l'étoile et les dimensions qui changent. La seconde porte les dimensions conformes, la matrice de bus et les trois étoiles de Boréal.

1. Ce que la forme normalisée fait bien, et pourquoi elle gêne ici

L'ERP de Boréal range ses commandes comme toute application sérieuse : chaque information vit à un seul endroit. Le nom d'un concessionnaire est écrit une fois, dans sa fiche, et les 25 483 commandes y renvoient par un numéro. Si le nom change, une seule ligne bouge.

C'est la forme normalisée, et elle est parfaitement adaptée à ce qu'une application fait toute la journée : écrire une ligne à la fois, sans jamais se contredire.

L'analyse fait le contraire. Elle écrit rarement et lit énormément, sur beaucoup de lignes à la fois, et sa question type ressemble à : quelle gamme s'est le mieux vendue au Québec, par trimestre, chez les concessionnaires de palier Or ? Sur un modèle normalisé, cette question demande de joindre cinq tables, de connaître le sens de trois codes et de savoir lesquelles des lignes comptent. Elle est écrite différemment par chaque personne qui la pose, et les résultats divergent.

Le modèle dimensionnel accepte la redondance pour retirer les jointures et les décisions. La province du concessionnaire est recopiée sur chaque ligne de sa dimension ; le libellé du palier est écrit en toutes lettres, pas en code. On stocke plus pour lire plus simplement, et le stockage ne coûte plus rien depuis longtemps.

Labo : Labo_02.md, étape 6.

Renvoi : la forme normalisée et le modèle relationnel sont au Cours 01 de SQL ; les jointures, au Cours 02.

À retenir — ce n'est pas un modèle meilleur, c'est un modèle pour un autre usage. L'ERP a raison d'être normalisé, et vous auriez tort de l'imiter. Les deux modèles coexistent chez Boréal, et c'est votre travail que de passer de l'un à l'autre.

2. La recette en quatre temps

Ralph Kimball a laissé une recette en quatre étapes, et son intérêt n'est pas dans les étapes elles-mêmes mais dans leur ordre. Chacune ferme des questions pour la suivante.

Temps	La question	Ce qu'on écrit
1. Le processus	Quel événement du métier mesure-t-on ?	une phrase : « un concessionnaire commande »
2. Le grain	Que représente une ligne du fait ?	une phrase : « une ligne de commande »
3. Les dimensions	Selon quels axes veut-on découper ?	la liste : date, concessionnaire, produit
4. Les faits	Que mesure-t-on, et comment ?	la liste : quantité, valeur nette, coût

L'erreur la plus commune est de commencer par le quatrième temps, parce que c'est le plus concret : on sait qu'on veut du chiffre d'affaires, alors on part de là. Le résultat est une table dont personne ne sait dire ce qu'une ligne représente, et dont les totaux se mettent à dépendre de la façon dont on l'interroge.

Le premier temps mérite un mot. Un processus métier est un événement qui se produit dans la vraie vie, pas un besoin de rapport. « Un concessionnaire commande » est un processus. « Le tableau de bord des ventes de la direction » n'en est pas un : c'est un usage, et un usage se sert de plusieurs processus.

Labo : Labo_02.md, étape 1.

3. Le grain

Le grain est la phrase qui dit ce qu'une ligne du fait représente. Il se déclare en deuxième, avant de choisir la moindre colonne, et il ne se rediscute plus ensuite.

Chez Boréal, pour les ventes, deux grains sont possibles :

Grain	Une ligne représente	Lignes
La ligne de commande	un article commandé, sur une commande	77 732
La commande	une commande, tous articles confondus	25 483

Le premier est plus fin, et c'est celui qu'il faut prendre. La règle est constante : prenez toujours le grain le plus fin que la source permet, même si personne ne demande ce niveau de détail aujourd'hui.

La raison est asymétrique. D'un grain fin, on remonte toujours au grain grossier par une somme. De l'inverse, on ne redescend jamais : l'information n'est plus là. Un entrepôt qui a agrégé trop tôt ne se répare qu'en refaisant le chargement, et parfois la source a disparu entre-temps.

Ce que le grain fin de Boréal permet, et que le grain « commande » interdirait pour toujours : la question « quelle gamme se vend le mieux », puisqu'une commande porte plusieurs gammes ; le compte des postes refusés, puisque le refus est par article ; le prix moyen d'un modèle, puisque la commande n'en connaît que le total.

Labo : Labo_02.md, étapes 1 et 5.

Piège — un grain qui se raconte en deux phrases n'en est pas un. Si vous écrivez « une ligne représente une ligne de commande, et parfois un total mensuel quand la ligne manque », vous avez deux faits dans une table. Séparez-les. Un fait porte un grain, un seul.

4. Les faits et leurs mesures

Un fait contient trois sortes de colonnes, et il vaut mieux savoir laquelle est laquelle : les clés vers les dimensions, les mesures, et parfois un attribut qui n'a pas de dimension à lui.

Les mesures ne se comportent pas toutes de la même façon quand on les somme, et c'est ce qu'on appelle l'additivité.

Type	Ce qu'on peut sommer	Exemple chez Boréal
Additive	selon toutes les dimensions	la valeur nette d'un poste, la quantité commandée
Semi-additive	selon toutes sauf le temps	un niveau de stock, la disponibilité d'un actif à une heure
Non additive	jamais directement	un taux, un pourcentage, un prix unitaire

La mesure additive est le cas confortable, et c’est celui du fait des ventes : additionner des valeurs nettes a du sens par date, par concessionnaire, par gamme, ou tout à la fois.

La semi-additive surprend. Un stock de 400 véhicules en janvier et 380 en février ne fait pas 780 véhicules : il se résume par une moyenne dans le temps, ou par la valeur d’un instant donné. Vous en rencontrerez une au Cours 06, avec la disponibilité des actifs de l’usine.

La non additive est celle qui fait le plus de dégâts, parce qu’elle semble se sommer. Un taux de marge de 18 pour cent et un autre de 22 pour cent ne donnent pas 40. La règle est simple et vaut la peine d’être écrite quelque part de visible : on ne stocke jamais un ratio dans un fait, on stocke son numérateur et son dénominateur, et le ratio se calcule à la lecture.

Labo : Labo_02.md, étape 5.

5. L’étoile et le flocon

Une fois le fait posé au centre et les dimensions autour, le schéma dessine une étoile. La question qui reste est de savoir si les dimensions ont, elles aussi, le droit d’avoir des tables autour d’elles.

	Étoile	Flocon
Les dimensions	à plat, dénormalisées	normalisées en plusieurs tables
Pour trouver la gamme d’un article	une colonne de dim_produit	une jointure de plus vers dim_gamme
Le nombre de jointures	une par dimension	deux ou trois pour certaines
Ce que ça économise	rien en stockage	quelques mégaoctets
Ce que ça coûte	quelques mégaoctets	de la lisibilité, à chaque requête

Le flocon est tentant pour qui vient du modèle relationnel, parce qu’il paraît plus propre : répéter « Motoneige » sur 15 articles heurte l’instinct. Mais l’économie est dérisoire à l’échelle d’une dimension, qui compte des dizaines ou des milliers de lignes, jamais des millions, et le coût est payé par chaque personne qui écrit une requête.

Chez Boréal, dim_produit porte 68 articles. La gamme, le type et l’année-modèle y sont des colonnes, pas des tables.

Labo : Labo_02.md, étape 4.

6. La clé de substitution

Une dimension a deux clés, et les confondre coûte cher.

La clé naturelle est celle du système source : 0000200077 pour un concessionnaire, avec ses zéros de tête. La clé de substitution est celle que l'entrepôt fabrique, et dont lui seul décide.

Trois raisons de fabriquer la seconde, et la troisième est celle qui compte.

La première est technique : un identifiant court et de type uniforme se joint plus vite qu'un texte de dix caractères, et l'entrepôt ne dépend plus du format de la source.

La deuxième est défensive : le jour où Boréal remplace son ERP, les identifiants changent. Si le fait pointait la clé naturelle, tout le fait serait à réécrire.

La troisième est la vraie : la clé de substitution permet de garder plusieurs versions d'une même entité. Le concessionnaire 0000200077 est une entité du monde ; il peut exister trois lignes qui le décrivent à trois époques, chacune avec sa propre clé de substitution. Sans cela, l'historique est impossible, et c'est tout l'objet de la section suivante.

Labo : Labo_02.md, étape 3.

7. Quand une dimension change

Un concessionnaire change de palier. Que fait votre dimension ?

La question paraît anodine et gouverne la moitié des erreurs d'un entrepôt. Kimball a numéroté les réponses ; deux suffisent en pratique.

Type	Ce qu'il fait	Ce qu'on garde	Ce qu'on perd
Type 1	écrase l'ancienne valeur	la vérité d'aujourd'hui	l'histoire, entièrement
Type 2	ferme l'ancienne ligne et en ouvre une neuve	les deux états, datés	de la simplicité

Le type 1 dit : ce concessionnaire est Or, et l'a toujours été pour ce que l'entrepôt en sait. Toute vente passée lui est désormais attribuée comme une vente Or.

Le type 2 dit : il était Bronze jusqu'au 30 juin, Or depuis le 1er juillet. Les ventes de mai restent des ventes Bronze. La dimension porte alors deux lignes pour un même concessionnaire, deux clés de substitution différentes, et deux dates de validité.

Le choix ne se fait pas par goût mais par question. « Quel palier a ce concessionnaire ? » demande un type 1. « Combien avons-nous vendu à des concessionnaires Or en mai ? » demande un type 2, et c'est une question à laquelle Boréal tient.

Chez Boréal, la révision des paliers du 1er juillet 2024 a touché 49 concessionnaires d'un coup. C'est le genre d'événement qui rend le choix visible : en type 1, ces 49 changements réécrivent silencieusement deux ans et demi d'historique commercial.

Labo : Labo_02.md, étape 3.

Piège — le type 2 ne s’ajoute pas après coup sans douleur. Passer une dimension de type 1 à type 2 oblige à rebrancher chaque fait qui la référence, pour qu’il pointe la version d’époque et non la version courante. C’est faisable, et c’est exactement ce que vous ferez au Cours 05 ; mais le savoir dès la conception évite de le découvrir en production.

8. La dimension dégénérée

Il reste un cas à nommer, parce qu’il surprend et qu’il est fréquent.

Le numéro de commande est un identifiant du monde réel : il regroupe les lignes d’une même commande, il sert au service à la clientèle, il figure sur les documents. C’est donc un axe d’analyse légitime. Pourtant il n’a aucun attribut : il n’y a rien à mettre dans une table `dim_commande`, ni libellé, ni catégorie, ni hiérarchie. Juste le numéro.

Dans ce cas, le numéro reste dans le fait, comme une colonne ordinaire, et on l’appelle une dimension dégénérée. Créer une table à une seule colonne pour lui serait une jointure payée pour rien.

La règle de reconnaissance tient en une question : cet identifiant a-t-il des attributs qui lui appartiennent ? Si oui, c’est une dimension. Si non, il reste dans le fait.

9. Les dimensions conformes

Ici commence la seconde séance de lecture.

Une entreprise n’a jamais une seule étoile. Boréal en aura trois, et la question qui décide de la valeur de l’ensemble n’est pas la qualité de chacune : c’est ce qu’elles partagent.

Une dimension conforme est une dimension unique, partagée par plusieurs faits, avec le même sens, les mêmes clés et les mêmes libellés. `dim_date` est conforme : la même table sert aux ventes, aux réclamations et aux heures de l’usine. `dim_vehicule` aussi : le véhicule assemblé, vendu au détail et réparé est le même objet, avec le même numéro de série.

Ce que cela rend possible est simple à énoncer et difficile à obtenir : poser une question qui traverse deux processus. Combien de véhicules assemblés la semaine du 20 octobre ont donné lieu à une réclamation ? Cette question ne se pose que si l’assemblage et les réclamations partagent la même dimension véhicule et la même dimension date.

L’échec est tout aussi simple : deux équipes construisent chacune leur dimension client, l’une nettoie les courriels et l’autre non, et plus personne ne peut relier les deux mondes. Ce n’est plus un problème technique à ce stade, c’est un problème d’organisation, et c’est pour cela qu’Archi reprendra cette pièce.

Renvoi : le Cours 02 d’Architecture et Gouvernance traite la dimension conforme comme un engagement entre équipes.

Labo : Labo_02.md, étapes 2 et 7.

10. La matrice de bus

La matrice de bus est l'outil qui rend tout cela visible en un coup d'œil. Les lignes sont les processus, les colonnes les dimensions, et une case cochée dit que ce processus se découpe selon cette dimension.

C'est la pièce maîtresse de la conception, et c'est aussi le document que vous montrerez à un métier : il le lit sans formation.

Elle sert à trois choses, et la troisième est la plus utile. Elle dit ce qu'on peut croiser aujourd'hui. Elle montre les trous, c'est-à-dire les questions qu'on ne peut pas encore poser. Et elle ordonne le travail : une dimension cochée par quatre processus se construit en premier, puisque tout en dépend.

Labo : Labo_02.md, étape 7.

11. Les trois étoiles de Boréal

Six processus, trois étoiles. Voici ce que vous allez concevoir, et ce que les cours 04 à 07 bâtiront.

Processus	Le fait	Le grain	Type de fait	Bâti au
Un concessionnaire commande	fct_ventes	une ligne de commande	transaction	Cours 04
Un véhicule est assemblé et expédié	fct_production	un numéro de série	sans mesure	Cours 06
Un véhicule est vendu au détail	fct_enregistrements	un enregistrement de garantie	transaction	Cours 06
Une réclamation suit son cycle	fct_reclamations	une réclamation	accumulation	Cours 06
Un véhicule connecté publie une sortie	fct_sorties	un message, dédoublonné	transaction	Cours 07
Un actif de l'usine passe une heure	fct_disponibilite_actifs	un actif et une heure	instantané périodique	Cours 06

Trois de ces types de faits sont neufs et arriveront au Cours 06 : l'instantané périodique, le fait d'accumulation et le fait sans mesure. Ce cours-ci pose leur grain, pas leur construction.

Ce qui les relie est la matrice que vous dessinerez au labo. Huit dimensions la traversent, dont trois sont partagées par presque tout : la date, le produit et le véhicule.

12. Le forage transversal

Le forage transversal est le geste que les dimensions conformes rendent possible : passer d'un fait à un autre en gardant le même axe.

Le cas de Boréal est celui de l'incident du compresseur, à l'automne 2025. Une dérive d'un compresseur d'air a touché les véhicules assemblés pendant une période donnée. La question qui compte est : parmi ces véhicules, combien ont fait l'objet d'une réclamation ?

Elle se répond en trois temps, et chacun passe par une dimension conforme. L'étoile de l'usine dit quand la dérive a eu lieu, par `dim_date`. L'étoile de la production dit quels numéros de série sont sortis pendant cette période, par `dim_date` et `dim_vehicule`. L'étoile de l'après-vente dit lesquels sont revenus, par `dim_vehicule`.

Sans dimensions conformes, cette chaîne se brise au premier maillon, et la seule façon de répondre est d'exporter trois fichiers et de les recouper à la main.

Recoupements. Le Cours 02 de SQL possède la forme normalisée et les jointures ; ici, on dit pourquoi l'analyse préfère l'étoile. Le modèle sémantique que Business Intelligence construira est la couche au-dessus de celle-ci, et n'en est pas une copie : il nomme et présente ce que les MARTS portent déjà. La matrice de bus est la pièce qu'Architecture et Gouvernance reprend au Cours 02, pour en faire un engagement entre équipes.

Points clés à retenir

- Le modèle d'une application et celui d'un entrepôt ne peuvent pas être le même : l'un écrit vite sans se contredire, l'autre répond à des questions.
- La recette tient en quatre temps, dans l'ordre : processus, grain, dimensions, faits. Commencer par les mesures produit une table dont personne ne sait ce qu'une ligne représente.
- Le grain se déclare en une phrase, avant les colonnes. Prenez le plus fin que la source permet : on remonte toujours par une somme, on ne redescend jamais.
- Une mesure additive se somme partout, une semi-additive partout sauf dans le temps, une non additive jamais. Un ratio ne se stocke pas : on stocke ses deux termes.
- L'étoile dénormalise ses dimensions et le flocon les normalise. L'économie du flocon est dérisoire, son coût est payé à chaque requête.
- La clé de substitution rend possible ce que la clé naturelle interdit : plusieurs versions datées d'une même entité.
- Type 1 écrase et perd l'histoire ; type 2 la garde et complique le fait. Le choix se fait par la question qu'on veut pouvoir poser.
- Un identifiant sans attributs propres reste dans le fait : c'est une dimension dégénérée.

- Une dimension conforme est partagée par plusieurs faits, avec le même sens et les mêmes clés. C'est elle qui rend le forage transversal possible, et son absence ne se rattrape pas en SQL.
-

Exercices

Les exercices de ce cours et leur corrigé vivent dans `Exercices_corrige_02.md`. Faites-les après le labo : plusieurs énoncés supposent que les prototypes ont été écrits.