Table des matières

Cours 00 — Générer les données sources 1
Ce que vous allez faire 1
Avant de commencer 1
Étape 1 — Générer la RAW · RAW 2
Étape 2 — Ce que vous avez maintenant · RAW 4
À retenir 4

Cours 00 — Générer les données sources

Cours de départ · La Brûlerie — Formation Analytics Engineering

Data Engineering	**Analytics Engineering**		
`RAW`	`STAGING`	`INTERMEDIATE`	`MARTS`
chargée telle que livrée →	reprendre la `RAW`, une vue par table	joindre, clarifier, préparer l'étoile	concevoir et livrer les étoiles
✓ ici			

Ce que vous allez faire

L'ingénieur analytique ne part jamais de rien : il reprend la couche `RAW` que l'ingénieur de données a chargée. En entreprise, cette `RAW` existe avant lui : Data Engineering la charge, et Analytics Engineering ne la modifie jamais. Il en tire plutôt ses propres versions, transformées et adaptées à ses besoins, une couche à la fois : le `STAGING`, l'`INTERMEDIATE`, puis les `MARTS`. La `RAW` reste telle que Data Engineering l'a chargée.

Ce cours vous donne votre `RAW` de départ, chargée par le code de Data Engineering : celui de la formation Data Engineering, déposé dans votre projet, ou le vôtre, si vous avez fait La Brûlerie en Data Engineering. Un script fait tout, et rien ne s'écrit à la main.

le mois livré → le chargeur de Data Engineering, `01_de` → la `RAW`, dans l'entrepôt partagé

Avant de commencer

Ce cours se fait dans l'Anaconda Prompt, placée dans `Data_Domain`, le dossier du parcours. Vérifier d'abord les outils :

© 2026 iAlexMG. Tous droits réservés.

```
conda activate formations
REM Attendu : (formations) au début de l'invite.
python --version
REM Attendu : une version 3.11 de Python.
duckdb --version
REM Attendu : v1.5.5 ou plus récent.
dbt --version
REM Attendu : sous Core, installed: 1.12.3 ; sous Plugins, duckdb: 1.11.0, ou plus récents.
```

Si l'un des outils manque, le guide d'installation du parcours, `00_Installation/Guide_installation.md`, le monte.

Étape 1 — Générer la RAW · RAW

La `RAW` de La Brûlerie compte sept tables, toutes en texte. Chaque ligne garde aussi, dans une colonne `filename`, le chemin du fichier livré d'où elle vient : c'est par elle que le cours 01 retrouvera une journée que la caisse a livrée deux fois. Quatre tables servent dès le cours 01 ; les trois journaux attendent les cours 05 et 06.

Table	Ce qu'elle garde	Sert dès le cours
`raw_tickets`	les tickets de la caisse	01
`raw_lignes`	leurs lignes, un produit vendu par ligne	01
`raw_produits`	le catalogue des produits	01
`raw_modifications`	le journal des modifications du catalogue	05
`raw_membres`	les membres du programme de fidélité	01
`raw_consentements`	le journal des consentements des membres	06
`raw_lots`	le journal des lots du torréfacteur	06

Le script de départ, `preparer_raw.py`, crée le projet et y copie le mois livré s'ils manquent. Puis il fait ce qu'une équipe d'analytique ne fait jamais elle-même : il fait charger la `RAW` par Data Engineering. Si votre projet n'a pas de dépôt `01_de`, il y dépose celui de la formation Data Engineering, tiré de son corrigé ; si vous avez fait La Brûlerie en Data Engineering, c'est votre propre `01_de` qui sert. Le chargeur de ce dépôt, `01_de\charger.py`, prend le mois jusqu'au 30 juin et l'écrit dans `plateforme\entrepot\brulerie.duckdb`, l'entrepôt que les deux formations partagent. Le script vérifie enfin chacune des sept tables : le nombre de lignes du mois, et le même contenu que le mois livré, ligne pour ligne.

1.1 Lancer le script, depuis `Data_Domain`.

```
python 02_Analytics_Engineering\01_Brulerie_facile\Paquet_de_depart\preparer_raw.py
REM Attendu : le bilan des sept tables, puis Conforme : la RAW d'AE est prête.
```


© 2026 iAlexMG. Tous droits réservés.

Si vous commencez par Analytics Engineering, le bilan se lit ainsi :

```
Sources : copiées du mini-cas, 101 fichiers
Data Engineering : le 01_de de la formation, déposé du corrigé, charge la RAW

Table                Lignes  Attendu  Provenance
raw_tickets            1585     1585  le 01_de de la formation
raw_lignes             2626     2626  le 01_de de la formation
raw_produits             32       32  le 01_de de la formation
raw_modifications       118      118  le 01_de de la formation
raw_membres             994      994  le 01_de de la formation
raw_consentements      1054     1054  le 01_de de la formation
raw_lots                 47       47  le 01_de de la formation

Conforme : la RAW d'AE est prête, dans Projet_Brulerie\plateforme\entrepot\brulerie.duckdb
```

Si vous avez fait La Brûlerie en Data Engineering, la première ligne devient `Sources : déjà là, 101 fichiers`, la deuxième `Data Engineering : votre dépôt 01_de, déjà là, charge la RAW`, et la provenance de chaque table, `votre 01_de`. Votre chargeur ne reprend que ce que son journal ne connaît pas : si vous l'avez mené jusqu'au 30 juin, il ne charge rien de neuf. Relancé, le script ne double rien non plus.

Si le script s'arrête, son dernier message dit pourquoi :

Message	**Ce qui se passe**	**Quoi faire**
`brulerie.duckdb est ouvert ailleurs, sans doute par le notebook`	un notebook de DuckDB, ou un autre programme, tient l'entrepôt : un fichier DuckDB ouvert par un processus bloque les autres	fermer le notebook (`.quit` dans son Anaconda Prompt), puis relancer
`1 écart(s) : la RAW chargée par votre 01_de n'est pas celle du mois livré`, ou plus d'un	votre `charger.py` de Data Engineering ne charge pas tout le mois, ou pas tel quel ; au-dessus, une ligne par table dit ce qui manque, `la table manque` ou `575 lignes au lieu de 1585`	finir ou corriger le cours 03 de Data Engineering, puis relancer ; ou partir du dépôt de la formation : `move Projet_Brulerie\01_de Projet_Brulerie\01_de_avant`, puis, depuis `Projet_Brulerie`, `python ..\01_Data_Engineering\01_Brulerie_facile\Paquet_de_depart\vider_tables_de.py`, et relancer
`1 écart(s)` alors que la provenance dit `le 01_de de la formation`	un fichier de `Projet_Brulerie\sources` a été changé	mettre le dossier de côté, `move Projet_Brulerie\sources Projet_Brulerie\sources_avant`, puis relancer : le script recopie le mois figé

© 2026 iAlexMG. Tous droits réservés.

Étape 2 — Ce que vous avez maintenant · RAW

2.1 Lister le projet.

```
dir /b Projet_Brulerie
REM Attendu : 01_de, plateforme et sources.
```

Trois dossiers, chacun avec son rôle :

- `sources\` : les fichiers que le café livre.
- `plateforme\` : ce que l'équipe de données fait tourner. L'entrepôt y vit, dans le fichier `plateforme\entrepot\brulerie.duckdb`, à côté du lac si vous avez fait Data Engineering.
- `01_de\` : le dépôt de Data Engineering, que vous l'ayez écrit ou que le script l'ait déposé. C'est lui qui charge la `RAW`, et au cours 07, c'est encore lui qui livrera juin jour après jour.

En entreprise, il n'y a pas un entrepôt par métier. L'organisation a d'ordinaire un seul entrepôt de données, sur une plateforme comme Snowflake ou BigQuery, et ses couches y vivent dans des zones séparées, des bases ou des schémas : Data Engineering écrit la `RAW`, Analytics Engineering la lit et écrit ses propres couches à côté, et des droits d'accès gardent chacun dans sa zone.

La formation fait de même, avec un seul fichier DuckDB. Les tables de Data Engineering et celles que vous bâtirez s'y côtoient, chacune reconnaissable à son préfixe, et chaque formation n'y efface jamais que les siennes. L'entrepôt porte donc aussi deux tables que vous ne lirez pas : `journal`, la liste des fichiers que Data Engineering a chargés, et `raw_courbes`, les courbes du torréfacteur. Votre propre dépôt, `02_ae`, s'ajoutera à côté de `01_de` au cours 03. Le cours 01 ouvre l'entrepôt dans le notebook de DuckDB et lit ce que la `RAW` a gardé.

À retenir

- La `RAW` est une frontière : Data Engineering la charge ; Analytics Engineering n'y touche jamais, il en tire ses propres versions, adaptées à ses besoins.
- La `RAW` de départ est chargée par le code de Data Engineering, le vôtre ou celui de la formation ; les deux donnent la même `RAW`, vérifiée table par table.

© 2026 iAlexMG. Tous droits réservés.