Table des matières

Cours 01 — Analyser la RAW reçue 1
Ce que vous allez faire 1
Avant de commencer 2
Étape 1 — La RAW reçue · STAGING 2
Étape 2 — Ce que la RAW garde exprès · STAGING 4
À retenir 6

Cours 01 — Analyser la RAW reçue

Cours 1/9 · La Brûlerie — Formation Analytics Engineering

Data Engineering	**Analytics Engineering**		
`RAW`	`STAGING`	`INTERMEDIATE`	`MARTS`
chargée telle que livrée →	reprendre la `RAW`, une vue par table	joindre, clarifier, préparer l'étoile	concevoir et livrer les étoiles
	✓ ici		

Ce que vous allez faire

La Brûlerie du Passage, un café de quartier fictif à Montréal, vous confie un mandat : livrer, pour juin 2025, des chiffres qui répondent à trois questions.

1. Qu'est-ce qui s'est vendu, par catégorie et par produit ?
2. Combien les membres du programme de fidélité ont-ils acheté, et combien les clients sans carte ?
3. Ces chiffres retombent-ils sur ceux de la caisse, au cent près ?

Le cours 00 a mis le mois dans l'entrepôt, tel qu'il a été livré : c'est la couche `RAW`. Votre métier d'ingénieur analytique commence là : vous recevez la `RAW`, et vous livrez une étoile qui répond au mandat. Entre les deux, trois couches, que montre le tableau en tête de chaque cours : le `STAGING` reprend la `RAW`, l'`INTERMEDIATE` la clarifie, les `MARTS` livrent l'étoile. « ✓ ici » marque la couche du cours. Avant d'écrire un modèle, vous lisez ce que vous recevez, avec les yeux du `STAGING`, la couche qui rendra la `RAW` lisible.

© 2026 iAlexMG. Tous droits réservés.

la RAW reçue → ce qu'elle garde exprès

Vous écrivez des requêtes dans ce cours, mais seulement pour lire et compter : aucune ne change l'entrepôt, puisqu'il s'ouvre en lecture seule, et aucun fichier du projet ne s'écrit. Les premiers modèles viennent au cours 03. Chaque requête se donne en pseudocode : les étapes en commentaire, et des trous ____ à remplir. Le code complet est dans Codes_01_AE.md, rangé par étape, à ouvrir après avoir essayé. Le café et ce qu'on attend de vous sont présentés dans Mise_en_situation_La_Brulerie_02_AE.md, dans le dossier 01_Brulerie_facile.

Avant de commencer

Le cours 00 a préparé la RAW : si Projet_Brulerie\plateforme\entrepot\brulerie.duckdb manque, faites-le d'abord. Deux fenêtres servent aux cours : l'Anaconda Prompt pour les commandes, et le notebook de DuckDB, dans le navigateur, pour les requêtes SQL (il s'ouvre à l'étape 1). Placez l'Anaconda Prompt dans Data_Domain, le dossier du parcours :

```
conda activate formations
REM Attendu : (formations) au début de l'invite.
cd Projet_Brulerie
dir /b
REM Attendu : 01_de, plateforme et sources.
```

L'Anaconda Prompt reste dans Projet_Brulerie jusqu'à la fin du cours.

Étape 1 — La RAW reçue · STAGING

Le cours 00 a rempli la RAW d'Analytics Engineering, dans l'entrepôt partagé. Le STAGING la reprendra sans jamais la modifier ; avant, on la lit.

1.1 Ouvrir le notebook de DuckDB, depuis l'Anaconda Prompt.

```
duckdb -ui
```

- L'interface s'ouvre dans le navigateur, à http://localhost:4213. Au premier lancement, DuckDB télécharge son extension ui : il faut Internet.
- Laisser l'Anaconda Prompt ouvert : le fermer arrête l'interface.
- Créer un notebook (+ à côté de Notebooks) et le renommer « AE Cours 01 » (double-clic sur son titre, puis Entrée) : chaque cours aura le sien.
- Une requête par cellule (Add Cell). Ctrl+Entrée l'exécute. Les lignes -- sont des commentaires : DuckDB les ignore.

1.2 Attacher l'entrepôt en lecture seule, dans la première cellule.

```
attach if not exists 'plateforme/entrepot/brulerie.duckdb' as brulerie (read_only);
-- Attendu : brulerie paraît sous Attached databases.
```


© 2026 iAlexMG. Tous droits réservés.

Chaque requête qui suit va dans une cellule neuve, et nomme ses tables en entier (`brulerie.raw_tickets`) : une cellule travaille en mémoire tant qu'on ne lui nomme pas l'entrepôt.

1.3 Lister les tables de l'entrepôt. Devant une `RAW` qu'on ne connaît pas, dans ce projet comme dans un autre, c'est le premier geste : voir ce qui est là, avant de choisir une table.

```
-- 1. les tables de la RAW
show tables from ____;
-- Attendu : 9 tables : journal, raw_consentements, raw_courbes, raw_lignes, raw_lots, raw_membres,
-- raw_modifications, raw_produits, raw_tickets ; plus argent_lots et direct_courbes si vous avez fait
-- Data Engineering jusqu'au bout.
```

L'entrepôt est partagé : `journal`, la liste des fichiers que Data Engineering a chargés, et `raw_courbes`, les courbes du torréfacteur, sont à Data Engineering, et cette formation ne les lit pas. Les sept autres sont votre `RAW`. Chaque nom dit d'où vient la table : `raw_`, puis le fichier livré. Le chargeur de Data Engineering a lu chacune dans un dossier de `Projet_Brulerie\sources`, qui range les fichiers par système du café :

Table	Lue de `sources\`	Une ligne, c'est
`raw_tickets`	`caisse\2025-06\tickets_*.csv`, un fichier par jour	un ticket de caisse, son total et son paiement
`raw_lignes`	`caisse\2025-06\lignes_*.csv`, un fichier par jour	un produit vendu sur un ticket : un ticket a souvent plusieurs lignes
`raw_produits`	`catalogue\produits.csv`	un produit du catalogue, à son prix d'aujourd'hui
`raw_modifications`	`catalogue\modifications.csv`	un changement du catalogue, avec sa date
`raw_membres`	`fidelite\membres.csv`	un membre du programme de fidélité
`raw_consentements`	`fidelite\consentements.csv`	une décision d'un membre sur l'infolettre, avec sa date
`raw_lots`	`torrefaction\lots.csv`	un lot de café torréfié

Le ticket, c'est ce qu'on appelle au Québec la facture ou le reçu du client. La caisse du café l'exporte sous le nom de ticket, et la formation garde son mot, celui des fichiers et des colonnes (`raw_tickets`, `ticket_id`).

Le reste des sources n'entre pas dans la `RAW` d'Analytics Engineering : la météo, les documents du café et les courbes de torréfaction, que Data Engineering charge pour lui, ne répondent à aucune question du mandat. Le dossier `graines` reprend les tickets, leurs lignes, les produits et les membres, un fichier chacun, déjà débarrassés du doublon que l'étape 2 trouve, et prêts à charger d'un coup : d'où les `produits.csv` et `membres.csv` qu'on y voit une seconde fois. La

© 2026 iAlexMG. Tous droits réservés.

formation ne s'en sert pas, puisqu'elle part des fichiers tels que livrés, défauts compris. Le sens de chaque fichier et de chaque colonne est dans le dictionnaire des sources, `Projet_Brulerie\sources\dictionnaire_brulerie.md`.

Les quatre premières tables suffisent au mandat : elles disent ce qui s'est vendu, et à qui. Les trois autres sont des journaux. Une table comme `raw_produits` donne l'état d'aujourd'hui : le Latte y coûte 5,75 $. Un journal garde plutôt chaque changement, avec sa date : `raw_modifications` sait que le Latte a coûté 5,25 $ à sa création, en novembre 2022, puis 5,50 $ en février 2024, et 5,75 $ depuis mars 2025. Le mandat n'en a pas besoin. Le cours 05 s'en sert pour retrouver le prix d'une vente au jour où elle s'est faite, et le cours 06 tire des deux autres journaux, les consentements et les lots, leurs propres faits.

Chaque table garde ses lignes telles que livrées : un ticket exporté deux fois y est deux fois, l'étape 2 le montre.

1.4 Lire les colonnes de `raw_tickets`. `describe` donne les colonnes d'une table et leur type.

```
-- 1. les colonnes des tickets et leurs types
____ brulerie.raw_tickets;
-- Attendu : 14 colonnes, toutes en VARCHAR ; la dernière, filename, porte le chemin du fichier.
```

Tout est en texte, et c'est voulu : la `RAW` ne décide d'aucun type. Typer est le travail du `STAGING`, au cours 03.

Étape 2 — Ce que la `RAW` garde exprès · STAGING

La `RAW` n'est pas faite pour l'analyse : elle garde les fichiers tels que la caisse et le programme de fidélité les ont exportés, même quand ils posent problème. Cette étape en regarde trois, que le `STAGING` réglera : la journée du 12 juin exportée deux fois (2.1 et 2.2), des montants gardés en texte (2.3), et les renseignements personnels des membres (2.4).

2.1 Compter les tickets. Un numéro de ticket ne sert qu'une fois : la caisse les donne dans l'ordre, depuis son installation.

```
-- 1. les lignes, puis les numéros de tickets distincts
select count(*) as lignes, count(distinct ____) as tickets
from brulerie.raw_tickets;
-- Attendu : 1585 lignes pour 1527 tickets.
```

La table a 1 585 lignes, mais seulement 1 527 numéros de tickets différents : 1 585 − 1 527 = 58 lignes répètent un ticket qui est déjà dans la table. Ces 58 tickets sont entrés deux fois dans la `RAW`.

2.2 Compter les tickets du 12 juin, fichier par fichier. La colonne `filename` garde le chemin du fichier d'où vient chaque ligne : `parse_filename` n'en garde que le nom, sans le chemin, et `contains` cherche un bout de texte, ici la date du jour, pour ne garder que les fichiers du 12 juin.

```
-- 1. les tickets du 12 juin, par fichier livré
select parse_filename(____) as fichier, count(*) as tickets
from brulerie.raw_tickets
where contains(filename, '____')
group by fichier
```


© 2026 iAlexMG. Tous droits réservés.

```
order by fichier;
-- Attendu : 58 tickets dans tickets_2025-06-12_202506121542.csv,
-- 65 dans tickets_2025-06-12_202506130705.csv.
```

La caisse a exporté la journée du 12 juin à 15 h 42, café encore ouvert, puis de nouveau le lendemain à 7 h 05. Le second export reprend les 58 tickets du premier et ajoute les 7 de la fin de l'après-midi : ce sont les 58 tickets de trop de l'étape 2.1.

Le même doublon touche `raw_lignes`, la table des produits vendus. La caisse exporte chaque jour les lignes de ses tickets dans un second fichier, `lignes_…`, et celui du 12 juin est lui aussi arrivé deux fois. Les 58 tickets du premier export y ramènent donc leurs produits une seconde fois : 94 des 2 626 lignes de `raw_lignes` sont en double. La `RAW` garde les deux exports, c'est son contrat. Garder le plus récent de chaque ticket s'appelle tirer l'état courant, et c'est un geste du `STAGING`.

2.3 Comparer un montant en texte et en nombre. Une conversion s'écrit `colonne::type`, et l'argent compté au cent prend le type `decimal(10, 2)` : un nombre décimal exact, deux chiffres après la virgule.

```
-- 1. le plus grand total, comparé en texte, puis converti en nombre
select max(total) as en_texte, max(total::____) as en_nombre
from brulerie.raw_tickets;
-- Attendu : 9.78 en texte, 74.93 en nombre.
```

En texte, `9.78` passe devant `74.93`, parce que le texte se compare caractère par caractère et que 9 vient après 7. Aucun message ne le signale. Le `STAGING` typera chaque montant.

2.4 Regarder les membres. `select * exclude (…)` prend toutes les colonnes sauf celles qu'on nomme.

```
-- 1. les trois premiers membres, sans le chemin du fichier
select * exclude (____)
from brulerie.raw_membres
limit 3;
-- Attendu : 3 membres, avec prénom, nom, courriel, téléphone et code postal.
```

La `RAW` garde les renseignements personnels, parce que le programme de fidélité les a livrés. Aucune analyse des ventes n'en a besoin, et un entrepôt qui les recopie de couche en couche multiplie les endroits d'où ils peuvent fuir. Le `STAGING` des membres ne les fera pas monter, au cours 03. Les membres du café sont fictifs : courriels en `.test`, téléphones de la plage 555-01XX.

2.5 Fermer le notebook : fermer l'onglet du navigateur, puis quitter DuckDB dans l'Anaconda Prompt.

```
.quit
```

Attendu : l'invite de l'Anaconda Prompt revient, toujours dans `Projet_Brulerie`. Le notebook « AE Cours 01 » reste enregistré : il sera là au prochain `duckdb -ui`.

© 2026 iAlexMG. Tous droits réservés.

Vous savez maintenant ce que vous recevez. Au cours 02, vous dessinez l'étoile qui répondra au mandat ; le cours 03 bâtit le `STAGING`, qui règle les trois défauts de cette étape.

À retenir

- La `RAW` se reçoit telle quelle et ne se modifie jamais : tout en texte, chaque export gardé, même deux fois.
- Devant une `RAW` inconnue : lister ses tables, puis lire le dictionnaire des sources pour savoir ce qu'une ligne de chacune représente.
- La `RAW` du café a trois défauts : la journée du 12 juin comptée deux fois, des montants en texte, et les renseignements personnels des membres. Le cours 03 les corrige dans le `STAGING` : un seul exemplaire de chaque ticket, des montants en nombres, et rien de personnel qui monte.

© 2026 iAlexMG. Tous droits réservés.