Table des matières

Cours 02 — Concevoir le modèle dimensionnel 1
Ce que vous allez faire 1
Avant de commencer 2
Étape 1 — L'étoile sur papier · MARTS 2
Étape 2 — Les taxes, laissées sur le ticket · MARTS 6
À retenir 8

Cours 02 — Concevoir le modèle dimensionnel

Cours 2/9 · La Brûlerie — Formation Analytics Engineering

STAGING	INTERMEDIATE	MARTS
reprendre la `RAW`, une vue par table	joindre, clarifier, préparer l'étoile	concevoir et livrer les étoiles
		✓ ici

Ce que vous allez faire

Le mandat que le café vous a confié au cours 01 tient en trois questions, sur juin 2025 :

1. Qu'est-ce qui s'est vendu, par catégorie et par produit ?
2. Combien les membres du programme de fidélité ont-ils acheté, et combien les clients sans carte ?
3. Ces chiffres retombent-ils sur ceux de la caisse, au cent près ?

Avant de bâtir quoi que ce soit, vous dessinez l'étoile qui y répondra : une table de faits au centre, ses dimensions autour. L'étoile est le plan du projet. Une fois bâtie, elle vivra dans les `MARTS`, la dernière couche, celle que liront les rapports. On la dessine quand même en premier : le `STAGING` du cours 03 et l'`INTERMEDIATE` du cours 04 ne servent qu'à préparer ce qu'elle demande, et sans le plan, on ne saurait pas quoi y préparer.

le mandat → l'étoile sur papier → les taxes, laissées sur le ticket

© 2026 iAlexMG. Tous droits réservés.

Dans ce cours, vous décidez. L'étape 1 se fait sur une feuille : vous y prenez les quatre décisions qui dessinent l'étoile, puis vous comparez votre feuille au corrigé. Les seules requêtes, à l'étape 2, lisent la `RAW` pour vérifier une décision : aucune ne change l'entrepôt, et aucun fichier du projet ne s'écrit, et chacune se donne en pseudocode. `Codes_02_AE.md`, à ouvrir après avoir essayé, donne la réponse de chaque décision, puis chaque requête en entier.

Avant de commencer

Le cours 01 a lu la `RAW` dans le notebook de DuckDB ; celui-ci y revient à l'étape 2. Placez l'Anaconda Prompt dans `Data_Domain`, le dossier du parcours :

```
conda activate formations
REM Attendu : (formations) au début de l'invite.
cd Projet_Brulerie
dir /b
REM Attendu : 01_de, plateforme et sources.
notepad sources\dictionnaire_brulerie.md
REM Attendu : le dictionnaire des sources s'ouvre dans le Bloc-notes.
```

Gardez le dictionnaire ouvert, avec une feuille et un crayon : l'étape 1 s'en sert. L'Anaconda Prompt reste dans `Projet_Brulerie` jusqu'à la fin du cours.

Étape 1 — L'étoile sur papier · MARTS

Une étoile, c'est une table de faits au centre et ses dimensions autour. La table de faits a une ligne par événement mesuré, et chaque ligne porte ses mesures, des nombres qui s'additionnent, comme une quantité ou un montant. Les dimensions sont ce par quoi on regarde les faits. Chaque ligne du fait porte une clé vers chacune, et c'est par cette clé qu'on retrouve, par exemple, la catégorie d'un produit vendu.

L'étoile sort de quatre décisions, prises toujours dans cet ordre : le processus, le grain, les dimensions, les mesures. Vous les prenez vous-même, sur votre feuille, à partir du mandat et du dictionnaire des sources. Chaque décision dit ce qu'elle demande et où chercher. Vous dessinez ensuite l'étoile, puis vous comparez votre feuille au corrigé. En entreprise, ce dessin se fait au tableau blanc, avec ceux qui poseront les questions, avant la première ligne de code.

Recopiez d'abord, en haut de la feuille, les trois questions du mandat, données au début du cours : la décision 3 s'en sert.

Décision 1 — Le processus

Le processus est l'activité du café que le fait mesure, et les trois questions parlent toutes de la même. Écrivez-la sous les questions, en quelques mots.

Décision 2 — Le grain

Le grain dit ce que représente une ligne du fait. Il se décide avant les dimensions et les mesures, parce qu'elles en découlent : une dimension décrit une ligne du fait, et une mesure s'y additionne. Trois candidats : un ticket, une ligne d'un ticket, une journée de ventes. Le bon grain répond à chaque question du mandat par une somme de lignes. Essayez chacun sur la première question, par produit, en gardant en tête ce que le cours 01 a montré : un ticket tient sur une ligne de `raw_tickets`, avec son total, et sur une ligne de `raw_lignes` par produit acheté.

© 2026 iAlexMG. Tous droits réservés.

Reste à dire quels tickets entrent dans le fait. Au dictionnaire, la section « Les codes de la caisse » classe chaque ticket par deux colonnes : `type_ticket` dit si c'est une vente ou un remboursement, `statut` s'il a été payé ou annulé. Lisez le sens de chacun de leurs codes : la caisse imprime aussi des tickets qui n'ont rien encaissé, et une seule des deux colonnes le dit. Écrivez le grain en une phrase qui commence par « Une ligne du fait est ».

Décision 3 — Les dimensions

Les dimensions disent quand, quoi et qui. Soulignez, dans les trois questions, chaque mot qui en dit un. Deux mots soulignés peuvent décrire la même chose : ils vont alors dans la même dimension, l'un comme renseignement de l'autre. Le temps est presque toujours une dimension, même quand aucun fichier ne le porte à part. Notez chaque dimension, et sous elle ce qu'on veut savoir d'elle, ses colonnes, prises au dictionnaire. Une dimension ne garde que ce par quoi on regarde les ventes : l'étape 2.4 du cours 01 a montré ce qui ne doit pas monter du programme de fidélité. Les clients sans carte font partie du mandat : notez aussi ce que leur vente portera à la place d'un membre.

Décision 4 — Les mesures

Une mesure garde son sens quand on l'additionne sur n'importe quel groupe de lignes : un produit, un jour, tous les membres. Prenez-les dans la section `lignes` du dictionnaire. Une colonne qui ne s'additionne pas peut encore servir, multipliée par une autre. Laissez les taxes de côté : l'étape 2 en décide. Notez les mesures sous le grain.

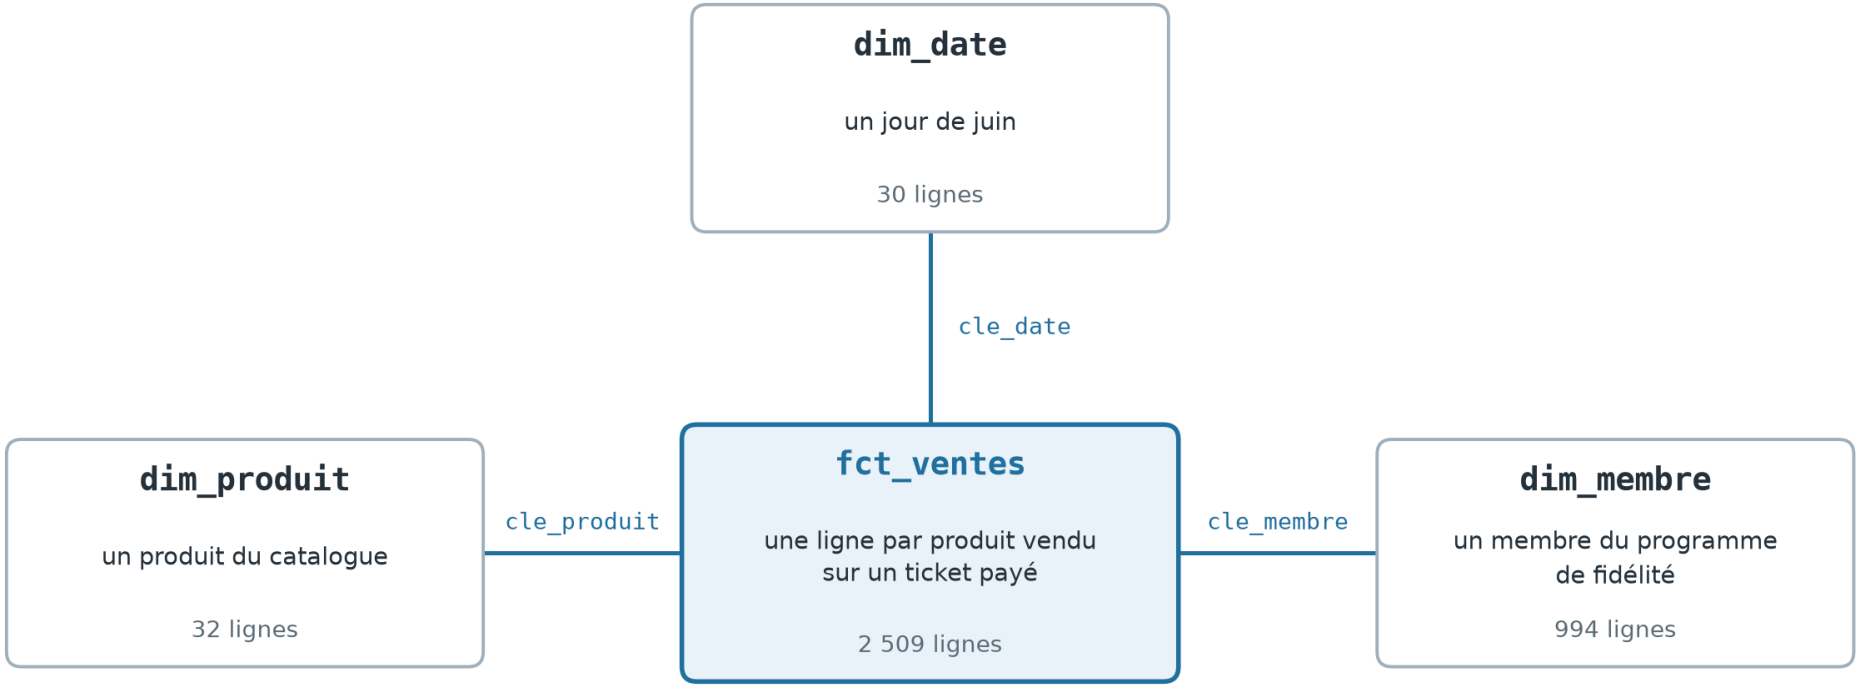
Dessiner l'étoile

Au centre de la feuille, une boîte pour le fait ; autour, une boîte par dimension ; un trait du fait vers chaque dimension, pour la clé que porte chacune de ses lignes. Chaque boîte prend un nom à préfixe, selon la convention de dbt : `fct_` pour le fait (de l'anglais *fact*), `dim_` pour une dimension. Le fait se nomme au pluriel de ce qu'il compte, une dimension au singulier de ce qu'elle décrit. Dans chaque boîte, écrivez ce qu'est une de ses lignes, puis ses colonnes. Le numéro du ticket n'est ni une mesure ni une dimension du mandat : décidez s'il reste dans le fait.

Comparer avec le corrigé

Une fois votre étoile dessinée, ouvrez `Codes_02_AE.md` : son étape 1 donne la réponse de chaque décision, telle qu'on l'écrit sur la feuille, avec les trois questions soulignées et les dimensions tentantes que l'étoile écarte. Voici l'étoile qui sort de ces quatre décisions, celle que les cours 03 et 04 bâtiront :

© 2026 iAlexMG. Tous droits réservés.



L'étoile des ventes : le fait au centre, une ligne par produit vendu, relié à ses trois dimensions par leurs clés.

Table	Ce qu'elle porte
`fct_ventes`	une clé vers chaque dimension, le numéro du ticket et de la ligne, puis les mesures : la quantité, le montant brut, le rabais, le montant
`dim_date`	la date, le nom du jour, si c'est la fin de semaine
`dim_produit`	le nom, la catégorie, le format
`dim_membre`	le secteur postal et la date d'inscription, rien de personnel

Les taxes n'y figurent pas : l'étape 2 dit pourquoi.

Le grain est la décision qui compte. Ici, une ligne du fait est une ligne d'un ticket : un produit, vendu en une quantité, pour un montant. C'est ce que la formation appelle une vente, d'où le nom `fct_ventes`. Prenons le ticket 158414, du 1er juin : le client y a acheté trois produits. Dans la `RAW`, ce ticket tient sur une ligne de `raw_tickets`, avec son total, et sur trois lignes de `raw_lignes`, une par produit. Dans le fait, il donne donc trois lignes, une par produit (leurs noms à la place des clés, pour la lecture) :

© 2026 iAlexMG. Tous droits réservés.

Date	Produit	Membre	Ticket	Ligne	Quantité	Montant
2025-06-01	Pérou Cajamarca	aucun	158414	1	1	21,50
2025-06-01	Thé infusé	aucun	158414	2	2	7,50
2025-06-01	Latte	aucun	158414	3	1	5,75

Le client n'a pas présenté de carte : la clé du membre reste vide. Chaque question du mandat devient alors une somme de ces lignes : par produit, celles du produit ; par catégorie, celles des produits de la catégorie, que donne `dim_produit` ; par jour, celles de la date ; pour les membres et les clients sans carte, celles dont la clé du membre est remplie ou vide. Le total d'un ticket est la somme de ses lignes.

Le numéro du ticket reste dans le fait comme une simple colonne : il sert à regrouper les lignes d'un même ticket. Ce que le ticket sait d'autre, sa date et son membre, passe par leurs dimensions, et il ne lui reste rien qui mérite une table à lui. On appelle ce cas une dimension dégénérée : une dimension réduite à son numéro, gardée dans le fait. Ce qui compte comme un ticket payé, au juste, l'`INTERMEDIATE` le fixera au cours 04 : la caisse imprime aussi des tickets qu'elle n'encaisse pas.

Les écarts les plus fréquents entre une feuille et ce corrigé, et ce qui les tranche :

Sur votre feuille	Ce qui tranche
une ligne par ticket, ou par journée	un ticket porte souvent plusieurs produits : le fait ne dirait plus lequel s'est vendu, et la première question resterait sans réponse
tous les tickets, annulés compris	un ticket `ANNULE` n'a rien encaissé (codes de `statut`, au dictionnaire) : ce n'est pas une vente
seulement les tickets de `type_ticket` `VENTE`	`type_ticket` ne dit pas ce qui a été encaissé : le remboursement du mois est payé, et sa ligne, négative, retranche du fait ce que le café a rendu
aucune dimension pour la date	les trois questions portent sur juin, qu'on regarde jour par jour ; `dim_date` ne vient d'aucun fichier, le cours 04 la fabrique
le nom, le courriel ou le code postal entier du membre	des renseignements personnels, qui ne répondent à aucune question ; les trois premiers caractères du code postal, le secteur, suffisent à situer un quartier
le prix unitaire parmi les mesures	des prix additionnés ne veulent rien dire ; la quantité fois le prix unitaire donne le montant brut, d'avant le rabais, qui s'additionne

© 2026 iAlexMG. Tous droits réservés.

Sur votre feuille	Ce qui tranche
le prix du catalogue dans `dim_produit`	`raw_produits` donne le prix d'aujourd'hui ; le prix d'une vente est sur sa ligne
un membre « sans carte » dans `dim_membre`	une pratique courante en entreprise, qui évite une clé vide ; le corrigé laisse la clé vide, et la deuxième question sépare les membres des clients sans carte par une clé remplie ou vide

Corrigez votre feuille au besoin, et gardez-la : le cours 04 bâtit cette étoile, table par table.

Étape 2 — Les taxes, laissées sur le ticket · MARTS

Le fait n'a pas de colonne pour les taxes. Pourtant, chaque ticket en porte deux : la TPS (la taxe fédérale, 5 %) et la TVQ (la taxe du Québec, 9,975 %). On pourrait les répartir sur les lignes, pour que chaque produit vendu ait sa part. Le problème : la caisse ne les calcule pas produit par produit. Elle additionne les lignes taxables du ticket, calcule la taxe sur ce sous-total, puis arrondit au cent une seule fois. Cette étape refait les deux calculs sur le ticket 158414 de l'étape 1, celui de la caisse, puis la répartition, et les compare.

2.1 Ouvrir le notebook de DuckDB, depuis l'Anaconda Prompt.

```
duckdb -ui
```

Laisser l'Anaconda Prompt ouvert : le fermer arrête l'interface. Créer un notebook et le renommer « AE Cours 02 », comme au cours 01.

2.2 Attacher l'entrepôt en lecture seule, dans la première cellule.

```
attach if not exists 'plateforme/entrepot/brulerie.duckdb' as brulerie (read_only);
-- Attendu : brulerie paraît sous Attached databases.
```

2.3 Additionner à la main les lignes du ticket 158414. Les numéros sont encore du texte dans la `RAW`, d'où les apostrophes. La colonne `ligne` numérote les lignes dans le ticket : c'est elle qui donne leur ordre.

```
-- 1. les lignes du ticket 158414, dans leur ordre
select ligne, description, code_taxe, montant
from brulerie.raw_lignes
where ticket_id = '158414'
order by ____;
-- Attendu : 3 lignes, Pérou Cajamarca DETAXE 21.50, Thé infusé TAXABLE 7.50, Latte TAXABLE 5.75.
```

21,50 + 7,50 + 5,75 = 34,75 $: le sous-total imprimé sur le ticket. Les lignes d'un ticket payé retombent sur son sous-total, et c'est ce que le témoin du cours 05 vérifiera, ticket par ticket. Les taxes, elles, ne portent que sur les deux lignes `TAXABLE` : le café en grains, `DETAXE`, n'en paie pas. Elles se calculent donc sur 7,50 + 5,75 = 13,25 $.

© 2026 iAlexMG. Tous droits réservés.

2.4 Lire les taxes que la caisse a imprimées. Elles sont sur le ticket lui-même, dans `raw_tickets`, une ligne par ticket, aux colonnes `tps` et `tvq`.

```
-- 1. les taxes imprimées sur le ticket 158414
select sous_total, ____, ____, total
from brulerie.raw_tickets
where ticket_id = '158414';
-- Attendu : 1 ligne, sous_total 34.75, tps 0.66, tvq 1.32, total 36.73.
```

La caisse a pris 5 % des 13,25 $ taxables, soit 0,6625 $, puis arrondi une seule fois, au cent le plus proche : 0,66 $ de TPS. La TVQ suit le même calcul à 9,975 % : 1,32 $. Ce sont les montants que le client a payés.

2.5 Répartir la TPS du ticket sur ses lignes taxables : chaque ligne reçoit 5 % de son montant, arrondi au cent. `round(x, 2)` arrondit au cent.

```
-- 1. la TPS de chaque ligne taxable, exacte, puis arrondie au cent
select ligne,
       montant::decimal(10, 2) * 0.05 as tps_exacte,
       round(montant::decimal(10, 2) * 0.05, ____) as tps_de_la_ligne
from brulerie.raw_lignes
where ticket_id = '158414' and code_taxe = '____'
order by ligne;
-- Attendu : ligne 2, 0.3750 arrondie à 0.38 ; ligne 3, 0.2875 arrondie à 0.29.
```

Additionnées, les parts des deux lignes ne redonnent pas la TPS du ticket :

Calcul	TPS du ticket 158414
La caisse : 5 % de 13,25 $, arrondi une fois	0,6625 arrondi à 0,66 $
La répartition : 5 % de chaque ligne, arrondi ligne par ligne, puis additionné	0,38 + 0,29 = 0,67 $

La répartition donne un cent de plus. Ses deux arrondis montent, 0,3750 à 0,38 et 0,2875 à 0,29, et ajoutent ensemble 0,0075 $, assez pour passer au cent suivant ; l'arrondi unique de la caisse, lui, descend, de 0,6625 à 0,66.

Ce cent n'est pas propre au ticket 158414. Refaite sur les 1 464 tickets payés de juin qui ont une ligne taxable, la même répartition donne :

Sur juin	TPS	TVQ
Imprimée par la caisse	651,55 $	1 295,66 $
Répartie sur les lignes, puis additionnée	652,30 $	1 293,36 $
Écart	0,75 $ de plus	2,30 $ de moins
Tickets qui s'écartent	145	245

© 2026 iAlexMG. Tous droits réservés.

En tout, 337 tickets s'écartent sur au moins une des deux taxes, d'un ou deux cents chacun, tantôt en plus, tantôt en moins, selon que les arrondis des lignes montent ou descendent.

On pourrait forcer la répartition à retomber, en ajoutant ou en retirant le cent d'écart sur une des lignes. Mais laquelle ? La caisse ne le dit pas : elle ne connaît que la taxe du ticket, et la part d'une ligne n'existe nulle part dans la `RAW`. Ce serait une règle inventée, et un rapport par produit montrerait des taxes que la caisse n'a jamais calculées. Les taxes restent donc là où la caisse les calcule : au grain du ticket, hors du fait.

2.6 Fermer le notebook : fermer l'onglet du navigateur, puis quitter DuckDB dans l'Anaconda Prompt.

```
.quit
```

Attendu : l'invite de l'Anaconda Prompt revient, toujours dans `Projet_Brulerie`.

L'étoile de l'étape 1 est maintenant complète : le fait des ventes et ses trois dimensions, les taxes laissées au ticket. C'est le plan que les deux cours suivants bâtissent, une couche à la fois :

Couche	Ce qui s'y bâtit	Cours
`STAGING`	une vue par table de la `RAW`, typée, à l'état courant	03
`INTERMEDIATE`	les lignes des tickets payés, avec leur date et leur membre	04
`MARTS`	les dimensions de la date, du produit et du membre, puis le fait des ventes	04

Les cours 05 à 08 la fiabilisent, lui ajoutent les faits que la vente ne montre pas et la font tourner jour après jour ; le 09 la rebâtit de bout en bout.

Le fait portera 2 509 lignes pour 16 718,00 $, exactement la somme des sous-totaux des tickets payés.

À retenir

- L'étoile se conçoit avant de se bâtir, en quatre temps : le processus, le grain, les dimensions, les mesures.
- Le grain est une ligne d'un ticket payé ; le numéro du ticket reste dans le fait, en dimension dégénérée.
- Les taxes restent au grain du ticket : la caisse les calcule sur le ticket entier, et réparties sur les lignes, elles ne retombent pas sur ce qu'elle a imprimé.

© 2026 iAlexMG. Tous droits réservés.