Table des matières

Cours 00 — Générer les données sources 1
Ce que vous allez faire 1
Avant de commencer 1
Étape 1 — Monter la couche RAW · RAW 2
Étape 2 — Ce que vous avez maintenant · RAW 4
À retenir 4

Cours 00 — Générer les données sources

Cours de départ · Boréal — Formation Analytics Engineering

Data Engineering	**Analytics Engineering**		
`RAW`	`STAGING`	`INTERMEDIATE`	`MARTS`
chargée telle que livrée →	reprendre la `RAW`, une vue par table	joindre, clarifier, préparer l'étoile	concevoir et livrer les étoiles
✓ ici			

Ce que vous allez faire

L'ingénieur analytique ne part jamais de rien : il reprend la couche `RAW` que l'ingénieur de données a chargée. En entreprise, cette `RAW` existe avant lui : Data Engineering la charge, et Analytics Engineering ne la modifie jamais. Il en tire plutôt ses propres versions, transformées et adaptées à ses besoins, une couche à la fois : le `STAGING`, l'`INTERMEDIATE`, puis les `MARTS`.

Ce cours monte la `RAW` de Boréal dans votre projet, `Projet_Boreal_intermediaire`, de l'une de deux façons : elle reprend celle que vous avez chargée vous-même, si vous avez fait Data Engineering, ou un kit de départ la reconstruit à zéro. Un script fait tout, et rien ne s'écrit à la main.

votre `RAW` de Data Engineering, ou le kit de départ → la `RAW` de Boréal, dans `Projet_Boreal_intermediaire`

Avant de commencer

© 2026 iAlexMG. Tous droits réservés.

Deux fenêtres servent aux cours : l'Anaconda Prompt pour les commandes, et le notebook de DuckDB (`duckdb -ui`) pour les requêtes SQL. Ce cours n'a besoin que de l'Anaconda Prompt, placée dans `Data_Domain`, le dossier du parcours, et d'Ubuntu pour la voie A :

```
conda activate formations
REM Attendu : (formations) au début de l'invite.
python --version
REM Attendu : une version 3.11 de Python.
git --version
REM Attendu : git version 2.51 ou plus récent.
duckdb --version
REM Attendu : v1.5.5 ou plus récent.
```

Si l'un des outils manque, le guide d'installation du parcours, `00_Installation/Guide_installation.md`, le monte. Aucun service à allumer : dbt arrive au cours 03.

Étape 1 — Monter la couche `RAW` · RAW

Deux voies mènent au même endroit. Prenez celle qui correspond à votre parcours ; la suite de la formation est identique.

Voie A : vous avez fait Data Engineering

Votre `Projet_Boreal_intermediaire/` existe déjà, mais Data Engineering l'a mené plus loin que le point où cette formation commence. Ses sources sont la génération jusqu'à mars 2026, et son entrepôt a chargé les trois mois de 2026 : 580 907 lignes dans `raw`, dont 28 271 en-têtes de commande. Cette formation part de la génération par défaut, qui s'arrête au 31 décembre 2025, et reçoit les mois de 2026 à son cours 07, un à la fois, comme une équipe d'analytique reçoit ses livraisons. Ramenez donc l'entrepôt au point de départ, en trois gestes. Votre dépôt `01_de` ne bouge pas, et l'entrepôt de Data Engineering reste sur le disque, à côté du neuf.

D'abord, arrêtez les services de la plateforme. Cette formation n'en allume aucun, et aucun ne doit tenir l'entrepôt ou le lac pendant que le kit les réécrit. Dans Ubuntu, depuis `Projet_Boreal_intermediaire/plateforme` :

```
docker compose stop
```

`stop` arrête les conteneurs sans rien effacer : `docker compose start` les rallume tels quels le jour où vous en aurez besoin. Arrêtés ainsi, ils ne repartent plus d'eux-mêmes au démarrage d'Ubuntu.

Ensuite, mettez de côté l'entrepôt de Data Engineering. Dans l'Anaconda Prompt, depuis `Projet_Boreal_intermediaire` :

```
move plateforme\entrepot plateforme\entrepot_de
```

La console répond `1 répertoires déplacés.`

Enfin, lancez le kit de la voie B, avec une option de plus. Depuis `Data_Domain` :

© 2026 iAlexMG. Tous droits réservés.

```
python _univers/kits/demarrer.py --formation 02 --projet Projet_Boreal_intermediaire --regenerer
```

`--regenerer` autorise le kit à refaire des sources qui ne sont pas celles qu'il attend ; sans elle, il s'arrête avant de toucher à quoi que ce soit. Il regénère la génération par défaut, garde votre `01_de` et le fait tourner, recharge la `RAW` et les séries de l'usine dans un entrepôt neuf, puis compte. Comptez une minute et demie. Son écran de fin doit dire `Conforme`, avec 22 tables et 513 857 lignes dans `raw`, 3 tables et 163 186 lignes dans `argent`.

Pourquoi — un entrepôt neuf, plutôt que de rejouer par-dessus le vôtre. Le chargeur de Data Engineering ajoute les lots qui arrivent et ne retire jamais un lot déjà chargé : c'est ce qui le rend sûr. Relancé sur votre entrepôt avec les sources par défaut, il y laisse les trois mois de 2026, et le kit finit sur `17 écart(s)`, `raw.erp_vbak` à 28 271 lignes au lieu de 26 538. Le lac, lui, n'a pas à être mis de côté : le bronze et l'argent s'y réécrivent d'après les sources, et vos tables Iceberg et Delta du cours 10 de Data Engineering n'y sont pas touchées.

Voie B : vous n'avez pas fait Data Engineering

Le kit de départ reconstruit ce que cette formation-là aurait livré. Depuis `Data_Domain` :

```
python _univers/kits/demarrer.py --formation 02 --projet Projet_Boreal_intermediaire
```

Le kit crée le dossier, génère les sources de Boréal, y dépose le dépôt de Data Engineering, `01_de`, puis rejoue son chargement et ses séries de l'usine. Comptez une minute et demie, dont l'essentiel est la génération. Son écran de fin affiche l'état de la couche `RAW`, table par table, et le dit conforme quand chaque compte égale ce que Data Engineering annonce : c'est celui que le Labo 01 vérifie, à son étape 1.

Le dépôt `01_de` est le code de Data Engineering, pas le vôtre : vous n'avez pas à le lire. L'étape 2 dit à quoi il sert.

Si le kit s'arrête, son dernier message dit pourquoi :

Message	**Ce qui se passe**	**Quoi faire**
`Le kit s'arrête : les sources présentes sont celles de la génération jusqu'à 2026-03, et vous demandez la génération par défaut.`	voie A : les sources de Data Engineering vont plus loin que cette formation, et le kit refuse de les réécrire sans qu'on le lui dise	relancer le kit avec `--regenerer`
`17 écart(s) avec les attendus de _univers/kits/`, dont `raw.erp_vbak` à 28 271	voie A : le kit a rechargé dans l'entrepôt de Data Engineering, qui garde ses lots de 2026	mettre cet entrepôt de côté, `move plateforme\entrepot plateforme\entrepot_de`, puis relancer la même commande : les sources, déjà refaites, sont gardées
`IO Error: Cannot open file ... utilisé par un autre processus`	le notebook de DuckDB, ou un autre programme, tient l'entrepôt : un fichier DuckDB ouvert par un processus bloque les autres	quitter DuckDB par `.quit` dans sa fenêtre, puis relancer

© 2026 iAlexMG. Tous droits réservés.

Étape 2 — Ce que vous avez maintenant · RAW

2.1 Lister le projet, depuis `Data_Domain`.

```
dir Projet_Boreal_intermediaire
REM Attendu : sources, plateforme et 01_de, au moins.
```

Trois dossiers au moins, chacun avec son rôle :

- `sources/` : les fichiers que les systèmes de l'entreprise livrent.
- `plateforme/` : ce que l'équipe de données fait tourner. L'entrepôt y vit, dans le fichier `plateforme/entrepot/boreal.duckdb` (près de 40 Mo), à côté du lac et, si vous avez fait Data Engineering, de ses services (la base de l'ERP, Airflow). Cette formation n'allume aucun service : elle ne se sert que de l'entrepôt, celui que Data Engineering remplit, comme dans une entreprise où les deux équipes partagent un seul entrepôt.
- `01_de/` : le dépôt de Data Engineering, que vous l'ayez écrit ou que le kit l'ait déposé. C'est lui qui charge la `RAW`, et au cours 07, c'est encore lui qui livrera les mois de 2026.

Votre propre dépôt, `02_ae`, s'ajoutera à côté au Cours 01, qui ouvre aussi l'entrepôt dans le notebook de DuckDB et compte ce que la `RAW` a reçu.

À retenir

- La `RAW` est une frontière : Data Engineering la charge ; Analytics Engineering n'y touche jamais, il en tire ses propres versions, adaptées à ses besoins.
- La `RAW` de départ reprend celle de Data Engineering, ramenée au point où cette formation commence, ou se reconstruit à zéro par le kit : les deux voies donnent le même entrepôt.

© 2026 iAlexMG. Tous droits réservés.