Table des matières

Exercices corrigés 01 — Analyser la RAW reçue 1
Questions courtes 1
Questions pratiques 1
Diagnostics 2
Questions à développer 2
Mises en situation 2
Corrigé 3

Exercices corrigés 01 — Analyser la RAW reçue

Comment travailler ces exercices. Répondez seul, puis vérifiez avec le corrigé. Les questions pratiques se tapent dans le notebook du labo, l'entrepôt attaché sous `boreal` (Labo 01, 1.2). Tout vient de la Théorie 01 et du Labo 01.

Le corrigé suit les énoncés, en fin de document. Répondez à l'énoncé en entier avant d'y passer : c'est en butant sur une question qu'on découvre ce qu'on avait lu sans le comprendre.

Questions courtes

1. La responsabilité du `STAGING`. Donnez trois choses que le `STAGING` fait, et une qu'il ne fait jamais.
2. À quoi sert `_lot`. Donnez la question à laquelle cette colonne permet de répondre, et qu'aucune autre ne permet.

Questions pratiques

P1. Les doublons d'une autre table. `raw.garanties_reclamations` porte 5 623 objets pour 3 348 réclamations. Écrivez la requête qui le montre, sachant que l'identifiant vit dans la colonne JSON `objet`, sous la clé `reclamation_id`.

P2. Typer une date. Écrivez l'expression qui convertit `aedat` en date en traitant la date vide comme une absence de date, et non comme une erreur. Vérifiez-la sur la table entière.

© 2026 iAlexMG. Tous droits réservés.

Diagnostics

E1. Le compte qui ne tombe pas. Un collègue écrit ceci pour compter les commandes de Boréal, et annonce 26 538 commandes à la direction :

```
  select count(*) as commandes from boreal.raw.erp_vbak;
```

Dites ce qui est faux, de combien, et écrivez la requête juste.

E2. Le décodage inventé. Dans un modèle, un collègue écrit :

```
  case kukla
      when 'Z001' then 'Or'
      when 'Z002' then 'Argent'
      when 'Z003' then 'Bronze'
  end as palier
```

Le modèle tourne sans erreur et tous les tests passent. Dites ce qui ne va pas, comment le constater, et quelle règle aurait évité l'erreur.

Questions à développer

A. La frontière. Data Engineering pourrait très bien décoder les codes SAP et dédoublonner les commandes avant de livrer : il en a les moyens, et cela vous épargnerait du travail. Expliquez pourquoi la frontière est placée là où elle est, ce qu'on perdrait à la déplacer, et ce que cela dit de la notion de couche.

Mises en situation

M1. Coopérative laitière de Sainte-Perpétue. La coopérative reçoit chaque nuit, d'un transporteur, un fichier des collectes de la journée : numéro de ferme, volume, température, heure de collecte. Le fichier arrive parfois deux fois, parfois en retard de deux jours, et le transporteur renvoie un fichier corrigé quand une ferme conteste un volume. On vous demande de bâtir les tableaux de bord de la coopérative. Dites quelle couche gardera quoi, ce que vous refusez de faire à l'ingestion, et la première chose que vous exigerez du transporteur.

© 2026 iAlexMG. Tous droits réservés.

Corrigé

Comment lire ce corrigé. Il donne la réponse et le pourquoi, jamais une notion neuve : tout ce qu'il emploie a été enseigné dans la Théorie 01 ou pratiqué dans le Labo 01. Les chiffres sont ceux de la `RAW` montée par le Cours 00.

Questions courtes

1. La responsabilité du `STAGING`. Il renomme, type, décode, et tire l'état courant de chaque source. Ce qu'il ne fait jamais : joindre deux sources. Un `STAGING` qui joint devient un endroit où l'on fait du métier, et le métier a déjà ses couches. *Théorie : `Theorie_01_AE.md`, section 3.*

2. À quoi sert `_lot`. Devant deux lignes qui portent le même numéro de commande, elle seule dit laquelle est la plus récente. Ni le contenu des lignes ni leur ordre dans la table ne le disent. C'est elle qui permettra, au Cours 03, de tirer l'état courant. *Théorie : `Theorie_01_AE.md`, section 6.*

Questions pratiques

P1. Les doublons d'une autre table.

```
select
    count(*) as objets,
    count(distinct objet ->> 'reclamation_id') as reclamations
from boreal.raw.garanties_reclamations;
```

Attendu : 5 623 objets pour 3 348 réclamations. L'opérateur `->>` tire une valeur d'une colonne JSON et la rend en texte : les flèches sont au Cours 08 de la formation SQL avancé, `Theorie_08_SQL.md`, section 4. La cause des doublons est celle des commandes, en plus systématique : le portail des garanties renvoie l'objet complet à chaque changement de statut. *Théorie : `Theorie_01_AE.md`, section 6.*

P2. Typer une date.

```
select count(try_strptime(nullif(aedat, '00000000'), '%Y%m%d')) as dates_valides
from boreal.raw.erp_vbak;
```

L'expression est `try_strptime(nullif(aedat, '00000000'), '%Y%m%d')`. La date vide devient une absence plutôt qu'une erreur, et chaque vraie date est lue avec son format : 2 308 dates sur 26 538 lignes, les autres étant les commandes jamais modifiées. C'est le typage que le `STAGING` fera au Cours 03. *Théorie : `Theorie_01_AE.md`, annexe A.5.*

Diagnostics

© 2026 iAlexMG. Tous droits réservés.

E1. Le compte qui ne tombe pas. `count(*)` compte les lignes, pas les commandes, et la `RAW` garde chaque livraison d'une même commande. L'annonce surestime de 1 055 : 26 538 au lieu de 25 483.

```
select count(distinct vbeln) as commandes from boreal.raw.erp_vbak;
```

L'erreur est instructive parce qu'elle ne se voit pas : 26 538 est un nombre plausible, et rien ne signale qu'il est faux. C'est le genre d'écart qu'un test attrapera au Cours 05. *Théorie : `Theorie_01_AE.md`, annexe A.3.*

E2. Le décodage inventé. `Z001`, `Z002` et `Z003` n'existent pas dans cette colonne : `kukla` porte `01`, `02` et `03`. Le `case` ne trouve aucune correspondance et rend `NULL` pour les 156 concessionnaires. Rien ne plante, et un test d'ensemble de valeurs ne voit pas les `NULL` : il les ignore. Pour le constater, il faut compter les valeurs obtenues, et non se fier au fait que le modèle tourne :

```
select palier, count(*) from le_modele group by 1;
```

La règle qui aurait évité l'erreur : les noms de colonnes et les codes sortent de `_univers/boreal/DICTIONNAIRE.md`, jamais de la mémoire ni d'un autre support. *Théorie : `Theorie_01_AE.md`, annexe A.4.*

Questions à développer

A. La frontière. Ce qu'on perdrait est une information, pas du confort. Décoder à l'ingestion fige le sens d'un code au jour du chargement : si le palier `03` change de nom l'an prochain, les lignes déjà chargées porteraient l'ancien libellé et les nouvelles le nouveau, dans la même colonne, sans que rien ne le signale. Dédoublonner à l'ingestion détruit l'historique des versions, et avec lui toute capacité à répondre à « que savait-on au 28 février ? ». La `RAW` est un enregistrement de ce qui est arrivé, et un enregistrement ne se corrige pas, il s'interprète. Ce que cela dit de la notion de couche : une couche n'est pas une étape de nettoyage de plus en plus poussé, c'est une responsabilité distincte. `RAW` répond de la fidélité, `STAGING` de la lisibilité, `MARTS` de la modélisation. Confondre les trois donne une plateforme où personne ne sait plus quelle transformation a eu lieu où. *Théorie : `Theorie_01_AE.md`, sections 3 et 6.*

Mises en situation

M1. Coopérative laitière de Sainte-Perpétue. Chaque fichier reçu est gardé tel quel, avec son horodatage de réception et son nom de fichier : c'est la `RAW`, et les colonnes de lignage y sont indispensables, puisque le même fichier arrive parfois deux fois. Rien n'est corrigé à l'ingestion, pas même les volumes contestés : le fichier corrigé est une livraison de plus, et la version qui vaut se choisit au `STAGING`, en gardant la plus récente pour chaque couple ferme-jour. Les températures aberrantes ne se suppriment pas non plus, elles se marquent à l'étage suivant. Ce qu'on exige du transporteur : un identifiant de livraison, ou à défaut une convention de nommage qui distingue une correction d'un renvoi du même fichier. Sans cela, la règle « la plus récente gagne » ne s'applique pas, et c'est le point que le Cours 03 rendra concret. *Théorie : `Theorie_01_AE.md`, sections 3 et 6.*

© 2026 iAlexMG. Tous droits réservés.