Table des matières

Cours 01 — Analyser la RAW reçue 1
Objectifs 1
1. Le métier 2
2. ELT et ETL : pourquoi l'ordre a changé 2
3. L'architecture en couches 3
4. Ces couches ne sont pas le bronze, l'argent et l'or 3
5. Ce que vous recevez 4
6. Ce que la RAW garde exprès 5
7. Analyser une livraison, en pratique 5
À retenir 6
Exercices 7
Annexe A — Le détail des étapes du labo 7

Cours 01 — Analyser la RAW reçue

Théorie · Cours 1/9 — Formation Analytics Engineering · débutant

Où vous êtes : `RAW`, chargée par Data Engineering → **`STAGING`** → `INTERMEDIATE` → `MARTS`, les couches d'Analytics Engineering. Le cours regarde ce que Data Engineering vous a livré, avec les yeux du `STAGING`, sans encore rien transformer.

Objectifs

- Situer l'ingénieur analytique (*analytics engineer*) entre l'ingénieur de données et l'analyste.
- Distinguer l'ELT de l'ETL, et dire pourquoi l'ordre a changé.
- Nommer les couches de la chaîne analytique, leur responsabilité, et celles qui forment le socle.
- Ne pas confondre ces couches avec le bronze, l'argent et l'or d'un lakehouse.
- Nommer ce que Data Engineering livre, et le compter contre le document qui l'annonce.

© 2026 iAlexMG. Tous droits réservés.

- Reconnaître les trois défauts que la couche `RAW` garde par contrat.

---

1. Le métier

L'ingénieur analytique tient la couche du milieu : il reçoit un brut chargé par quelqu'un d'autre, et livre des tables sur lesquelles on peut fonder une décision.

Métier	**Sa question**	**Son terrain**
Ingénieur de données (*data engineer*)	Comment amener la donnée, à l'échelle, de façon fiable ?	ingestion, lac, orchestration, temps réel
Ingénieur analytique (*analytics engineer*)	Comment transformer le brut en tables fiables et compréhensibles ?	modélisation, transformation, tests, documentation
Analyste (*data analyst*)	Qu'est-ce que la donnée raconte ?	analyses, tableaux de bord, réponses au métier

- Les trois écrivent du SQL : le partage tient à la question, pas à l'outil.
- Son geste signature, celui qui justifie le mot « ingénieur » : appliquer à la transformation les pratiques du génie logiciel, soit le versionnement dans Git, les tests automatisés, la documentation tirée du code et l'intégration continue.
- Le SQL des Cours 01 et 02 de la formation SQL avancé est supposé acquis. Le reste de l'outillage, comme Git, s'enseigne dans sa propre formation : à son premier emploi, Boréal nomme le cours et la section qui l'enseignent.

2. ELT et ETL : pourquoi l'ordre a changé

Extraire (*extract*), transformer (*transform*), charger (*load*) : d'une méthode à l'autre, ce sont les deux derniers gestes qui changent de place.

	ETL	**ELT**
L'ordre	extraire, transformer, charger	extraire, charger, transformer
Où se transforme la donnée	dans un outil dédié, avant l'entrepôt	dans l'entrepôt lui-même, en SQL
Ce qui arrive dans l'entrepôt	le résultat, déjà mis en forme	le brut, tel que livré
Une règle qui change	il faut réextraire la source	il suffit de rejouer la transformation
Qui écrit la transformation	un spécialiste de l'outil	quiconque écrit du SQL

© 2026 iAlexMG. Tous droits réservés.

- L'ETL régnait quand le stockage coûtait cher et que le calcul de l'entrepôt était rare. Un stockage presque gratuit et des moteurs analytiques rapides ont renversé ce calcul.
- L'avantage décisif de l'ELT est de garder le brut : une règle qui change, ou une erreur trouvée six mois plus tard, se rejoue sur un brut qu'on a encore.
- Cette formation est un ELT d'un bout à l'autre : Data Engineering charge sans corriger, et tout ce que vous écrivez se passe après le chargement, dans l'entrepôt.

3. L'architecture en couches

Une transformation se découpe en couches, chacune avec une seule responsabilité.

Couche	Sa responsabilité	Ce qu'elle ne fait pas	Socle
`RAW`	garder ce qui a été livré, sans rien changer	décoder, dédoublonner, joindre	oui, et vous la recevez
`STAGING`	rendre chaque source lisible : renommer, typer, décoder, tirer l'état courant	joindre deux sources	oui
`INTERMEDIATE`	préparer un calcul métier qui servira à plusieurs endroits	être consommée directement	au besoin
`MARTS`	offrir le modèle sur lequel on interroge : les faits et les dimensions	dépendre d'un outil de restitution	oui
`PRESENTATION`	servir une forme qu'un rapport précis réclame	inventer un chiffre que les `MARTS` n'ont pas	au besoin

Deux règles, qui reviennent à chaque cours :

- Une couche ne saute jamais sa voisine. Un modèle des `MARTS` qui lirait la `RAW` mettrait le décodage d'un code à deux endroits, et le jour où il change, l'un des deux serait oublié.
- Le `STAGING` ne joint rien : une vue par table livrée. Un `STAGING` qui joint devient un endroit où l'on fait du métier, et le métier a déjà ses couches.

Une couche est une responsabilité, pas un schéma de la base : une plateforme qui reçoit dix sources peut avoir dix schémas de staging.

4. Ces couches ne sont pas le bronze, l'argent et l'or

© 2026 iAlexMG. Tous droits réservés.

	Médaillon d'un lakehouse	Chaîne analytique
Ce qu'il découpe	des zones d'un lac de données, en fichiers	des couches d'un entrepôt, en tables et en vues
Le premier étage	bronze : le fichier tel qu'il est arrivé	`RAW` : une table par fichier livré, en texte
L'étage du milieu	argent : nettoyé, typé, souvent déjà joint	`STAGING` : lisible, mais jamais joint
Le dernier étage	or : agrégé pour un usage	`MARTS` : modélisé en étoile, pas agrégé pour un usage
Qui le tient	l'ingénieur de données	l'ingénieur analytique

- L'écart qui compte est au milieu : l'argent joint volontiers plusieurs sources, le `STAGING` jamais.
- Chez Boréal, les deux coexistent. Le schéma `argent` de l'entrepôt porte les séries nettoyées de l'usine : de l'argent au sens du lakehouse, pas un `STAGING`. Le médaillon appartient au Cours 10 de Data Engineering.

5. Ce que vous recevez

Data Engineering s'arrête à la couche `RAW`, et c'est là que vous commencez.

Ce que vous recevez	Où ça vit	Fabriqué par
La couche `RAW`, 22 tables, 513 857 lignes	schéma `raw` de `Projet_Boreal_intermediaire/plateforme/entrepot/boreal.duckdb`	Data Engineering, Cours 03
Les séries horaires de l'usine	schéma `argent` du même entrepôt	Data Engineering, Cours 08
Le journal des chargements	table `pipeline.chargements`	Data Engineering, Cours 03
Le document qui décrit tout cela	`01_Data_Engineering/02_Boreal_intermediaire/Solution/LIVRAISON.md`	Data Engineering

- Sans avoir fait Data Engineering, le kit de départ du Cours 00 monte la même `RAW`.
- Le document de livraison est le produit qu'on oublie, et le seul qui distingue une livraison complète d'une livraison tronquée.
- Le premier geste devant une livraison neuve n'est pas de la transformer : c'est de la compter, et de comparer ses comptes à ceux qui sont annoncés.
- Boréal, fabricant fictif de véhicules récréatifs, est entièrement synthétique, sauf la météo, tirée des archives publiques d'Environnement et Changement climatique Canada. Chaque chiffre des cours se reproduit : si le vôtre diffère, une étape a été sautée.

© 2026 iAlexMG. Tous droits réservés.

6. Ce que la `RAW` garde exprès

La `RAW` garde ce qui a été livré : les colonnes des fichiers, avec leurs noms d'origine, toutes en texte. Trois colonnes s'y ajoutent, qui disent d'où vient chaque ligne :

Colonne	Ce qu'elle porte
`_fichier`	le chemin du fichier chargé, depuis le projet
`_lot`	la livraison : le mois pour un extrait, le jour pour la télémétrie, `complet` pour un export entier
`_charge_le`	l'heure du chargement

Trois défauts la traversent, et aucun n'est un accident :

Défaut	Chez Boréal	Pourquoi la `RAW` le garde
Le même objet, livré plusieurs fois	l'ERP (progiciel de gestion intégré, le système qui tient les commandes et les clients) renvoie une commande modifiée dans l'extrait du mois de sa modification, et l'extrait de mars 2023 a été livré deux fois	dédoublonner effacerait la valeur qu'une commande avait à une date donnée
Des codes que personne n'a décodés	le palier d'un concessionnaire, `01`, `02` ou `03` dans la colonne `KUKLA` ; leur sens est au dictionnaire de l'univers	décoder à l'ingestion réécrirait l'histoire le jour où un code change de sens
Des textes qui ne sont pas du texte	une date SAP (l'éditeur allemand du progiciel le plus répandu en entreprise) s'écrit `20230302`, une date vide `00000000`, jamais `NULL` ; un montant s'écrit `1622.88`	typer est une décision, et elle appartient au `STAGING`

- `_lot` est ce qui départage deux versions d'une même commande. Garder la plus récente de chaque clé s'appelle tirer l'état courant, le premier geste du Cours 03.
- Ces défauts sont le contrat, pas la dette : le décodage, le dédoublonnage et le typage ne manquent pas à la chaîne, ils sont à votre étage, au Cours 03.

7. Analyser une livraison, en pratique

© 2026 iAlexMG. Tous droits réservés.

Devant une livraison neuve, l'ingénieur analytique mesure avant d'écrire un modèle. Il ne corrige rien : il compte, il compare, et il note ce que le `STAGING` devra régler.

Question	Ce qu'on mesure	Chez Boréal (labo)
Tout est-il arrivé ?	les tables et les lignes, contre le document de livraison	22 tables, 513 857 lignes, 0 écart (1.3 à 1.5)
Combien de fichiers lus ?	le journal des chargements	1 572 fichiers (1.6)
Sous quelle forme ?	le type des colonnes	250 `VARCHAR`, 22 horodatages, 2 `JSON` (2.1)
D'où vient une ligne ?	les colonnes de lignage	`_fichier`, `_lot`, `_charge_le` (2.2)
Une ligne, c'est quoi ?	les lignes contre les clés distinctes	26 538 lignes pour 25 483 commandes (3.1)
D'où viennent les doublons ?	les lots, puis une clé suivie d'un lot à l'autre	le lot `2023-03_bis` (3.2) ; la commande `0010006931` (3.3)
Quels codes ?	les valeurs d'un code, puis leur sens au dictionnaire	`KUKLA` à `01`, `02`, `03` (4.1, 4.2)
Les textes se lisent-ils ?	les dates vides, une conversion, un montant en texte et en nombre	24 230 dates vides (5.1) ; 0 date contre 2 308 (5.2) ; 9 996,26 contre 293 478,95 (5.3)

Ce premier regard se fait à la main, une fois. Ce qu'il apprend devient, au Cours 05, des tests qui tournent à chaque construction.

À retenir

- L'ingénieur analytique reçoit un brut chargé par un autre et livre des tables fiables. Ce qui le distingue n'est pas le SQL, mais les méthodes du génie logiciel qu'il y applique.
- L'ELT charge d'abord et transforme dans l'entrepôt ; son avantage décisif est de garder le brut.
- `RAW` → `STAGING` → `INTERMEDIATE` → `MARTS`. Le socle est `RAW`, `STAGING`, `MARTS`. Une couche ne saute jamais sa voisine, et le `STAGING` ne joint rien.
- L'argent d'un lakehouse joint volontiers ; le `STAGING`, jamais.
- Le premier geste devant une livraison : la compter contre le document qui l'annonce.

© 2026 iAlexMG. Tous droits réservés.

- La `RAW` garde exprès trois défauts : le même objet livré plusieurs fois, des codes non décodés, des textes qui ne sont pas du texte. Les régler est votre travail, au Cours 03.

Exercices

Les exercices de ce cours et leur corrigé vivent dans `Exercices_corriges_01_AE.md`. Faites-les après le labo.

Annexe A — Le détail des étapes du labo

A.1 Étape 1 : compter la livraison

Labo : `Labo_01_AE.md`, étape 1.

Notions : section 5, ce que vous recevez ; section 7, analyser une livraison.

- 1.1. Le notebook vit dans votre profil, sous `.duckdb\extension_data\ui\` : ni versionné, ni sauvegardé avec le projet. Il sert à explorer.
- 1.2. L'entrepôt s'attache en lecture seule : rien dans ce cours n'écrit, et la `RAW` est à l'abri d'une fausse manœuvre. L'alias `boreal` est le nom du fichier, celui sous lequel dbt connaîtra l'entrepôt à partir du Cours 03. Une cellule travaille en mémoire tant qu'on ne lui nomme pas l'entrepôt, d'où les noms complets, `boreal.raw.erp_vbak`. Sous Windows, tant que le notebook tient l'entrepôt, aucun autre processus ne peut y écrire, même en lecture seule : le labo le ferme en 6.1. L'entrepôt, le fichier `boreal.duckdb` et la base `boreal` ne sont pas trois choses, mais une seule, vue de trois côtés :

Le mot	Ce qu'il nomme
l'entrepôt	le rôle : l'endroit où vivent la `RAW` de Data Engineering et vos couches
`plateforme\entrepot\boreal.duckdb`	le fichier qui le tient, sur le disque : avec DuckDB, un entrepôt tient dans un fichier
`boreal`	la base de données que contient ce fichier ; le notebook l'attache sous ce nom, et dbt la nomme ainsi, d'après le fichier

  En entreprise, l'entrepôt est un serveur, Snowflake ou BigQuery, et non un fichier, mais la base y porte de même un nom, qui ouvre le nom complet de chaque table.
- 1.3. Le catalogue donne le compte de chaque table d'un coup, sans la lire : une estimation, qui suffit à un inventaire. Les noms suivent `raw.<source>_<fichier>`, ce qui dit d'où vient chaque table sans ouvrir le document.

© 2026 iAlexMG. Tous droits réservés.

- 1.4. Ici l'estimation tombe juste, parce qu'aucune table n'a changé depuis son chargement.
- 1.5. `count(*)` lit la table : c'est le compte exact, celui d'un contrôle. Les cinq tables de l'ERP sont celles sur lesquelles la formation travaillera le plus.
- 1.6. Le journal garde une ligne par fichier lu. Si un compte ne tombe pas, le Cours 00 n'est pas allé au bout : tout ce que vous bâtirez ensuite hériterait de l'écart.

A.2 Étape 2 : tout est du texte

Labo : `Labo_01_AE.md`, étape 2.

Notions : section 6, ce que la `RAW` garde exprès.

- 2.1. Trois types en tout, et chacun dit d'où vient la colonne :

Type	Colonnes	D'où il vient
`VARCHAR`	250	tout ce qui vient d'un fichier : un CSV ne transporte aucun type
`TIMESTAMP WITH TIME ZONE`	22	`_charge_le`, une par table, écrite par le chargeur
`JSON`	2	les réclamations et la télémétrie, livrées en JSON et gardées telles quelles

- 2.2. Le chemin part du projet, le lot est le mois de l'extrait, et l'heure est celle de votre chargement.

A.3 Étape 3 : le même objet, livré plusieurs fois

Labo : `Labo_01_AE.md`, étape 3.

Notions : section 6, le premier défaut.

- 3.1. 1 055 lignes de trop : la `RAW` garde chaque livraison d'une même commande.
- 3.2. Première cause, un incident : l'extrait de mars 2023 a été livré deux fois, sous deux noms de lot. Les mêmes commandes, deux fois.
- 3.3. Seconde cause, le fonctionnement normal de l'ERP : une commande modifiée revient dans l'extrait du mois de sa modification. La commande `0010006931` valait 6 079,02 $ en février, avant modification, et 5 556,72 $ en mars, après ; la troisième ligne est sa jumelle du lot `2023-03_bis`. Une `RAW` dédoublonnée aurait perdu « au 28 février, cette commande valait 6 079,02 $ », et personne n'aurait pu le retrouver.

A.4 Étape 4 : des codes que personne n'a décodés

Labo : `Labo_01_AE.md`, étape 4.

© 2026 iAlexMG. Tous droits réservés.

Notions : section 6, le deuxième défaut.

- 4.1. Trois codes, aucune étiquette. Les comptes sont des lignes, pas des concessionnaires : un concessionnaire revient dans chaque extrait mensuel.
- 4.2. Le sens des codes n'est écrit nulle part dans la donnée. Le dictionnaire de l'univers en est la seule source, et la règle vaut pour toute la formation : un nom de table, de colonne ou un code qui entre dans un modèle sort du dictionnaire, jamais de la mémoire ni d'un corrigé. Un support qui le recopierait finirait par mentir.

A.5 Étape 5 : des textes qui ne sont pas du texte

Labo : `Labo_01_AE.md`, étape 5.

Notions : section 6, le troisième défaut.

- 5.1. La date vide de SAP n'est pas `NULL` : c'est une chaîne de huit zéros, qui se compte, se compare et se trie comme n'importe quel texte.
- 5.2. `20230302` n'est pas un format de date que DuckDB reconnaît d'office : le cast direct n'en trouve aucune, même parmi les 2 308 vraies dates, et il faut lui donner le format. Avec `try_`, l'échec rend `NULL` sans un message : une conversion entièrement ratée ressemble à une colonne vide.
- 5.3. Le maximum en texte se trompe d'un facteur trente, sans un message, et rend un chiffre plausible pour une commande de motoneiges. Le texte se compare caractère par caractère, et `9996.26` passe devant `293478.95` : c'est le tri alphabétique déguisé en tri numérique, au Cours 08 de la formation SQL avancé, `Theorie_08_SQL.md`, section 5. Tout chiffre tiré d'une colonne de la `RAW` sans conversion explicite est donc suspect ; typer est le travail du `STAGING`, au Cours 03.

A.6 Étape 6 : le dépôt `02_ae`

Labo : `Labo_01_AE.md`, étape 6.

Notions : section 1, le versionnement, geste signature du métier ; Git s'enseigne dans la formation Git et GitHub.

Dossier	Contenu	Versionné
`Projet_Boreal_intermediaire/`	les sources, la plateforme et son entrepôt, le dépôt `01_de` de Data Engineering	non : tout se reconstruit
`Projet_Boreal_intermediaire/02_ae/`	votre code, du Cours 01 au capstone	oui, votre dépôt Git

- 6.1. Quitter DuckDB libère l'entrepôt : au Cours 03, dbt devra y écrire. Le notebook, lui, reste enregistré.
- 6.2. Le geste est celui de La Brûlerie, avec deux familles de plus à écarter. Les artefacts de dbt se refont par une commande et n'ont rien à faire dans un historique. La connexion portera un mot de passe dès qu'une plateforme infonuagique sera visée. `git -C 02_ae` lance Git dans le dépôt sans quitter `Projet_Boreal_intermediaire`. Le dossier `Data_Domain/` est le dépôt des supports de cours ; votre travail d'apprenant n'y entre jamais, il vit dans `02_ae`.

© 2026 iAlexMG. Tous droits réservés.