Table des matières

Labo 02 — Concevoir le modèle dimensionnel 1
Avant de commencer 2
Étape 1 — Déclarer le grain des quatre processus 2
Étape 2 — `dim_date`, et le piège des libellés 3
Étape 3 — `dim_concessionnaire` 4
Étape 4 — `dim_produit` 5
Étape 5 — `fct_ventes`, au grain de la ligne 6
Étape 6 — La question du métier 7
Étape 7 — La matrice de bus 8
Dépannage 8

Labo 02 — Concevoir le modèle dimensionnel

Labo · Cours 2/9 — Formation Analytics Engineering

But : déclarer le grain des quatre processus de Boréal, prototyper la première étoile en SQL pur, sans aucun outil (une table de dates en français, deux dimensions, un fait au grain de la ligne de commande), répondre à la question du métier en une requête, puis dessiner la matrice de bus. Le pourquoi de chaque étape est dans `Theorie_02_AE.md`, annexe A.

Deux outils :

- l'Anaconda Prompt, environnement `formations` actif : il lance le notebook ;
- l'interface web de DuckDB (`duckdb -ui`), le notebook « AE Labo 02 » : le SQL. Le prototype vit dans la mémoire du notebook, à côté de l'entrepôt attaché en lecture seule, et disparaît quand DuckDB se ferme : rien ne s'écrit dans l'entrepôt.

Liste de contrôle :

- ☐ À vous : le grain des quatre processus, une phrase chacun
- ☐ `dim_date` : 1 551 jours, du 2022-01-01 au 2026-03-31, libellés en français
- ☐ `dim_concessionnaire` : 156 lignes, 156 clés, 0 palier non décodé

© 2026 iAlexMG. Tous droits réservés.

- ☐ À vous : `dim_produit`, 68 articles, quatre gammes
- ☐ `fct_ventes` : 75 652 lignes, grain vérifié, 430 148 012,16 $
- ☐ La question du métier répondue en une requête, notebook fermé
- ☐ La matrice de bus remplie pour les quatre processus

Avant de commencer

La couche `RAW` vient du Cours 00, `Cours_00_AE_Boreal.md`, et le dépôt `02_ae` du Cours 01 : si `Projet_Boreal_intermediaire` manque, faire le Cours 00 d'abord. Anaconda Prompt, environnement `formations` actif, placée dans `Projet_Boreal_intermediaire` :

```
dir /b plateforme\entrepot
REM Attendu : boreal.duckdb.
```

L'Anaconda Prompt reste dans `Projet_Boreal_intermediaire` pour tout le labo : aucun `cd` à taper ensuite.

Étape 1 — Déclarer le grain des quatre processus

Théorie : `Theorie_02_AE.md`, annexe A.1.

1.1 À vous : sur une feuille, écrire le grain de chaque processus, une phrase qui commence par « une ligne représente ». La source dit ce que Data Engineering livre, pas encore ce qu'une ligne du fait représentera.

Le processus	**Où la donnée vit**
Un concessionnaire commande	`raw.erp_vbak` et `raw.erp_vbap`
Un véhicule est assemblé et expédié	`raw.erp_zserie`
Un véhicule est vendu au détail	`raw.garanties_enregistrements`
Une réclamation suit son cycle	`raw.garanties_reclamations`

Indice : une ligne de la `RAW` est une livraison, pas un objet (Labo 01, 3.1). Cherchez l'objet le plus fin que chaque source décrit.

1.2 Lancer l'interface, depuis l'Anaconda Prompt.

```
duckdb -ui
```


© 2026 iAlexMG. Tous droits réservés.

Attendu : l'interface s'ouvre dans le navigateur. Créer un notebook et le renommer « AE Labo 02 ». Une requête par cellule ; Ctrl+Entrée l'exécute.

1.3 Attacher l'entrepôt en lecture seule, dans la première cellule.

```
-- Attendu : boreal paraît sous Attached databases.
attach if not exists 'plateforme/entrepot/boreal.duckdb' as boreal (read_only);
```

1.4 Vérifier le grain le plus fin des ventes.

```
-- Attendu : 81 292 lignes, 25 483 commandes, 77 732 couples commande-poste.
select
    count(*) as lignes,
    count(distinct vbeln) as commandes,
    count(distinct (vbeln, posnr)) as couples_commande_poste
from boreal.raw.erp_vbap;
```

1.5 Comparer vos quatre phrases au corrigé, à l'annexe A.1 de la théorie. Si l'une diffère, demandez-vous laquelle des deux permet la question la plus fine.

Étape 2 — `dim_date`, et le piège des libellés

Théorie : `Theorie_02_AE.md`, annexe A.2.

2.1 Erreur voulue : demander à DuckDB le nom d'un mois et d'un jour.

```
-- Attendu : January, January, Saturday.
select
    strftime(date '2022-01-01', '%B') as mois_strftime,
    monthname(date '2022-01-01') as mois_monthname,
    dayname(date '2022-01-01') as jour_dayname;
```

À retenir — DuckDB n'a pas de langue, et aucune option ne la change. Un libellé se décode une fois, à l'endroit unique qui fabrique la dimension, sinon chaque rapport le corrige à sa façon.

2.2 Fabriquer la dimension, une ligne par jour. `create table … as` s'apprend au Cours 03 de la formation SQL avancé, `Theorie_03_SQL.md`, section 2 ; `generate_series` à son Cours 05, `Theorie_05_SQL.md`, section 6, et sur des dates à son Cours 09, `Theorie_09_SQL.md`, section 2.

```
-- Attendu : la table est créée, 1 551 lignes.
create or replace table dim_date as
select
    jour::date as date_jour,
    year(jour) as annee,
    quarter(jour) as trimestre,
    month(jour) as mois,
    case month(jour)
```


© 2026 iAlexMG. Tous droits réservés.

```
        when 1 then 'janvier' when 2 then 'février' when 3 then 'mars' when 4 then 'avril'
        when 5 then 'mai' when 6 then 'juin' when 7 then 'juillet' when 8 then 'août'
        when 9 then 'septembre' when 10 then 'octobre' when 11 then 'novembre'
        when 12 then 'décembre'
    end as nom_mois,
    case isodow(jour)
        when 1 then 'lundi' when 2 then 'mardi' when 3 then 'mercredi' when 4 then 'jeudi'
        when 5 then 'vendredi' when 6 then 'samedi' when 7 then 'dimanche'
    end as nom_jour,
    isodow(jour) >= 6 as est_fin_de_semaine
from generate_series(date '2022-01-01', date '2026-03-31', interval 1 day) as jours(jour);
```

2.3 Vérifier les bornes et les libellés.

```
-- Attendu : 1 551 jours, du 2022-01-01 au 2026-03-31, 0 libellé vide.
select
    count(*) as jours,
    min(date_jour) as premier,
    max(date_jour) as dernier,
    2 * count(*) - count(nom_mois) - count(nom_jour) as libelles_vides
from dim_date;
```

Étape 3 — `dim_concessionnaire`

Théorie : `Theorie_02_AE.md`, annexe A.3.

3.1 Fabriquer la dimension : l'état courant, la clé de substitution, le palier décodé d'après le dictionnaire de l'univers, à la section de `KUKLA` (Labo 01, 4.2). `row_number()` s'apprend au Cours 04 de la formation SQL avancé, `Theorie_04_SQL.md`, section 3, et `with` à son Cours 05, `Theorie_05_SQL.md`, section 2.

```
-- Attendu : la table est créée, 156 lignes.
create or replace table dim_concessionnaire as
with courant as (
    select *, row_number() over (partition by kunnr order by _lot desc) as rang
    from boreal.raw.erp_kna1
)
select
    md5(kunnr) as cle_concessionnaire,
    kunnr as code_concessionnaire,
    name1 as nom,
    ort01 as ville,
    regio as province,
    case kukla when '01' then 'Or' when '02' then 'Argent' when '03' then 'Bronze' end as palier,
```


© 2026 iAlexMG. Tous droits réservés.

```
    try_strptime(erdat, '%Y%m%d')::date as date_creation
from courant
where rang = 1;
```

3.2 Vérifier les clés et le décodage.

```
-- Attendu : 156 lignes, 156 clés, 0 palier non décodé.
select
    count(*) as lignes,
    count(distinct cle_concessionnaire) as cles,
    count(*) - count(palier) as paliers_non_decodes
from dim_concessionnaire;
```

Étape 4 — `dim_produit`

Théorie : `Theorie_02_AE.md`, annexe A.4.

4.1 À vous : fabriquer `dim_produit` sur `boreal.raw.erp_mara`, par le même geste qu'en 3.1, celui des dimensions du Cours 04 de La Brûlerie, sans son code. Cinq colonnes :

Colonne	D'où elle vient
`cle_produit`	l'empreinte du numéro d'article, `matnr`
`code_article`	`matnr`
`gamme`	`matkl` décodé : quatre codes, quatre gammes
`type_article`	`mtart` décodé : deux codes, deux types
`annee_modele`	`zzannee_mod`, vide pour une pièce

Les codes et leur sens sont dans `Data_Domain/_univers/boreal/DICTIONNAIRE.md`, aux sections de `MATKL` et de `MTART`, et nulle part ailleurs. Attendu : la table est créée, 68 lignes. Le corrigé est à l'annexe A.4 de la théorie.

4.2 Compter les articles par gamme et par type.

```
-- Attendu : 4 lignes. Hors-route Véhicule 15, Motomarine Véhicule 15, Motoneige Véhicule 15,
-- Pièces et accessoires Pièce 23.
select gamme, type_article, count(*) as articles
from dim_produit
group by 1, 2
order by 1;
```


© 2026 iAlexMG. Tous droits réservés.

Étape 5 — `fct_ventes`, au grain de la ligne

Théorie : `Theorie_02_AE.md`, annexe A.5.

5.1 Fabriquer le fait : les postes à leur état courant, joints à leur en-tête et aux trois dimensions, sans les postes refusés.

```
-- Attendu : la table est créée, 75 652 lignes.
create or replace table fct_ventes as
with postes as (
    select *, row_number() over (partition by vbeln, posnr order by _lot desc) as rang
    from boreal.raw.erp_vbap
),
entetes as (
    select *, row_number() over (partition by vbeln order by _lot desc) as rang
    from boreal.raw.erp_vbak
)
select
    d.date_jour as cle_date,
    c.cle_concessionnaire,
    pr.cle_produit,
    p.vbeln as numero_commande,
    p.posnr as numero_poste,
    p.kwmeng::decimal(18, 3) as quantite,
    p.netwr::decimal(18, 2) as valeur_nette,
    p.wavwr::decimal(18, 2) as cout
from postes p
join entetes e on e.vbeln = p.vbeln and e.rang = 1
join dim_date d on d.date_jour = try_strptime(e.erdat, '%Y%m%d')::date
join dim_concessionnaire c on c.code_concessionnaire = e.kunnr
join dim_produit pr on pr.code_article = p.matnr
where p.rang = 1
  and (p.abgru is null or p.abgru = '');
```

5.2 Contrôler le grain : autant de lignes que de couples qui le définissent.

```
-- Attendu : 75 652 et 75 652.
select
    count(*) as lignes,
    count(distinct (numero_commande, numero_poste)) as couples_distincts
from fct_ventes;
```

5.3 Totaliser le fait.

© 2026 iAlexMG. Tous droits réservés.

```sql
-- Attendu : 75 652 lignes, 25 256 commandes, 430 148 012,16 $ de valeur nette,
-- 312 784 347,46 $ de coût.
select
    count(*) as lignes,
    count(distinct numero_commande) as commandes,
    sum(valeur_nette) as valeur_nette,
    sum(cout) as cout
from fct_ventes;
```

5.4 Expliquer les deux écarts avec l'ERP, les postes refusés et les commandes qui n'ont plus rien.

```sql
-- Attendu : 77 732 postes dont 2 080 refusés ; 25 483 commandes dont 25 256 gardent au moins
-- un poste actif.
with postes as (
    select *, row_number() over (partition by vbeln, posnr order by _lot desc) as rang
    from boreal.raw.erp_vbap
)
select
    count(*) as postes,
    count(nullif(abgru, '')) as refuses,
    count(distinct vbeln) as commandes,
    count(distinct case when nullif(abgru, '') is null then vbeln end) as commandes_actives
from postes
where rang = 1;
```

Étape 6 — La question du métier

Théorie : `Theorie_02_AE.md`, annexe A.6.

6.1 Répondre à la question de la mise en situation : quelle gamme se vend le mieux au Québec, par trimestre de 2025, chez les concessionnaires de palier Or ? Avant de lire la requête, soulignez dans la question les mots qui disent quand, quoi et qui : chacun mène à une dimension et à sa colonne, et deux mots peuvent mener à la même. Le corrigé est à l'annexe A.6 de la théorie.

```sql
-- Attendu : 16 lignes, quatre gammes sur quatre trimestres. Motoneige : 574 546,57 $,
-- 28 525,10 $, 3 273 517,55 $, 910 380,72 $. Motomarine : 2 224 614,99 $ au premier trimestre,
-- 41 641,32 $ au quatrième.
select
    p.gamme,
    d.trimestre,
    sum(f.valeur_nette) as valeur_nette
from fct_ventes f
join dim_produit p on p.cle_produit = f.cle_produit
```


© 2026 iAlexMG. Tous droits réservés.

```
join dim_date d on d.date_jour = f.cle_date
join dim_concessionnaire c on c.cle_concessionnaire = f.cle_concessionnaire
where c.province = 'QC'
  and d.annee = 2025
  and c.palier = 'Or'
group by 1, 2
order by 1, 2;
```

6.2 Fermer le notebook : fermer l'onglet du navigateur, puis quitter DuckDB dans l'Anaconda Prompt.

```
.quit
```

Attendu : l'invite revient, dans `Projet_Boreal_intermediaire`. Les quatre tables du prototype ont disparu avec la mémoire de DuckDB ; le notebook « AE Labo 02 » garde ses cellules, qui les refont en quelques secondes.

Étape 7 — La matrice de bus

Théorie : `Theorie_02_AE.md`, annexe A.7.

7.1 Sur la feuille de l'étape 1, dresser la matrice : une ligne par processus, une colonne par dimension, une croix quand le processus se découpe selon elle. Les cinq dimensions de Boréal intermédiaire : `dim_date`, `dim_concessionnaire`, `dim_produit`, `dim_vehicule`, `dim_client`.

Indice : pour chaque case, une question. Le processus produit-il une date ? Un concessionnaire y est-il en cause ? Un article ? Un véhicule identifié par son numéro de série ? Un client ?

7.2 Comparer avec la matrice de la section 9 de la théorie, puis lire ses colonnes : celle qui porte le plus de croix se construit en premier.

Dépannage

Symptôme	Correctif
`IO Error: Cannot open file "…\plateforme\entrepot\boreal.duckdb"` en 1.3	`duckdb -ui` n'a pas été lancé dans `Projet_Boreal_intermediaire` : `.quit`, se placer dans `Projet_Boreal_intermediaire`, relancer
`Binder Error: Catalog "boreal" does not exist!`	l'entrepôt n'est pas attaché (interface relancée) : relancer la cellule de 1.3
`Catalog Error: Table with name dim_date does not exist!`	DuckDB a été relancé, et la mémoire avec lui : relancer les cellules des étapes 2 à 4
`Binder Error: Referenced column "…" not found`	le nom ne vient pas du dictionnaire : le relire dans `DICTIONNAIRE.md`

© 2026 iAlexMG. Tous droits réservés.

Symptôme	Correctif
Le fait porte plus de lignes que de couples distincts	une jointure tombe sur plusieurs lignes : vérifier que chaque dimension a une ligne par code
`paliers_non_decodes` ou une gamme vide n'est pas à 0	les codes du `case` ne sont pas ceux de la source : relire le dictionnaire
La valeur nette dépasse l'attendu de 18 001 551,21 $	les postes refusés n'ont pas été écartés : la condition sur `abgru` manque

© 2026 iAlexMG. Tous droits réservés.