

Table des matières

Exercices 01 — Le métier, la chaîne et la RAW reçue	1
Questions courtes	1
Questions pratiques	2
Diagnostics	3
Questions à développer	4
Mises en situation	4

Exercices 01 — Le métier, la chaîne et la RAW reçue

Comment travailler ces exercices. Répondez seul, puis vérifiez avec le corrigé. Les exercices marqués [labo] portent sur ce que vous venez de faire au labo ; les autres vérifient que le cours est clair dans votre tête. Tout vient de la Théorie 01 et du Labo 01.

Le corrigé est dans `Corrige_01.md`. Répondez à l'énoncé en entier avant de l'ouvrir : c'est en butant sur une question qu'on découvre ce qu'on avait lu sans le comprendre.

Questions courtes

1. Les trois métiers. Nommez les trois métiers qui se partagent la chaîne de la donnée, et la question à laquelle chacun répond.
2. Le geste signature. L'analyste écrit du SQL, l'ingénieur analytique aussi. Qu'est-ce qui distingue le second, et pourquoi le mot « ingénieur » figure dans son titre ?
3. Les deux lettres qui bougent. Que veulent dire les lettres d'ELT et d'ETL, et laquelle des deux change de place ?
4. L'avantage décisif. L'ELT est souvent présenté comme plus rapide et moins cher. Quel est pourtant son avantage le plus important, et dans quelle situation le mesure-t-on ?
5. Les couches du socle. Parmi RAW, STAGING, INTERMEDIATE, MARTS et PRESENTATION, lesquelles forment le socle, et lesquelles ne viennent qu'au besoin ?
6. La responsabilité du STAGING. Donnez trois choses que le STAGING fait, et une qu'il ne fait jamais.
7. Sauter une couche. Un collègue écrit un modèle des MARTS qui lit directement une table de la RAW, parce que c'est plus court. Nommez le problème que cela crée, en une phrase.

8. Couche et schéma. Pourquoi la phrase « le STAGING, c'est le schéma staging » est-elle fausse en général ?
 9. L'étage du milieu. Qu'est-ce que l'argent d'un lakehouse s'autorise et que le STAGING refuse ?
 10. Les quatre produits. Nommez ce que Data Engineering livre à cette formation, en comptant le document qui les décrit.
 11. Le premier geste. Devant une livraison de données neuve, quel est le premier geste d'un ingénieur analytique, avant toute transformation ?
 12. La porte d'entrée. Un lecteur arrive dans cette formation sans avoir fait Data Engineering. Comment obtient-il la couche RAW ?
 13. Les trois colonnes. Nommez les trois colonnes que le chargeur ajoute à chaque table de la RAW, et ce que porte chacune.
 14. À quoi sert _lot. Donnez la question à laquelle cette colonne permet de répondre, et qu'aucune autre ne permet.
 15. Les trois défauts. Nommez les trois formes de défaut que la RAW garde par contrat.
 16. Le contrat, pas la dette. Pourquoi une couche RAW qui aurait dédoublonné les commandes serait moins utile, et non plus propre ?
 17. [labo] Les comptes. Combien de tables la couche RAW porte-t-elle, et combien de lignes en tout ?
 18. [labo] Les types. Quels types de colonnes trouve-t-on dans le schéma raw, et d'où vient chacun ?
 19. [labo] La date vide. Comment SAP écrit-il une date vide, et pourquoi n'est-ce pas NULL ?
 20. [labo] Le maximum faux. Sur quelle colonne l'avez-vous constaté, quelles sont les deux valeurs, et quelle est la cause ?
 21. [labo] Le dépôt. Nommez deux familles de fichiers que le .gitignore de 02_ae écarte, et la raison de chacune.
 1. Le terrain réel. Dans l'univers de Boréal, une seule source n'est pas fabriquée. Laquelle, et d'où vient-elle ?
-

Questions pratiques

- P1. [labo] Compter une table. Écrivez la requête qui donne le nombre de lignes de `raw.garanties_visites`, et dites le résultat attendu.
- P2. [labo] L'inventaire. Écrivez la requête qui liste les tables du schéma raw avec leur nombre de lignes estimé, triées par nom.
- P3. Le total, autrement. La requête du labo somme `estimated_size`. Écrivez une requête qui donne le total exact des lignes des cinq tables de l'ERP, sans passer par l'estimation.
- P4. [labo] Les doublons d'une autre table. `raw.garanties_reclamations` porte 5 623 objets pour 3 348 réclamations. Écrivez la requête qui le montre, sachant que l'identifiant vit dans la colonne JSON `objet`, sous la clé `reclamation_id`.

P5. Le lot le plus récent. Écrivez la requête qui donne, pour la table `raw.erp_kna1`, la liste des lots distincts et le nombre de lignes de chacun, du plus récent au plus ancien.

P6. [labo] Typier une date. Écrivez l'expression qui convertit `aedat` en date en traitant la date vide comme une absence de date, et non comme une erreur.

P7. Le montant juste. Écrivez la requête qui donne la valeur nette totale des commandes du lot 2023-02, avec le type qui convient.

P8. Une ligne, son origine. Écrivez la requête qui affiche, pour la commande 0010006931, toutes les lignes de `raw.erp_vbak` avec leur fichier source et leur lot, du plus ancien au plus récent.

Diagnostics

E1. Le compte qui ne tombe pas. Un collègue écrit ceci pour compter les commandes de Boréal, et annonce 26 538 commandes à la direction :

```
select count(*) as commandes from raw.erp_vbak;
```

Dites ce qui est faux, de combien, et écrivez la requête juste.

E2. Le tri qui ment. Cette requête doit donner les dix commandes les plus grosses :

```
select vbeln, netwr
from raw.erp_vbak
order by netwr desc
limit 10;
```

Elle rend des commandes autour de 9 000 \$ alors que la plus grosse dépasse 290 000 \$. Dites pourquoi, et corrigez.

E3. La conversion silencieuse. Un collègue écrit ceci et conclut que la colonne est vide :

```
select count(*) as dates_valides
from raw.erp_vbak
where try_cast(aedat as date) is not null;
```

Il obtient 0. Dites ce qui se passe vraiment et ce qu'il faut écrire.

E4. Le décodage inventé. Dans un modèle, un collègue écrit :

```
case kukla
  when 'Z001' then 'Or'
  when 'Z002' then 'Argent'
  when 'Z003' then 'Bronze'
end as palier
```

Le modèle tourne sans erreur et tous les tests passent. Dites ce qui ne va pas, comment le constater, et quelle règle aurait évité l'erreur.

E5. Le verrou. Un collègue lance son script de chargement et reçoit :

```
IO Error: Cannot open file "...boreal.duckdb": Le processus ne peut pas accéder au
fichier car ce fichier est utilisé par un autre processus.
```

Il jure n'avoir rien lancé d'autre. Dites ce qui tient probablement l'entrepôt, et la parade.

Questions à développer

A. La frontière. Data Engineering pourrait très bien décoder les codes SAP et dédoublonner les commandes avant de livrer : il en a les moyens, et cela vous épargnerait du travail. Expliquez pourquoi la frontière est placée là où elle est, ce qu'on perdrait à la déplacer, et ce que cela dit de la notion de couche.

B. Le document de livraison. Le labo vous fait comparer vos comptes à ceux de `LIVRAISON.md`. Expliquez ce que ce contrôle protège vraiment, ce qu'il ne protège pas, et ce qui se passerait dans une équipe où ce document n'existerait pas.

C. (avancé) Deux vocabulaires. Un architecte vous dit que votre `STAGING` est « l'argent, en gros ». Expliquez en un paragraphe pourquoi cette équivalence est dangereuse en pratique, avec un exemple concret de ce qui casse si l'équipe l'adopte.

Mises en situation

M1. Coopérative laitière de Sainte-Perpétue. La coopérative reçoit chaque nuit, d'un transporteur, un fichier des collectes de la journée : numéro de ferme, volume, température, heure de collecte. Le fichier arrive parfois deux fois, parfois en retard de deux jours, et le transporteur renvoie un fichier corrigé quand une ferme conteste un volume. On vous demande de bâtir les tableaux de bord de la coopérative. Dites quelle couche gardera quoi, ce que vous refusez de faire à l'ingestion, et la première chose que vous exigerez du transporteur.

M2. (avancé) Transport Baie-des-Sables. L'entreprise vous embauche pour reprendre une plateforme existante. Vous découvrez que les tableaux de bord lisent directement les tables brutes, qu'un même indicateur est calculé dans quatre rapports différents avec trois résultats, et que personne ne sait d'où vient le chiffre affiché en page d'accueil. Proposez l'ordre dans lequel vous reprendriez cela, en justifiant ce que vous faites en premier et ce que vous laissez pour la fin.

M3. La livraison silencieuse. Un matin, votre chargement quotidien se termine sans erreur, et tous vos modèles tournent. Pourtant le chiffre d'affaires du tableau de bord a chuté de 40 pour cent. Décrivez la démarche par laquelle vous cherchez la cause, en partant de ce que le Cours 01 vous a appris sur les livraisons.