

Table des matières

Cours 01 — Le métier, la chaîne et la RAW reçue.....	1
Objectifs.....	2
1. Le métier : ingénieur analytique	2
2. ELT et ETL : pourquoi l'ordre a changé	3
3. L'architecture en couches	3
4. Ces couches ne sont pas le bronze, l'argent et l'or	4
5. Ce que vous recevez, et comment l'obtenir	5
6. Ce que la RAW garde exprès	6
7. Le fil rouge, et les deux autres terrains.....	7
Points clés à retenir.....	7
Exercices.....	8

Cours 01 — Le métier, la chaîne et la RAW reçue

Théorie · Module 1/9 — Formation Analytics Engineering · ~35 min · débutant

Où vous êtes : RAW → **STAGING** → INTERMEDIATE → MARTS. Le Cours 01 pose la carte du métier et regarde ce que la formation précédente vous a livré, sans encore rien transformer.

En 30 secondes :

- L'ingénieur analytique tient la couche du milieu : il reçoit du brut chargé par quelqu'un d'autre, et livre des tables sur lesquelles on peut fonder une décision.
- Son geste signature n'est pas le SQL, que l'analyste écrit aussi : c'est d'appliquer au SQL les méthodes du génie logiciel, versionnement, tests, documentation, intégration continue.
- La chaîne va de la couche RAW aux MARTS, par le STAGING et, au besoin, par l'INTERMEDIATE. Chaque couche a une seule responsabilité, et aucune ne fait le travail d'une autre.
- La couche RAW de Boréal arrive telle qu'elle a été livrée : 22 tables, 513 857 lignes, tout en texte, avec trois colonnes qui disent d'où chaque ligne vient.

- Elle garde exprès ce qui vous gênera : un extrait livré deux fois, des codes que personne n’a décodés, des dates qui n’en sont pas. Ce n’est pas une négligence, c’est le contrat.

L’idée du cours. Avant d’écrire une ligne de transformation, on regarde ce qu’on reçoit et on vérifie que c’est bien ce qui était annoncé. Un ingénieur analytique qui commence à modéliser sans avoir compté ses sources découvre ses surprises trois cours plus tard, dans un chiffre qui ne tombe pas juste. Au labo, vous monterez la RAW, vous la compterez table par table contre le document de livraison, et vous irez voir de vos yeux trois défauts qu’elle garde volontairement.

Objectifs

- Situer l’ingénieur analytique (*analytics engineer*) entre l’ingénieur de données et l’analyste : ce qu’il reçoit, ce qu’il possède, ce qu’il livre.
- Distinguer l’ELT de l’ETL, et dire ce qui a fait basculer l’ordre des deux lettres.
- Nommer les couches de la chaîne analytique, leur responsabilité, et lesquelles forment le socle.
- Ne pas confondre ces couches avec le bronze, l’argent et l’or d’un lakehouse.
- Nommer ce que Data Engineering livre, où ça vit, et comment l’obtenir sans avoir fait cette formation.
- Vérifier une livraison contre le document qui l’annonce, plutôt que de la croire sur parole.
- Reconnaître les trois formes de défaut que la couche RAW garde par contrat.

1. Le métier : ingénieur analytique

Une donnée brute ne vaut rien tant que personne ne peut s’y fier. Entre le moment où un système d’entreprise crache ses tables et le moment où un gestionnaire regarde un chiffre et décide, quelqu’un doit décoder, recouper, modéliser, tester et documenter. Ce quelqu’un est l’ingénieur analytique.

Trois métiers se partagent la chaîne, et on les confond souvent. Voici la ligne de partage :

Métier	Sa question	Son terrain
Ingénieur de données (<i>data engineer</i>)	Comment amener la donnée, à l’échelle, de façon fiable ?	ingestion, lac, orchestration, temps réel
Ingénieur analytique (<i>analytics engineer</i>)	Comment transformer le brut en tables fiables et compréhensibles ?	modélisation, transformation, tests, documentation
Analyste (<i>data analyst</i>)	Qu’est-ce que la donnée raconte ?	analyses, tableaux de bord, réponses au métier

Le partage ne tient pas à l'outil : les trois écrivent du SQL. Il tient à la question. L'ingénieur de données répond de l'arrivée de la donnée, l'analyste répond de sa lecture, et l'ingénieur analytique répond de ce qui se passe entre les deux, c'est-à-dire de la confiance qu'on peut placer dans un chiffre.

Son geste signature, celui qui justifie le mot « ingénieur » dans le titre, est d'appliquer à la transformation des données les pratiques du génie logiciel : le versionnement dans Git, les tests automatisés, la documentation générée depuis le code, l'intégration continue. C'est la différence entre un SQL qui marche sur votre poste et une plateforme que l'on tient en production.

Le fil de la formation. Vous savez déjà écrire du SQL : jointures, agrégats, expressions de table communes, fonctions de fenêtre. C'était la formation SQL avancé, et cette formation-ci ne les réenseigne pas, elle y renvoie. Ici, on quitte la requête isolée pour bâtir un projet : la même logique SQL, mais versionnée, testée, documentée, déployée.

2. ELT et ETL : pourquoi l'ordre a changé

Trois lettres, trois gestes : extraire (*extract*), transformer (*transform*), charger (*load*). Ce qui change d'une méthode à l'autre, c'est l'ordre des deux dernières, et l'endroit où la transformation se fait.

	ETL	ELT
L'ordre	extraire, transformer, charger	extraire, charger, transformer
Où se transforme la donnée	dans un outil dédié, avant l'entrepôt	dans l'entrepôt lui-même, en SQL
Ce qui arrive dans l'entrepôt	le résultat, déjà mis en forme	le brut, tel que livré
Une règle qui change	il faut réextraire la source	il suffit de rejouer la transformation
Qui écrit la transformation	un spécialiste de l'outil	quiconque écrit du SQL

L'ETL a régné tant que le stockage coûtait cher et que le calcul de l'entrepôt était rare et précieux : on ne chargeait que ce qu'on allait consommer, et on jetait le reste. Deux choses ont renversé ce calcul. Le stockage est devenu presque gratuit, ce qui retire la raison de jeter le brut. Et les moteurs analytiques modernes calculent vite sur de grands volumes, ce qui retire la raison de transformer ailleurs.

L'avantage décisif de l'ELT n'est pourtant ni le coût ni la vitesse : c'est de garder le brut. Quand une règle métier change, ou quand vous découvrez une erreur dans une transformation écrite il y a six mois, vous rejouez la transformation sur un brut que vous avez encore. En ETL, la donnée d'origine n'a jamais été chargée, et il faut retourner voir la source, qui a parfois été purgée depuis.

Cette formation est un ELT du premier au dernier cours : Data Engineering a chargé le brut sans le corriger, et tout ce que vous allez écrire ici se passe après le chargement, dans l'entrepôt.

3. L'architecture en couches

Une transformation ne se fait pas d'un bloc, du brut jusqu'au chiffre. Elle se découpe en couches, et chaque couche a une seule responsabilité. C'est ce découpage qui rend une plateforme lisible, et c'est le même chez tout le monde, aux noms près.

Couche	Sa responsabilité	Ce qu'elle ne fait pas	Socle
RAW	garder ce qui a été livré, sans rien changer	décoder, dédoublonner, joindre	oui, et vous la recevez
STAGING	rendre chaque source lisible : renommer, typer, décoder, tirer l'état courant	joindre deux sources	oui
INTERMEDIATE	préparer un calcul métier qui servira à plusieurs endroits	être consommée directement	au besoin
MARTS	offrir le modèle sur lequel on interroge : les faits et les dimensions	dépendre d'un outil de restitution	oui
PRESENTATION	servir une forme qu'un rapport précis réclame	inventer un chiffre que les MARTS n'ont pas	au besoin

Deux règles gouvernent ce tableau, et elles reviendront à chaque cours.

La première : une couche ne saute jamais sa voisine. Un modèle des MARTS ne lit pas la RAW directement, même quand ce serait plus court. Sinon le décodage d'un code vit à deux endroits, et le jour où il change, l'un des deux est oublié.

La seconde : le STAGING ne joint rien. Il travaille source par source, une vue par table livrée. C'est contre-intuitif quand on vient du SQL, où l'on joint dès qu'on peut. Mais un STAGING qui joint devient un endroit où l'on fait du métier, et le métier a déjà ses couches.

Piège — un même type de couche peut vivre dans plusieurs schémas. Rien n'oblige à ce que STAGING soit un seul schéma. Une plateforme qui reçoit dix sources peut fort bien avoir dix schémas de staging, un par source. Ce qui compte est la responsabilité, pas le nombre de schémas : « couche » désigne un rôle dans la chaîne, pas un objet de la base.

4. Ces couches ne sont pas le bronze, l'argent et l'or

Si vous venez d'un lakehouse, vous connaissez l'architecture en médaillon : bronze, argent, or. La ressemblance avec RAW, STAGING et MARTS est forte, et c'est justement ce qui rend la confusion coûteuse. Les deux vocabulaires ne découpent pas au même endroit.

	Médaillon	Chaîne analytique
Ce qu'il découpe	des zones d'un lac de données, en fichiers	des couches d'un entrepôt, en tables et en vues

	Médaille	Chaîne analytique
Le premier étage	bronze : le fichier tel qu'il est arrivé	RAW : la table, une par fichier livré, en texte
L'étage du milieu	argent : nettoyé, typé, souvent déjà joint	STAGING : lisible, mais jamais joint
Le dernier étage	or : agrégé pour un usage	MARTS : modélisé en étoile, pas agrégé pour un usage
Qui le tient	l'ingénieur de données	l'ingénieur analytique

L'écart qui compte est celui du milieu. L'argent d'un lakehouse joint volontiers plusieurs sources, là où le STAGING s'y refuse. Chez Boréal, les deux coexistent : Data Engineering tient un lac avec son bronze et son argent, et vous tenez les couches de l'entrepôt. Le schéma argent qu'il vous livre porte les séries nettoyées de l'usine, et c'est bien de l'argent au sens du lakehouse, pas un STAGING.

Renvoi : le Cours 10 de Data Engineering possède le lakehouse et le médaille.

5. Ce que vous recevez, et comment l'obtenir

Cette formation est la première du parcours à consommer le produit d'une autre. Data Engineering s'arrête à la couche RAW, et c'est là que vous commencez.

Ce que vous recevez	Où ça vit	Fabriqué par
La couche RAW, 22 tables	schéma raw de Projet_Boreal/plateforme/entrepot/boreal. duckdb	Data Engineering, Cours 03
Les séries horaires de l'usine	schéma argent du même entrepôt	Data Engineering, Cours 08
Le journal des chargements	table pipeline.chargements	Data Engineering, Cours 03
Le document qui décrit tout cela	01_Data_Engineering/Cours/Solution/LIVRAISON.md	Data Engineering

Porte d'entrée. Vous n'avez pas fait Data Engineering ? Vous n'en avez pas besoin. Le kit de départ de cette formation reconstruit exactement ce que cette formation-là aurait livré, par une commande unique décrite au labo. Vous entrez ici de plain-pied, avec la même RAW que celui qui arrive du cours précédent.

Le dernier produit de cette liste est le plus important des quatre, et c'est celui qu'on oublie. Une livraison de données s'accompagne d'un document qui dit ce qu'elle contient : les tables, leurs comptes, ce qu'elles gardent de bancal et pourquoi. Sans lui, vous ne pouvez pas distinguer une livraison complète d'une livraison tronquée, et vous bâtirez sur du sable.

Le premier geste d'un ingénieur analytique devant une livraison neuve n'est donc pas de la transformer. C'est de la compter, et de comparer ses comptes à ceux qui sont annoncés. C'est exactement ce que vous ferez au labo, sur les 22 tables, et c'est un geste que vous referez à chaque livraison de votre carrière.

6. Ce que la RAW garde exprès

La couche RAW de Boréal est fidèle à sa définition : elle garde ce qui a été livré, sans rien changer. Ses colonnes sont celles des fichiers, avec leurs noms d'origine, et toutes en texte. Trois colonnes s'ajoutent, qui disent d'où chaque ligne vient.

Colonne	Ce qu'elle porte
_fichier	le chemin du fichier chargé, depuis le projet
_lot	la livraison : le mois pour un extrait, le jour pour la télémétrie, complet pour un export entier
_charge_le	l'heure du chargement

Ces trois colonnes ne sont pas de la décoration. Sans elles, vous ne pouvez pas dire, devant deux lignes qui portent le même numéro de commande, laquelle est la plus récente. Vous vous en servirez dès le Cours 03.

Trois formes de défaut traversent cette couche, et aucune n'est un accident.

Le même objet, livré plusieurs fois

L'ERP (progiciel de gestion intégré, le système qui tient les commandes et les clients) livre un extrait par mois, et une commande modifiée revient dans l'extrait du mois de sa modification. En mars 2023, en plus, l'extrait a été livré deux fois par erreur, sous deux noms de lot. Résultat : raw.erp_vbak porte 26 538 lignes pour 25 483 commandes. La RAW garde les deux, et c'est à vous de décider laquelle vaut.

Des codes que personne n'a décodés

Le palier commercial d'un concessionnaire s'écrit 01, 02 ou 03 dans la colonne KUKLA. Ce que valent ces codes est écrit dans le dictionnaire de l'univers, pas dans la donnée. Data Engineering ne les décode pas, et il a raison : le jour où le sens d'un code change, un décodage fait à l'ingestion aurait réécrit l'histoire.

Des textes qui ne sont pas du texte

Une date SAP (l'éditeur allemand du progiciel le plus répandu en entreprise) s'écrit 20230302, et une date vide s'écrit 00000000, jamais NULL. Un montant s'écrit 1622.88, en texte. Tant que ces colonnes restent du texte, elles se comparent alphabétiquement, et une comparaison alphabétique sur des nombres donne des résultats faux sans rien signaler. Vous le verrez au labo, sur un maximum qui se trompe d'un facteur trente.

À retenir — ces défauts sont le contrat, pas la dette. Une couche RAW qui aurait décodé, dédoublonné et typé serait plus agréable, et elle aurait détruit l'information dont vous avez besoin : quelle version d'une commande était connue à quelle date. Le travail de décodage n'est pas absent de la chaîne, il est à votre étage. C'est le Cours 03.

7. Le fil rouge, et les deux autres terrains

Trois terrains servent dans cette formation, et ils ne se mêlent jamais.

Terrain	Ce que c'est	Où il sert
Véhicules Boréal inc.	un fabricant fictif de véhicules récréatifs : usine, concessionnaires, garanties, véhicules connectés	le fil rouge, du Cours 01 au capstone
Brûlerie du Passage	un torréfacteur, un mois de ventes de caisse, figé en fichiers	un mini-cas court, pour un premier arc complet
Comptoir Aurore inc.	une boutique en ligne, deux pays, deux régimes de taxes	la synthèse de clôture, à refaire d'un bloc

Boréal est fictif, et ses données sont entièrement synthétiques : les personnes, les courriels et les adresses sont inventés. Ce qui est réel, dans ce décor, tient en une chose : la météo, tirée des archives publiques d'Environnement et Changement climatique Canada. Le reste sort d'un générateur, ce qui a un avantage que vous mesurerez souvent : chaque chiffre de ces cours est reproductible, et si le vôtre diffère, c'est qu'une étape a été sautée.

Recoupements. Data Engineering livre la couche RAW et les séries de l'usine, et s'arrête là : son Cours 03 explique pourquoi il ne décode rien. Business Intelligence prend la suite après l'étoile, et ne conçoit pas le modèle qu'elle consomme. Le bronze, l'argent et l'or du lakehouse recourent RAW, STAGING et MARTS sans se confondre avec eux (section 4).

Points clés à retenir

- L'ingénieur analytique tient la couche du milieu : il reçoit un brut chargé par un autre et livre des tables sur lesquelles on fonde une décision. Ce qui le distingue n'est pas d'écrire du SQL, c'est d'y appliquer les méthodes du génie logiciel.
- L'ELT charge d'abord et transforme ensuite, dans l'entrepôt. Son avantage décisif est de garder le brut : une règle qui change se rejoue, au lieu de se réextraire.
- La chaîne va de RAW à MARTS. Le socle est RAW, STAGING, MARTS ; INTERMEDIATE et PRESENTATION viennent au besoin. Une couche ne saute jamais sa voisine, et le STAGING ne joint rien.
- Le bronze, l'argent et l'or d'un lakehouse ne se superposent pas à ces couches : l'argent joint volontiers, le STAGING jamais.
- Vous recevez 22 tables, 513 857 lignes, et un document qui les décrit. Le premier geste devant une livraison est de la compter contre ce document.

- La RAW garde exprès trois formes de défaut : le même objet livré plusieurs fois, des codes non décodés, des textes qui ne sont pas du texte. C'est le contrat, et le décodage est votre travail.
-

Exercices

Les exercices de ce cours vivent dans `Exercices_01.md`, et leur corrigé dans `Corrige_01.md`. Faites-les après le labo : plusieurs énoncés supposent que la RAW a été montée et comptée.