

Table des matières

Corrigé 02 — Modélisation dimensionnelle et matrice de bus	1
Questions courtes	1
Questions pratiques	3
Diagnostics	6
Questions à développer	7
Mises en situation	8

Corrigé 02 — Modélisation dimensionnelle et matrice de bus

Comment lire ce corrigé. Il donne la réponse et le pourquoi, jamais une notion neuve : tout ce qu'il emploie a été enseigné dans la Théorie 02 ou pratiqué dans le Labo 02. Quand une réponse repose sur un geste du labo, le renvoi le nomme.

L'énoncé est dans Exercices_02.md.

Questions courtes

1. Deux modèles, deux usages. La forme normalisée écrit chaque information à un seul endroit, ce qui permet d'écrire vite sans jamais se contredire. C'est exactement ce qui gêne l'analyse : pour lire, il faut rassembler ce qui a été dispersé, donc joindre, donc connaître les codes et les règles. La même propriété sert l'écriture et dessert la lecture.
2. La recette. Le processus, quel événement du métier mesure-t-on ; le grain, que représente une ligne du fait ; les dimensions, selon quels axes veut-on découper ; les faits, que mesure-t-on.
3. L'ordre qui compte. On commence le plus souvent par les mesures, parce que c'est ce qu'on sait vouloir. Le résultat est une table dont personne ne sait dire ce qu'une ligne représente, et dont les totaux se mettent à dépendre de la façon dont on l'interroge.
4. Un processus, ou pas. « Un véhicule est assemblé » est un processus : c'est un événement qui se produit dans la vraie vie, que le métier reconnaîtrait sans qu'on lui explique. « Le rapport hebdomadaire du directeur des ventes » est un usage, et il se sert de plusieurs processus. « Le suivi de la performance commerciale » est un objectif, plus vague encore. Ni l'un ni l'autre ne se modélise directement, et essayer donne un fait qui mélange des grains.
5. Le grain, en une phrase. « Une ligne de `fct_ventes` représente une ligne de commande, c'est-à-dire un article commandé sur une commande. »

6. Fin ou grossier. Prenez toujours le grain le plus fin que la source permet, même si personne ne demande ce détail aujourd'hui. La raison est asymétrique : d'un grain fin, on remonte au grain grossier par une somme ; de l'inverse, on ne redescend jamais, l'information n'est plus là.
 7. Ce qu'un grain grossier interdit. « Quelle gamme se vend le mieux », puisqu'une commande porte plusieurs gammes ; le compte des postes refusés, puisque le refus est par article. On pourrait ajouter le prix moyen d'un modèle, que la commande ne connaît pas.
 8. Trois additivités. Additive, sommable selon toutes les dimensions : la valeur nette d'un poste. Semi-additive, sommable sauf dans le temps : la disponibilité d'un actif de l'usine à une heure donnée. Non additive, jamais sommable directement : un taux de marge, un prix unitaire.
 9. Le ratio. Parce qu'un ratio ne se somme ni ne se moyenne : 18 pour cent et 22 pour cent ne font ni 40 ni 20, sauf si les deux dénominateurs sont égaux, ce qui n'arrive pas. On stocke le numérateur et le dénominateur, ici la marge et la valeur nette, et le ratio se calcule à la lecture, sur les sommes.
 10. Étoile ou flocon. L'étoile garde ses dimensions à plat, le flocon les normalise en plusieurs tables. Le flocon économise quelques mégaoctets sur des tables qui comptent des dizaines ou des milliers de lignes ; il coûte une jointure de plus à chaque personne qui écrit une requête, pour toujours.
 11. Deux clés. La clé naturelle vient du système source : 0000200077, avec ses zéros de tête. La clé de substitution est fabriquée par l'entrepôt, et lui seul en décide. *Labo : Labo_02.md, étape 3.*
 12. La vraie raison. La troisième : garder plusieurs versions datées d'une même entité. Les deux autres, la performance de jointure et l'indépendance vis-à-vis de la source, sont réelles mais ne justifieraient pas à elles seules le travail supplémentaire : on peut vivre avec une jointure sur un texte de dix caractères. L'historique, lui, est impossible sans clé de substitution, et c'est une capacité qu'on ne rattrape pas après coup.
 13. Type 1 ou type 2. Le type 1 écrase l'ancienne valeur : il garde la vérité d'aujourd'hui et perd l'histoire, entièrement. Le type 2 ferme l'ancienne ligne et en ouvre une neuve : il garde les deux états, datés, et perd en simplicité, puisque le fait doit désormais pointer la bonne version.
1. Choisir par la question. Type 2 : « combien avons-nous vendu à des concessionnaires de palier Or en mai 2024 ? », qui exige de savoir qui était Or à ce moment-là. Type 1 : « quel est le palier de ce concessionnaire ? », qui ne demande que l'état courant.
 2. La dimension dégénérée. Un identifiant du monde réel qui sert d'axe d'analyse mais n'a aucun attribut propre : le numéro de commande chez Boréal. Il reste dans le fait, comme une colonne ordinaire. On le reconnaît à une question : cet identifiant a-t-il des attributs qui lui appartiennent ? Si non, une table à une seule colonne serait une jointure payée pour rien.
 3. Conforme. Une dimension unique, partagée par plusieurs faits, avec le même sens, les mêmes clés et les mêmes libellés. Son absence rend impossible toute question qui traverse deux processus : on peut interroger chaque étoile, jamais les relier.
 4. La matrice de bus. Les lignes sont les processus, les colonnes les dimensions, une case cochée dit que ce processus se découpe selon cette dimension. Elle sert à trois choses : dire ce qu'on peut croiser aujourd'hui, montrer les trous, et ordonner le travail.
 5. Lire les colonnes. Une colonne très cochée désigne une dimension à construire en premier, puisque tout en dépend. Une case vide n'est pas une erreur : elle dit une question qu'on ne peut pas poser, et il faut savoir si c'est normal, comme la disponibilité d'un actif qui ne se découpe pas par concessionnaire, ou si c'est un manque à combler.

6. Le forage transversal. Passer d'un fait à un autre en gardant le même axe : de l'heure d'un actif de l'usine aux véhicules assemblés à ce moment, puis aux réclamations qui les visent. Il faut pour cela que les dimensions traversées soient conformes, c'est-à-dire que `dim_date` et `dim_vehicule` soient les mêmes tables, avec les mêmes clés, pour les trois faits.
 7. Les libellés. Parce que `monthname()` rend l'anglais, sans option de langue : DuckDB n'a pas de notion de locale. À la place, on décode une fois, à l'endroit unique qui fabrique la dimension, par une liste indexée sur le numéro du mois. *Labo : Labo_02.md, étape 2.*
 8. Le contrôle du grain. Comparer le nombre de lignes au nombre de couples distincts qui définissent le grain : ils doivent être égaux. Il prouve qu'aucune jointure n'a dupliqué de lignes, et donc que le fait dit bien ce que son grain annonce. *Labo : Labo_02.md, étape 5.*
 9. Les deux écarts. Sur les lignes, 2 080 postes sont refusés et le fait des ventes ne les compte pas : 77 732 moins 2 080 donne 75 652. Sur les commandes, 227 commandes n'ont que des postes refusés et disparaissent donc entièrement du fait : 25 483 moins 227 donne 25 256. Les deux écarts sont voulus, et il faut savoir les expliquer avant que quelqu'un ne les découvre dans un rapport. *Labo : Labo_02.md, étape 5.*
-

Questions pratiques

P1. Les fins de semaine.

```
select
    count(*) as jours_2025,
    count(*) filter (where est_fin_de_semaine) as fins_de_semaine
from prototype.dim_date
where annee = 2025;
```

Attendu : 365 jours, dont 104 de fin de semaine. Cinquante-deux samedis et cinquante-deux dimanches.

P2. La semaine ISO.

```
select date_jour, nom_jour, weekofyear(date_jour) as semaine_iso
from prototype.dim_date
where date_jour between date '2025-12-29' and date '2026-01-04'
order by date_jour;
```

Les sept jours portent tous la semaine 1, y compris les 29, 30 et 31 décembre 2025. Ce n'est pas une anomalie : dans la norme ISO, une semaine appartient à l'année où tombe son jeudi, et le jeudi de cette semaine-là est le 1er janvier 2026.

Ce qu'il faut en conclure est net : grouper par `year(date_jour)` et `weekofyear(date_jour)` range ces trois jours dans la semaine 1 de 2025, à onze mois de leur vraie place, et le total de la semaine 1 mélange alors deux années. La parade est de stocker aussi l'année ISO, et de grouper sur elle :

```
select isoyear(date_jour) as annee_iso, weekofyear(date_jour) as semaine
from prototype.dim_date
where date_jour = date '2025-12-29';
```

Attendu : année ISO 2026, semaine 1, pour une date dont l'année civile est 2025. C'est exactement le genre de règle qu'une dimension de dates existe pour porter : une fois, au bon endroit, plutôt que dans chaque requête.

P3. Le grain d'un autre fait.

```
select
  count(*) as lignes,
  count(distinct sernr) as numeros_de_serie,
  count(distinct (sernr, _lot)) as couples_serie_lot
from raw.erp_zserie;
```

Attendu : 32 597 lignes, 27 775 numéros de série, 32 597 couples. Le grain à choisir est le numéro de série : un véhicule, une ligne. Les 4 822 lignes de plus sont des livraisons multiples du même véhicule, exactement comme pour les commandes, et l'état courant se tire de la même façon. Le couple numéro-lot n'est pas un grain : c'est un compte de livraisons, pas un compte d'objets du monde.

P4. Le prix unitaire.

```
select
  sum(valeur_nette) / sum(quantite) as prix_unitaire_moyen_correct,
  avg(valeur_nette / quantite) as moyenne_des_ratios
from prototype.fct_ventes;
```

Attendu : 1 389,57 \$ par la division des sommes, 2 172,48 \$ par la moyenne des ratios, soit 56 pour cent de plus. La première est juste. La seconde donne le même poids à une ligne de 24 motoneiges et à une ligne d'une seule courroie, alors que la première pèse infiniment plus dans la réalité.

C'est la démonstration concrète de la non-additivité : le prix unitaire est un ratio, il ne se moyenne pas, et le seul calcul juste passe par les deux sommes.

P5. La valeur par gamme.

```
select p.gamme, count(*) as lignes, sum(f.valeur_nette) as valeur_nette
from prototype.fct_ventes f
join prototype.dim_produit p on p.cle_produit = f.cle_produit
group by 1
order by 3 desc;
```

Gamme	Lignes	Part des lignes	Valeur nette	Part de la valeur
Motoneige	3 708	4,9 %	154 146 280,98 \$	35,8 %

Gamme	Lignes	Part des lignes	Valeur nette	Part de la valeur
Hors-route	4 911	6,5 %	133 674 387,82 \$	31,1 %
Motomarine	2 148	2,8 %	83 432 098,97 \$	19,4 %
Pièces et accessoires	64 885	85,8 %	58 895 244,39 \$	13,7 %

Les deux classements s'opposent, et c'est tout l'intérêt de la question. Les pièces font 86 pour cent des lignes et 14 pour cent de la valeur. Un tableau de bord qui compterait des lignes parlerait presque uniquement de pièces ; un qui somme des dollars parle de véhicules. Les deux sont vrais, et c'est pourquoi un indicateur se nomme toujours par ce qu'il compte.

P6. Prototyper dim_vehicule.

```
create or replace table prototype.dim_vehicule as
with courant as (
    select *, row_number() over (partition by sernr order by _lot desc) as rang
    from raw.erp_zserie
)
select
    md5(sernr) as cle_vehicule,
    sernr as numero_serie,
    matnr as code_article,
    try_strptime(erdatt, '%Y%m%d')::date as date_assemblage,
    try_strptime(nullif(wadat_ist, '00000000'), '%Y%m%d')::date as date_expedition
from courant
where rang = 1;

select count(*) as vehicules, count(distinct cle_vehicule) as cles,
       count(date_expedition) as expedies
from prototype.dim_vehicule;
```

Attendu : 27 775 véhicules, 27 775 clés, 27 698 expédiés. Le nullif est le point de la question : sans lui, la date vide 00000000 de SAP devient une conversion ratée, et 77 véhicules non encore expédiés ressemblent à une erreur de données plutôt qu'à des véhicules en attente.

P7. Mesurer le besoin d'un type 2.

```
with versions as (
    select kunnr, kukla, _lot,
           lag(kukla) over (partition by kunnr order by _lot) as kukla_precedent
    from raw.erp_kna1
)
select count(*) as changements_de_palier
```

```
from versions
where kukla_precedent is not null and kukla <> kukla_precedent;
```

Attendu : 49 changements, sur toute l’histoire de la table. Et ce sont les mêmes 49 que ceux du 1er juillet 2024, ce que confirme le compte des documents de modification de cette date : tous les changements de palier de Boréal ont eu lieu le même jour, à la révision annuelle.

Ce que cela implique : le besoin d’un type 2 est réel mais concentré. Quarante-neuf concessionnaires sur 156, soit près d’un tiers, ont changé de palier une fois. En type 1, toutes les ventes des deux années et demie qui précèdent leur seraient attribuées avec leur palier d’aujourd’hui, ce qui fausse silencieusement toute analyse commerciale par palier.

Renvoi : Lag() et les fonctions de fenêtre sont au Cours 04 de SQL.

P8. La matrice, en SQL.

```
select count(*) as articles_du_fait_absents_de_la_dimension
from prototype.fct_ventes f
left join prototype.dim_produit p on p.cle_produit = f.cle_produit
where p.cle_produit is null;
```

Attendu : 0. Un résultat non nul signifierait qu’une ligne du fait pointe une clé de produit qui n’existe pas dans la dimension, c’est-à-dire un fait orphelin. Concrètement, les ventes de cet article disparaîtraient de tout rapport qui joint la dimension, sans erreur et sans trace. C’est le premier test que vous écrierez en dbt, au Cours 05, et il porte un nom : le test de relation.

Diagnosics

E1. La jointure qui multiplie. Deux causes se cumulent, et le résultat passe de 75 652 à 6 890 576 lignes, un facteur 91.

La première est la langue. La table des désignations porte une ligne par article et par langue, ici deux, le français et l’anglais. Une jointure sans filtre sur la langue double donc chaque ligne.

La seconde est la livraison. Cette table vient de la RAW, qui garde chaque extrait mensuel : 4 918 lignes pour 68 articles, soit 72 lignes par article en moyenne. Un article présent dès le premier extrait en porte 98, ses 49 lots multipliés par ses deux langues ; le plus récent en porte 16.

La conception aurait évité cette requête, et c’est là le vrai enseignement. La désignation d’un article est un attribut de l’article : elle appartient à `dim_produit`, où elle aurait été résolue une fois, avec sa langue choisie et son état courant tiré. Un fait ne joint pas une table brute pour aller chercher un libellé ; s’il en a besoin, c’est que la dimension est incomplète.

E2. Le taux stocké. `avg(taux_marge)` donne la moyenne des taux ligne à ligne, où une commande de 40 motoneiges pèse autant qu’une courroie. La mesure P4 donne l’ordre de grandeur de l’erreur sur un ratio comparable : 56 pour cent d’écart.

Dans le fait, la colonne `taux_marge` se retire, remplacée par ses deux termes, la marge et la valeur nette, qui sont additifs. Dans le rapport, la formule devient `sum(marge) / sum(valeur_nette)`. Le taux se calcule à la lecture, jamais à l'écriture.

E3. La clé naturelle dans le fait. Deux situations, et la seconde est celle qui compte.

La première : Boréal remplace son ERP et les identifiants changent de format. Le fait, qui porte `kunnr` sur des dizaines de millions de lignes, est à réécrire en entier.

La seconde : la dimension passe en type 2. Il y a alors trois lignes pour le concessionnaire `0000200077`, à trois époques, et toutes portent le même `kunnr`. La jointure du fait en ramène trois, et chaque vente est comptée trois fois. La clé naturelle ne désigne plus une ligne de la dimension : elle désigne une entité, dont il existe plusieurs versions. Seule la clé de substitution désigne une version.

E4. Le jour décalé. Le dimanche est vide. `dayofweek()` rend 0 pour dimanche et 6 pour samedi, là où `isodow()` rend 1 pour lundi et 7 pour dimanche. Or les listes de DuckDB s'indexent à partir de 1 : l'indice 0 ne désigne aucun élément, et l'expression rend NULL sans erreur.

Mesuré sur la semaine du 6 au 12 janvier 2025 : les six premiers jours sortent justes, le dimanche 12 sort vide.

```
['lundi', 'mardi', 'mercredi', 'jeudi', 'vendredi', 'samedi', 'dimanche'][isodow(date_jour)] as nom_jour
```

Remarquez ce qui rend ce défaut vicieux : six jours sur sept étant justes, une relecture rapide ne voit rien, et l'erreur ne se manifeste que sur un rapport hebdomadaire où une journée manque.

E5. La version d'époque. Le fait joint sur le code du concessionnaire, et la dimension porte désormais plusieurs lignes par code, une par période de validité. Chaque ligne du fait en ramène donc autant que le concessionnaire a connu de versions, et les ventes sont comptées plusieurs fois : les totaux gonflent sans qu'aucune erreur n'apparaisse.

Il faut corriger le fait, pas la dimension. Chaque ligne du fait doit porter la clé de substitution de la version valide à la date de l'événement, résolue au moment où le fait se construit : la vente de mai 2024 pointe la version Bronze, celle de septembre la version Or. C'est ce que vous ferez au Cours 05, et c'est la raison pour laquelle la section 7 de la théorie insiste : le type 2 ne s'ajoute pas après coup sans rebrancher les faits.

Questions à développer

A. Le grain le plus fin, jusqu'où ? La règle vaut parce que l'information perdue ne se retrouve jamais, et elle tient dans l'immense majorité des cas. Elle coûte plus qu'elle ne rapporte dans un cas précis : quand la source produit un volume dont le grain fin n'est pas exploitable et ne le sera pas. L'exemple type est une télémétrie à la seconde sur des milliers d'équipements, où l'entrepôt devrait porter des dizaines de milliards de lignes pour des questions qui se posent toutes à l'heure. On le reconnaît à trois signes qui doivent être réunis : le volume au grain fin dépasse d'un ou deux ordres de grandeur ce que la plateforme traite confortablement, aucune question connue ne descend sous le grain agrégé, et la source garde elle-même le détail. Ce dernier point est le plus important, parce qu'il change la nature de la décision : on ne détruit pas l'information, on choisit de ne pas la recopier. Ce qu'on fait alors : on agrège à l'entrée, on documente le

grain retenu et la règle d'agrégation, et on écrit noir sur blanc où le détail reste disponible. Chez Boréal, la question se pose pour l'usine, dont les points bruts restent au lac et dont l'entrepôt ne reçoit que l'heure.

B. Le type 2 n'est pas gratuit. Il oblige à changer trois choses ailleurs. D'abord chaque fait qui référence la dimension : il ne peut plus joindre sur la clé naturelle, il doit porter la clé de substitution de la version valide à la date de l'événement, ce qui change sa construction et son grain de jointure. Ensuite les tests : l'unicité de la clé naturelle dans la dimension, qui tenait jusque-là, devient fausse, et le test qui la vérifiait doit être réécrit sur la clé de substitution. Enfin les rapports : « les ventes par palier » devient une question ambiguë, qui demande de préciser si l'on veut le palier d'époque ou le palier courant, et les deux réponses sont légitimes.

Décider dès la conception coûte une conversation ; convertir ensuite coûte une reprise de tous les faits concernés, avec un rechargement complet et une période où les deux versions coexistent. La différence n'est pas technique, elle est de volume de travail et de risque : au moment de la conception, aucun rapport ne dépend encore de la dimension.

C. (avancé) La matrice comme outil d'organisation. Ce qu'elle rend visible pour un métier tient en un regard : les lignes sont des choses qu'il reconnaît, « un client commande », « une réclamation est ouverte », et les colonnes sont les mots de son propre vocabulaire. Il n'a rien à apprendre pour la lire, et il repère immédiatement ce qui manque, parce qu'il connaît les questions qu'il se pose.

Dans une réunion où deux équipes défendent chacune leur définition d'un indicateur, la matrice déplace la discussion. Tant qu'on parle de l'indicateur, chacun défend son chiffre et la conversation est un arbitrage. Devant la matrice, la question devient : de quel processus cet indicateur sort-il, et à quel grain ? Il arrive alors souvent que les deux définitions soient justes et portent sur deux processus différents, auquel cas il faut deux indicateurs nommés différemment, pas un compromis. Et quand elles portent bien sur le même processus au même grain, l'une des deux est simplement fausse, et cela se démontre en comptant plutôt qu'en argumentant. La matrice ne tranche pas le débat, elle le rend décidable.

Mises en situation

M1. Les Serres de Saint-Fulgence. Deux processus au moins, et il faut résister à l'envie de les fondre. « Un plant est vendu » a pour grain une ligne de vente, un plant d'une variété sur un ticket ou un bon de commande : c'est le grain le plus fin, et c'est lui qui répond aux variétés qui partent le plus. « Un plant est mis au compost » est un autre processus, avec son propre grain, une ligne par lot éliminé ; le fondre dans le premier avec une quantité négative produirait un fait dont le grain se raconte en deux phrases, ce que la théorie proscriit. Les dimensions partagées sont la date, la variété et le client, et c'est leur partage qui permet la troisième question : croiser ce qui s'est vendu et ce qui a été jeté, par variété et par semaine. La date mérite une attention particulière dans ce cas : avec mai qui fait la moitié de l'année, l'analyse portera sur des semaines plutôt que sur des mois, et la dimension doit donc porter la semaine ISO et son année, comme la question P2 l'a montré. Le client demande un type 2 si l'on veut savoir si un paysagiste revient d'une année à l'autre alors qu'il a changé de statut entre-temps.

M2. (avancé) Cliniques vétérinaires d'Amqui. Le problème est celui des dimensions non conformes, et il est entier : quatre bases, quatre espaces d'identifiants, aucune garantie qu'un même propriétaire porte le même numéro dans deux cliniques. Tant que ce n'est pas réglé, consolider revient à additionner des choses qu'on ne sait pas distinguer, et un même propriétaire compte pour deux.

L'ordre que je suivrais. D'abord mesurer l'ampleur, plutôt que de la supposer : combien de propriétaires apparaissent dans plus d'une clinique, sur quels critères peut-on les rapprocher, et quelle proportion reste ambiguë. Ensuite bâtir la dimension conforme du propriétaire, avec une clé de substitution de l'entrepôt et la table qui relie chaque identifiant de clinique à cette clé : c'est cette table qui porte toute la difficulté, et elle a besoin d'un propriétaire humain qui tranche les cas douteux. L'animal suit la même logique, en plus simple, puisqu'il appartient à une clinique à la fois dans la plupart des cas. Les faits viennent après, et seulement après.

Ce que je refuserais de promettre tant que ce n'est pas réglé : tout indicateur qui compte des propriétaires ou qui raisonne par propriétaire, comme le nombre de clients actifs, le panier moyen par client ou le taux de rétention. Les indicateurs qui comptent des actes, eux, sont livrables tout de suite, parce qu'un acte appartient sans ambiguïté à une clinique. Dire cette frontière dès le début vaut mieux que livrer un tableau de bord complet dont un tiers des chiffres sera faux.

M3. Location d'équipement Cap-Chat. Le grain est la journée de location d'une machine sur un contrat, et non le contrat ni la ligne de contrat. La raison tient à la question posée : un taux d'utilisation se calcule sur des jours, et une ligne de contrat qui couvre douze jours ne se découpe plus une fois qu'elle est écrite. Le fait s'appelle un instantané périodique, et vous en verrez un autre au Cours 06 avec les actifs de l'usine.

Le taux d'utilisation n'est pas une colonne de ce fait parce que c'est un ratio : le nombre de journées louées sur le nombre de journées disponibles. Stocké ligne à ligne, il ne se sommerait ni ne se moyennerait, et une moyenne par machine donnerait le même poids à une nacelle louée presque toute l'année et à une autre louée deux jours.

Il se calcule malgré tout, et sans difficulté, parce que ses deux termes sont additifs. Le numérateur est le compte des lignes du fait sur la période. Le dénominateur demande de définir ce que « disponible » veut dire, et c'est la vraie question de conception, celle du sort d'une machine en réparation. La réponse se range dans une dimension du parc, avec l'état de la machine, et le taux devient une division de deux sommes sur la période et le sous-ensemble qu'on veut.