

Table des matières

Labo 03 — Monter dbt, déclarer les sources, écrire le STAGING	1
Avant de commencer	2
Étape 1 — Le fichier de connexion, hors du dépôt.....	2
Étape 2 — Le projet dbt, à la racine du dépôt	3
Étape 3 — La macro des schémas.....	4
Étape 4 — Déclarer les sources.....	5
Étape 5 — Voir ce que dbt connaît	6
Étape 6 — La première vue de staging	6
Étape 7 — La vue qui retrouve les 25 483 commandes.....	8
Étape 8 — Relier deux modèles, et voir le graphe.....	9
Récapitulatif	10
Dépannage	11

Labo 03 — Monter dbt, déclarer les sources, écrire le STAGING

Labo · Module 3/9 — Formation Analytics Engineering

Ce que vous allez faire. Monter un projet dbt dans le dépôt créé au Cours 01, brancher sa connexion hors du dépôt, déclarer la couche RAW comme source, puis écrire vos premières vues de staging. La dernière retrouvera les 25 483 commandes de Boréal malgré l'extrait livré deux fois, et un modèle de contrôle reliera deux vues pour que le graphe ait sa première arête. Objectif de fin : `dbt debug` au vert, trois modèles construits, et un graphe qui remonte jusqu'aux sources.

Deux terminaux servent dans ce labo. L'Anaconda Prompt, environnement `formations` actif, sert à dbt et à Git. La ligne de commande DuckDB sert à vérifier ce que dbt a écrit, et elle doit être fermée quand dbt travaille.

La liste de contrôle du cours :

- ☐ Le schéma prototype du Cours 02 abandonné
- ☐ `profiles.yml` écrit hors du dépôt, avec un chemin absolu
- ☐ `dbt_project.yml` à la racine de `02_ae`, et `dbt debug` au vert

- ☐ La macro `generate_schema_name` en place, les schémas portent leur nom nu
- ☐ Les sources déclarées, et `dbt ls` qui les montre
- ☐ `stg_concessionnaires` : 156 lignes, 0 palier vide, 4 fiches fermées
- ☐ `stg_commandes` : 25 483 lignes, malgré les 26 538 de la source
- ☐ Le modèle de contrôle construit, et le graphe qui le relie aux deux vues

Durée : de deux heures et demie à trois heures, en deux séances. La première va jusqu'à l'étape 5, la seconde porte les modèles de staging.

Avant de commencer

Ce labo suppose la couche RAW montée au Cours 01 et le dépôt 02_ae créé à son étape 7. Il suppose aussi dbt installé, ce que le guide d'installation du parcours a fait.

Deux vérifications, dans l'Anaconda Prompt :

```
dbt --version
```

Vous devez lire `dbt=1.12.3` ou plus récent pour le cœur, et `duckdb: 1.11.0` sous Plugins. Si la ligne Plugins ne mentionne pas DuckDB, c'est l'adaptateur qui manque, et il s'installe par `pip install dbt-duckdb`.

Le Cours 02 vous a fait écrire des tables dans un schéma `prototype`, en vous annonçant qu'il servirait une fois. C'est maintenant. Dans la ligne de commande DuckDB, depuis `Projet_Boreal` :

```
drop schema if exists prototype cascade;
```

Ce que vous avez appris en l'écrivant reste ; les tables, elles, vont être refaites par dbt, mieux. Quittez ensuite DuckDB par `.exit` : un seul processus à la fois sur l'entrepôt, et dbt va l'ouvrir.

Étape 1 — Le fichier de connexion, hors du dépôt

Théorie : Theorie_03.md, section 3.

dbt cherche `profiles.yml` dans un dossier `.dbt` de votre répertoire personnel. Créez-le, puis le fichier :

```
mkdir %USERPROFILE%\dbt
notepad %USERPROFILE%\dbt\profiles.yml
```

Sur macOS ou Linux, c'est `~/dbt/profiles.yml`, avec l'éditeur de votre choix.

Contenu, en remplaçant le chemin par le vôtre :

```
boreal_ae:
  target: dev
  outputs:
    dev:
      type: duckdb
      path: C:/Users/<vous>/.../Data_Domain/Projet_Boreal/plateforme/entrepot/boreal.duckdb
      schema: staging
      threads: 4
```

Quatre points méritent un mot.

Le nom `boreal_ae` en tête est le nom du profil, et le `dbt_project.yml` le réclamera à l'identique à l'étape suivante. Une faute de frappe ici produit une erreur qui parle de profil introuvable.

Le chemin est absolu, et les barres obliques sont celles de l'avant, même sous Windows. Un chemin relatif fonctionnerait tant que vous lancez `dbt` depuis le projet, et échouerait le jour où vous le lancez d'ailleurs.

`schema: staging` est le schéma par défaut de cette cible.

`threads: 4` autorise `dbt` à construire quatre modèles en parallèle quand le graphe le permet.

Piège — un `profiles.yml` vide est pire qu'absent. Sans fichier, `dbt` dit clairement qu'il n'a pas trouvé de profil et où il a cherché. Avec un fichier vide, `dbt 1.12.3` s'arrête sur une trace Python et le message `cannot access local variable 'summary_message'`, qui ne dit rien à personne. Si vous créez le fichier maintenant pour le remplir plus tard, vous rencontrerez ce message.

Étape 2 — Le projet `dbt`, à la racine du dépôt

Théorie : `Theorie_03.md`, section 2.

Vous avez déjà un dépôt, `02_ae`, créé au Cours 01. Le projet `dbt` va vivre à sa racine, et non dans un sous-dossier : le dépôt et le projet sont la même chose.

La commande `dbt init` existe, et c'est elle qu'on emploie quand on part de rien : elle crée un dossier et son squelette. Ici elle ne convient pas, pour deux raisons. Elle créerait un dossier dans votre dépôt, alors que vous voulez le projet à la racine. Et le nom d'un projet `dbt` ne peut pas commencer par un chiffre : `dbt init 02_ae` est refusé et vous laisse dans une invite qui redemande un nom, même avec l'option qui saute la configuration du profil.

Écrivez donc `dbt_project.yml` vous-même, à la racine de `02_ae` :

```
name: boreal_ae
version: 1.0.0
profile: boreal_ae

model-paths: ["models"]
macro-paths: ["macros"]
test-paths: ["tests"]
target-path: "target"
clean-targets: ["target", "dbt_packages"]

models:
  boreal_ae:
    staging:
      +materialized: view
      +schema: staging
```

Remarquez la cascade du bloc `models` : le nom du projet, puis le dossier, puis les réglages. Tout ce qui vivra dans `models/staging/` sera une vue, dans le schéma `staging`, sans avoir à le répéter.

Créez les dossiers, puis lancez la vérification :

```
mkdir models\staging
mkdir macros
dbt debug
```

Attendu, quatre lignes qui comptent :

```
Using profiles.yml file at C:\Users\<vous>\.dbt\profiles.yml
Using dbt_project.yml file at ...\Projet_Boreal\02_ae\dbt_project.yml
  profiles.yml file [OK found and valid]
  dbt_project.yml file [OK found and valid]
  Connection test: [OK connection ok]
All checks passed!
```

Si le test de connexion échoue sur un fichier introuvable, c'est le chemin du profil : recopiez-le depuis l'explorateur plutôt que de le retaper.

Étape 3 — La macro des schémas

Théorie : Theorie_03.md, section 5.

Avant d'écrire le moindre modèle, posez la macro qui décide où dbt écrit. Sans elle, vos vues atterriront dans un schéma nommé `staging_staging`, par concaténation du schéma du profil et de celui du dossier.

Dans `macros/generate_schema_name.sql` :

```
{% macro generate_schema_name(custom_schema_name, node) -%}

    {%- if custom_schema_name is none -%}
        {{ target.schema }}
    {%- else -%}
        {{ custom_schema_name | trim }}
    {%- endif -%}

{%- endmacro %}
```

Elle dit à dbt : si un modèle déclare un schéma, prends-le tel quel ; sinon, prends celui du profil. C'est la version que tout projet finit par écrire, et celle que les trois projets de cette formation partagent. Elle ne changera plus jusqu'au capstone.

Notez la forme des commentaires : dans un fichier de Jinja pure comme une macro, un commentaire s'écrit `{# ... #}` et non `--`, parce que dbt évalue ce qui ressemble à du Jinja même dans un commentaire SQL.

Étape 4 — Déclarer les sources

Théorie : Theorie_03.md, section 4.

Dans `models/staging/_sources.yml` :

```
version: 2

sources:
- name: raw
  description: "La couche RAW livrée par Data Engineering, 22 tables."
  schema: raw
  tables:
    - name: erp_kna1
      description: "Le référentiel des concessionnaires, un extrait par mois."
    - name: erp_vbak
      description: "Les en-têtes de commande."
```

Deux tables, et pas une de plus : ce sont celles que les modèles de ce labo vont lire. Déclarer une source qu’aucun modèle n’utilise ajoute une promesse que rien ne vérifie, et vous verrez la règle s’appliquer deux fois de suite. Les articles arrivent avec la question P1 des exercices, qui vous fera déclarer `erp_mara` ; les postes de commande arrivent au Cours 04, avec le fait des ventes.

Le schéma `argent`, qui porte les séries horaires de l’usine, se déclarera au Cours 06, quand l’étoile de l’usine le réclamera.

Étape 5 — Voir ce que dbt connaît

Théorie : Theorie_03.md, section 9.

```
dbt ls
```

Deux lignes sortent, une par source, préfixées de `source :` :

```
source:boreal_ae.raw.erp_kna1
source:boreal_ae.raw.erp_vbak
```

Aucun modèle encore : c’est normal, vous n’en avez pas écrit. dbt le signale d’ailleurs par un avertissement, « Configuration paths exist in your `dbt_project.yml` file which do not apply to any resources », qui vise le bloc `staging` que rien ne remplit. Il disparaîtra à l’étape 6.

Cette commande est celle qu’on lance quand un chiffre surprend, parce qu’elle dit exactement ce que dbt connaît, dans l’ordre où il le connaît. Retenez-la.

Étape 6 — La première vue de staging

Théorie : Theorie_03.md, section 6.

Dans `models/staging/stg_concessionnaires.sql` :

```
with courant as (

    select
        *,
        row_number() over (
            partition by kunnr
            order by _lot desc
        ) as rang

    from {{ source('raw', 'erp_kna1') }}
```

)

```
select
  kunnr as code_concessionnaire,
  name1 as nom_concessionnaire,
  ort01 as ville,
  regio as province,
  case kukla
    when '01' then 'Or'
    when '02' then 'Argent'
    when '03' then 'Bronze'
  end as palier,
  try_strptime(erdat, '%Y%m%d')::date as date_creation,
  loevm = 'X' as est_supprime,
  _lot as lot_source

from courant
where rang = 1
```

Les quatre gestes du staging y sont, et rien d'autre. Renommer, dans le select. Typier, par try_strptime et par la comparaison qui rend un booléen. Décoder, par le case. Tirer l'état courant, par la fonction de fenêtre et le where rang = 1.

Aucune jointure, et c'est la règle.

Construisez :

```
dbt run
```

Puis vérifiez dans la ligne de commande DuckDB, après avoir laissé dbt finir :

```
select
  count(*) as concessionnaires,
  count(*) filter (where palier is null) as paliers_vides,
  count(*) filter (where est_supprime) as fiches_fermees
from staging.stg_concessionnaires;
```

Attendu : 156 concessionnaires, 0 palier vide, 4 fiches fermées. La deuxième colonne est le contrôle du décodage, celui du Cours 02 : un case qui ne trouve rien rend NULL en silence.

Remarquez le nom du schéma : staging, et non staging_staging. C'est la macro de l'étape 3 qui l'a rendu nu.

Étape 7 — La vue qui retrouve les 25 483 commandes

Théorie : Theorie_03.md, sections 6 et 7.

Dans models/staging/stg_commandes.sql :

```
with courant as (  
    select  
        *,  
        row_number() over (  
            partition by vbeln  
            order by _lot desc  
        ) as rang  
    from {{ source('raw', 'erp_vbak') }}  
  
)  
  
select  
    vbeln as numero_commande,  
    kunnr as code_concessionnaire,  
    auart as type_document,  
    try_strptime(erdat, '%Y%m%d')::date as date_creation,  
    try_strptime(nullif(aedat, '00000000'), '%Y%m%d')::date as date_modification,  
    netwr::decimal(18, 2) as valeur_nette,  
    waerk as devise,  
    _lot as lot_source  
  
from courant  
where rang = 1
```

Deux détails valent le détour. Le nullif traite la date vide de SAP comme une absence, sans quoi try_strptime rendrait NULL de toute façon, mais pour une mauvaise raison : on veut dire « pas de modification », pas « conversion ratée ». Et netwr se type en decimal, jamais en double : un montant se compte au cent près.

```
dbt run
```

Puis la vérification qui est le but du cours :

```
select  
    (select count(*) from raw.erp_vbak) as lignes_dans_la_raw,
```

```
(select count(*) from staging.stg_commandes) as commandes_dans_le_staging,
(select count(*) from staging.stg_commandes where date_modification is not null) as commandes_modifiees;
```

Mesure	Attendu
Lignes dans la RAW	26 538
Commandes dans le STAGING	25 483
Commandes portant une date de modification	2 231

Les 1 055 lignes en trop de la RAW ont disparu, et aucune commande n’a été perdue. C’est le quatrième geste du staging, celui qu’on oublie, et vous venez de le faire tenir en six lignes de SQL.

Étape 8 — Relier deux modèles, et voir le graphe

Théorie : Theorie_03.md, section 9.

Un dernier modèle, qui ne sert à rien d’autre qu’à vérifier une promesse : toute commande doit pointer un concessionnaire connu.

Dans `models/staging/ctl_commandes_sans_concessionnaire.sql` :

```
select
  c.numero_commande,
  c.code_concessionnaire,
  c.date_creation

from {{ ref('stg_commandes') }} as c
left join {{ ref('stg_concessionnaires') }} as d
  on d.code_concessionnaire = c.code_concessionnaire

where d.code_concessionnaire is null
```

Remarquez que ce modèle joint, alors que la règle du staging l’interdit. C’est qu’il n’est pas un modèle de staging au sens de la couche : c’est un contrôle, et son préfixe `ctl_` le dit. Il ne sera consommé par personne.

```
dbt run
dbt ls
```

`dbt ls` liste maintenant trois modèles et deux sources. L’ordre d’exécution vous l’a déjà montré : `dbt` a construit les deux vues de staging avant le contrôle, parce que `ref()` lui a dit qu’il en dépendait. Vous ne le lui avez dit nulle part ailleurs.

La vérification :

```
select count(*) as commandes_sans_concessionnaire
from stagingctl_commandes_sans_concessionnaire;
```

Attendu : 0.

Ce zéro mérite qu’on s’y arrête, parce qu’il est le produit d’un choix. Un concessionnaire de Boréal a passé une commande avant que sa fiche n’arrive : la commande est livrée au lot de mai 2024, sa première fiche au lot de juin. À l’époque, cette commande était orpheline. En tirant l’état courant, vous avez regardé le référentiel d’aujourd’hui, où la fiche existe, et le problème a disparu.

Vérifiez-le par vous-même :

```
select
  (select count(*) from raw.erp_kna1 where kunnr = '0000200154' and _lot = '2024-05') as fiche_en_mai,
  (select min(_lot) from raw.erp_kna1 where kunnr = '0000200154') as premiere_fiche,
  (select _lot from raw.erp_vbak where vbeln = '0010015405') as lot_de_la_commande;
```

Attendu : 0 fiche en mai, première fiche au lot 2024-06, commande livrée au lot 2024-05.

Au Cours 05, quand la dimension passera en type 2 et que le fait pointer la version d’époque, la même question donnera une autre réponse. Les deux seront justes, et il faudra savoir laquelle on pose.

Récapitulatif

L’état du projet à la fin du labo :

Ce qui est en place	Vérification
Le projet dbt dans 02_ae	dbt debug rend « All checks passed! »
Les schémas nus	les vues vivent dans staging, pas staging_staging
Deux sources déclarées	dbt ls les liste, préfixées de source :
Trois modèles	dbt run rend PASS=3 WARN=0 ERROR=0
Le staging des concessionnaires	156 lignes, 0 palier vide, 4 fiches fermées
Le staging des commandes	25 483 lignes, contre 26 538 dans la source

Ce qui est en place	Vérification
Le contrôle	0 commande sans concessionnaire

Le Cours 04 ouvre la couche des MARTS et bâtit la première étoile, celle que le Cours 02 a conçue. Le prototype que vous aviez écrit à la main y renaîtra, mais versionné, testé et rejouable.

Pensez à commiter : c'est la première fois que votre dépôt porte du travail.

```
git add dbt_project.yml macros models
git commit -m "Cours 03 : le projet dbt et la couche staging"
```

Dépannage

Le message	Ce qu'il veut dire	La parade
cannot access local variable 'summary_message'	profiles.yml existe mais est vide	le remplir, ou le supprimer pour obtenir un vrai message
profiles.yml file [ERROR invalid], puis « Connection test skipped since no profile was found »	le nom du profil diffère entre les deux fichiers	comparer la première ligne de profiles.yml et la clé profile du projet ; le message ne nomme ni l'un ni l'autre
IO Error: Cannot open file ... Le chemin d'accès spécifié est introuvable	chemin relatif dans profiles.yml, ou faute de frappe	écrire un chemin absolu, avec des barres obliques
IO Error: ... utilisé par un autre processus	la ligne de commande DuckDB est restée ouverte	la fermer par .exit avant de lancer dbt
Les vues atterrissent dans staging_staging	la macro generate_schema_name manque ou n'est pas dans macros/	vérifier l'étape 3, puis relancer dbt run
Compilation Error ... depends on a source named 'raw.xxx' which was not found	un modèle lit une source non déclarée	l'ajouter à _sources.yml
dbt init demande un nom alors qu'on lui en a donné un	le nom commence par un chiffre	ce labo n'utilise pas dbt init ; écrire dbt_project.yml à la main