

Table des matières

Exercices 04 — Bâtir l'étoile des ventes	1
Questions courtes	1
Questions pratiques	2
Diagnostics	3
Questions à développer	4
Mises en situation	4

Exercices 04 — Bâtir l'étoile des ventes

Comment travailler ces exercices. Répondez seul, puis vérifiez avec le corrigé. Les exercices marqués [labo] portent sur ce que vous venez de faire au labo ; les autres vérifient que le cours est clair dans votre tête. Tout vient de la Théorie 04 et du Labo 04.

Le corrigé est dans `Corrige_04.md`. Répondez à l'énoncé en entier avant de l'ouvrir : c'est en butant sur une question qu'on découvre ce qu'on avait lu sans le comprendre.

Questions courtes

1. La vue et la table. Nommez les quatre choses qui séparent une vue de staging d'une table de la couche MARTS.
2. Trois fichiers. Dites ce que portent `packages.yml`, `package-lock.yml` et `dbt_packages/`, et lesquels se versionnent.
3. La fourchette. Expliquez ce que déclare `[ ">=1.0.0", "<2.0.0" ]`, et ce qu'on refuse en l'écrivant ainsi.
4. [labo] Le paquet oublié. Dites ce que fait `dbt` quand `packages.yml` déclare un paquet que personne n'a installé.
5. Les deux macros. Nommez les deux macros de `dbt_utils` employées dans ce cours, et ce que chacune fabrique.
6. La clé compilée. Sur une colonne qui n'est jamais vide, dites à quoi `generate_surrogate_key` se réduit une fois compilée.
7. Trois propriétés. Nommez les trois propriétés de la clé de substitution fabriquée par hachage, et celle qui change la façon d'écrire un fait.
8. Le prix de la clé recalculée. Le fait ne joint pas les dimensions pour retrouver leurs clés. Dites ce qu'on perd, et où ce trou se rebouche.
9. L'ordre des colonnes. Expliquez pourquoi une clé fabriquée sur deux colonnes n'est pas la même selon l'ordre où on les donne.

10. La valeur vide. Dites ce que la macro met à la place d'une valeur vide, et la conséquence quand deux lignes ont la même clé naturelle vide.
 11. `date_spine`. Dites ce que la macro produit, le nom de la colonne qu'elle rend, et le traitement qu'elle réserve à la borne de fin.
 12. La dimension plus longue que les faits. `dim_date` va jusqu'au 31 mars 2026 alors que les ventes s'arrêtent au 31 décembre 2025. Donnez les deux raisons.
 13. La clé de `dim_date`. Dites pourquoi elle n'est pas un hachage, contrairement aux deux autres dimensions.
 14. Les mois en anglais. Dites ce que rendent `strftime(date, '%B')` et `dayname()` sous DuckDB, et la parade retenue par la formation.
 15. Ce qu'une dimension ajoute. Le modèle de `dim_concessionnaire` est court. Dites ce qu'il ajoute à la vue de staging dont il part, et pourquoi il n'a pas à faire plus.
 16. Le type 1. Dites ce qu'une dimension de type 1 garde, ce qu'elle perd, et le chiffre qui mesure la perte chez Boréal.
 17. La couche du milieu. Dites ce qu'on range dans `INTERMEDIATE`, et la raison qui le justifie.
 18. Un fait mince. Définissez l'expression, et dites ce qu'elle change pour qui relit le modèle.
 19. `ephemeral`. Dites ce que dbt écrit dans la base, ce qu'il liste quand même, et ce qu'on ne peut plus faire avec un tel modèle.
 20. La marge et son taux. Dites lequel des deux se stocke dans un fait, lequel ne s'y stocke jamais, et la règle qui tranche.
 21. Trois familles. Nommez les trois familles de colonnes d'un fait, avec un exemple de chacune dans `fct_ventes`.
1. [labo] Le témoin. Dites ce qui fait de la valeur nette des en-têtes de commande un témoin valable pour contrôler le fait, et pourquoi la somme des postes n'en serait pas un.
-

Questions pratiques

- P1. [labo] Le contrôle du grain. Écrivez la requête qui vérifie le grain de `fct_ventes`, donnez le résultat attendu, et dites ce qu'un écart signifierait.
- P2. [labo] La réconciliation. Écrivez la requête qui compare la valeur nette du fait à celle des en-têtes de commande et rend l'écart. Donnez les trois valeurs attendues.
- P3. Les jours sans vente. Écrivez la requête qui compte, sur les années 2022 à 2025, les jours de `dim_date` qu'aucune ligne de `fct_ventes` ne touche, en distinguant les fins de semaine. Donnez les résultats et dites ce qu'ils confirment.
- P4. La marge par gamme. Écrivez la requête qui donne, par gamme, le nombre de lignes, la valeur nette et la marge. Donnez le résultat.

P5. Recalculer une clé. Écrivez la requête qui prouve que `cle_concessionnaire` est bien le md5 du code du concessionnaire, sans passer par dbt. Donnez l'attendu.

P6. Voir ce que dbt envoie. Donnez la commande qui produit le SQL réellement exécuté pour `fct_ventes`, dites où le fichier atterrit, et nommez les deux mécanismes du cours qu'on y voit à l'œil nu.

P7. Le lignage du fait. Donnez la commande qui liste tout ce dont `fct_ventes` dépend, sources comprises, et le résultat attendu. Dites ce qui vous surprend dans cette liste.

P8. (avancé) Le libellé de la province. `dim_concessionnaire` porte le code de la province, QC, et non son nom. Le libellé vit dans `raw.erp_t005u`, une ligne par province et par langue. Écrivez la vue de staging qui le rend lisible, branchez-la sur la dimension, et donnez les contrôles que vous lancez ensuite.

Diagnostics

E1. La clé qui ne joint rien. Un collègue écrit le fait ainsi :

```
select
  date_commande as cle_date,
  {{ dbt_utils.generate_surrogate_key(['code_concessionnaire', 'numero_commande']) }}
  as cle_concessionnaire,
  ...
```

`dbt run` passe, le fait se construit, ses 75 652 lignes sont là. Dites ce qui ne va pas, ce que rend une jointure du fait vers `dim_concessionnaire`, et pourquoi rien n'a signalé le problème.

E2. Le taux qui se moyenne. Un collègue ajoute une colonne `taux_marge` au fait, calculée ligne à ligne, en expliquant que « ça évitera de le recalculer partout ». Un rapport affiche ensuite la moyenne de cette colonne. Dites ce que le rapport annonce, ce qu'il aurait dû annoncer, et d'où vient l'écart.

E3. Le `left join` prudent. Un collègue remplace la jointure interne de `int_lignes_enrichies` par un `left join` vers les commandes, « pour ne perdre aucun poste ». Le fait garde exactement le même nombre de lignes, et tous les contrôles passent. Dites pourquoi, et ce qui arriverait le jour où un poste n'aurait pas d'en-tête.

E4. Le jour qui manque. Un collègue écrit `end_date="cast('2026-03-31' as date)"` dans `dim_date`, en se disant que la période finit le 31 mars. Dites ce qu'il obtient, et le genre de symptôme que ce défaut produit plus tard.

E5. Le modèle qui ne se reconstruit pas. Un collègue corrige le calcul de la marge dans `int_lignes_enrichies`, lance `dbt run --select int_lignes_enrichies`, lit « Finished running » sans erreur, puis constate que `fct_ventes` porte toujours l'ancienne marge. Dites ce qui s'est passé et la commande à lancer.

Questions à développer

- A. Recalculer ou joindre. Pour retrouver la clé d'une dimension dans un fait, deux écoles : la recalculer par la même macro, ou joindre la dimension et lire sa clé. Défendez les deux, dites laquelle ce cours a retenue et pourquoi, et nommez la condition sans laquelle le choix retenu devient dangereux.
- B. Ce qu'une livraison doit dire. Le `LIVRAISON.md` du labo se termine par une phrase sur ce que l'étoile ne contient pas encore. Expliquez pourquoi cette phrase vaut plus que les quatre lignes du tableau qui la précèdent, et ce qui arrive quand elle manque.
- C. (avancé) Livrer une dimension de type 1. Chez Boréal, 35,5 pour cent de la valeur vendue avant le 1er juillet 2024 est attribuée à un palier que le concessionnaire n'avait pas à l'époque. On vous demande si l'étoile peut être livrée dans cet état. Répondez, en donnant les conditions que vous posez et ce que vous écrivez noir sur blanc.
-

Mises en situation

- M1. Microbrasserie de Trois-Pistoles. La microbrasserie vend des fûts aux bars et des canettes aux épiceries. Son logiciel de facturation exporte deux fichiers, les factures et leurs lignes, avec un code de produit, un code de client et un montant. On vous demande la première étoile. Dites le grain que vous déclarez et pourquoi, les dimensions que vous montez en premier, et le témoin indépendant que vous cherchez avant de livrer quoi que ce soit.
- M2. (avancé) Coopérative forestière de Chibougamau. La coopérative change de logiciel de gestion. Le nouveau système renumérote tous les membres : le membre M-0042 devient 4711003. On vous demande de reprendre l'étoile existante, dont le fait porte des clés de substitution fabriquées par hachage du numéro de membre. Dites ce qui casse, ce qui tient, et la marche à suivre pour que l'historique reste interrogeable.
- M3. Traiteur de Baie-Saint-Paul. Le contrôleur vous dit que le chiffre d'affaires de votre étoile diffère de celui de la comptabilité, de 1,4 pour cent, et que l'écart n'est pas le même tous les mois. Personne ne sait d'où il vient. Décrivez votre démarche pour le trouver, dans l'ordre, et ce que vous ferez du résultat selon les deux issues possibles.