

Table des matières

Exercices 05 — Fiabiliser l'étoile : tests, snapshots, documentation	1
Questions courtes	1
Questions pratiques	2
Diagnostics	3
Questions à développer	4
Mises en situation	4

Exercices 05 — Fiabiliser l'étoile : tests, snapshots, documentation

Comment travailler ces exercices. Répondez seul, puis vérifiez avec le corrigé. Les exercices marqués [labo] portent sur ce que vous venez de faire au labo ; les autres vérifient que le cours est clair dans votre tête. Tout vient de la Théorie 05 et du Labo 05.

Le corrigé est dans `Corrige_05.md`. Répondez à l'énoncé en entier avant de l'ouvrir : c'est en butant sur une question qu'on découvre ce qu'on avait lu sans le comprendre.

Questions courtes

1. La définition. Dites ce qu'est un test dbt, en une phrase, et nommez deux choses qu'il n'est pas.
2. Les trois sortes. Nommez les trois sortes de tests de dbt, et dites où chacune se déclare.
3. Le nom du bloc. Donnez le nom du bloc qui porte les tests dans un fichier YAML, et dites ce que l'ancien nom produit aujourd'hui.
4. Les quatre génériques. Nommez les quatre tests génériques livrés avec dbt, et dites sur quoi le cours pose chacun chez Boréal.
5. [labo] Le test qui ment. Dites lequel des quatre passe au vert sur un décodage entièrement raté, pourquoi, le compte que vous avez vu sortir, et la parade.
6. Le trou rebouché. Dites ce que `relationships` garantit, et quel choix du Cours 04 le rend obligatoire plutôt que facultatif.
7. Le grain, une fois pour toutes. Nommez le test de `dbt_utils` qui vérifie le grain d'un fait, et dites ce qu'il remplace.
8. Le test singulier. Dites où vit un test singulier, ce que dbt attend de sa requête, et pourquoi la réconciliation de Boréal ne peut pas être un test générique.

9. [labo] La jointure aveugle. Dites ce qu'une jointure interne ne voit pas dans une réconciliation, donnez les deux comptes que vous avez mesurés sur le fait amputé, et nommez les trois cas qu'une réconciliation doit sortir.
 10. Les trois réglages. Nommez les trois réglages qui changent le comportement d'un test qui échoue, et dites ce que chacun fait.
 11. [labo] Le seuil. Donnez la valeur du seuil posé sur `annee_model`, la raison de cette valeur, et dites ce qu'un seuil documente qu'un test retiré ne documente pas.
 12. Le test unitaire. Nommez ses trois parties, dites ce qu'il attrape qu'aucun test de données n'attrape, et ce qui arrive aux colonnes que `expect` ne cite pas.
 13. Le modèle invisible. Dites pourquoi un test unitaire échoue quand une de ses entrées est un modèle `ephemeral`, et donnez la parade.
 14. Le snapshot. Dites ce que `dbt snapshot` fait à chaque `dbt snapshot`, nommez les quatre colonnes qu'il pose, et dites ce que chacune porte.
 15. Les deux stratégies. Nommez les deux stratégies de détection d'un changement, dites celle que Boréal emploie, et pourquoi.
 16. [labo] La date des versions. Dites ce que `dbt` fait sans la configuration `updated_at`, ce qu'il fait avec, et pourquoi le cas de Boréal impose la seconde.
 17. La table et la vue. Dites en quoi un snapshot diffère d'un modèle ordinaire quant au moment où il change, et donnez la conséquence que le labo vous a fait constater sur un staging cassé.
 18. La fréquence. Chez Boréal, la révision des paliers a eu lieu le 1er juillet 2024 et le snapshot la date du 31. Dites pourquoi, ce que cela change pour les ventes du mois, et le montant.
 19. Les trois décisions du type 2. Dites sur quoi se hache la clé d'une dimension de type 2, ce qu'on fait des colonnes qu'on ne suit pas, et à quelle date s'ouvre la première version de chaque entité.
1. La jointure temporelle. Donnez la forme de l'intervalle, et dites ce que chacun des deux contrôles du Cours 04 attrape quand elle est fausse.
 2. Ce qui change et ce qui ne change pas. Dites ce que l'historisation change dans l'étoile, ce qu'elle ne change pas, et donnez le chiffre que le labo a mesuré chez Boréal.
 3. La documentation. Nommez les trois fichiers que `dbt docs generate` produit, dites ce que chacun porte, et nommez les deux usages du `manifest.json` dans la suite du parcours.
 4. L'exposure et le `rpt_`. Dites ce qu'un `exposure` déclare et qui doit en être le propriétaire, puis nommez les trois choses qu'un modèle `rpt_*` a le droit de faire.
-

Questions pratiques

- P1. [labo] Tester une dimension qui a changé de forme. La dimension du concessionnaire porte maintenant une ligne par version. Dites ce qu'un unique posé sur `code_concessionnaire` rendrait, donnez le compte, et écrivez le test qui vérifie réellement le grain de cette dimension.
- P2. [labo] La réconciliation. Écrivez le test singulier qui compare la valeur nette du fait à celle des en-têtes de commande. Dites ce que chacune de ses trois particularités règle, et donnez le résultat attendu.
- P3. Le coût du type 1, mesuré après coup. Maintenant que la dimension porte l'histoire, écrivez la requête qui compte les lignes de vente dont le palier d'époque diffère du palier d'aujourd'hui, avec leur valeur, année par année. Donnez le résultat et dites ce que la dernière année vous apprend.
- P4. Un test de plus. La dimension ne doit ni laisser de trou ni faire chevaucher deux versions d'un même concessionnaire. Écrivez le test singulier qui le vérifie, donnez l'attendu, et dites ce que les tests déjà en place feraient de ces deux défauts.
- P5. (avancé) Le test unitaire du plancher. Écrivez le test unitaire qui vérifie que la première version d'un concessionnaire s'ouvre au plancher et la seconde à sa vraie date. Dites combien d'entrées il faut donner et pourquoi, et ce que dbt répond quand on en oublie une.
- P6. Ce que je casse, et d'où ça vient. Donnez la commande qui liste tout ce qui dépend de `dim_concessionnaire`, et celle qui liste tout ce dont le tableau de bord des ventes dépend. Donnez les deux comptes, et dites à quelle question chacune répond.
- P7. Le taux de marge par palier. Depuis le résumé de la couche `PRESENTATION`, écrivez la requête qui donne le taux de marge par palier pour 2025. Donnez le résultat, puis celui qu'on obtient en moyennant les taux mensuels, et dites lequel est juste.
- P8. (avancé) Rejouer les quarante-neuf lots. Le labo n'en rejoue que quatre. Dites comment rejouer les 49, ce que cela change dans le snapshot, ce que cela change dans l'étoile finale, et ce que cela coûte.
-

Diagnostics

- E1. L'histoire datée d'aujourd'hui. Un collègue reprend le snapshot et retire la ligne `updated_at='date_extrait'`, en expliquant que dbt sait bien dater ses versions tout seul. Il rejoue les quatre lots, reconstruit l'étoile, et tout passe au vert : 35 tests, réconciliation à 0,00 \$ d'écart. Dites ce que porte le snapshot, ce que le tableau des ventes 2025 par palier annonce désormais, et pourquoi aucun test ne l'a vu.
- E2. Le lot rejoué trop tard. Un collègue construit le projet par un `dbt build` complet, sans exclure le snapshot, avant d'avoir rejoué le moindre lot. Puis il suit le labo et lance `dbt snapshot --vars "{lot: 2024-06}"`. Dites ce que le snapshot contient ensuite, donnez les comptes, et dites ce qui, dans la mécanique de la stratégie `check`, produit ce résultat.
- E3. Les lignes qui manquent, puis celles qui restent. Un collègue écrit la jointure temporelle avec l'intervalle semi-ouvert, mais sans le plancher de la première version. Il lance `dbt build --exclude snp_concessionnaire` : un seul test tombe. Il remplace alors la jointure interne par un `left join`, « pour ne plus perdre de lignes », et relance. Dites ce qui tombe dans chacun des deux cas, avec les comptes, et dites ce que l'histoire enseigne sur la complémentarité des tests.

E4. Le rouge qu'on met en jaune. Un collègue, pressé de livrer, met la réconciliation en `severity: warn` « le temps de trouver d'où vient l'écart ». Le pipeline de nuit tourne depuis trois semaines. Dites ce que dbt affiche, ce que l'ordonnanceur en conclut, et ce qu'il aurait fallu faire à la place.

E5. La dimension qui triple. Un collègue trouve le snapshot trop avare et ajoute `date_extrait` aux colonnes suivies, « pour garder la trace de chaque extrait ». Il rejoue les quatre lots et reconstruit. Tous les tests passent, le chiffre d'affaires par palier est inchangé au cent près. Donnez le nombre de versions, dites ce qui s'est passé, et dites où le défaut se voit puisque aucun test ne le signale.

Questions à développer

A. Combien de tests est-ce assez. On vous reproche vingt-quatre tests sur douze modèles, « du temps passé à tester des évidences ». Défendez le nombre, dites ce qui distingue un test qui gagne sa place d'un test qui remplit un tableau de bord de qualité, et nommez ce que vos tests actuels ne vérifient toujours pas.

B. Type 1 ou type 2. On vous demande d'historiser toutes les colonnes de toutes les dimensions, « parce qu'on ne sait jamais ». Défendez la position inverse, dites ce qui décide qu'une colonne mérite d'être suivie, et ce que vous écrivez pour que le choix reste défendable dans deux ans.

C. (avancé) Le jour où les clés changent. Le passage en type 2 a refait toutes les clés de `dim_concessionnaire`. Dites ce que cela casse chez ceux qui consomment déjà l'étoile, ce qui ne casse pas, et la façon de mener ce changement pour qu'il ne se découvre pas un lundi matin dans un rapport vide.

Mises en situation

M1. Distribution alimentaire de Saint-Raymond. L'entreprise a une étoile des ventes bâtie l'an dernier par un consultant, qui tourne tous les soirs et qu'aucun test ne couvre. On vous donne une journée pour la rendre défendable. Dites les tests que vous posez en premier et dans quel ordre, celui que vous ne poserez pas tout de suite, et ce que vous rendez à la fin de la journée.

M2. (avancé) Réseau de garderies de Deschambault. Le logiciel de gestion écrase la subvention applicable à chaque installation : la fiche dit le taux d'aujourd'hui, et personne ne sait ce qu'elle disait l'an dernier. Le ministère demande un rapport des trois dernières années par taux de subvention. Dites ce que vous pouvez livrer, ce que vous ne pouvez pas, ce que vous mettez en place pour que la question ne se repose pas, et à partir de quand le rapport sera juste.

M3. Transport scolaire de Yamachiche. Le coût par kilomètre existe à trois endroits : dans un modèle dbt, dans une mesure du tableau de bord, et dans un chiffrier que le directeur tient à jour. Les trois donnent des valeurs différentes, et chacun défend la sienne. Décrivez votre démarche, dites où ce calcul doit vivre selon la règle du cours, et ce que vous faites des deux autres.