

Table des matières

Exercices corrigés 06 — Les faits que la vente ne montre pas	1
Questions courtes	1
Questions pratiques	2
Diagnostics	3
Questions à développer	4
Mises en situation	4
Corrigé	5

Exercices corrigés 06 — Les faits que la vente ne montre pas

Comment travailler ces exercices. Répondez seul, puis vérifiez avec le corrigé. Les exercices marqués [labo] portent sur ce que vous venez de faire au labo ; les autres vérifient que le cours est clair dans votre tête. Tout vient de la Théorie 06 et du Labo 06, les deux étoiles comprises.

Le corrigé suit les énoncés, en fin de document. Répondez à l'énoncé en entier avant d'y passer : c'est en butant sur une question qu'on découvre ce qu'on avait lu sans le comprendre.

Questions courtes

1. Les quatre formes. Nommez les quatre types de faits, et dites à quelle question chacun répond.
2. Ce qui arrive à une ligne. Pour chacun des quatre types, dites ce que devient une ligne déjà écrite quand la source change.
3. Reconnaître le bon type. On vous décrit un processus : une demande de permis est déposée, étudiée, puis accordée ou rejetée, et chaque étape est datée. Dites quel type de fait vous choisissez, et ce qui aurait changé si la source livrait une ligne par changement d'état.
4. Les jalons. Dites ce qu'est un jalon dans un fait d'accumulation, ce qu'un jalon vide signifie, et donnez les quatre jalons de la réclamation chez Boréal.
5. Les durées. Dites où se calculent les durées entre jalons, pourquoi à cet endroit, et ce qu'elles valent tant que le jalon d'arrivée n'est pas atteint.
6. [labo] Trois comportements. Donnez, pour chacune des trois sources de l'après-vente, le nombre de lignes livrées, le nombre d'objets distincts, et ce que l'écart veut dire.
7. L'ordre des deux gestes. Dites dans quel ordre se font la déduplication et le dépliage de l'historique, et ce que l'ordre inverse produit.

8. Le pivot. Nommez les trois mécanismes SQL qui font passer d'une liste d'étapes à une colonne par jalon, et dites ce que chacun fait.
 9. Une dimension conforme. Définissez-la, et dites ce qu'elle rend possible qu'une étoile isolée ne sait pas faire.
 10. [labo] Le forage transversal. Donnez le taux de réclamation par gamme mesuré au labo, et dites pourquoi aucun des deux faits ne pouvait le donner seul.
 11. La date d'époque. Dites quelle date choisit la version d'un concessionnaire dans chacun des trois faits qui le citent, et pourquoi ce choix n'est pas technique.
 12. Les mesures qui ne sont pas des montants. Nommez les deux mesures de `fct_enregistrements`, et dites ce qu'on peut faire de chacune.
 13. La dimension des clients. Dites ce que la dimension porte, ce qu'elle laisse à la source, et la question à se poser devant chaque colonne.
 14. [labo] Le témoin de l'après-vente. Dites pourquoi ce fait n'a pas de total à réconcilier, quelle règle le remplace, et donnez les trois comptes qui la vérifient.
 15. L'instantané périodique. Dites ce que son grain garantit, et donnez les deux chiffres qui le montrent chez Boréal.
 16. La couverture. Dites ce qu'elle distingue, et donnez la répartition mesurée sur les 22 090 lignes.
 17. Semi-additive. Définissez le terme, puis classez les trois mesures de l'instantané de Boréal.
 18. [labo] La moyenne qui dilue. Donnez les deux séries de chiffres de la vibration du compresseur 2 entre le 14 et le 28 octobre, et dites ce que la comparaison enseigne.
 19. Le fait sans mesure. Dites ce qu'il porte, et écarter les deux fausses bonnes idées que la théorie nomme.
 20. Le grain de l'événement. Dites pourquoi le grain de `fct_production` est l'assemblage et non le véhicule, et ce que cela change si un véhicule était réassemblé.
 21. Deux niveaux, une dimension. Dites pourquoi les zones et les équipements vivent dans la même dimension, et ce que deux dimensions séparées casseraient.
 22. [labo] Le témoin de l'usine. Nommez les deux systèmes qu'il oppose, dites pourquoi ils sont indépendants, et donnez le compte.
 23. [labo] L'instant et le jour. Dites pourquoi la clé de date de l'instantané se calcule par une conversion écrite, et donnez le chiffre qui le justifie.
 24. [labo] La matrice dans le graphe. Dites ce que `dbt ls --select dim_vehicule+` rend, ce qu'il ne rend pas, et ce que cela apprend sur la matrice de bus.
-

Questions pratiques

- P1. [labo] L'entonnoir. Écrivez la requête qui compte, sur `fct_reclamations`, les dossiers à chaque jalon et ceux qui attendent une décision ou un paiement. Donnez le résultat et dites ce que la dernière colonne apprend au service des garanties.
- P2. Le délai par cause. Écrivez la requête qui donne, par cause, le nombre de dossiers, le délai moyen de décision, le délai moyen de clôture et le montant moyen. Donnez le résultat, et dites ce qui varie et ce qui ne varie pas.
- P3. [labo] Le témoin de la couverture. Écrivez le test singulier qui vérifie qu'une réclamation ouverte hors garantie est refusée pour ce motif, et dites ce qu'un échec signifierait.
- P4. (avancé) La complétude de l'instantané. Un instantané promet une ligne par sujet et par période. Écrivez le test singulier qui vérifie qu'aucun couple ne manque, sans écrire les comptes en dur, et dites ce qu'il attraperait.
- P5. La disponibilité mensuelle. Écrivez la requête qui donne, mois par mois, les heures de marche des trois convoyeurs. Donnez le résultat et expliquez la ligne des motomarines.
- P6. Les véhicules jamais vendus. Écrivez la requête qui compte les véhicules assemblés, expédiés, vendus au détail, et ceux qu'aucun enregistrement ne réclame. Donnez le résultat et deux explications possibles.
- P7. La cadence. Écrivez la requête qui rapproche, jour par jour, la production de la ligne des motoneiges et les heures de marche de son convoyeur. Donnez le nombre de jours arrêtés, la cadence moyenne, et dites ce qu'une incohérence signifierait.
- P8. (avancé) Le fil de l'incident. Écrivez la requête unique qui part de la fenêtre de la dérive et rend, pour les motoneiges assemblées pendant cette fenêtre, le nombre d'exemplaires, de ventes au détail et de réclamations. Donnez le résultat et dites ce qu'il permet de conclure.
-

Diagnostics

- E1. Le dépliage trop pressé. Un collègue écrit l'intermédiaire des jalons directement sur `raw.garanties_reclamations`, sans passer par le staging. Le fait des réclamations garde ses 3 348 lignes, ses dates sont justes, tous les tests passent. Dites ce qui est faux, donnez les deux comptes, et dites pourquoi les dates, elles, ont survécu.
- E2. Le test de trop. Un collègue trouve suspect que `cle_date_paiement` n'ait pas de `not_null` alors que toutes les autres clés en ont un, et l'ajoute. `dbt build` échoue. Dites sur combien de lignes, dites qui a raison, et donnez la règle générale.
- E3. La mauvaise date d'époque. Un collègue joint `fct_enregistrements` à `dim_concessionnaire` sur la date d'enregistrement plutôt que sur la date de vente, en expliquant que c'est la date où la ligne entre dans le système. Le fait garde ses 26 732 lignes et tous les tests passent. Dites combien de ventes changent de version, montrez-en deux, et dites comment on attrape ce genre d'erreur.

E4. La somme qui ne veut rien dire. Un collègue publie un tableau de bord qui annonce « 30 600 kW consommés par le compresseur 1 au dernier trimestre », en additionnant `puissance_moyenne_kw`. Dites ce que ce nombre est vraiment, ce qu'il aurait fallu calculer, et ce que la colonne aurait dû s'appeler pour éviter la faute.

E5. Le fuseau du poste. Un collègue reprend le projet sur un serveur réglé en UTC et lance `dbt build`. Tous les tests passent, y compris le témoin du compteur. Le tableau de bord de la disponibilité, lui, ne donne plus les mêmes journées. Dites pourquoi, donnez le nombre d'heures concernées, et dites ce qui, dans le modèle, aurait dû empêcher cela.

Questions à développer

A. Le fait d'accumulation et son prix. Un fait d'accumulation se met à jour, ce qui interdit de se contenter d'ajouter les lignes neuves à chaque exécution. Expliquez ce que cela coûte quand le volume grossit, nommez les deux stratégies possibles, et dites ce que vous feriez chez Boréal avec 3 348 dossiers, puis avec trois millions.

B. La période d'un instantané. Boréal livre une série horaire, et l'étoile la reprend telle quelle. Défendez ce choix, dites ce que coûterait la minute et ce que perdrait le jour, et nommez ce qui décide vraiment de la période.

C. (avancé) Ce qu'on annonce quand on n'a rien prouvé. Le directeur de la qualité vous demande si les 240 motoneiges assemblées pendant la dérive du compresseur ont un problème. Vos chiffres disent 5 réclamations sur 201 véhicules vendus, contre 3,3 pour cent chez les autres motoneiges de l'année-modèle. Rédigez ce que vous lui répondez, dites ce que vous mettez en place, et dites ce que vous ne dites surtout pas.

Mises en situation

M1. Atelier de carrosserie de Nicolet. L'atelier veut savoir où ses dossiers de réparation s'enlisent : l'estimation, l'accord de l'assureur, la commande des pièces, la réparation, la livraison. Son logiciel garde une ligne par dossier, écrasée à chaque changement, avec la date de la dernière modification et le statut courant. Dites ce que vous pouvez livrer aujourd'hui, ce que vous ne pouvez pas, et ce que vous mettez en place dès la première semaine.

M2. (avancé) Fromagerie de Plessisville. La fromagerie veut relier ses lots de production à ses plaintes clients. Les lots sont dans un fichier de l'atelier, les plaintes dans le courriel du service à la clientèle, et rien ne relie les deux sauf le code de lot imprimé sur l'emballage, que le client cite une fois sur trois. Dites comment vous montez ces deux étoiles, ce que vous faites des deux tiers de plaintes sans code de lot, et ce que vous promettez au directeur.

M3. Scierie de Coaticook. La scierie a un historien qui enregistre l'état de ses quatre lignes de sciage, et une production comptée à la fin de chaque quart par un contremaître sur une feuille papier saisie le lendemain. On vous demande un tableau de bord de rendement. Dites quelles formes de faits vous montez, quel témoin vous cherchez, et ce que vous faites du décalage d'une journée entre les deux sources.

Corrigé

Comment lire ce corrigé. Il donne la réponse et le pourquoi, jamais une notion neuve : tout ce qu'il emploie a été enseigné dans la Théorie 06 ou pratiqué dans le Labo 06. Quand une réponse repose sur un geste du labo, le renvoi le nomme.

Questions courtes

1. Les quatre formes. La transaction enregistre un événement et répond à « combien, quand ». L'accumulation suit un dossier qui avance par étapes et répond à « combien de temps, et où ça bloque ». L'instantané périodique mesure un état à intervalle régulier et répond à « quel était l'état à ce moment, et combien de temps ». Le fait sans mesure enregistre un événement dont seule l'occurrence compte, et répond à « est-ce arrivé, et combien de fois ». *Théorie : Theorie_06.md, section 1.*
2. Ce qui arrive à une ligne. Dans une transaction, un instantané et un fait sans mesure, une ligne écrite ne bouge plus : la source peut changer, la ligne reste. Dans un fait d'accumulation, la ligne se met à jour à chaque jalon franchi, et c'est la seule forme où cela arrive. C'est la propriété qui décide de la stratégie de rafraîchissement, et le Cours 07 y reviendra. *Théorie : Theorie_06.md, sections 1 et 2.*
3. Reconnaître le bon type. Un fait d'accumulation : le permis est un dossier qui avance par étapes datées, et la question qui vient toujours est celle des délais entre étapes. Si la source livrait une ligne par changement d'état, rien ne changerait au choix du type, seulement à la façon de le bâtir : il faudrait pivoter ces lignes en jalons plutôt que déplier un historique. Le type de fait suit le processus, jamais la forme de la source. *Théorie : Theorie_06.md, sections 1 et 3.*
4. Les jalons. Un jalon est une étape du processus, portée par une colonne de date qui se remplit quand l'étape est franchie. Un jalon vide n'est pas une donnée manquante : c'est un dossier qui n'en est pas encore là, et c'est de l'information. Chez Boréal : l'ouverture, l'approbation, le refus et le paiement. *Théorie : Theorie_06.md, section 2.*
5. Les durées. Dans le fait, parce que c'est lui qui possède les deux bornes, et qu'une durée calculée une fois vaut mieux que la même soustraction réécrite dans chaque rapport. Tant que le jalon d'arrivée n'est pas atteint, la durée est vide, ce qui est exactement ce qu'on veut dire : on ne connaît pas encore le délai d'un dossier qui n'est pas fini, et zéro serait un mensonge. *Théorie : Theorie_06.md, section 2.*
6. Trois comportements. Les enregistrements : 26 732 lignes pour 26 732 objets, donc rien ne revient, la source ne livre jamais deux fois le même. Les clients : 25 379 lignes pour 23 527 objets, donc la fiche revient chaque fois qu'elle change. Les réclamations : 5 623 lignes pour 3 348 objets, donc l'objet revient à chaque changement de statut, avec son historique allongé. *Labo : Labo_06.md, étape 2.*
7. L'ordre des deux gestes. On dédouble d'abord, on déplie ensuite. L'ordre inverse déplie l'historique de toutes les versions livrées, qui sont emboîtées : mesuré chez Boréal, 13 455 étapes au lieu de 9 447, et six étapes au lieu de trois pour RC0000040. *Théorie : Theorie_06.md, section 3.*
8. Le pivot. `json_transform` donne un type à chaque champ de la liste, ce qui évite de recaster ensuite. `unnest`, dans un `lateral`, rend une ligne par élément de la liste, pour chaque réclamation. Et `max(case when statut = ... then date end)` replie ces lignes en une seule, avec une colonne par jalon. *Labo : Labo_06.md, étape 5.*

9. Une dimension conforme. La même dimension, avec les mêmes clés et les mêmes libellés, partagée par plusieurs étoiles : le même véhicule a la même clé partout. Elle rend possible le forage transversal, c'est-à-dire de recouper deux processus qui ne se connaissent pas, ce qu'une étoile isolée ne peut pas faire puisqu'elle ne sait rien de l'autre. *Théorie : Theorie_06.md, section 4.*
10. Le forage transversal. 12,3 pour cent des véhicules hors-route vendus ont une réclamation, 12,0 pour cent des motomarines, 11,1 pour cent des motoneiges. Aucun des deux faits ne pouvait le donner seul, parce que la gamme n'est écrite ni dans l'un ni dans l'autre : elle est dans `dim_vehicule`, que les deux partagent. *Labo : Labo_06.md, étape 12.*
11. La date d'époque. La date de commande pour `fct_ventes`, la date de vente au détail pour `fct_enregistrements`, la date d'ouverture du dossier pour `fct_reclamations`. Le choix n'est pas technique parce qu'il décide à quel palier une opération est attribuée : deux équipes qui choisissent deux dates différentes obtiennent deux chiffres différents, tous les deux défendables, et personne ne sait ensuite pourquoi ils diffèrent. *Théorie : Theorie_06.md, section 5.*
12. Les mesures qui ne sont pas des montants. `jours_avant_enregistrement`, l'écart entre la vente et son enregistrement, qui se moyenne et ne s'additionne pas utilement ; mesuré, 0,99 jour en moyenne et trois jours au plus. Et `mois_de_couverture`, la durée de la garantie, qui ne s'additionne pas du tout et sert à grouper : 12 mois sous GAR-2022, 24 sous GAR-2024. Un fait n'est pas obligé de porter de l'argent. *Théorie : Theorie_06.md, section 5.*
13. La dimension des clients. Elle porte la clé, le code du client, la ville, la province et son libellé, la langue, un drapeau d'effacement et la date de création. Elle laisse à la source le prénom, le nom, le courriel, le téléphone, l'adresse et le code postal. La question à se poser devant chaque colonne est « quelle analyse devient impossible sans elle », et si la réponse est « aucune », la colonne ne monte pas. *Théorie : Theorie_06.md, section 6.*
14. Le témoin de l'après-vente. Personne chez Boréal ne tient un total indépendant des réclamations : il n'y a rien à réconcilier. La règle qui le remplace est la couverture, une réclamation ouverte après la fin de la garantie devant être refusée pour ce motif. Mesuré : 329 réclamations hors garantie, 329 portant le motif, et toutes refusées, sur 395 refus en tout. *Labo : Labo_06.md, étape 11.*
15. L'instantané périodique. Son grain garantit une ligne par sujet et par période, même quand il ne s'est rien passé, donc une heure d'arrêt est une ligne à zéro et non une ligne absente. Chez Boréal : 10 actifs par 2 209 heures, soit exactement 22 090 lignes, sans un trou. *Théorie : Theorie_06.md, section 8.*
16. La couverture. Elle distingue une heure pleinement mesurée, une heure à peine mesurée et une heure sans aucune mesure, que la seule valeur confond. Mesuré sur les 22 090 lignes : 21 952 heures pleines, 81 partielles, 57 sans mesure. *Labo : Labo_06.md, étape 16.*
17. Semi-additive. Une mesure semi-additive s'additionne sur certaines dimensions et pas sur d'autres. `part_en_marche` s'additionne sur le temps, et sa somme est un nombre d'heures de marche, donc la disponibilité ; elle ne s'additionne pas entre actifs sans devenir difficile à défendre. `puissance_moyenne_kw` et `vibration_moyenne` ne s'additionnent sur rien : elles se moyennent. `couverture_s` s'additionne sur tout, c'est un temps. *Théorie : Theorie_06.md, section 8.*
18. La moyenne qui dilue. Sur les seules heures où le compresseur tourne, la vibration passe de 2,57 à 8,47 millimètres par seconde entre le 14 et le 28 octobre. Sur toutes les heures, elle passe de 1,02 à 1,78. La comparaison enseigne que la disponibilité n'est pas seulement une mesure de plus : c'est le filtre de toutes les autres, et l'oublier transforme une panne annoncée en frémissement. *Théorie : Theorie_06.md, section 8.*

19. Le fait sans mesure. Il ne porte que des clés, plus au besoin des dimensions dégénérées, et la mesure implicite est le compte de ses lignes. Les deux fausses bonnes idées : ajouter une colonne `quantite` qui vaut toujours 1, que `count(*)` remplace et qui finira additionnée par erreur ; et ranger l'événement comme un attribut de la dimension, ce qui empêche de compter par période. *Théorie : Theorie_06.md, section 9.*
20. Le grain de l'événement. Parce que le fait enregistre un assemblage, pas un véhicule : si un véhicule était réassemblé, il y aurait deux lignes, et c'est ce qu'on veut. Aujourd'hui les deux se confondent, 27 775 lignes pour 27 775 numéros de série, et c'est une coïncidence du processus, pas une propriété du modèle. *Théorie : Theorie_06.md, section 9.*
21. Deux niveaux, une dimension. Parce que les deux faits de l'usine ne visent pas le même niveau, la disponibilité un équipement et la production une zone, et qu'ils doivent quand même se recouper. Deux dimensions séparées donneraient deux clés pour la même chose selon le fait interrogé, et il faudrait une jointure écrite à la main chaque fois qu'on veut les lire ensemble. La conformité se perdrait là. *Théorie : Theorie_06.md, section 10.*
22. Le témoin de l'usine. L'automate du convoyeur, qui compte les véhicules terminés depuis minuit, et l'ERP, qui enregistre un numéro de série par véhicule assemblé. Ils sont indépendants parce qu'ils ne se parlent pas : l'un compte des passages sur une ligne, l'autre crée des objets dans un progiciel. Mesuré : 1 833 véhicules des deux côtés sur les 92 jours couverts, et aucun jour en écart. *Labo : Labo_06.md, étape 18.*
23. L'instant et le jour. Parce que `heure::date` suit le fuseau de la session : le même modèle donnerait des journées différentes selon le réglage de la machine qui lance dbt. Mesuré : 4 280 des 22 090 heures changent de jour entre l'heure locale et l'heure UTC, presque une sur cinq. La conversion s'écrit donc dans le modèle. *Labo : Labo_06.md, étape 16.*
24. La matrice dans le graphe. Il rend 10 nœuds : la dimension et neuf tests. Il ne rend aucun fait, parce que les faits recalculent leurs clés par hachage au lieu de joindre les dimensions, donc rien ne les relie dans le graphe de dbt. Ce qu'on y voit à la place, ce sont les tests de relation, un par couple d'un fait et d'une dimension : la matrice de bus n'existe dans le projet que par eux. *Labo : Labo_06.md, étape 20.*

Questions pratiques

P1. L'entonnoir.

```
select
  count(*) as dossiers,
  count(cle_date_ouverture) as soumis,
  count(cle_date_approbation) as approuves,
  count(cle_date_refus) as refuses,
  count(cle_date_paiement) as payes,
  count(*) filter (where cle_date_approbation is null and cle_date_refus is null)
    as en_attente_de_decision,
  count(*) filter (where cle_date_approbation is not null and cle_date_paiement is null)
    as en_attente_de_paiement
from marts.fct_reclamations;
```

Attendu : 3 348 dossiers, 3 348 soumis, 2 905 approuvés, 395 refusés, 2 799 payés, 48 en attente d'une décision et 106 en attente d'un paiement.

Les deux dernières colonnes sont celles qui intéressent le service des garanties, et elles n'ont pas la même nature. Les 48 en attente de décision sont son propre travail à faire. Les 106 en attente de paiement sont de l'argent dû à des concessionnaires, dont le dossier est accepté et qui attendent leur chèque : c'est une dette, et personne ne la voyait avant que ce fait existe. *Labo : Labo_06.md, étape 9.*

P2. Le délai par cause.

```
select
  cause,
  count(*) as dossiers,
  round(avg(jours_jusqua_la_decision), 2) as jours_decision,
  round(avg(jours_jusqua_la_cloture), 2) as jours_cloture,
  round(avg(montant_total), 2) as montant_moyen
from marts.fct_reclamations
group by 1
order by 1;
```

Cause	Dossiers	Jours de décision	Jours de clôture	Montant moyen
CHASSIS	626	5,37	24,16	1 045,10 \$
ELECTRIQUE	584	5,18	24,13	306,86 \$
LIVRAISON	1 032	5,18	24,16	132,92 \$
MOTEUR	445	5,26	24,11	590,58 \$
REFROIDISSEMENT	186	5,35	24,47	330,70 \$
TRANSMISSION	475	5,39	24,09	346,68 \$

Ce qui ne varie pas est le délai : cinq jours pour décider, vingt-quatre pour clore, quelle que soit la cause. Le traitement d'une réclamation ne dépend donc pas de ce qu'elle contient, ce qui est en soi un constat : il n'y a pas de dossier difficile qui traîne, il y a un circuit administratif qui prend le même temps pour tout le monde.

Ce qui varie est le montant, d'un facteur huit entre un défaut de livraison et une réparation de châssis. Un tableau de bord qui compterait les dossiers sans les peser donnerait donc la première place à la cause la moins chère.

P3. Le témoin de la couverture. Dans tests/assert_refus_hors_garantie.sql :

```
with r as (

  select
```

```

        numero_reclamation,
        est_hors_garantie,
        statut,
        motif_refus

    from {{ ref('fct_reclamations') }}

)

select *
from r
where est_hors_garantie != (motif_refus = 'Hors de la période de garantie')
    or (est_hors_garantie and statut != 'REFUSEE')

```

Un échec signifierait l'une de deux choses, et il faudrait les départager avant de corriger quoi que ce soit. Ou bien votre calcul de la couverture est faux, parce que la date de fin de garantie n'est pas celle que vous croyez ou parce qu'un cas particulier existe, une prolongation par exemple. Ou bien le portail a accepté une réclamation qu'il aurait dû refuser, et c'est alors un constat de gestion, pas un défaut de modèle. Un témoin ne dit jamais qui a tort, il dit que deux choses ne concordent plus. *Labo : Labo_06.md, étape 11.*

P4. (avancé) La complétude de l'instantané. Dans `tests/assert_instantane_complet.sql` :

```

with actifs as (

    select distinct cle_actif from {{ ref('fct_disponibilite_actifs') }}

),

heures as (

    select distinct heure from {{ ref('fct_disponibilite_actifs') }}

)

select
    a.cle_actif,
    h.heure

from actifs as a
cross join heures as h
left join {{ ref('fct_disponibilite_actifs') }} as f
    on f.cle_actif = a.cle_actif and f.heure = h.heure

```

```
where f.cle_actif is null
```

Attendu : aucune ligne. Le produit des actifs par les heures donne 22 090 couples, et le fait les porte tous.

Ce test attrape ce qu'un unique_combination_of_columns ne voit pas : non pas un couple en trop, mais un couple qui manque. Un capteur qui cesse d'émettre une nuit entière, une étiquette renommée par l'intégrateur, une jointure qui perd un actif : dans les trois cas le grain reste unique et les comptes ont l'air normaux, mais la grille a un trou.

Ce qu'il ne voit pas non plus mérite d'être dit, puisque la question demandait de ne pas écrire les comptes en dur : une heure absente pour tous les actifs à la fois ne sera pas détectée, puisqu'elle n'apparaît dans aucun des deux ensembles. Attraper ce cas demande une grille venue d'ailleurs, dim_date par exemple, ou une comparaison au nombre d'heures attendu dans la période.

P5. La disponibilité mensuelle.

```
select
  date_trunc('month', f.cle_date) as mois,
  round(sum(f.part_en_marche) filter (where a.actif_id = 'LMN-CNV'), 1) as motoneiges,
  round(sum(f.part_en_marche) filter (where a.actif_id = 'LMM-CNV'), 1) as motomarines,
  round(sum(f.part_en_marche) filter (where a.actif_id = 'LHR-CNV'), 1) as hors_route
from marts.fct_disponibilite_actifs as f
inner join marts.dim_actif as a on a.cle_actif = f.cle_actif
where a.type_actif = 'CONVOYEUR'
group by 1
order by 1;
```

Mois	Motoneiges	Motomarines	Hors-route
2025-10	187,2	11,1	108,5
2025-11	170,3	4,9	67,2
2025-12	139,9	9,8	61,7

La ligne des motomarines tourne dix fois moins que celle des motoneiges, et ce n'est pas une panne ni un capteur muet : c'est la saison. On assemble les motoneiges à l'automne pour l'hiver, et les motomarines l'hiver pour l'été ; l'historien ne couvre que le dernier trimestre, donc il attrape une ligne en pleine production et une autre à l'arrêt. Un taux d'utilisation ne se lit jamais sans sa période.

P6. Les véhicules jamais vendus.

```
select
  (select count(*) from marts.fct_production) as assemblees,
  (select count(*) from marts.fct_production where est_expedie) as expedies,
```

```
(select count(*) from marts.fct_enregistrements) as vendus,
(select count(*) from marts.fct_production as p
 where not exists (select 1 from marts.fct_enregistrements as e
                   where e.cle_vehicule = p.cle_vehicule)) as jamais_vendus;
```

Attendu : 27 775 assemblés, 27 698 expédiés, 26 732 vendus au détail, 1 043 sans enregistrement.

Deux explications se tiennent, et elles ne s'excluent pas. Les 77 véhicules non expédiés sont encore à l'usine, donc évidemment invendus. Les autres sont partis chez un concessionnaire et n'ont pas encore trouvé preneur : c'est du stock chez le détaillant, et sa mesure intéresse beaucoup de monde. Ce qu'il ne faut pas conclure, c'est qu'il y a une anomalie : le décalage entre l'assemblage et la vente au détail est le fonctionnement normal du réseau.

P7. La cadence.

```
with marche as (

    select f.cle_date as jour, sum(f.part_en_marche) as heures
    from marts.fct_disponibilite_actifs as f
    inner join marts.dim_actif as a on a.cle_actif = f.cle_actif
    where a.actif_id = 'LMN-CNV'
    group by 1

),

produits as (

    select p.cle_date_assemblage as jour, count(*) as vehicules
    from marts.fct_production as p
    inner join marts.dim_actif as a on a.cle_actif = p.cle_actif
    where a.actif_id = 'LMN'
    group by 1

)

select
    count(*) as jours,
    count(*) filter (where m.heures = 0) as jours_arretes,
    round(sum(p.vehicules) / sum(m.heures), 2) as vehicules_par_heure,
    count(*) filter (where m.heures = 0 and coalesce(p.vehicules, 0) > 0) as incoherences
from marche as m
left join produits as p on p.jour = m.jour;
```

Attendu : 92 jours, dont 33 arrêtés, une cadence de 2,82 véhicules par heure de marche, et zéro incohérence.

Une incohérence, c'est-à-dire une journée où l'ERP enregistre des véhicules alors que le convoyeur n'a pas tourné, voudrait dire que les deux sources ne parlent pas de la même chose : une date d'assemblage saisie à la main, un fuseau mal converti, ou des véhicules montés sur une autre ligne que celle qu'indique l'ERP. Le fait qu'il n'y en ait aucune est ce qui autorise à croire la cadence.

P8. (avancé) Le fil de l'incident.

```
with exposees as (  
  
    select p.cle_vehicule, p.numero_serie  
    from marts.fct_production as p  
    inner join marts.dim_actif as a on a.cle_actif = p.cle_actif  
    where a.actif_id = 'LMN'  
    and p.cle_date_assemblage between date '2025-10-15' and date '2025-10-28'  
  
)  
  
select  
    count(*) as assemblees,  
    count(e.cle_vehicule) as vendues,  
    count(distinct r.cle_vehicule) as avec_reclamation,  
    min(x.numero_serie) as premiere,  
    max(x.numero_serie) as derniere  
  
from exposees as x  
left join marts.fct_enregistrements as e on e.cle_vehicule = x.cle_vehicule  
left join marts.fct_reclamations as r on r.cle_vehicule = x.cle_vehicule;
```

Attendu : 240 motoneiges assemblées, de MN26001238 à MN26001477, 201 vendues au détail, 5 avec au moins une réclamation.

Ce qu'on peut conclure tient en une phrase : rien encore. Cinq réclamations sur 201 véhicules font 2,5 pour cent, contre 3,3 pour cent chez les autres motoneiges de l'année-modèle 2026 ; l'écart va dans le mauvais sens pour la thèse du défaut, et il porte sur trop peu de cas pour dire quoi que ce soit. Ce que la requête livre est une cohorte nommée par ses numéros de série, qu'on pourra resurveiller quand les mois de 2026 seront chargés. *Labo : Labo_06.md, étape 19.*

Diagnostics

E1. Le dépliage trop pressé. Ce qui est faux est le compte des étapes, et lui seul. En dépliant raw.garanties_reclamations, on déplie l'historique de toutes les versions livrées, qui sont emboîtées : la version de mai porte une étape, celle de juin deux, celle de juillet trois, et le dépliage les additionne. Mesuré : 13 455 étapes au lieu de 9 447, et six au lieu de trois pour RC0000040.

Les dates ont survécu parce que le pivot prend un maximum par statut. La date d’approbation apparaît deux fois, dans la version de juin et dans celle de juillet, mais c’est la même date, donc le maximum la rend intacte. Le modèle est faux et son résultat principal est juste, ce qui est la pire des situations : rien ne le signale, et la colonne `etapes_franchies` ment sans bruit.

La leçon est celle de l’ordre : un dépliage se fait sur un état courant, jamais sur un journal de versions. *Théorie : Theorie_06.md, section 3.*

E2. Le test de `trop.dbt build` échoue sur 549 lignes, celles des réclamations qui n’ont pas encore été payées : 395 refusées, 106 approuvées en attente du chèque et 48 encore à l’étude.

C’est le collègue qui a tort, et il a tort pour une bonne raison, ce qui rend le cas intéressant. La règle qu’il applique est juste partout ailleurs : une clé étrangère vide est presque toujours un défaut. Elle ne vaut pas sur un jalon, parce qu’un jalon vide est un état du dossier et non une donnée manquante. La règle générale se dit donc ainsi : `not_null` se pose sur ce qui doit exister dès la naissance de la ligne, et jamais sur ce qui n’existera qu’à une étape ultérieure. Le `relationships` reste, lui, puisqu’il ignore les valeurs absentes et vérifie seulement celles qui sont là. *Labo : Labo_06.md, étape 10.*

E3. La mauvaise date d’époque. Quatre ventes changent de version, sur 26 732. Elles ont toutes été vendues les 29 et 30 juillet 2024 et enregistrées après le 31, jour où le snapshot a vu la révision des paliers.

Enregistrement	Vente	Enregistrement	Palier à la vente	Palier à l’enregistrement
EN0016415	2024-07-29	2024-07-31	Argent	Or
EN0016416	2024-07-29	2024-07-31	Argent	Bronze

Quatre lignes sur 26 732 ne se voient dans aucun total, et c’est précisément ce qui rend l’erreur durable : elle ne fait pas de bruit cette année-ci, et elle en fera le jour où une révision de paliers tombera en pleine saison de vente.

On n’attrape pas ce genre d’erreur avec un test, parce qu’il n’y a rien de faux au sens des données : les deux jointures rendent une version valide. On l’attrape en écrivant la définition quelque part, dans la description du modèle, et en la faisant relire par quelqu’un du métier. C’est la limite honnête des tests, et le `LIVRAISON.md` existe pour cela. *Théorie : Theorie_06.md, section 5.*

E4. La somme qui ne veut rien dire. Le nombre 30 600 est la somme de 2 209 moyennes horaires exprimées en kilowatts. Additionner des kilowatts sur des heures ne donne ni des kilowatts ni des kilowattheures : cela ne donne rien, c’est un nombre sans unité.

Ce qu’il fallait calculer dépend de la question. Pour une puissance moyenne, la moyenne des heures, 13,9 kW. Pour une énergie, la somme des produits de la puissance par la durée de marche, ce que l’instantané permet puisqu’il porte `part_en_marche`. Et pour un temps de fonctionnement, la somme des parts en marche, 549,8 heures sur le trimestre.

Le nom de la colonne aurait évité la faute. `puissance_moyenne_kw` dit déjà qu’il s’agit d’une moyenne, et c’est déjà mieux que `puissance` ; une convention plus stricte suffixerait les mesures non additives, ou les rangerait dans une description qui l’annonce. Une mesure semi-additive dont le nom ne dit rien finit toujours par être additionnée. *Théorie : Theorie_06.md, section 8.*

E5. Le fuseau du poste. Parce que la clé de date se calculait par une troncature implicite, qui suit le fuseau de la session : sur un poste réglé à l'heure du Québec, heure : : date rend la date locale ; sur un serveur en UTC, il rend la date UTC, et les heures de fin de soirée basculent au lendemain. Mesuré : 4 280 des 22 090 heures changent de jour entre les deux lectures, presque une sur cinq, et le nombre de journées passe de 92 à 93.

Les tests n'ont rien vu, et c'est logique : la grille reste complète, le grain reste unique, chaque clé pointe une date qui existe. Le témoin du compteur, lui, convertit explicitement, donc il continue de tomber juste ; c'est d'ailleurs ce qui rend le cas pervers, un contrôle vert à côté d'un tableau de bord faux.

Ce qui aurait dû l'empêcher est dans le modèle : une conversion écrite, (heure at time zone 'America/Toronto')::date, qui donne le même résultat partout. La règle vaut au-delà du fuseau : un modèle dont le résultat dépend d'un réglage de la machine qui le lance n'est pas reproductible, et ce qui n'est pas reproductible ne se teste pas. *Labo : Labo_06.md, étape 16.*

Questions à développer

A. Le fait d'accumulation et son prix. Ce que cela coûte est simple à dire et désagréable à découvrir en production : on ne peut pas se contenter d'ajouter les lignes neuves, puisque des lignes anciennes ont bougé. Sur 3 348 dossiers, la question ne se pose pas, on reconstruit tout en une seconde. Sur trois millions, reconstruire chaque nuit devient une heure de calcul pour quelques milliers de lignes réellement changées.

Les deux stratégies sont connues. La première reconstruit tout, et elle a pour elle la simplicité : aucun état à garder, aucun risque de manquer un changement, un résultat toujours cohérent avec la source. La seconde ne reprend que ce qui a bougé, ce qui suppose de savoir le dire : une date de modification fiable dans la source, ou une fenêtre de reprise assez large pour rattraper les retards. C'est un modèle incrémental avec une stratégie de fusion, et c'est le sujet du Cours 07.

Chez Boréal, aujourd'hui, je reconstruis tout et je ne m'en cache pas : c'est le bon choix tant que la reconstruction se compte en secondes, et le complexifier avant d'en avoir besoin serait payer une dette qu'on n'a pas contractée. À trois millions de dossiers, je passerais à l'incrémental avec une fenêtre de reprise, et je garderais une reconstruction complète hebdomadaire, parce qu'une fenêtre trop courte finit toujours par laisser passer quelque chose.

B. La période d'un instantané. L'heure se défend d'abord parce que c'est ce que la source livre : Data Engineering rend une série horaire, et rien n'oblige l'étoile à défaire ce travail. Elle se défend surtout par ce qu'elle permet, la lecture d'un incident dans sa journée : la dérive du compresseur du 28 octobre s'est vue à l'heure près, et le passage de relais au compresseur d'appoint aussi.

La minute coûterait soixante fois plus de lignes, 1,3 million pour un trimestre plutôt que 22 090, sans rien apprendre de plus sur un processus dont les événements durent des heures. Elle se justifierait si les arrêts qu'on cherche duraient quelques minutes, ce qui est le cas sur certaines lignes rapides, mais pas ici.

Le jour perdrait tout ce qui compte. La disponibilité quotidienne du compresseur 2 le 28 octobre serait de 4,7 heures sur 24, ce qui ne dit ni qu'il a fonctionné normalement le matin ni qu'il a déclenché à 10 h 50. Et la comparaison entre équipes de jour et de soir deviendrait impossible.

Ce qui décide vraiment de la période n'est ni la source ni le volume : c'est la durée du phénomène qu'on veut voir. La règle usuelle est de prendre une période plusieurs fois plus courte que l'événement le plus bref qui doit rester visible. Ici, un arrêt de production se compte en heures, donc l'heure est à la limite basse du raisonnable, et c'est un argument pour ne pas monter au jour.

C. (avancé) Ce qu'on annonce quand on n'a rien prouvé. Ce que je réponds au directeur tient en quatre phrases. Les 240 motoneiges assemblées pendant la dérive sont identifiées, une à une, par leur numéro de série. Sur les 201 déjà vendues, cinq ont eu une réclamation, soit 2,5 pour cent, contre 3,3 pour cent chez les autres motoneiges de la même année-modèle. Ces chiffres ne montrent aucun excès, et ils ne peuvent pas en montrer : un serrage insuffisant se manifeste après des mois d'usage, et la moitié de ces véhicules ont été vendus il y a moins d'un trimestre. La question se rouvrira avec les données de 2026.

Ce que je mets en place est ce qui rendra la réponse possible plus tard : la cohorte est figée dans une table ou une liste versionnée, pas dans une requête que quelqu'un réécrira de mémoire ; une surveillance mensuelle compare son taux de réclamation à celui du reste de la production ; et le seuil à partir duquel on rappelle les véhicules se discute maintenant, à froid, plutôt que dans l'urgence.

Ce que je ne dis surtout pas, c'est « il n'y a pas de problème ». La phrase est fausse et elle ferme le dossier. Je ne dis pas non plus « 2,5 contre 3,3 pour cent, donc ces véhicules vont mieux que les autres » : c'est vrai arithmétiquement, c'est absurde en pratique, et une seule phrase de ce genre suffit à faire perdre confiance dans tout ce qu'on présentera ensuite. L'honnêteté d'un chiffre commence par dire ce qu'il ne mesure pas.

Mises en situation

M1. Atelier de carrosserie de Nicolet. Ce que je peux livrer aujourd'hui est un fait d'accumulation à un seul jalon rempli : le statut courant de chaque dossier et la date de sa dernière modification. Cela répond déjà à « combien de dossiers sont bloqués à l'attente de l'assureur en ce moment », qui est probablement la question la plus urgente, et ça ne demande aucun changement dans le logiciel.

Ce que je ne peux pas livrer, ce sont les durées entre étapes, et il faut le dire tout de suite parce que c'est ce qu'on va me demander. La source écrase : le dossier passé par l'estimation la semaine dernière ne porte plus aucune trace de cette date. Aucune requête ne reconstruit une histoire qui n'a pas été gardée.

Ce que je mets en place dès la première semaine est un snapshot sur la table des dossiers, en stratégie check sur le statut, lancé au moins une fois par jour. À partir de là, chaque changement d'état est daté, et le fait d'accumulation se remplira de lui-même. La précision sera celle de la fréquence, comme au Cours 05 : un snapshot quotidien ne verra pas deux changements le même jour, et c'est acceptable pour un atelier dont les étapes durent des jours.

Je regarde aussi, avant de conclure à l'impossible, si le logiciel tient un journal d'audit. Les progiciels de gestion en ont souvent un, sous-employé, et il porte exactement ce qui manque.

M2. (avancé) Fromagerie de Plessisville. Je monte deux étoiles et une dimension conforme. Un fait de production, au grain du lot, avec sa date, sa recette et sa quantité. Un fait de plainte, au grain de la plainte, avec sa date, son motif et le lot quand il est connu. Et entre les deux, `dim_lot`, qui porte le code de lot, sa date de fabrication, sa recette et sa date limite : c'est elle qui rend le recoupement possible, et c'est elle qu'il faut soigner.

Les deux tiers de plaintes sans code de lot ne se jettent pas, et c'est le cœur du dossier. Je leur donne une clé de lot inconnue, une ligne dédiée dans la dimension, pour qu'elles restent dans le fait et qu'on puisse les compter. Une plainte sans lot reste une plainte : elle compte dans le total, elle compte par mois, elle compte par motif, et elle ne compte simplement pas dans les analyses par lot. Les exclure du fait ferait disparaître les deux tiers du problème du tableau de bord, ce qui est exactement l'effet inverse de celui qu'on cherche.

Je regarde ensuite si une partie de ces deux tiers se rattrape autrement : la date de la plainte et la recette citée dans le courriel réduisent souvent les lots candidats à deux ou trois, et un rattachement probable, marqué comme tel, vaut mieux qu'un vide. Ce que je ne fais pas, c'est attribuer un lot au hasard parmi les candidats.

Ce que je promets au directeur est donc mesuré, et en deux parties. Sur le tiers de plaintes identifiées, je livre un taux de plainte par lot et par recette, avec les limites que donne le tiers. Sur le reste, je livre le compte et son évolution, et je propose le seul vrai correctif, qui n'est pas technique : faire demander le code de lot dès le premier contact, par le formulaire du site ou par la personne au téléphone. Six mois de cette discipline valent tous les modèles.

M3. Scierie de Coaticook. Je monte deux faits de formes différentes, et c'est le cas d'école du cours. Un instantané périodique sur l'état des quatre lignes, à l'heure ou au quart selon ce que l'historien permet, qui donne les heures de marche, les arrêts et leur durée. Et un fait de transaction pour la production déclarée, au grain du quart et de la ligne, tel que le contremaître le saisit.

Le témoin que je cherche est celui du Cours 06 : deux systèmes qui comptent la même chose sans se parler. Si les lignes portent un compteur de pièces ou de mètres cubes, il donne une production mesurée que je compare à la production déclarée, et l'écart devient un indicateur en soi. S'il n'y en a pas, je le dis, et le rendement reposera sur une seule source, ce qui change la confiance qu'on peut lui accorder.

Le décalage d'une journée ne se corrige pas, il se modélise. La feuille du contremaître porte la date du quart, pas celle de la saisie : c'est la date du quart qui est la clé de date du fait, et la date de saisie devient une colonne à part, utile pour mesurer le retard de saisie. Le tableau de bord annonce alors clairement qu'une journée est incomplète tant que la saisie n'est pas arrivée, plutôt que d'afficher un rendement en chute tous les matins. Et je surveille le retard lui-même : le jour où il passe de un à trois jours, c'est le processus qui se dégrade, et le tableau de bord l'aura vu avant tout le monde.