

Table des matières

Data Science — plan des modules 1

1. Ce que cette formation est, et ce qu’elle n’est pas 1

2. Ce qu’elle reçoit, et ce qu’elle livre..... 2

3. La pile technique 2

4. La bonification : dire ce qui est commun..... 3

5. Les onze modules..... 4

6. Ce qui reste à décider avant d’écrire 6

Data Science — plan des modules

Écrit le 2026-08-31, raccordé au parcours le 2026-09-21. Ce fichier n’est pas un support de cours : c’est la feuille de route de la formation, qui n’est pas encore rédigée. Il dit ce qu’elle couvrira, ce qu’elle reçoit des formations qui la précèdent et ce qu’elle livre à celles qui la suivent. Il sera révisé une dernière fois au début de sa rédaction, comme l’a été celui d’Analytics Engineering.

1. Ce que cette formation est, et ce qu’elle n’est pas

Elle couvre l’aval de la chaîne : une fois la donnée propre et disponible, comment on en tire une réponse défendable. La statistique d’abord, l’apprentissage automatique ensuite, et le jugement en permanence.

Formation	Ce qu’elle possède	Frontière
SQL avancé	le langage	Data Science interroge, elle n’enseigne pas la fenêtre analytique
Analytics Engineering	la table propre	Data Science part de la couche MARTS, elle ne la modélise pas
Data Engineering	le pipeline	Data Science consomme ce que le pipeline livre, elle ne l’orchestre pas
Python	le langage	Data Science suppose la syntaxe acquise

Formation	Ce qu'elle possède	Frontière
Statistiques (site)	les vitrines du portfolio	la formation enseigne, le site montre

La règle des renvois de `_commun/STYLE.md`, section 5, s'applique : une notion qui appartient à une autre formation n'est pas réexpliquée, elle est renvoyée nommément.

2. Ce qu'elle reçoit, et ce qu'elle livre

Les sept formations du parcours travaillent sur le même univers fictif, Véhicules Boréal inc. : un fabricant de véhicules récréatifs, avec son progiciel de gestion, son usine instrumentée, ses véhicules connectés et son portail des garanties. Chaque formation reprend ce que la précédente a produit, et personne ne refait le travail du voisin.

Ce qu'elle reçoit	De qui	Pour quoi
Les étoiles des MARTS	Analytics Engineering, ses cours 04 et 06	des données propres dès le Cours 00, sans refaire la préparation
Les séries horaires de l'usine, schéma argent	Data Engineering, son cours 08	la maintenance prédictive et la prévision de la demande électrique

Ce qu'elle livre	À qui	Sous quelle forme
La segmentation des clients	Analytics Engineering, pour enrichir la dimension client ; Machine Learning Engineering	une table de l'entrepôt
Un modèle validé, avec son jeu d'évaluation	Machine Learning Engineering, ses cours 00 et 08	le code d'entraînement, les paramètres, les métriques attendues

Le fil rouge est donc Boréal, avec deux terrains que cette formation est seule à avoir : les séries de l'usine, pour la maintenance prédictive, et l'historique des ventes, pour la prévision de la demande. Les deux cas de clôture du parcours servent aussi : La Brûlerie pour la part des boissons froides selon la température du jour, ce que son seul mois de caisse permet d'estimer, Aurore pour la segmentation des clients et la prédiction des retours.

Entrer par cette formation sans avoir fait les précédentes restera possible : un kit de départ reconstruit ce qu'elle reçoit, en quelques minutes et sans refaire les cours d'avant. Les kits sont décrits dans `_univers/kits/README.md`.

3. La pile technique

Python : pandas pour la manipulation, statsmodels pour l'inférence et l'interprétation, scikit-learn pour l'apprentissage, matplotlib pour la figure. JupyterLab pour explorer, un module Python pour ce qui doit durer. Rien qui exige un compte payant ni un cloud.

Les exemples viennent de domaines variés (santé publique, commerce de détail, ressources humaines, service en ligne, capteurs), pas seulement de la finance. Le marché financier revient au Cours 09, où la validation temporelle est incontournable, et c'est là qu'il apporte le plus.

4. La bonification : dire ce qui est commun

Décision prise avec l'utilisateur le 2026-08-31 : chaque module doit nommer explicitement ce qu'il partage avec une ou deux autres formations. Le lecteur doit savoir où il se tient dans la chaîne et quel autre cours creuse le point qu'il vient d'effleurer.

Forme retenue, à poser en fin de chaque théorie : un encadré court, une ligne par formation voisine, qui dit ce qui est commun et qui possède la matière.

Cours	Recoupe	Ce que l'encadré doit dire
00	AE, Data Engineering	Les trois métiers se partagent la même chaîne. La donnée qui arrive ici a traversé les deux autres.
01	SQL	groupby et merge de pandas sont le GROUP BY et le JOIN déjà appris, sur une autre machine. Le tableau de correspondance est un vrai outil.
02	AE	Les tests dbt attrapent en amont une partie de ce qu'on nettoie ici. Ce qui est réglé au STAGING ne revient jamais dans le carnet.
03	aucune	Terrain propre à la formation. C'est le module qu'aucune autre ne couvre.
04	SQL, Snowflake	La régression existe aussi en SQL et dans Cortex. Ce qui change n'est pas le calcul, c'est le diagnostic.
05	Data Engineering	Une validation croisée mal faite est le même défaut de rigueur qu'un pipeline non idempotent : le résultat n'est pas reproductible.
06	aucune	Terrain propre à la formation.

Cours	Recoupe	Ce que l'encadré doit dire
07	AE	Une caractéristique stable a sa place dans un modèle MARTS, pas dans un carnet. Le partage de responsabilité est à trancher explicitement.
08	AE	La segmentation client produit une dimension. Où vit-elle, dans le carnet ou dans l'entrepôt ?
09	SQL, Order Flow	Le Cours 09 de SQL pose les jointures as-of et les fenêtres temporelles. Le portfolio Order Flow montre ce que la validation temporelle empêche de croire.
10	Data Engineering	Réentraîner un modèle est un DAG. La frontière avec le data engineer est le sujet du module.

5. Les onze modules

Cours 00 — Mise en place et démarche du projet

L'installation du poste n'est plus ici : le socle du parcours (Python, Git, DuckDB, Docker dans WSL 2, les pilotes) vit dans `Data_Domain/GUIDE_INSTALLATION.md`, et cette formation n'allume que ce qui lui est propre, au début du cours qui s'en sert. Ce cours se refond là-dessus à la révision du plan.

L'environnement (conda, JupyterLab, le dépôt). Le cycle d'un projet de données, et la seule règle qui compte : la question métier avant le modèle. Ce qui distingue une analyse d'une prédiction. Où le scientifique se branche sur la chaîne construite par les autres formations. Le jeu de données fil rouge est posé ici.

Cours 01 — Manipulation et exploration avec pandas

Séries et cadres, indexation, sélection, jointures, agrégation, remodelage entre format long et format large. L'exploration comme discipline : distributions, valeurs extrêmes, corrélations, et la figure qui sert à comprendre plutôt qu'à décorer. Le pont explicite avec le SQL déjà appris.

Cours 02 — Nettoyage, valeurs manquantes et fuite de données

Typage, doublons, valeurs aberrantes, catégories mal orthographiées. Les trois régimes de valeur manquante et ce que chacun autorise comme imputation. Puis le piège central du métier : la fuite de données, sous ses formes ordinaires (imputer avant de séparer, normaliser sur tout le jeu, une colonne qui contient la réponse). Un modèle trop bon est un modèle qui triche.

Cours 03 — Statistique inférentielle et tests A/B

Population et échantillon, estimation, intervalle de confiance. Le test d'hypothèse, ce qu'il dit et surtout ce qu'il ne dit pas. Puissance et taille d'échantillon calculées avant l'expérience. Comparaisons multiples. Le protocole d'un test A/B honnête, et les façons courantes de le saboter sans le vouloir.

Cours 04 — Régression linéaire et interprétation

Moindres carrés, hypothèses, diagnostic des résidus. Lire un coefficient et son incertitude. Colinéarité, variables catégorielles, interactions, transformations. Régularisation par crête et lasso. Le module où l'on apprend à expliquer, pas seulement à prédire.

Cours 05 — Évaluation, validation et sélection de modèles

Placé tôt, et volontairement : on ne juge pas un modèle qu'on ne sait pas évaluer. Séparation en trois jeux, validation croisée, le compromis biais-variance rendu concret. Choisir sa métrique en fonction du coût réel d'une erreur. Classes déséquilibrées. Validation temporelle, et pourquoi le brassage aléatoire ment sur une série.

Cours 06 — Classification et modèles à base d'arbres

Régression logistique, arbre de décision, forêt aléatoire, gradient boosté. Ce que chacun capte et ce qu'il rate. Réglage des hyperparamètres sans se mentir. Importance des variables, effets marginaux, et les limites de l'interprétation post-hoc.

Cours 07 — Ingénierie des caractéristiques et pipelines

Encodages, mise à l'échelle, discrétisation, variables de calendrier, agrégats par groupe. Puis l'outil qui empêche la fuite par construction : Pipeline et ColumnTransformer, avec toute transformation apprise dans la validation croisée. La question de fond : quelle caractéristique appartient au carnet, et laquelle appartient à l'entrepôt.

Cours 08 — Apprentissage non supervisé et réduction de dimension

k-moyennes, classification hiérarchique, DBSCAN, et la difficulté honnête d'évaluer un regroupement. Analyse en composantes principales, ce qu'elle conserve et ce qu'elle sacrifie. Détection d'anomalies. Segmentation client comme cas d'application, avec sa suite naturelle dans l'entrepôt.

Cours 09 — Séries temporelles et prévision

Décomposition, tendance, saisonnalité, stationnarité. Lissage exponentiel, SARIMA, puis l'approche par apprentissage avec des caractéristiques de calendrier et de retard. Validation glissante, horizon, intervalles de prévision. Cas d'application : la prévision de ventes, celle qui manque au portfolio.

Cours 10 — Mise en production, dérive et cycle de vie

Versionner données, code et modèle. Suivre une dérive de données et une dérive de concept. Décider quand réentraîner. Servir un modèle, par lots ou à la demande. Ce qui appartient au data engineer, et ce qui reste au scientifique. Capstone : un projet complet, de la question métier au modèle défendable, avec ce qu'on a choisi de ne pas faire et pourquoi.

6. Ce qui reste à décider avant d'écrire

Trois points que le mandat du parcours a tranchés depuis l'écriture de ce plan : le jeu de données fil rouge est Boréal et non un jeu public, la porte d'entrée hors séquence passe par le kit 04, et un cours compte trois supports, théorie, labo et exercices corrigés.

Restent ouverts :

1. Le sort du Cours 03. C'est le module le plus éloigné de l'apprentissage automatique et le plus rentable en entretien. Le garder à cette place, ou le remonter avant l'exploration.
2. L'articulation avec le portfolio de trading. Le Cours 09, sur les séries temporelles, peut y renvoyer comme cas réel, ou rester neutre. La deuxième option élargit le public, la première montre le travail déjà fait.
3. La frontière avec Machine Learning Engineering. Ce plan s'arrête au modèle validé ; reste à décider si le Cours 10 va jusqu'à un service minimal ou laisse tout le déploiement à MLE.