

Table des matières

AI Engineering — plan des modules 1

1. Ce que cette formation est, et ce qu'elle n'est pas 1

2. Ce qu'elle reçoit, et ce qu'elle livre..... 2

3. La pile technique 3

4. La bonification : dire ce qui est commun..... 3

5. Les neuf modules 4

6. Ce qui reste à décider avant d'écrire 5

AI Engineering — plan des modules

Écrit le 2026-08-31, raccordé au parcours le 2026-09-21. Ce fichier n'est pas un support de cours : c'est la feuille de route de la formation, qui n'est pas encore rédigée. Il dit ce qu'elle couvrira, ce qu'elle reçoit des formations qui la précèdent et ce qu'elle livre à celles qui la suivent. Il sera révisé une dernière fois au début de sa rédaction, comme l'a été celui d'Analytics Engineering.

1. Ce que cette formation est, et ce qu'elle n'est pas

Elle couvre la construction de systèmes à base de modèles de langage : récupération augmentée, appels d'outils, agents, évaluation, mise en production. Le rôle visé est celui d'ingénieur en IA, qui assemble des modèles qu'il n'entraîne pas.

C'est la formation la plus proche du marché actuel, et celle que le poste BRP nomme explicitement lorsqu'il demande de concevoir des agents d'IA.

Formation	Ce qu'elle possède	Frontière
Machine Learning Engineering	l'entraînement et le service d'un modèle	ici on n'entraîne rien. On appelle un modèle existant et on juge le système autour
Data Science	l'évaluation statistique	l'évaluation d'un système génératif emprunte la rigueur mais change les métriques
Data Engineering	l'ingestion	un corpus documentaire est un pipeline. Le découpage et l'indexation sont une ingestion de plus

Formation	Ce qu'elle possède	Frontière
Snowflake	Cortex	la plateforme offre ces fonctions clés en main. Savoir ce qu'elles font permet de décider quand les prendre
Architecture et Gouvernance	les règles	ce qu'on a le droit d'envoyer à un modèle tiers est une question de gouvernance

2. Ce qu'elle reçoit, et ce qu'elle livre

Les sept formations du parcours travaillent sur le même univers fictif, Véhicules Boréal inc. : un fabricant de véhicules récréatifs, avec son progiciel de gestion, son usine instrumentée, ses véhicules connectés et son portail des garanties. Chaque formation reprend ce que la précédente a produit, et personne ne refait le travail du voisin.

Ce qu'elle reçoit	De qui	Pour quoi
Le corpus documentaire de Boréal : manuels, bulletins de service, politique de garantie	Data Engineering, qui le charge dans la couche RAW	la récupération augmentée, aux cours 02 et 03
La documentation dbt et son <code>manifest.json</code>	Analytics Engineering, ses cours 05 et 08	un agent qui sait ce que l'entrepôt contient, au Cours 04
Les étoiles des MARTS et les prédictions par lots	Analytics Engineering et Machine Learning Engineering	les outils que l'agent appelle, au Cours 04

Ce qu'elle livre	À qui	Sous quelle forme
Rien en aval : elle ferme la chaîne applicative	—	son capstone reste dans la formation

Le fil rouge est donc la documentation de Boréal, une trentaine de documents dont les bulletins de service qui décrivent les incidents de l'usine. C'est un corpus petit, cohérent et vérifiable : un assistant qui répond à côté se prend en défaut en ouvrant le bulletin. Les deux cas de clôture du parcours suivent : un assistant sur les fiches des cafés pour La Brûlerie, un agent de service client pour Aurore, avec l'injection indirecte par les avis comme terrain de sécurité.

Entrer par cette formation sans avoir fait les précédentes restera possible : un kit de départ reconstruit ce qu'elle reçoit, en quelques minutes et sans refaire les cours d'avant. Les kits sont décrits dans `_univers/kits/README.md`.

3. La pile technique

Python, une bibliothèque cliente d'API de modèle, une base vectorielle locale, et le moins de cadriciel possible. Le parti pris est assumé : on écrit la boucle d'agent à la main avant de prendre un cadriciel, parce que le cadriciel cache exactement ce qu'il faut comprendre.

Le domaine se déplace vite. Chaque module sépare ce qui est stable (le raisonnement, les arbitrages, les modes d'échec) de ce qui est daté (les noms de modèles, les prix, les limites), et le daté est regroupé pour être révisable sans réécrire le cours.

Une dépense d'API est à prévoir, faible mais réelle. Le Cours 06 en fait un sujet d'étude plutôt qu'une contrainte subie.

4. La bonification : dire ce qui est commun

Chaque module doit nommer explicitement ce qu'il partage avec une ou deux autres formations, en encadré court de fin de théorie, avec ce qui est commun et qui possède la matière.

Cours	Recoupe	Ce que l'encadré doit dire
00	MLE	Les deux formations mettent un modèle en production. L'une l'entraîne, l'autre l'appelle : tout le reste en découle.
01	Data Science	La température et l'échantillonnage sont de la statistique. Un modèle de langage est un modèle probabiliste, pas un oracle.
02	Data Engineering	Découper, plonger et indexer un corpus, c'est une ingestion. Les Cours 03 et 04 de DE possèdent l'idempotence et la reprise.
03	SQL, Snowflake	La recherche hybride marie vecteur et mot-clé. Le Cours 08 de SQL possède le semi-structuré, Cortex Search fait la version gérée.
04	Data Engineering	Une boucle d'agent est une orchestration sans DAG connu d'avance. Comparer avec Airflow éclaire les deux.
05	Data Science	Le Cours 05 de DS possède la validation. Ici la vérité terrain est floue, ce qui change la méthode mais pas l'exigence.

Cours	Recoupe	Ce que l'encadré doit dire
06	Architecture et Gouvernance	Le coût par appel est un critère d'architecture, comme le coût d'un entrepôt au Cours 07 de la formation Architecture.
07	Gouvernance, Snowflake	L'injection de prompt est une faille d'entrée. La confidentialité de ce qu'on envoie relève du masquage déjà vu côté plateforme.
08	MLE	Versionner un prompt pose le même problème que versionner un modèle, avec moins d'outillage disponible.

5. Les neuf modules

Cours 00 — Mise en place et paysage des modèles de langage

L'installation du poste n'est plus ici : le socle du parcours (Python, Git, DuckDB, Docker dans WSL 2, les pilotes) vit dans `Data_Domain/GUIDE_INSTALLATION.md`, et cette formation n'allume que ce qui lui est propre, au début du cours qui s'en sert. Ce cours se refond là-dessus à la révision du plan.

L'environnement, la clé d'API, le premier appel, le suivi de la dépense. Ce qu'est un modèle de langage et, plus utile, ce qu'il n'est pas. La carte des usages sérieux, séparée des usages qui font une belle démonstration et rien d'autre.

Cours 01 — Prompt, contexte et limites du modèle

Jetons, fenêtre de contexte, coût. Température, échantillonnage, déterminisme et son absence. Ce qui marche vraiment dans un prompt et ce qui relève du folklore. Sortie structurée et validation de schéma. Les modes d'échec de base, dont l'hallucination confiante.

Cours 02 — Récupération augmentée, les fondations

Pourquoi la récupération plutôt que le réglage fin, dans la plupart des cas. Découpage d'un corpus, plongements, base vectorielle, recherche par similarité. Le montage minimal de bout en bout, construit à la main pour voir chaque pièce.

Cours 03 — Récupération augmentée en pratique

Là où le montage minimal se casse. Recherche hybride, reclassement, filtrage par métadonnées, découpage qui respecte la structure du document. Citer ses sources et rendre la réponse vérifiable. Diagnostic d'un système qui répond à côté, en distinguant l'échec de récupération de l'échec de génération.

Cours 04 — Appels d'outils et agents

L'appel de fonction, décrit honnêtement : le modèle propose, le code dispose. La boucle d'agent écrite à la main. Planification, mémoire, outils. Les garde-fous obligatoires : budget, nombre d'étapes, actions irréversibles soumises à confirmation. Et la question qui manque à la plupart des projets, est-ce qu'un agent est vraiment nécessaire ici.

Cours 05 — Évaluation des systèmes d'IA

Le module qui sépare un prototype d'un produit. Construire un jeu d'évaluation, définir des critères observables, utiliser un modèle comme juge en connaissant ses biais. Tests de non-régression sur les prompts. Pourquoi la démonstration qui marche ne prouve rien.

Cours 06 — Coût, latence et choix de modèle

Le calcul du coût par appel et par utilisateur. Mise en cache, réduction du contexte, traitement par lots. Petit modèle contre grand modèle, et le routage entre les deux. Latence perçue et diffusion en continu. Les arbitrages posés comme un problème d'ingénieur, chiffres à l'appui.

Cours 07 — Sécurité, injection et confidentialité

L'injection de prompt directe et indirecte, avec des cas concrets. La frontière entre instruction et donnée, et pourquoi elle ne tient pas toute seule. Fuite de données vers un fournisseur tiers, ce qu'on a le droit d'envoyer, journalisation et rétention. Filtrage en entrée et en sortie.

Cours 08 — Mise en production et capstone

Versionner prompts et configurations, observer un système non déterministe, tracer une conversation, recueillir un retour utilisateur. Capstone : un assistant qui répond sur les données de l'entrepôt construit dans les formations précédentes, avec sa récupération, ses outils, son jeu d'évaluation et ses garde-fous.

6. Ce qui reste à décider avant d'écrire

Trois points que le mandat du parcours a tranchés depuis l'écriture de ce plan : le corpus fil rouge est la documentation de Boréal, la porte d'entrée hors séquence passe par le kit 06, et un cours compte trois supports, théorie, labo et exercices corrigés.

Restent ouverts :

1. Le fournisseur de modèle. Une API commerciale, dépense faible mais réelle, un modèle local par Ollama, gratuit et plus lent, ou les deux avec une couche d'abstraction. Recommandation : les deux, l'abstraction étant elle-même une leçon.
2. La gestion du vieillissement. Les modèles, leurs prix et leurs limites changent tous les trimestres. Regrouper tout ce qui est daté dans un fichier unique, révisable seul, reste à confirmer.
3. La part du corpus des formations. Un assistant qui répond sur les supports du parcours lui-même serait un beau capstone, en plus du corpus de Boréal. À trancher au début de la rédaction.