

Table des matières

Cours 06 — Collaboration de données	1
Objectifs	1
Théorie	1
QCM — style examen (Cours 06)	4
Points clés à retenir	9

Cours 06 — Collaboration de données

Module 6/8 — Formation Snowflake (préparation SnowPro Core, COF-C03)

Comment lire ce module — Le domaine 5 pèse 10 %, le plus léger, mais il porte une des idées les plus distinctives de Snowflake : partager et dupliquer la donnée sans la copier. Comme le stockage est unique et découplé (Cours 01), on peut donner accès à la même donnée, en faire des clones instantanés, ou remonter le temps, le tout sans déplacer un octet. On ajoute la résilience (réplication, Fail-safe) et les places de marché.

Objectifs


À la fin de ce module, vous saurez :

- expliquer le Secure Data Sharing : fournisseur, consommateur, reader account ;
- décrire le clonage *zero-copy* et pourquoi il est instantané ;
- utiliser le Time Travel (revenir à un état passé, UNDROP) et connaître ses durées ;
- situer le Fail-safe et ce qui le distingue du Time Travel ;
- reconnaître la réplication et le failover (bascule) ;
- reconnaître Marketplace, data clean rooms et Native Apps.

Théorie

1. L'idée maîtresse : collaborer sans copier

Au Cours 01, une seule copie des données vit dans le stockage, séparée du calcul. Conséquence directe et puissante : donner accès à cette donnée ne demande aucune copie. Deux comptes peuvent lire les mêmes octets ; un « clone » n'est qu'un nouveau jeu de pointeurs vers les mêmes micro-partitions. Presque tout ce module découle de là.



une seule copie · aucun transfert · lecture LIVE chez le fournisseur

Un compte fournisseur expose une base par un partage ; plusieurs comptes consommateurs la lisent en lecture seule, sur une seule copie et sans transfert.

2. Le Secure Data Sharing

Le partage sécurisé de données laisse un compte fournisseur (*provider*) exposer des objets à un compte consommateur (*consumer*), sans copie ni transfert : le consommateur lit la donnée live du fournisseur.

- Le fournisseur crée un share (partage) et y accorde des objets (base, schéma, tables, vues sécurisées).
- Le consommateur monte le share comme une base en lecture seule : il ne paie que le calcul qu'il utilise pour lire, et il ne stocke rien.
- Un reader account permet de partager avec quelqu'un qui n'est pas client Snowflake : le fournisseur crée pour lui un compte lecteur, qu'il gère et paie.

À retenir : rien n'est dupliqué, la donnée reste chez le fournisseur, et toute mise à jour est immédiatement visible du consommateur. On partage souvent via des vues sécurisées (Cours 01, section 7) pour ne montrer que le nécessaire.

Deux limites que l'examen aime, et qu'aucune intuition ne donne.

La première est géographique. Un partage direct ne franchit pas la frontière : il ne va qu'à un compte de la même région, chez le même fournisseur de cloud. Pour servir un consommateur ailleurs, le fournisseur réplique sa base dans un compte de la région visée, et partage depuis ce compte-là. Les listings, eux, ont leur propre mécanisme, qui remplit automatiquement les régions demandées.

La seconde tient à ce que le consommateur peut faire de la base qu'il monte, et la réponse est « presque rien d'autre que lire ». Elle est en lecture seule, ce qui se comprend, mais la restriction va plus loin : on ne peut ni la cloner, ni y faire du Time Travel, ni la répliquer, ni même en changer les commentaires. Le repartage, lui, dépend du fournisseur : il faut qu'il l'ait autorisé, et la colonne `resharing_settings` de `SHOW DATABASES` dit ce qu'il en est.

Piège — « Lecture seule » ne dit pas tout. Le clonage et le Time Travel ne modifient rien chez le fournisseur, et pourtant ils sont refusés au consommateur : ce qu'il monte n'est pas une copie de la base, c'est une vue sur le stockage d'un autre compte, et ce stockage ne lui appartient pas.

3. Le clonage *zero-copy*

Cloner, c'est créer une copie logique instantanée d'une table, d'un schéma ou d'une base :

```
CREATE TABLE ventes_bac CLONE ventes;
```

Le clone ne duplique pas le stockage : il pointe vers les mêmes micro-partitions que l'original. C'est instantané et gratuit en stockage au départ. Ensuite, copie sur écriture (*copy-on-write*) : dès que vous modifiez le clone (ou l'original), seules les partitions changées sont réécrites, et les deux divergent sans se gêner. Idéal pour un environnement de test sur des données de prod, sans les copier.

4. Le Time Travel

Le Time Travel permet de relire (ou restaurer) une table telle qu'elle était dans le passé, c'est le filet contre les erreurs :

```
SELECT * FROM ventes AT(OFFSET => -300);           -- telle qu'il y a 5 minutes
SELECT * FROM ventes BEFORE(STATEMENT => '<query_id>'); -- juste avant une requête
UNDROP TABLE ventes;                               -- ressusciter une table supprimée
```

- Fenêtre de rétention (`DATA_RETENTION_TIME_IN_DAYS`) : 1 jour en Standard, jusqu'à 90 jours en Enterprise+ (Cours 01, section 2). 0 à 1 pour les tables *transient* et temporaires.
- Usages : requêter un état passé (`AT/BEFORE`), recréer une table depuis ce passé, ou `UNDROP` un objet supprimé par erreur.

5. Le Fail-safe

Le Fail-safe est le dernier filet, après le Time Travel : 7 jours supplémentaires pendant lesquels seul le support Snowflake peut récupérer des données (tables permanentes uniquement).

	Time Travel	Fail-safe
Qui récupère	vous (<code>AT/BEFORE/UNDROP</code>)	Snowflake (support)

	Time Travel	Fail-safe
Durée	0–90 j (configurable)	7 j, fixe
But	annuler vos erreurs	catastrophe / dernier recours

Deux pièges d'examen : le Fail-safe n'est pas configurable et n'est pas un self-service ; et les tables `transient` et temporaires n'ont pas de Fail-safe, ce qui les rend moins chères (Cours 01, section 7).

6. Réplication et failover

Pour la continuité d'activité, Snowflake réplique bases (et comptes entiers) entre régions ou clouds, et permet un failover (bascule) vers la copie si la région primaire tombe :

- Réplication — copier une base ou un compte vers une autre région ou un autre cloud, en la tenant à jour.
- Failover / failback — basculer le trafic vers le secondaire (puis revenir), pour la reprise après sinistre. Fonctions avancées, Business Critical+ pour le failover de comptes. (*Reconnaître.*)

7. Aller plus loin : Marketplace, clean rooms, Native Apps

- Snowflake Marketplace — une place de marché où des fournisseurs publient des listings (jeux de données, services) que n'importe quel compte peut monter, soit le Secure Data Sharing à l'échelle publique. Il existe aussi des listings privés (partage ciblé).
- Data Clean Rooms — collaborer sur des données sensibles sans que chacun voie les données brutes de l'autre (on n'échange que des résultats agrégés, sous contrôle). Cas type : recoupement publicitaire entre deux entreprises.
- Native Apps (Cours 02, section 7) — leur distribution passe par le Marketplace : on empaquette logique et données en une application que d'autres comptes installent chez eux.

QCM — style examen (Cours 06)

Comment répondre — Faites les dix questions avant d'ouvrir le corrigé, qui commence à la page suivante. Une question à choix multiple dit combien de réponses cocher, comme à l'examen. Comptez une minute par question.

1. Un client vous demande un extrait quotidien de votre catalogue, en CSV. Vous lui proposez plutôt un partage. Qu'est-ce qui change pour lui ?
 - a. Il reçoit une copie de la base, rafraîchie chaque nuit chez lui.
 - b. Il monte la base en lecture seule, lit vos données à jour en direct, et ne paie que le calcul de ses lectures.
 - c. Il reçoit un export déposé dans son stage, qu'il charge ensuite lui-même.

- d. Il devient copropriétaire des tables partagées, et peut les modifier.
2. Votre compte est sur AWS au Canada, votre consommateur sur Google Cloud en Belgique. Le partage direct refuse de les relier.
- a. Le partage direct traverse les régions : c'est un réglage à activer sur le share.
 - b. Le consommateur doit ouvrir un reader account chez vous.
 - c. Il faut convertir la base au format Iceberg pour la rendre portable.
 - d. Il faut répliquer la base dans un compte de la région visée et partager depuis là ; un listing, lui, remplit les régions demandées de lui-même.
3. Le consommateur d'un partage veut cloner la base qu'il a montée, pour faire ses essais dessus.
- a. Impossible : une base montée ne se clone pas, ne remonte pas le temps et ne se réplique pas.
 - b. Possible : le clone est zero-copy, il ne coûte donc rien au fournisseur.
 - c. Possible si le fournisseur lui a accordé le repartage.
 - d. Possible à partir de l'édition Business Critical.
4. (choix multiple, sélectionnez-en DEUX) Deux de ces affirmations sur le clonage zero-copy sont exactes.
- a. Le clone copie d'emblée une part des micro-partitions, environ un dixième, pour s'amorcer.
 - b. Le clone pointe vers les mêmes micro-partitions que l'original : il est instantané et ne coûte rien au stockage au départ.
 - c. Modifier le clone laisse l'original intact : seules les partitions changées sont réécrites.
 - d. Le clonage ne vaut que pour une table, jamais pour un schéma ni pour une base.
5. Une mise à jour maladroite a écrasé une colonne il y a vingt minutes. Le compte est en Enterprise, la rétention est celle par défaut, et la transaction est validée depuis longtemps.
- a. Le Fail-safe : on ouvre un billet et le support restaure la table.
 - b. ROLLBACK, qui défait la transaction fautive.
 - c. Un `SELECT ... AT(OFFSET => -1200)` ou `BEFORE(STATEMENT => ...)`, dont on recrée la table.
 - d. Rien : en Enterprise, le Time Travel doit être demandé à la création de la table.
6. Un développeur affirme qu'il ira chercher lui-même, dans le Fail-safe, des données perdues il y a trois jours.
- a. Il se trompe : le Fail-safe n'est pas en libre-service, seul le support Snowflake y récupère, et il ne commence qu'après le Time Travel.

- b. Il a raison, avec UNDROP, tant qu'on est dans les sept jours.
 - c. Il a raison s'il prend le rôle ACCOUNTADMIN et un AT(OFFSET => ...).
 - d. Il se trompe : le Fail-safe précède le Time Travel, sa fenêtre est donc déjà passée.
7. Pour alléger la facture de stockage, une équipe veut basculer ses tables de travail, toutes rejouables, en transient. Qu'est-ce qu'elle abandonne ?
- a. Le clonage, qui demande une table permanente.
 - b. Le partage : une table transient ne s'expose pas.
 - c. Le Time Travel en entier, qui tombe à zéro.
 - d. Le Fail-safe, et un Time Travel qui plafonne désormais à un jour.
8. *(choix multiple, sélectionnez-en DEUX)* Deux besoins tombent ensemble : servir un partenaire qui n'est pas client de Snowflake, et publier un jeu de données au grand public. Deux réponses conviennent.
- a. Un reader account, que vous créez, gérez et payez, pour le partenaire sans compte.
 - b. Une data clean room, seule voie vers un partenaire qui n'a pas de compte.
 - c. Un export en Parquet vers le bucket du partenaire, rafraîchi chaque jour.
 - d. Un listing sur le Marketplace, qui porte le partage à l'échelle publique.
9. Deux entreprises veulent mesurer le recoupement de leurs clientèles sans se montrer leurs fichiers de clients.
- a. Un partage direct de la table des clients, en lecture seule, dans les deux sens.
 - b. Une data clean room, où l'on n'échange que des résultats sous contrôle.
 - c. Un clone de chaque table dans un compte tiers, qui fait le calcul.
 - d. Une vue sécurisée sur chaque fichier, partagée à l'autre partie.
10. L'entreprise veut pouvoir continuer à travailler si la région qui porte son compte tombe.
- a. Le Time Travel, qui remonte à l'état d'avant l'incident.
 - b. Un clone quotidien de la base, dans le même compte.
 - c. La réplication de la base vers une autre région, et la bascule vers le secondaire.
 - d. Le Fail-safe, qui garde sept jours de données chez Snowflake.

À lire après avoir répondu. Chaque réponse nomme la section à relire : ce que vous ratez ici vous dit quoi reprendre.

1. Réponse b. Le partage sécurisé ne transfère rien : le consommateur monte une base en lecture seule sur votre stockage, voit vos mises à jour aussitôt, et ne paie que le calcul de ses lectures. Les options a et c décrivent une copie, c'est-à-dire ce que le partage remplace. L'option d confond l'accès et la propriété : la donnée reste chez vous (section 2).
2. Réponse d. Un partage direct ne sort pas de sa région ni de son fournisseur de cloud : pour servir ailleurs, on réplique la base dans un compte de la région visée et on partage depuis ce compte, ou l'on passe par un listing, qui a son propre remplissage automatique. L'option a invente un réglage. Le reader account de l'option b sert un partenaire sans compte, pas une autre région. L'option c change de format de table sans rien régler (section 2).
3. Réponse a. Ce que le consommateur monte n'est pas une copie, c'est une vue sur le stockage d'un autre compte : il ne peut ni cloner, ni remonter le temps, ni répliquer, ni même changer les commentaires. Le repartage de l'option c est une autre permission, qui ne débloque pas le clonage. Les options b et d cherchent une condition, alors que la restriction est de principe (section 2).
4. Réponses b et c. Le clone pointe vers les mêmes micro-partitions, ce qui le rend instantané et gratuit au départ, puis la copie sur écriture fait diverger les deux sans qu'ils se gênent. L'option a invente une copie partielle. L'option d oublie qu'on clone aussi un schéma ou une base entière (section 3).
5. Réponse c. Vingt minutes, c'est très en deçà de la rétention d'un jour qui s'applique par défaut, y compris en Enterprise : le Time Travel lit l'état d'avant et permet de recréer la table. ROLLBACK de l'option b ne vaut que dans une transaction ouverte. Le Fail-safe de l'option a ne commence qu'après le Time Travel. L'option d invente une activation à la création (section 4).
6. Réponse a. Le Fail-safe vient après le Time Travel, dure sept jours fixes et n'est pas en libre-service : seul le support Snowflake y récupère des données, et seulement pour des tables permanentes. Les options b et c rendent au développeur des outils du Time Travel. L'option d inverse l'ordre des deux filets (section 5).
7. Réponse d. Une table `transient` n'a pas de Fail-safe et son Time Travel plafonne à un jour : c'est exactement ce qu'on échange contre un stockage moins cher, et c'est raisonnable pour des données rejouables. Les options a et b inventent des restrictions sur le clonage et le partage. L'option c exagère : le Time Travel n'est pas supprimé, il est raccourci (section 5).
8. Réponses a et d. Le reader account sert un partenaire qui n'est pas client de Snowflake, le fournisseur le créant et le payant ; le Marketplace porte le partage à l'échelle publique, par des listings. L'option b détourne la clean room, qui sert à calculer sans exposer, pas à pallier l'absence de compte. L'option c retombe dans la copie de fichiers (sections 2 et 7).
9. Réponse b. Une data clean room fait collaborer deux parties sur des données sensibles sans que l'une voie les données brutes de l'autre : on n'échange que des résultats, sous contrôle. Les options a et d donnent accès aux lignes elles-mêmes, ce que l'énoncé refuse. L'option c déplace le problème dans un troisième compte, où les fichiers seraient tous les deux visibles (section 7).

10. Réponse c. La continuité d'activité passe par la réplication vers une autre région, puis la bascule vers le secondaire si la primaire tombe. Le Time Travel et le Fail-safe, aux options a et d, protègent d'une erreur de données, pas de la perte d'une région. Le clone de l'option b reste dans le même compte, donc dans la même région (section 6).

Points clés à retenir

- Idée maîtresse : le stockage unique et découplé permet de collaborer sans copier, et le partage, le clonage et le Time Travel en découlent.
- Secure Data Sharing : le fournisseur expose un share ; le consommateur le lit live, en lecture seule, sans copie ; reader account pour les non-clients Snowflake.
- Ses deux limites : un partage direct reste dans la région et le cloud du fournisseur (pour en sortir, on réplique, ou on passe par un listing) ; la base montée ne se clone pas, ne remonte pas le temps, ne se réplique pas, et ne se repartage que si le fournisseur l'a autorisé.
- Clonage zero-copy : CLONE instantané, pointe vers les mêmes micro-partitions ; copy-on- write à la première modification.
- Time Travel : AT/BEFORE/UNDROP ; rétention 1 j (Standard) → 90 j (Enterprise+). Fail-safe : 7 j fixes après, récupérable par Snowflake seul, tables permanentes uniquement (pas les *transient*).
- Résilience : réplication entre régions/clouds + failover (Business Critical+ pour les comptes).
- À l'échelle : Marketplace (listings publics ou privés), data clean rooms (collaboration sans exposer le brut), Native Apps (distribution, voir le Cours 02).