

Table des matières

Exercices 00 — Mettre en place l'environnement.....	1
Questions courtes	1
Questions pratiques	2
Diagnostics	3
Questions à développer	3
Mises en situation	3

Exercices 00 — Mettre en place l'environnement

Comment travailler ces exercices. Ce module est un module d'installation, et ses exercices le reflètent : ils portent moins sur le SQL que sur la compréhension de ce que vous venez de monter. Ils sont volontairement moins nombreux que ceux des autres cours. Faites-les une fois l'installation terminée, avant d'aborder le Cours 01 : s'ils vous coûtent, c'est le signe qu'une pièce de l'environnement vous échappe encore, et il vaut mieux le découvrir maintenant. Comptez deux heures et quart pour y répondre, le corrigé non compris.

Les repères de terrain. Un énoncé marqué [OLTP] porte sur PostgreSQL et la base Adventureworks. Un énoncé marqué [OLAP] porte sur DuckDB et l'entrepôt adventureworksdw.duckdb. Sans marque, la question vaut pour les deux.

Le corrigé est dans `Corrige_00.md`. Répondez à l'énoncé en entier avant de l'ouvrir.

Questions courtes

1. Les deux mondes. Que veulent dire OLTP et OLAP, et quelle est la vocation de chacun en une phrase ?
2. Une entreprise, deux bases. AdventureWorks existe en version DW et en version OLTP. S'agit-il de deux entreprises, de deux périodes, ou de deux arrangements ? Expliquez.
3. Le rangement. Comment sont rangées les données dans chacune des deux versions, et quel problème chaque rangement cherche-t-il à résoudre ?
4. Le nombre de tables. La version OLTP compte 68 tables, la version DW beaucoup moins. Ce n'est pas parce qu'elle contient moins d'information : expliquez d'où vient l'écart.
5. [OLAP] Ce qu'il faut nommer. Pour atteindre une table de l'entrepôt, vous désignez trois niveaux. Nommez-les, du plus englobant au plus précis, et dites où chacun se trouve sur votre disque.

6. [OLAP] Une base dans un fichier. DuckDB ne demande ni service, ni port, ni mot de passe. Donnez deux conséquences pratiques de ce choix, une agréable et une contraignante.
 7. Créer puis remplir. Le script de la Partie 2 fait deux choses de suite, dans cet ordre. Nommez-les et dites pourquoi elles sont distinctes.
 8. Le format des données. Sous quelle forme AdventureWorks est-elle distribuée, et qu'est-ce que cela implique sur ce que fait réellement une installation de base de données d'exemple ?
 9. La vérification. Après un chargement, quelle est la première requête à écrire, et pourquoi est-elle plus utile qu'un coup d'œil à la liste des tables ?
 10. [OLTP] Le port. Quel port PostgreSQL utilise-t-il par défaut, et à quoi sert de le connaître ?
 11. [OLTP] Le mot de passe. Pour quel utilisateur l'installateur vous demande-t-il un mot de passe, et pourquoi insiste-t-on pour que vous le notiez ?
 12. [OLTP] La commande introuvable. Vous tapez `psql --version` et le terminal répond que la commande n'est pas reconnue. Est-ce que l'installation a raté ? Expliquez, dites ce qu'il faut faire, et pourquoi passer à pgAdmin ne suffit pas ici.
 13. [OLTP] Le portage. AdventureWorks est née pour SQL Server. Pourquoi faut-il un portage pour la charger dans PostgreSQL, plutôt que de lancer le script Microsoft tel quel ?
 14. La casse, des deux côtés. DuckDB ignore la casse des identifiants, PostgreSQL replie les identifiants non protégés en minuscules. Dites ce que chacun fait de `SELECT ListPrice FROM DimProduct`, et quelle erreur concrète vous attend au Cours 02 si vous l'oubliez.
 15. Les deux clients. On propose pgAdmin, DBeaver ou `psql` pour PostgreSQL, et la ligne de commande pour DuckDB. Qu'est-ce qu'un client, et le choix change-t-il quoi que ce soit aux requêtes que vous écrivez ?
1. L'ordre de montage. Pourquoi la formation vous fait-elle monter l'entrepôt d'abord, et à partir de quel cours PostgreSQL devient-il indispensable ?
 2. Les chemins relatifs. Le script de montage se lance depuis le dossier des fichiers `.csv`, et non depuis le dossier où il est rangé. Expliquez pourquoi, et dites quel message vous recevez si vous vous trompez de dossier.

Questions pratiques

Ces énoncés se tapent vraiment, dans votre environnement fraîchement monté.

- P1. [OLAP] L'inventaire. Écrivez les deux commandes qui listent les tables chargées dans le schéma `dbo` de l'entrepôt, et vérifiez que celles du Cours 01 y sont.
- P2. [OLAP] Le compte de contrôle. Écrivez, en une seule requête, le nombre de lignes de `DimProduct` et celui de `FactInternetSales`. Notez les deux nombres quelque part : ils vous serviront de repère tout au long de la formation.
- P3. [OLTP] Le même inventaire, de l'autre côté. Listez les schémas de la base `Adventureworks`, puis les tables du schéma `production`. Comparez le nombre de tables avec celui de l'entrepôt.

P4. [OLTP] Le compte de contrôle, de l'autre côté. Comptez les lignes de `production.product` et de `sales.salesorderdetail`.

P5. La même question, deux fois. Comptez les produits sur les deux bases, avec la requête appropriée à chacune. Les deux nombres sont proches sans être identiques : proposez au moins deux explications possibles avant de lire le corrigé.

P6. (avancé) L'ordre de grandeur. Sur chacune des deux bases, trouvez la table qui contient le plus de lignes. Puis dites ce que la réponse vous apprend sur la vocation de chaque base.

Diagnostics

On vous décrit une situation d'installation qui tourne mal. Dites ce qui se passe et comment vous vous y prenez.

E1. [OLAP] Le script de montage s'est déroulé sans une erreur, et le tableau final affichait bien 60 398 ventes. Vous rouvrez l'entrepôt le lendemain et tapez `SELECT COUNT(*) FROM DimProduct`; le moteur répond `Table with name DimProduct does not exist!`. Donnez la cause la plus probable, la commande qui règle le problème, et une deuxième cause possible si la première ne s'applique pas.

E2. [OLAP] Une collègue vous écrit : son script Python refuse d'ouvrir l'entrepôt sur un `IO Error: Cannot open file`, alors que le fichier est bien là et qu'elle a les droits dessus. Elle en conclut que le fichier est corrompu. Dites ce qui se passe le plus probablement, pourquoi son explication est peu plausible, et ce que le message lui disait déjà.

E3. [OLTP] Vous avez lancé `install.sql` et le chargement s'est arrêté au milieu avec une erreur de fichier introuvable. Vous relancez le script : cette fois, ce sont des erreurs de table déjà existante qui défilent. Expliquez ce qui se passe, dites pourquoi relancer bêtement ne peut pas marcher, et donnez la marche à suivre. Puis dites pourquoi le script de la Partie 2, lui, se rejoue sans dommage.

Questions à développer

Un court paragraphe de raisonnement, pas un mot juste.

A. Pourquoi une base d'exemple. On aurait pu enseigner le SQL sur trois tables inventées de dix lignes chacune. Expliquez ce qu'apporte une vraie base d'exemple comme AdventureWorks, et ce qu'elle coûte. Traitez au moins l'installation, le réalisme des données et la transférabilité de ce que vous apprenez vers votre futur emploi.

B. Le local et le distant. DuckDB tient dans un fichier sur votre disque ; les entrepôts d'entreprise, Snowflake, BigQuery, Databricks, tournent sur des machines que vous ne verrez jamais. Décrivez ce que cette différence change concrètement : sur ce que vous contrôlez, sur ce qui peut casser, sur ce que ça coûte, et sur ce qui se passe si vous n'y touchez pas pendant deux mois. Dites ensuite ce qu'elle ne change pas, et pourquoi c'est ce qui justifie d'apprendre ici.

Mises en situation

On décrit une situation et on vous demande une décision, pas une commande.

M1. Le poste de travail partagé. Vous devez faire suivre cette formation à trois personnes de votre équipe, sur des postes gérés par le service informatique, où personne n'a les droits d'administrateur et où l'installation de logiciels demande une demande formelle de deux semaines.

Décrivez la solution que vous proposeriez, en traitant séparément le cas de DuckDB et celui de PostgreSQL. Dites ce que vous perdez par rapport à l'installation décrite dans ce module, et à quel cours cette perte se fera sentir pour la première fois. Terminez en disant ce que vous demanderiez au service informatique, en une seule demande, pour que le reste tienne.

M2. Le jour où il faut porter tout ça. Six mois après la formation, votre employeur met en service un entrepôt Snowflake et vous demande d'y porter les requêtes d'analyse que vous aviez écrites sur votre poste. Vous avez une centaine de requêtes, un entrepôt local de 25 Mo, et deux semaines.

Décrivez ce que vous faites, dans l'ordre. Distinguez trois catégories : ce qui se transporte tel quel, ce qui demande une retouche connue d'avance, et ce qui n'a pas d'équivalent et doit être repensé. Dites ensuite quelle habitude prise dès ce Cours 00 rend ce portage possible en deux semaines plutôt qu'en deux mois, et pourquoi c'est une leçon qui dépasse largement le cadre d'une formation.