

Table des matières

Exercices 02 — Le langage SQL : lire et calculer	1
Questions courtes	1
Questions pratiques	2
Diagnostics	3
Questions à développer	4
Mises en situation	5

Exercices 02 — Le langage SQL : lire et calculer

Comment travailler ces exercices. Répondez à chaque énoncé seul, puis vérifiez. Les questions courtes vérifient que le vocabulaire est en place ; les pratiques vous font écrire du SQL, tantôt sur le transactionnel, tantôt sur l'entrepôt ; les diagnostics vous montrent du code qui cloche ; les mises en situation vous demandent de choisir une approche et de la défendre. Comptez quatre heures et quart pour y répondre, le corrigé non compris.

Les repères de terrain. Un énoncé marqué [OLTP] se traite dans PostgreSQL sur Adventureworks (schémas production, person, sales, humanresources). Un énoncé marqué [OLAP] se traite dans DuckDB sur l'entrepôt adventureworksdw.duckdb (schéma dbo). Sans marque, la question vaut pour les deux, ou se passe sur le moteur que l'énoncé nomme.

Le corrigé est dans Corrigé_02.md. Répondez à l'énoncé en entier avant de l'ouvrir : c'est en butant sur une question qu'on découvre ce qu'on avait lu sans le comprendre.

Questions courtes

1. L'alias. À quoi sert AS dans un SELECT, et pourquoi PostgreSQL refuse-t-il qu'on se serve de cet alias dans le WHERE ?
2. Le palmarès instable. Que garantit SELECT ... ORDER BY prix DESC LIMIT 5 quand plusieurs lignes ont le même prix, et que faut-il ajouter pour que le résultat ne change pas d'une exécution à l'autre ?
3. Le tri du texte. Dans une colonne de texte, pourquoi « 64 » se range-t-il après « 410 », et quelles sont les deux façons d'obtenir l'ordre numérique ?
4. La priorité. Dans quel ordre le moteur applique-t-il NOT, AND et OR ? Réécrivez a OR b AND c avec les parenthèses qu'il sous-entend.
5. BETWEEN et l'horodatage. Pourquoi BETWEEN '2026-03-01' AND '2026-03-31' perd-il des lignes sur une colonne TIMESTAMP, et quelle écriture le remplace ?

6. `ILIKE`. Qu'est-ce que `ILIKE` ignore, qu'est-ce qu'il n'ignore pas, et sur quels moteurs de la formation existe-t-il ?
7. L'ordre des `WHEN`. Que fait le moteur quand plusieurs conditions d'un même `CASE` sont vraies pour une ligne, et quelle règle d'écriture en découle ?
8. Le `CASE` simple. Pourquoi `CASE couleur WHEN NULL THEN 'aucune' ... END` ne rend-il jamais « aucune » ? Donnez l'écriture qui fonctionne.
9. `TRY_CAST`. Que fait-il de plus que `CAST`, sur quel type de valeur de départ fonctionne-t-il, et quel risque introduit-il ?
10. La division entière. Que vaut `9 / 12` sur PostgreSQL et sur DuckDB ? Écrivez une expression qui donne 0,75 sur les deux.
11. La concaténation. Que vaut `'Jean' || NULL` ? Écrivez le nom complet `prenom second_prenom nom` d'une façon qui fonctionne sur les deux moteurs quand le second prénom manque.
12. L'âge. Pourquoi `DATEDIFF(year, date_naissance, CURRENT_DATE)` donne-t-il parfois un an de trop, et à quelles personnes ?
13. Les trois `COUNT`. Quelle différence entre `COUNT(*)`, `COUNT(colonne)` et `COUNT(DISTINCT colonne)` ? Donnez un exemple où les trois diffèrent.

Questions pratiques

Écrivez la requête complète avant de regarder. Quand un énoncé existe en deux versions, faites les deux et comparez-les : c'est là que le contraste entre les deux mondes devient concret.

- P1. [OLAP] Le palmarès des prix. Affichez les dix lignes de `DimProduct` au prix de liste le plus élevé, sans aucune ligne sans prix, et avec un ordre stable entre les ex aequo.
- P2. [OLTP] Le même palmarès. Reproduisez P1 sur `production.product`, en écartant les pièces dont le prix est la sentinelle 0.
- P3. [OLTP] Les commandes du week-end. Comptez les commandes de l'année 2024 passées un samedi ou un dimanche. Utilisez la convention ISO du jour de la semaine et un intervalle demi-ouvert sur l'année.
- P4. [OLAP] Les clients de 1970. Comptez les clients nés en 1970 dont le prénom commence par la lettre J, quelle que soit la casse.
- P5. [OLAP] La gamme en clair. Pour chaque code de `ProductLine`, affichez un libellé (R pour route, M pour montagne, T pour tourisme, S pour standard, « sans gamme » sinon) et le nombre de lignes. Méfiez-vous du type de la colonne.
- P6. [OLTP] La même gamme. Reproduisez P5 sur `production.product`, et dites ce qui change dans l'écriture.
- P7. [OLTP] Le taux de vente en ligne par année. Pour chaque année de commande, affichez le pourcentage de commandes passées en ligne, arrondi à une décimale.
- P8. [OLAP] L'annuaire. Affichez les cinq premiers employés dans l'ordre alphabétique, sous la forme « TREMBLAY, Sophie » : le nom en majuscules, une virgule, le prénom tel quel.

P9. [OLTP] (avancé) L'identifiant et le courriel. Pour chaque employé, comparez l'identifiant de connexion sans son domaine (ken0 dans adventure-works\ken0) à la partie de son adresse courriel qui précède l'arobase. Comptez les employés dont les deux concordent. L'adresse est dans person.emailaddress, liée à l'employé par businessentityid.

P10. [OLAP] L'âge des clients. Calculez l'âge moyen des clients au 1er janvier 2014, arrondi à une décimale, une fois avec DATEDIFF('year', ...) seul et une fois avec la correction du labo. Commentez l'écart.

P11. [OLTP] L'âge à l'embauche. Calculez l'âge moyen des employés au jour de leur embauche, arrondi à une décimale, une fois par soustraction des années et une fois avec AGE.

P12. [OLAP] Les ventes par jour de la semaine. Pour chaque jour, du lundi au dimanche selon la convention ISO, affichez le nombre de commandes et le montant des ventes.

P13. [OLTP] (avancé) Le mois record. Trouvez le mois de 2024 où le montant des commandes (subtotal) a été le plus élevé. Affichez le mois sous forme de date, le nombre de commandes et le montant arrondi au cent.

Diagnostics

On vous montre du code qui ne fait pas ce que son auteur croit. Dites ce qui cloche, pourquoi, et donnez le correctif.

E1. Un analyste veut les dix produits les plus chers. Il écrit sa requête sur DuckDB, où elle rend les vélos attendus :

```
SELECT EnglishProductName, ListPrice
FROM dbo.DimProduct
ORDER BY ListPrice DESC
LIMIT 10;
```

Une collègue lance la même requête sur une copie de l'entrepôt chargée dans PostgreSQL. Elle obtient dix lignes au prix vide et conclut que sa copie est mal chargée. Expliquez ce qu'elle voit, pourquoi DuckDB ne le montrait pas, et corrigez la requête pour qu'elle soit juste sur les deux.

E2. [OLTP] Une développeuse calcule la part des commandes en ligne :

```
SELECT COUNT(CASE WHEN onlineorderflag THEN 1 END) / COUNT(*) AS part_en_ligne
FROM sales.salesorderheader;
```

Le résultat vaut 0, alors que la très grande majorité des commandes sont en ligne. Expliquez et corrigez.

E3. [OLAP] Un rapport compte les produits de la gamme montagne :

```
SELECT COUNT(*) AS gamme_montagne
FROM dbo.DimProduct
WHERE ProductLine = 'M';
```

Le rapport affiche zéro depuis sa création, et personne ne s'en est inquiété. Dites pourquoi la requête ne trouve rien, comment vous l'auriez détecté, et corrigez.

E4. Un tableau de bord mensuel filtre ainsi les commandes de mars :

```
WHERE date_commande BETWEEN '2026-03-01' AND '2026-03-31'
```

La colonne date_commande est un TIMESTAMP. Le tableau de bord a été juste pendant deux ans, puis il a commencé à sous-estimer chaque mois. Rien n'a été modifié dans la requête. Proposez une explication, et corrigez.

E5. [OLAP] Une liste d'envoi construit le nom complet des clients :

```
SELECT FirstName || ' ' || MiddleName || ' ' || LastName AS nom_complet
FROM dbo.DimCustomer;
```

Le service des communications signale que des milliers d'enveloppes partent sans nom. Combien, et pourquoi ? Corrigez.

E6. [OLAP] Les ressources humaines veulent les employés embauchés à 30 ans ou plus :

```
SELECT FirstName, LastName
FROM dbo.DimEmployee
WHERE DATEDIFF('year', BirthDate, HireDate) >= 30;
```

Plusieurs employés embauchés à 29 ans figurent dans la liste. Expliquez et corrigez.

E7. Une étiquette de prix classe les produits :

```
CASE
  WHEN prix > 100 THEN 'moyen'
  WHEN prix > 1000 THEN 'cher'
  ELSE 'bon marché'
END
```

Aucun produit n'est jamais « cher ». Expliquez et corrigez.

Questions à développer

Un court paragraphe de raisonnement, pas un mot juste.

A. L'échec bruyant et le NULL silencieux. PostgreSQL fait échouer une requête entière pour une seule valeur non convertible, là où TRY_CAST rend NULL et continue. Défendez d'abord l'échec bruyant, puis la conversion tolérante. Dites ensuite ce que vous exigeriez de tout code qui emploie TRY_CAST, et pourquoi.

B. La frontière et la durée. DATEDIFF(year, ...) compte des passages au 1er janvier ; AGE compte des années écoulées. Expliquez la différence sur un exemple, puis donnez deux questions métier pour lesquelles la frontière est la bonne réponse et deux pour lesquelles c'est la durée.

C. Le type fait partie de la donnée. Un code de gamme se filtre juste sur le transactionnel et échoue sur l'entrepôt ; un numéro national se trie mal en texte, mais ne doit pas pour autant devenir un nombre. Tirez de ces deux cas une règle pour choisir le type d'une colonne, et une règle pour interroger une colonne dont vous n'avez pas choisi le type.

Mises en situation

On décrit une entreprise et une question métier. À vous de choisir l'approche, de l'écrire, et surtout de la justifier. Il y a plusieurs bonnes réponses, mais il y a des réponses indéfendables.

M1. Clinique vétérinaire des Laurentides, la facture au cent près. La clinique calcule ses factures dans une base où les montants des actes sont rangés en `FLOAT`. Les taxes se calculent ligne par ligne, puis se totalisent. Chaque mois, quelques factures diffèrent d'un cent de ce que la comptable recalcule à la main, et le vérificateur externe a noté l'écart.

Expliquez d'où peut venir ce cent. Proposez un type pour les montants, et dites à quel moment arrondir : ligne par ligne, ou sur le total. Prenez position, sachant que les deux choix ne donnent pas toujours le même total, et dites ce que vous répondez au propriétaire qui demande pourquoi « un ordinateur ne sait pas compter ».

M2. Club de natation de Rimouski, les numéros de membre. Le club attribue des numéros de membre sur six chiffres, dont certains commencent par des zéros, comme 004217. Un bénévole propose de les ranger en `INTEGER` « pour économiser de la place et pouvoir les trier ». Un autre préfère du texte.

Tranchez. Traitez le tri, les zéros en tête, les recherches par début de numéro, et le jour où la fédération imposera un préfixe de lettres. Dites comment vous obtiendriez quand même un tri numérique si on vous le demandait.

M3. Distributeur alimentaire de Drummondville, le rapport qui se met à mentir. Le rapport mensuel des livraisons filtre chaque mois avec `BETWEEN` sur la date de livraison. L'ancien système ne gardait que la date ; le nouveau, installé en juillet, garde l'heure de passage du camion. Depuis, les livraisons de fin de mois semblent baisser.

Expliquez le mécanisme, puis décrivez comment vous le prouveriez avec une requête avant de toucher au rapport. Proposez la correction, et dites comment vous empêcheriez qu'un rapport voisin, écrit par quelqu'un d'autre, ne tombe dans le même piège.

M4. (avancé) Centre d'appels de Trois-Rivières, les numéros de téléphone. Le centre fusionne trois listes de clients : l'une écrit 819-555-0142, l'autre (819) 555-0142, la troisième 1 819 555 0142. Il faut dédoubler les clients par numéro de téléphone avant une campagne.

Décrivez la normalisation en SQL, étape par étape, avec les fonctions du cours. Dites comment vous vérifieriez qu'elle couvre toutes les lignes, ce que vous feriez des numéros qui résistent, et pourquoi vous garderiez le numéro d'origine à côté du numéro normalisé.