

Table des matières

Exercices 06 — Agrégation avancée et pivots	1
Questions courtes	1
Questions pratiques	3
Diagnostics	4
Questions à développer	5
Mises en situation	5

Exercices 06 — Agrégation avancée et pivots

Comment travailler ces exercices. Répondez à chaque énoncé seul, puis vérifiez. Les questions courtes vérifient que le vocabulaire est en place ; les pratiques vous font écrire du SQL, tantôt sur le transactionnel, tantôt sur l'entrepôt ; les diagnostics vous montrent du code qui cloche ; les mises en situation vous demandent de choisir une approche et de la défendre. Comptez quatre heures et quart pour y répondre, le corrigé non compris.

Les repères de terrain. Un énoncé marqué [OLTP] se traite dans PostgreSQL sur Adventureworks (schémas sales, production, person). Un énoncé marqué [OLAP] se traite dans DuckDB sur adventureworksdw.duckdb, ouvert par `USE dbo;`. Sans marque, la question vaut pour les deux.

Le corrigé est dans `Corrige_06.md`. Répondez à l'énoncé en entier avant de l'ouvrir : c'est en butant sur une question qu'on découvre ce qu'on avait lu sans le comprendre.

Questions courtes

1. Le manque du `GROUP BY`. Qu'est-ce qu'un `GROUP BY` ordinaire ne sait pas produire, et que les extensions de ce cours produisent en une seule passe ?
2. La solution naïve. Avant `ROLLUP`, comment obtenait-on le détail et ses sous-totaux ? Donnez deux défauts de cette méthode.
3. `GROUPING SETS`. Que désigne une paire de parenthèses vides `()` dans la liste, et pourquoi la notation est-elle cohérente ?
4. `ROLLUP`. Écrivez le `GROUPING SETS` équivalent à `ROLLUP (a, b, c)`, dans l'ordre.
5. L'ordre compte. Qu'est-ce qui change entre `ROLLUP (annee, pays)` et `ROLLUP (pays, annee)` ?
6. `CUBE`. Combien de niveaux produit `CUBE` sur `n` colonnes, et quelle conséquence pratique en tirez-vous avant d'y mettre quatre colonnes ?

7. Choisir. Vous voulez le détail par catégorie et sous-catégorie, plus le sous-total par catégorie, plus le total. Lequel des trois mots-clés prenez-vous, et pourquoi pas les deux autres ?
 8. Le NULL ambigu. Dans un résultat de ROLLUP, qu'est-ce qui distingue une ligne où pays vaut NULL parce que c'est un sous-total d'une ligne où le pays est réellement inconnu ?
 9. GROUPING(). Que renvoie cette fonction, et sur quel argument s'applique-t-elle ?
 10. Le tri des totaux. Pourquoi trie-t-on souvent par GROUPING(col) avant de trier par la colonne elle-même ?
 11. L'agrégat conditionnel. Expliquez le mécanisme de SUM(CASE WHEN cond THEN mesure END) en une phrase, en disant précisément ce que devient une ligne qui ne remplit pas la condition.
 12. Le ELSE absent. Pourquoi n'écrit-on pas ELSE 0 dans ce CASE ? Dans quel cas le choix change-t-il le résultat ?
 13. Compter sous condition. Écrivez l'expression qui compte les lignes remplissant une condition, et dites pourquoi COUNT(CASE WHEN cond THEN 1 END) ne se remplace pas par COUNT(*).
 14. [OLTP] La clause FILTER. Écrivez l'équivalent de la question 11 avec FILTER, et donnez son avantage.
 15. La portabilité de FILTER. FILTER passe-t-il sur les deux moteurs de cette formation ? Est-ce pour autant une écriture qu'on peut employer sans y penser ? Dites ce qui rend cette dette particulièrement discrète.
 16. PIVOT. Nommez les trois choses qu'il faut fournir à un PIVOT sous sa forme standard, et dites laquelle ne peut pas venir des données. L'entrepôt offre une seconde forme qui lève cette contrainte : dites ce qu'elle coûte en échange.
1. Le piège de la sous-requête source. Pourquoi ne met-on que les colonnes utiles dans la sous-requête d'un PIVOT, et que se passe-t-il si on en laisse une de trop ?
 2. UNPIVOT. Que fait-il, à quoi sert le format qu'il produit, et quel piège guette celui qui replie un tableau large reçu d'ailleurs ?
 3. [OLTP] L'absence de PIVOT. PostgreSQL n'a pas PIVOT. Donnez la raison technique, puis les trois voies possibles.
 4. Le format long. Qu'est-ce que c'est, et quel argument décisif joue en sa faveur quand la liste des colonnes peut changer ?
 5. [OLTP] Le mot réservé. Quelle colonne d'AdventureWorks OLTP oblige à écrire des guillemets doubles dans ce cours, et pourquoi ?
 6. [OLTP] L'alias dans le ROLLUP. PostgreSQL accepte GROUP BY ROLLUP (annee, pays) quand annee est un alias défini dans le SELECT. Pourquoi ne pas compter sur cette tolérance, et quelle construction du Cours 05 rend la question sans objet ?
 7. Le pays en clair. Sur l'entrepôt, le nom du pays est une colonne de la dimension ; sur le transactionnel, c'est un code à joindre. Qu'est-ce que cet écart dit du travail d'alimentation ?

8. Ce qui est standard. Parmi ROLLUP, CUBE, GROUPING SETS, GROUPING(), FILTER, PIVOT, DISTINCT ON et QUALIFY, dites lesquels sont présents des deux côtés, et rangez les autres par moteur.

Questions pratiques

Écrivez la requête complète avant de regarder. Quand un énoncé existe en deux versions, faites les deux et comparez-les : c'est là que le contraste entre les deux mondes devient concret.

P1. [OLAP] La cascade continent puis pays. Avec ROLLUP, affichez les ventes par continent (SalesTerritoryGroup) puis par pays, avec les sous-totaux par continent et le total général.

P2. [OLTP] La même cascade, l'autre voie. Reproduisez P1 sur le transactionnel. Vous aurez besoin de deux jointures de plus et des guillemets du labo.

P3. [OLAP] Les quantités par continent, en colonnes. Comme en 2.3 du labo, mais affichez la quantité vendue (SUM(OrderQuantity)) par année, une colonne par continent.

P4. [OLTP] Les quantités par continent, avec FILTER. La même chose, écrite avec la clause FILTER plutôt qu'avec des CASE.

P5. [OLAP] Le pivot par catégorie de produit. Faites pivoter les catégories (EnglishProductCategoryName : 'Bikes', 'Components', 'Clothing', 'Accessories') en colonnes, les années en lignes. Vous devrez joindre DimProduct, DimProductSubcategory et DimProductCategory.

P6. [OLTP] Le même tableau, sans PIVOT. Reproduisez P5 sur le transactionnel, avec l'écriture que vous jugez la meilleure. Justifiez votre choix en une phrase.

P7. Le total étiqueté. Reprenez P1 et remplacez les NULL de sous-total par « Tous continents » et « Tous pays » à l'aide de GROUPING(). Donnez la version de votre terrain préféré.

P8. La part dans le sous-total. Pour chaque pays, affichez ses ventes et sa part dans les ventes de son continent. Deux approches sont possibles, l'une avec ROLLUP, l'autre avec une fonction de fenêtrage du Cours 04 : donnez celle que vous préférez et dites pourquoi.

P9. [OLAP] Le tableau croisé à deux mesures. Affichez, par année, le montant et la quantité pour chacun des trois continents, soit six colonnes de mesure. Dites ce que PIVOT vous impose ici.

P10. (avancé) Le comptage sous conditions multiples. Pour chaque année, affichez le nombre de commandes distinctes, le nombre de celles à plus de 1 000 dollars, et la proportion des secondes dans les premières. Une seule passe sur les données.

P11. (avancé) Le grain qui dérape. Écrivez volontairement le PIVOT de P5 avec une colonne de trop dans la sous-requête source, constatez le résultat, puis expliquez précisément le mécanisme qui produit ces lignes supplémentaires. Donnez ensuite la règle que vous en tirez.

P12. (avancé) Le pivot dynamique. On vous demande un tableau croisé dont les colonnes sont les sous-catégories de produits, sans en écrire aucune en dur, sachant que la liste peut changer. Écrivez-le sur l'entrepôt, qui sait le faire, et comptez les colonnes obtenues : le compte devrait vous surprendre, dites pourquoi. Expliquez ensuite pourquoi PostgreSQL refuse par principe de faire la même chose, et ce que son refus protège. Terminez en proposant deux solutions défendables pour un rapport qui doit durer, et dites laquelle vous mettriez en production.

Diagnostics

On vous montre du code qui ne fait pas ce que son auteur croit. Dites ce qui cloche, pourquoi, et donnez le correctif.

E1. Un analyste veut le détail par année et par pays, plus le sous-total par année. Il écrit :

```
SELECT d.CalendarYear AS annee, t.SalesTerritoryCountry AS pays,
       SUM(f.SalesAmount) AS ventes
FROM   dbo.FactInternetSales AS f
JOIN   dbo.DimDate           AS d ON d.DateKey = f.OrderDateKey
JOIN   dbo.DimSalesTerritory AS t ON t.SalesTerritoryKey = f.SalesTerritoryKey
GROUP BY CUBE (d.CalendarYear, t.SalesTerritoryCountry)
ORDER BY annee, pays;
```

Le résultat contient bien ce qu'il demandait, et il le livre en fichier. Sa collègue l'ouvre dans un tableur, somme la colonne ventes et trouve 117 434 708,88 \$, quand l'entrepôt en compte 29 358 677,22 \$ en tout. Dites ce que la requête produit en trop et donnez le correctif ; puis appliquez votre correctif, refaites la somme de la collègue, et dites si le désaccord est réglé. Terminez par les deux façons de le régler vraiment.

E2. Une développeuse veut le montant total et le montant des seules ventes européennes :

```
SELECT d.CalendarYear AS annee,
       SUM(f.SalesAmount) AS total,
       SUM(CASE WHEN t.SalesTerritoryGroup = 'Europe' THEN f.SalesAmount ELSE 0 END) AS europe,
       AVG(CASE WHEN t.SalesTerritoryGroup = 'Europe' THEN f.SalesAmount ELSE 0 END) AS moy_europe
FROM   dbo.FactInternetSales AS f
JOIN   dbo.DimDate           AS d ON d.DateKey = f.OrderDateKey
JOIN   dbo.DimSalesTerritory AS t ON t.SalesTerritoryKey = f.SalesTerritoryKey
GROUP BY d.CalendarYear;
```

La colonne europe est juste, la colonne moy_europe est absurdement basse. Expliquez pourquoi la même écriture donne un résultat juste dans un cas et faux dans l'autre, et corrigez.

E3. Un rapport doit distinguer les lignes de sous-total :

```
SELECT
       COALESCE(t.SalesTerritoryCountry, 'Total') AS pays,
       SUM(f.SalesAmount) AS ventes
FROM   dbo.FactInternetSales AS f
JOIN   dbo.DimSalesTerritory AS t ON t.SalesTerritoryKey = f.SalesTerritoryKey
GROUP BY ROLLUP (t.SalesTerritoryCountry);
```

L'auteur trouve son écriture plus courte que le CASE WHEN GROUPING(...) du cours, et il a raison sur la longueur. Dites dans quelles conditions précises sa requête devient fausse, pourquoi cette faute est particulièrement difficile à repérer, et donnez le correctif.

Questions à développer

Un court paragraphe de raisonnement, pas un mot juste.

A. Le rapport et le grain. Un ROLLUP produit, dans un même résultat, des lignes qui ne sont pas au même grain : du détail et des agrégats mélangés. Expliquez pourquoi c'est commode pour un rapport et dangereux pour tout ce qui consomme ce résultat en aval. Donnez au moins deux façons dont un traitement automatique peut se tromper là-dessus, et dites ce que vous feriez pour l'en protéger.

B. Le pivot, en SQL ou ailleurs. On peut croiser des données dans la requête, ou livrer du format long et laisser l'outil d'affichage croiser. Défendez d'abord le pivot en SQL, puis l'argument inverse, et concluez par la règle que vous adopteriez dans une équipe qui alimente à la fois des tableaux de bord et des exports de fichiers.

C. La portabilité, jusqu'où. Ce cours contient à la fois le morceau le plus portable de la formation (les extensions du GROUP BY) et l'un des moins portables (PIVOT). Expliquez comment vous décidez, en pratique, d'utiliser ou non une facilité propre à un moteur. Distinguez le cas d'une équipe mono-moteur de celui d'une équipe qui migre, et dites ce que vous écririez dans une convention d'équipe.

Mises en situation

On décrit une entreprise et une question métier. À vous de choisir l'approche, de l'écrire, et surtout de la justifier. Il y a plusieurs bonnes réponses, mais il y a des réponses indéfendables.

M1. Réseau de quincailleries Beauport, le rapport du lundi matin. Le réseau compte vingt-deux succursales réparties en quatre régions, et vend six familles de produits. La direction veut un seul rapport hebdomadaire qui montre, pour chaque région, le chiffre de chaque succursale, le sous-total de la région, le total du réseau, et à droite une colonne par famille de produits. Le rapport doit tenir sur une page et se lire sans formation.

Décrivez la requête complète : où va le ROLLUP, où vont les colonnes de famille, et dans quel ordre les deux se combinent. Le point difficile est de mêler un pivot et des lignes de sous-total : dites pourquoi ces deux besoins se gênent, et comment vous les faites cohabiter. Terminez sur l'étiquetage : que mettez-vous dans la colonne « succursale » sur la ligne de sous-total d'une région, et pourquoi ce détail n'est pas cosmétique.

M2. Coopérative agricole Saint-Hyacinthe, le tableau qui grandit. La coopérative suit les livraisons de ses membres par culture. Un rapport existant croise les cultures en colonnes, écrites en dur dans un PIVOT : blé, maïs, soya, avoine. Cette année, trois membres se sont mis au sarrasin. Le rapport continue de tourner sans erreur, et personne ne s'aperçoit de rien pendant deux mois.

Expliquez exactement pourquoi aucune erreur n'a été levée, et ce que le rapport a montré pendant ces deux mois. Puis proposez une reconception. Vous devez traiter trois questions : comment détecter automatiquement qu'une valeur nouvelle est apparue, faut-il ou non que le rapport s'adapte tout seul, et où placer la responsabilité du croisement. Prenez position, et dites ce que vous répondez au gestionnaire qui demande simplement « ajoutez le sarrasin ».

M3. (avancé) Groupe hôtelier Charlevoix, l'audit du chiffre. Le groupe exploite neuf établissements. Le service financier produit un rapport mensuel avec sous-totaux par établissement, par région et pour le groupe, à partir d'un entrepôt. Le service des opérations produit son propre tableau à partir de la base de réservation. Les deux totaux généraux diffèrent de trois pour cent, et chaque service accuse l'autre.

Décrivez la démarche que vous suivriez pour trancher, en SQL. Il ne s'agit pas d'écrire une requête mais une méthode : comment on compare deux agrégats produits par deux chaînes différentes, à quel grain on descend, et dans quel ordre. Traitez explicitement les quatre causes classiques d'un écart de ce genre, dont au moins une tient aux sujets de ce cours. Terminez en disant ce que vous recommanderiez pour que cette situation ne se reproduise pas, sachant que supprimer un des deux rapports n'est pas une option acceptable pour la direction.