

Table des matières

Exercices 07 — Sous-requêtes, corrélation et ensembles.....	1
Questions courtes.....	1
Questions pratiques.....	2
Diagnostics.....	3
Questions à développer.....	4
Mises en situation.....	4

Exercices 07 — Sous-requêtes, corrélation et ensembles

Comment travailler ces exercices. Répondez à chaque énoncé seul, puis vérifiez. Les questions courtes vérifient que le vocabulaire est en place ; les pratiques vous font écrire du SQL, tantôt sur le transactionnel, tantôt sur l'entrepôt ; les diagnostics vous montrent du code qui cloche ; les mises en situation vous demandent de choisir une approche et de la défendre. Comptez trois heures et quart pour y répondre, le corrigé non compris.

Les repères de terrain. Un énoncé marqué [OLTP] se traite dans PostgreSQL sur Adventureworks (schémas sales, production, person). Un énoncé marqué [OLAP] se traite dans DuckDB sur `adventureworksdw.duckdb`, ouvert par `USE dbo;`. Sans marque, la question vaut pour les deux.

Le corrigé est dans `Corrige_07.md`. Répondez à l'énoncé en entier avant de l'ouvrir : c'est en butant sur une question qu'on découvre ce qu'on avait lu sans le comprendre.

Questions courtes

1. Le manque du `GROUP BY`. Donnez deux questions métier qu'une agrégation ordinaire ne sait pas exprimer, et dites en une phrase ce qui leur manque à toutes les deux.
2. Les trois formes. Nommez les trois formes de sous-requête et, pour chacune, l'endroit de la requête où elle a le droit d'apparaître.
3. Une sous-requête scalaire placée dans un `WHERE` ne renvoie aucune ligne. Que vaut-elle, et qu'arrive-t-il à la ligne testée ?
4. Une sous-requête scalaire renvoie deux lignes au lieu d'une. Que se passe-t-il, et en quoi est-ce moins dangereux que le cas de la question 3 ?
5. Corrélée ou pas. Comment reconnaît-on, à la seule lecture, qu'une sous-requête est corrélée ?
6. « Une sous-requête corrélée est lente, il faut toujours la réécrire en jointure. » Cette phrase était vraie autrefois. Pourquoi ne l'est-elle plus, et que faut-il faire à la place de la croire ?

7. Dans un EXISTS, on écrit habituellement `SELECT 1`. Écrire `SELECT *` changerait-il le résultat ? Pourquoi cette convention alors ?
 8. Semi-jointure et anti-jointure. Définissez chacune en une phrase, et donnez le mot-clé SQL qui la porte.
 9. Pourquoi EXISTS est-il en général moins coûteux qu'un `COUNT(*) > 0` équivalent ?
 10. Le piège central du module. Expliquez, sans citer de table réelle, pourquoi `x NOT IN (SELECT c FROM t)` ne renvoie aucune ligne dès que `c` contient un seul NULL.
 11. Toujours sur ce piège : pourquoi est-il plus dangereux qu'une erreur de syntaxe ?
 12. Trois écritures existent pour une anti-jointure. Citez-les, et dites laquelle vous écrivez par défaut.
 13. Équivalences. Réécrivez `x IN (...)` et `x NOT IN (...)` avec ANY et ALL.
 14. Que vaut `x > ALL (...)` quand la sous-requête ne renvoie aucune ligne ? Et `x > ANY (...)` dans le même cas ? (avancé)
 15. Les quatre opérateurs d'ensembles. Citez-les et dites lequel ne dédouble pas.
 16. Compatibilité. Trois conditions doivent être remplies pour empiler deux résultats. Nommez-les, et dites ce qui décide du nom des colonnes du résultat final.
 17. Pourquoi UNION ALL doit-il être votre choix par défaut, et dans quel cas précis passe-t-on à UNION ?
 18. LATERAL. Que permet-il qu'une sous-requête ordinaire du FROM ne permet pas ?
 1. Dans `LEFT JOIN LATERAL (...) AS t ON true`, à quoi sert le `ON true`, et à quoi sert le `LEFT` ?
 2. Le top N par groupe s'écrit de trois façons. Citez-les et donnez, pour chacune, le cas où elle est le meilleur choix.
-

Questions pratiques

- P1. [OLTP] Les produits jamais commandés. Écrivez la requête qui liste le nom et le prix de liste des produits de `production.product` qui n'apparaissent dans aucune ligne de `sales.salesorderdetail`. Utilisez l'écriture que la théorie recommande.
- P2. [OLAP] Les clients sans commande récente. Sur `ADVENTUREWORKSDW`, listez les `CustomerKey` de `DimCustomer` qui n'ont aucune ligne dans `FactInternetSales` dont le `OrderDateKey` dépasse 20130101. Attention au piège : il ne s'agit pas des clients sans aucune commande.
- P3. [OLTP] Le prix relatif. Pour chaque produit ayant une sous-catégorie, affichez son nom, son prix, le prix moyen de sa sous-catégorie, et l'écart entre les deux. Écrivez-la deux fois, une fois avec une sous-requête corrélée, une fois avec une fonction de fenêtrage, puis dites laquelle vous gardez et pourquoi.

- P4. [OLAP] Les deux catégories. Listez les CustomerKey qui ont acheté au moins un produit de la catégorie Bikes et au moins un de la catégorie Clothing, en utilisant un opérateur d'ensemble. Puis écrivez la même chose sans opérateur d'ensemble, et comparez la lisibilité.
- P5. [OLTP] Le top 2 par sous-catégorie. Affichez, pour chaque sous-catégorie, ses deux produits les plus chers, en conservant les sous-catégories qui n'ont aucun produit. Utilisez LATERAL.
- P6. [OLAP] Le même top 2, en QUALIFY. Écrivez la version la plus courte possible, puis dites en une phrase ce que la version LATERAL fait que celle-ci ne fait pas.
- P7. Le contrôle de cohérence. Écrivez, sur le terrain de votre choix, la requête qui compte les lignes de fait dont la clé de dimension n'a aucune correspondance. Puis transformez-la pour qu'elle renvoie non pas un compte, mais les dix clés fautives les plus fréquentes.
- P8. [OLTP] L'anti-jointure sur colonne nullable. Listez les sous-catégories de production.productssubcategory auxquelles aucun produit n'est rattaché. Écrivez d'abord la version NOT IN, constatez le résultat, puis corrigez-la de deux façons différentes. (avancé)
-

Diagnostics

E1. Un analyste veut les produits jamais vendus. Il écrit :

```
SELECT p.name
FROM production.product AS p
WHERE p.productid NOT IN (SELECT d.productid
                          FROM sales.salesorderdetail AS d
                          WHERE d.orderqty > 5);
```

Il obtient un résultat, mais il est faux. Deux défauts se cumulent ici. Trouvez-les et corrigez.

E2. Une requête censée afficher le nombre de commandes par client :

```
SELECT c.customerid,
       (SELECT COUNT(*) FROM sales.salesorderheader) AS nb_commandes
FROM sales.customer AS c;
```

Toutes les lignes affichent le même nombre. Expliquez pourquoi et corrigez.

E3. Un collègue empile deux résultats :

```
SELECT productid, name FROM production.product WHERE listprice > 1000
UNION
SELECT name, productid FROM production.product WHERE listprice = 0;
```

La requête échoue sur PostgreSQL. Elle aurait pu ne pas échouer. Expliquez ce qui se passe, et dites dans quel cas le même genre d'erreur passerait inaperçu.

E4. Une requête de contrôle qui ne contrôle rien :

```
SELECT COUNT(*)  
FROM FactInternetSales AS f  
WHERE f.ProductKey NOT IN (SELECT ProductKey FROM DimProduct WHERE Status = 'Current');
```

Elle renvoie 0 et l'auteur conclut que tout va bien. Donnez deux raisons distinctes pour lesquelles ce zéro ne prouve rien.

E5. Le top N qui perd des groupes :

```
SELECT e.businessentityid, top.salesorderid, top.totaldue  
FROM humanresources.employee AS e,  
LATERAL (SELECT h.salesorderid, h.totaldue FROM sales.salesorderheader AS h  
WHERE h.salespersonid = e.businessentityid  
ORDER BY h.totaldue DESC LIMIT 3) AS top;
```

Le rapport devait couvrir les 290 employés, et n'en montre que 17. Expliquez le mécanisme, corrigez, et dites pourquoi la disparition passe si facilement inaperçue dans un rapport livré. (avancé)

Questions à développer

A1. La règle de la section 1 dit qu'une sous-requête doit répondre à une question qu'une jointure ne sait pas poser. Défendez cette règle en un paragraphe, puis donnez un contre-exemple : un cas où la sous-requête est préférable alors qu'une jointure suffirait techniquement.

A2. On vous dit : « nous avons remplacé tous les NOT IN par des NOT EXISTS dans notre dépôt, la migration a pris deux jours ». Expliquez en un paragraphe pourquoi ce travail se justifie même si aucune requête ne renvoyait de résultat faux au moment de la migration.

A3. Comparez EXCEPT et NOT EXISTS comme façons d'exprimer une différence. Décrivez précisément ce que chacun compare, et donnez un cas où remplacer l'un par l'autre change le résultat.

A4. Un architecte affirme que LATERAL est un pis-aller à éviter, parce qu'il force une exécution pour chaque ligne de la table de gauche. Répondez-lui en un paragraphe. Votre réponse doit reconnaître ce qu'il y a de juste dans son objection. (avancé)

Mises en situation

M1. Coopérative maraîchère Deux-Rives, la relance commerciale. La coopérative vend des paniers hebdomadaires à quatre mille foyers et tient trois tables : abonne, livraison et ligne_livraison. Le service commercial veut trois listes pour sa campagne d'automne : les abonnés qui n'ont reçu aucune livraison

depuis trois mois ; ceux qui prenaient des produits laitiers l'an dernier et n'en prennent plus ; et, pour chaque région, les cinq abonnés au plus fort volume annuel.

Décrivez la requête de chaque liste, en nommant l'outil du module que vous employez et pourquoi. Pour la deuxième, dites précisément où le piège NULL pourrait vous atteindre. Vous n'avez pas besoin d'écrire le SQL complet, mais votre réponse doit être assez précise pour qu'un collègue puisse le faire.

M2. Clinique vétérinaire Saint-Élie, l'audit du référentiel. La clinique a migré son logiciel de gestion. L'ancien système et le nouveau ont chacun exporté leurs tables `animal`, `proprietaire` et `consultation` en CSV, chargées telles quelles dans un entrepôt. La directrice veut savoir si la migration a perdu quelque chose.

Proposez une batterie de contrôles fondée sur les outils du module. Dites, pour chaque contrôle, quel outil vous employez et ce qu'un résultat non vide signifierait. Précisez ensuite ce qu'un résultat vide **ne** prouve **pas**, et quel contrôle supplémentaire il faudrait pour combler ce trou.

M3. Plateforme de location d'outillage Ferblanc, le tableau de bord des sous-utilisés. La plateforme gère huit cents machines louées à la journée, avec les tables `machine`, `agence`, `location` et `categorie`. La direction veut un tableau mensuel qui montre, par agence, les machines jamais louées du mois, les trois machines les plus rentables, et les catégories présentes dans une agence mais absentes d'une autre.

Concevez la requête ou l'ensemble de requêtes. Justifiez le choix entre LATERAL et une fonction de fenêtrage pour la deuxième demande, en distinguant ce que vous feriez sur chacun des deux terrains de la formation. Dites enfin quelle partie de ce tableau de bord vous refuseriez de livrer en l'état, et quelle question vous poseriez à la direction avant d'aller plus loin. (avancé)