

Table des matières

Exercices 09 — Séries temporelles et as-of joins.....	1
Questions courtes	1
Questions pratiques	2
Diagnostics	3
Questions à développer	5
Mises en situation.....	5

Exercices 09 — Séries temporelles et as-of joins

Comment travailler ces exercices. Répondez à chaque énoncé seul, puis vérifiez. Les questions courtes vérifient que le vocabulaire est en place ; les pratiques vous font écrire du SQL, tantôt sur le transactionnel, tantôt sur l'entrepôt ; les diagnostics vous montrent du code qui cloche ; les mises en situation vous demandent de choisir une approche et de la défendre. Comptez quatre heures et quart pour y répondre, le corrigé non compris.

Les repères de terrain. Un énoncé marqué [OLTP] se traite dans PostgreSQL sur Adventureworks (schémas sales, production, person). Un énoncé marqué [OLAP] se traite dans DuckDB sur adventureworksdw.duckdb, ouvert par `USE dbo;`. Sans marque, la question vaut pour les deux.

Le corrigé est dans `Corrige_09.md`. Répondez à l'énoncé en entier avant de l'ouvrir : c'est en butant sur une question qu'on découvre ce qu'on avait lu sans le comprendre.

Questions courtes

1. Distinguez en une phrase chacune un instant, une période et un intervalle de validité.
2. Quelle erreur produit la confusion entre un instant et une période ? Donnez la forme d'écriture qui l'évite.
3. Pourquoi `BETWEEN '2023-01-01' AND '2023-12-31'` est-il dangereux sur une colonne horodatée, et pourquoi le danger peut-il rester invisible pendant des années ?
4. Une série issue d'un `GROUP BY` sur le mois ne montre pas les mois vides. Expliquez pourquoi, et dites comment on les fait apparaître.
5. Sur une série trouée, la moyenne calculée sur l'axe complet et la moyenne calculée sur les jours actifs diffèrent. Laquelle est fausse ?
6. À quoi sert `NULLIF` dans le calcul d'une variation relative, et que se passe-t-il si on l'oublie ?

7. Une hausse de 50 % suivie d'une baisse de 50 % laisse à combien de la valeur initiale ? Que démontre ce résultat ?
 8. Donnez la propriété du rendement logarithmique qui le rend préférable pour cumuler, et le prix qu'on paie pour cette propriété.
 9. `ROWS BETWEEN 6 PRECEDING` et `RANGE BETWEEN INTERVAL '6 days' PRECEDING`. Sur quelle sorte de série donnent-ils le même résultat, et sur quelle sorte divergent-ils ?
 10. Vous voulez la moyenne des sept derniers jours d'un indicateur de tendance. Quel cadre choisissez-vous, et quelle est la parade portable si le moteur ne le supporte pas ?
 11. Quel cadre le moteur applique-t-il quand un `OVER` porte un `ORDER BY` sans cadre explicite ? Pourquoi ce défaut est-il gênant sur une série temporelle ?
 12. `DATE_TRUNC('week', d)` ne donne pas forcément le même résultat sur les deux moteurs. Expliquez.
 13. Pourquoi `LAST_VALUE` sans cadre explicite renvoie-t-il la ligne courante ? Donnez le cadre à écrire.
 14. Définissez un `as-of join` en une phrase, sans employer de nom de fonction.
 15. Écrivez de mémoire la forme portable de l'`as-of join`, et dites à quoi sert le mot `LEFT`.
 16. Pourquoi l'`as-of join` s'appuie-t-il sur la date de début et jamais sur l'intervalle fermé ? Donnez les deux défauts de données auxquels cette règle rend insensible.
 17. Dans la sous-requête d'un `as-of join`, la comparaison s'écrit `<=` plutôt que `<`. Qu'est-ce que cela change concrètement ?
 18. Décrivez le motif de résolution des îlots et lacunes, en deux étapes. Pourquoi la somme cumulée donne-t-elle un identifiant de session ?
1. `PERCENTILE_CONT` et `PERCENTILE_DISC` renvoient parfois deux nombres différents. Expliquez la différence, et donnez un cas où l'interpolation est illégitime.
 2. Une cohorte de mars n'a pas encore atteint son rang 6. Quelle valeur de rétention faut-il afficher à ce rang, et pourquoi celle-là ?
-

Questions pratiques

- P1. [OLTP] Construisez la série quotidienne du nombre de commandes sur l'année 2023, avec un axe complet et un zéro sur les jours sans commande. Renvoyez aussi une colonne qui distingue un zéro observé d'un zéro reconstitué.
- P2. [OLAP] Écrivez la requête qui donne, par mois, le total des ventes, la variation en valeur, la variation en pourcentage et le rendement logarithmique. Protégez la division.

P3. [OLTP] Les achats cette fois : construisez la série quotidienne du montant des bons de commande de `purchasing.purchaseorderheader`, la somme de `subtotal` par jour de `orderdate`. Calculez la moyenne mobile à sept jours en cadre de lignes et en cadre de durée, sur la série brute, puis sur l'axe complet. Dites laquelle des colonnes obtenues répond à « le montant moyen acheté par jour sur les sept derniers jours », et ce que calculent les autres.

P4. [OLTP] Chaque représentant reçoit un quota de ventes, révisé par trimestre dans `sales.salespersonquotahistory`. Écrivez l'as-of join qui rattache à chaque commande passée par un représentant le quota en vigueur à sa date. Comptez les commandes sans quota, puis refaites le compte en remplaçant `<=` par `<`, et dites ce que ce second compte ne montre pas.

P5. [OLAP] Retournez l'as-of join. Pour chaque nouvelle version d'un produit de `dbo.DimProduct`, c'est-à-dire chaque version qui a une version antérieure de même `ProductAlternateKey`, trouvez la première vente du produit à partir de son entrée en vigueur, et le délai qui les sépare. Écrivez-le une fois en `LATERAL` et une fois en `QUALIFY`, et vérifiez que les deux donnent les mêmes comptes.

P6. [OLTP] Écrivez les trois requêtes de contrôle de l'historique des affectations des employés à leurs services, `humanresources.employeehistory` : intervalles incohérents, chevauchements, versions courantes multiples. Regardez ensuite les employés qui ont changé de service, et dites comment une date de fin s'enchaîne avec la date de début suivante, et ce que cela impose à un as-of join sur cette table.

P7. [OLTP] Découpez les commandes du client 29825 en sessions séparées par plus de 120 jours d'inactivité, puis renvoyez pour chaque session sa date de début, sa date de fin, le nombre de commandes et le montant total. (avancé)

P8. [OLAP] Construisez la table de rétention par cohorte mensuelle, du rang 0 au rang 6, en pourcentage de la taille de la cohorte. Ajoutez une colonne qui marque les cellules dont la valeur n'est pas encore observable. (avancé)

Diagnostics

E1. Un rapport annuel sur PostgreSQL :

```
SELECT COUNT(*) FROM sales.salesorderheader
WHERE orderdate BETWEEN '2023-01-01' AND '2023-12-31';
```

L'auteur affirme compter toutes les commandes de 2023. Dites dans quelles conditions il a raison, dans quelles conditions il a tort, et donnez l'écriture qui n'a jamais tort.

E2. Une moyenne mobile sur l'entrepôt :

```
SELECT jour, ventes,
       AVG(ventes) OVER (ORDER BY jour) AS moyenne_mobile_7j
FROM   ventes_jour;
```

L'auteur croit avoir écrit une moyenne mobile à sept jours. Dites ce qu'il a réellement calculé.

E3. Un rattachement de prix :

```
SELECT h.salesorderid, d.productid, p.listprice
FROM   sales.salesorderheader AS h
JOIN   sales.salesorderdetail AS d ON d.salesorderid = h.salesorderid
JOIN   production.product AS p ON p.productid = d.productid;
```

La requête s'exécute, ne perd aucune ligne et renvoie un prix pour chaque commande. Elle est pourtant fautive pour l'usage prévu, qui est un rapport de marge historique. Expliquez.

E4. Un as-of join sur l'entrepôt :

```
SELECT f.SalesOrderNumber, v.ListPrice
FROM   dbo.FactInternetSales AS f
JOIN   dbo.DimProduct AS ref ON ref.ProductKey = f.ProductKey
JOIN   dbo.DimProduct AS v
      ON v.ProductAlternateKey = ref.ProductAlternateKey
      AND f.OrderDate BETWEEN v.StartDate AND v.EndDate;
```

Elle renvoie zéro ligne. Donnez les deux causes, et l'écriture correcte.

E5. Un as-of join sur PostgreSQL :

```
SELECT h.salesorderid, prix.listprice
FROM   sales.salesorderheader AS h
JOIN   sales.salesorderdetail AS d ON d.salesorderid = h.salesorderid
JOIN   LATERAL (
      SELECT pl.listprice
      FROM   production.productlistpricehistory AS pl
      WHERE  pl.productid = d.productid
      AND    pl.startdate <= h.orderdate
      ORDER BY pl.modifieddate DESC
      LIMIT  1
    ) AS prix ON true;
```

Deux défauts, dont un seul est visible sur cette base. Nommez-les tous les deux. (avancé)

E6. Une sessionisation :

```
WITH marque AS (
  SELECT customerid, orderdate,
         CASE WHEN orderdate - LAG(orderdate) OVER (ORDER BY orderdate) > INTERVAL '120 days'
              THEN 1 ELSE 0 END AS rupture
  FROM   sales.salesorderheader
```

```
)  
SELECT customerid, orderdate,  
       SUM(rupture) OVER (PARTITION BY customerid ORDER BY orderdate) AS session  
FROM   marque;
```

Le résultat est incohérent : des clients n'ont qu'un seul numéro de session alors qu'ils ont commandé sur trois ans, et d'autres en reçoivent un qui ne doit rien à leurs propres commandes. Trouvez l'erreur, puis dites ce qu'il manque encore à cette requête pour rendre deux fois le même résultat.

Questions à développer

- A1. La théorie affirme que l'as-of join doit s'appuyer sur la date de début et jamais sur l'intervalle fermé. Défendez cette règle en un paragraphe, puis dites ce qu'elle coûte : nommez au moins une situation où cette écriture donne un résultat que l'intervalle fermé aurait refusé, et dites si ce comportement est souhaitable.
- A2. Le laboratoire OLAP montre que l'as-of join recalculé contredit la clé du fait sur 6 899 lignes. Trois lectures sont possibles. Exposez-les, dites laquelle vous privilégiez et par quelle mesure vous trancheriez. Précisez ce que vous feriez si vous ne pouviez pas trancher.
- A3. Comparez la façon dont le monde transactionnel et l'entrepôt conservent l'historique d'un attribut. Votre réponse doit expliquer pourquoi l'un place l'historique dans une table dédiée et l'autre le replie dans la dimension, et dire où se logent les erreurs dans chaque cas.
- A4. Les trois derniers modules ont chacun montré une faute qui ne lève pas d'erreur : le NOT IN sur colonne nullable, la comparaison d'un VARIANT sans conversion, et l'intervalle de validité non contrôlé. Dégagez ce que ces trois fautes ont en commun, et proposez une pratique d'équipe qui les attraperait toutes les trois avant la production. (avancé)
-

Mises en situation

M1. Gestion de portefeuille Havre-Blanc, la valorisation à la date de l'ordre. Havre-Blanc tient deux tables. La première enregistre les ordres exécutés : un identifiant, un horodatage à la seconde, un symbole, un sens, une quantité. La seconde enregistre les cours : un symbole, un horodatage, un prix. Les cours n'arrivent pas à intervalle fixe, et il n'y a jamais de cours à la seconde exacte d'un ordre. La conformité demande, pour chaque ordre, le dernier cours coté avant l'exécution, plus l'écart entre le prix d'exécution et ce cours.

Décrivez la requête que vous écririez, en nommant l'outil et en justifiant chaque clause. Dites ce que vous faites des ordres pour lesquels aucun cours antérieur n'existe, et pourquoi ce cas doit rester visible. Précisez enfin ce qui changerait si la conformité demandait le cours suivant plutôt que le précédent.

M2. Coopérative de crédit Kamouraska, la courbe de taux. La coopérative affiche chaque jour une courbe de taux : pour cinq échéances, le taux en vigueur. Les taux ne changent pas tous en même temps ; chaque échéance a son propre historique de révisions, avec une date d'entrée en vigueur. L'équipe veut un tableau

qui donne, pour chaque jour ouvrable des trois dernières années et pour chacune des cinq échéances, le taux applicable ce jour-là, même les jours où aucune révision n'a eu lieu.

Décrivez votre construction en trois étapes, en nommant l'outil de chacune. Dites pourquoi la question ne peut pas se résoudre par une jointure d'égalité, et ce qui se passerait si vous omettiez la première étape. Précisez comment vous traitez le début de la plage, avant la première révision connue.

M3. Parc éolien Anse-Verte, la volatilité glissante. Le parc reçoit une mesure de production toutes les dix minutes, par turbine, avec des interruptions de télémétrie qui durent de quelques minutes à plusieurs heures. L'exploitant veut, par turbine et par jour, l'écart type de la production sur une fenêtre glissante de vingt-quatre heures, et il veut pouvoir comparer les turbines entre elles.

Cette demande contient un piège que l'énoncé ne nomme pas. Trouvez-le, dites ce qu'il fait au résultat, et proposez la construction qui le désamorce. Votre réponse doit trancher entre le cadre en lignes et le cadre en durée, et dire ce que vous faites des périodes d'interruption : une valeur de zéro, une valeur manquante, ou une exclusion de la fenêtre. Défendez le choix, et dites quelle information vous ajouteriez au tableau pour que l'exploitant sache quand ne pas lire le chiffre. (avancé)