

Table des matières

Exercices 12 — SQL analytique appliqué	1
Questions courtes	1
Questions pratiques	2
Diagnostics	3
Questions à développer	4
Mises en situation	5

Exercices 12 — SQL analytique appliqué

Comment travailler ces exercices. Ce module est un projet, et ses exercices lui ressemblent : ils demandent moins d'écrire du SQL que de défendre ce que vous avez écrit. Les questions courtes balaient les douze modules ; les pratiques vous font concevoir plutôt que taper ; les diagnostics vous montrent des livrables plausibles et faux ; les questions à développer et les mises en situation sont l'exercice d'un entretien technique. Comptez trois heures et demie pour y répondre, le corrigé non compris.

Les repères de terrain. Ce module n'a qu'un laboratoire, sur l'entrepôt. Un énoncé marqué [OLAP] se traite donc dans DuckDB sur `adventureworksdw.duckdb`, ou sur le schéma `RAPPORT` que vous avez construit. Les énoncés sans marque ne demandent pas de moteur : ils demandent un raisonnement.

Le corrigé est dans `Corrige_12.md`. Répondez à l'énoncé en entier avant de l'ouvrir, et surtout répondez à voix haute : la moitié de ces questions se posent en entretien, et savoir les écrire ne suffit pas.

Questions courtes

1. Citez les cinq temps de la méthode, dans l'ordre, et dites ce qu'on perd à en inverser deux.
2. La demande de départ contenait trois mots indéfinis. Nommez-les, et donnez pour chacun deux interprétations qui mènent à deux rapports différents.
3. Qu'est-ce que le grain d'une table de faits, et pourquoi celui de `dbo.FactInternetSales` surprend-il ?
4. Vous voulez le nombre de commandes à partir d'une requête au grain `article`. Qu'écrivez-vous, et qu'arrive-t-il si vous l'oubliez ?
5. Vous summez le montant total d'une commande dans une requête au grain `article`. Que vaut le résultat, et de combien est-il faux en moyenne sur ce jeu de données ?
6. Pourquoi la période du rapport a-t-elle été fixée du 1er janvier 2011 au 31 décembre 2013, alors que la donnée va plus loin des deux côtés ?

7. Que contient une note de cadrage, et pourquoi est-elle le livrable qui vaut le plus six mois plus tard ?
 8. Pourquoi ne peut-on pas joindre le fait à toute la dimension de date ?
 9. À quoi sert la colonne `jour_reconstitue`, et quelle question permet-elle de trancher plus tard ?
 10. Sur l'axe complet de ce projet, le cadre en lignes et le cadre en durée donnent le même résultat. Pourquoi, et qu'est-ce que cela vous autorise à écrire ?
 11. Pourquoi le classement des produits groupe-t-il sur `ProductAlternateKey` plutôt que sur `ProductKey` ?
 12. Les jointures vers la sous-catégorie et la catégorie sont des `LEFT JOIN`. Que se passerait-il avec des jointures internes, et comment le sauriez-vous ?
 13. Un contrôle de qualité qui ne trouve rien est-il inutile ? Justifiez, puis dites ce que vous en faites dans le livrable.
 14. Trois des contrôles de la partie 4 trouvent quelque chose. Lesquels sont des anomalies et lequel ne l'est pas ?
 15. L'as-of join de la partie 5 n'emploie jamais `EndDate`. Pourquoi, sur cette dimension en particulier ?
 16. Le fait porte déjà `TotalProductCost`. Donnez la raison pour laquelle on recalcule quand même la marge.
 17. À quoi servent les colonnes issues de `GROUPING()` dans le rapport de synthèse ?
 18. Pourquoi livrer les mesures au format long plutôt qu'en tableau croisé, alors que le lecteur veut un tableau croisé ?
 19. Dans quel ordre optimise-t-on et vérifie-t-on l'exactitude ? Justifiez en une phrase.
 1. Un rafraîchissement en deux commandes, suppression puis insertion, sans transaction. Décrivez ce que voit un lecteur, et pourquoi personne ne le signalera.
-

Questions pratiques

Ces énoncés demandent de concevoir. Écrivez le SQL quand il est court, et l'esquisse quand il est long : ce qui est évalué est la décision, pas la frappe.

P1. [OLAP] Un collègue veut ajouter la mesure « panier moyen par territoire et par mois ». Dites à quel grain elle se calcule, écrivez la requête, et expliquez pourquoi la moyenne des paniers moyens quotidiens ne donne pas le même résultat.

P2. [OLAP] Ajoutez à `V_TENDANCE` une colonne qui compare chaque jour au même jour de l'an précédent. Traitez explicitement le cas du 29 février et celui du premier exercice, où il n'y a pas d'an précédent.

P3. [OLAP] Écrivez le contrôle qui vérifie qu'aucune commande n'a deux lignes portant le même numéro de ligne, et le contrôle qui vérifie qu'une commande appartient toujours à un seul client. Dites lequel des deux est le plus susceptible de trouver quelque chose sur une vraie source.

P4. [OLAP] Votre vue V_LIGNE_ENRICHIÉ renvoie des lignes sans version de produit valide. Proposez trois traitements possibles de ces lignes dans le rapport final, et dites lequel vous retenez et pourquoi.

P5. [OLAP] Concevez la table de journal du chargement : donnez ses colonnes, dites qui l'alimente, et écrivez la requête qu'un opérateur lance le matin pour savoir si tout s'est bien passé. (avancé)

P6. [OLAP] Le rapport doit maintenant couvrir aussi les ventes des revendeurs, qui vivent dans une autre table de faits, au même grain. Dites ce que vous changez dans chacune des huit parties du laboratoire, et ce qui ne change pas. (avancé)

Diagnostics

E1. Un collègue livre ce chiffre comme « nombre de commandes de 2013 » :

```
SELECT COUNT(*) FROM dbo.FactInternetSales WHERE YEAR(OrderDate) = 2013;
```

Deux défauts, de natures différentes. Nommez-les et corrigez.

E2. Une tendance mensuelle livrée telle quelle :

```
SELECT DATE_TRUNC('month', OrderDate) AS mois, SUM(SalesAmount) AS ventes
FROM   dbo.FactInternetSales
GROUP BY 1 ORDER BY 1;
```

Le lecteur conclut que les ventes se sont effondrées en janvier 2014 et que décembre 2010 a été catastrophique. Expliquez, et dites ce que vous changez dans la requête et dans le livrable.

E3. Un classement des meilleurs produits :

```
SELECT p.EnglishProductName, SUM(f.SalesAmount) AS ventes
FROM   dbo.FactInternetSales AS f
JOIN   dbo.DimProduct AS p ON p.ProductKey = f.ProductKey
GROUP BY 1 ORDER BY ventes DESC LIMIT 10;
```

Deux produits du catalogue apparaissent chacun deux fois dans le résultat avec des montants différents. Expliquez et corrigez.

E4. Un rapport de marge :

```
SELECT SUM(f.SalesAmount - v.StandardCost * f.OrderQuantity) AS marge
FROM   dbo.FactInternetSales AS f
JOIN   dbo.DimProduct AS ref ON ref.ProductKey = f.ProductKey
JOIN   dbo.DimProduct AS v ON v.ProductAlternateKey = ref.ProductAlternateKey
WHERE  f.OrderDate BETWEEN v.StartDate AND v.EndDate;
```

Elle renvoie NULL. Donnez les deux causes et l'écriture correcte.

E5. Une synthèse avec sous-totaux, livrée dans un fichier :

```
SELECT COALESCE(categorie, 'Total') AS categorie,  
       COALESCE(pays, 'Total')     AS pays,  
       SUM(ventes)                  AS ventes  
FROM   ventes_detail  
GROUP BY ROLLUP (categorie, pays);
```

Le destinataire additionne la colonne des ventes dans son tableur et obtient trois fois le chiffre d'affaires réel. Expliquez le facteur trois, et dites ce qui manque au livrable. (avancé)

E6. Un chargement quotidien censé être rejouable :

```
DELETE FROM rapport.fait WHERE jour = :jour;  
INSERT INTO rapport.fait  
SELECT * FROM source.fait WHERE jour >= :jour;
```

Il produit des doublons dès qu'on le relance. Trouvez l'erreur, et dites ce que le contrôle de la partie 4 aurait détecté. (avancé)

Questions à développer

A1. Le module affirme que le cadrage se fait avant le SQL et ne se rattrape pas après. Défendez cette affirmation en un paragraphe, puis décrivez ce qui arrive concrètement à un projet où le cadrage est fait après coup, en suivant une mesure précise du laboratoire.

A2. Les contrôles de la partie 4 précèdent les mesures de la partie 3 dans l'ordre logique, alors que le laboratoire les place après. Expliquez pourquoi cet ordre a été retenu, dites ce qu'il coûte, et donnez l'ordre que vous adopteriez sur un projet réel.

A3. La partie 5 propose trois traitements de l'écart entre la marge du fait et la marge recalculée. Exposez-les, dites lequel vous retenez, et surtout à quelles conditions vous changeriez d'avis. Traitez explicitement le cas où l'écart est important et inexplicable à la veille de la livraison.

A4. Un collègue soutient qu'un rapport juste suffit, et que la partie 8 est du travail d'administrateur qui ne concerne pas un analyste. Répondez-lui en un paragraphe, en reconnaissant ce que son objection a de fondé, puis en montrant par un scénario concret ce que son rapport deviendra en son absence.

A5. Le capstone ne remobilise pas le Cours 08. Expliquez pourquoi, dites où l'étape correspondante se placerait si la source en contenait, et ce qu'elle changerait aux parties 4 et 7. (avancé)

Mises en situation

M1. Coopérative Trois-Pistoles, la demande de la direction. La direction vous demande « un tableau de bord des ventes, comme celui de l'an dernier, mais en mieux ». Le tableau de bord de l'an dernier existe, personne ne sait comment il est calculé, son auteur est parti, et deux services citent des chiffres différents pour le même mois.

Décrivez votre démarche, dans l'ordre. Dites ce que vous faites du tableau existant, ce que vous demandez et à qui, et comment vous traitez la divergence entre les deux services sans transformer la réunion en tribunal. Précisez ce que vous livrez en premier, et pourquoi ce n'est probablement pas un tableau de bord.

M2. Manufacture Joliette, le chiffre qui a changé. Votre rapport tourne depuis trois mois. Ce matin, un directeur vous écrit que le chiffre d'affaires d'octobre, qu'il avait noté à 4,1 millions, en affiche maintenant 4,4. Personne n'a modifié votre code.

Listez toutes les causes possibles de ce changement, classées de la plus probable à la moins probable, et dites pour chacune comment vous la vérifiez. Décrivez ensuite ce que vous répondez au directeur avant d'avoir fini l'enquête. Précisez enfin ce que vous mettriez en place pour que la question ne se pose plus dans les mêmes termes la prochaine fois.

M3. Distributeur Verchères, l'entretien technique. Vous présentez ce projet en entretien. Le recruteur ouvre votre code, s'arrête sur la vue de l'as-of join, et vous dit : « pourquoi cette complexité, il y a déjà une colonne de coût dans le fait ».

Répondez-lui. Votre réponse doit tenir en deux minutes à l'oral, commencer par reconnaître ce que la question a de légitime, et se terminer par ce que vous avez mesuré. Le recruteur enchaîne : « et si je vous disais que sur mon entrepôt, cette écriture met quarante minutes ». Répondez encore.

M4. Assurance Baie-des-Sables, le rapport hérité. Vous héritez d'un rapport de 900 lignes de SQL, d'une seule requête, sans commentaire, qui produit le tableau de bord mensuel de la direction. Il fonctionne. Il met vingt minutes. Personne n'ose y toucher, et la direction demande deux mesures supplémentaires pour le trimestre prochain.

Décrivez votre plan, en étapes datées. Dites ce que vous faites en premier, et pourquoi ce n'est ni de le réécrire ni d'ajouter les deux mesures. Traitez explicitement la question de la non-régression : comment prouvez-vous que votre version donne les mêmes chiffres que l'ancienne, et que faites-vous si elle donne des chiffres différents et que les vôtres semblent plus justes ? (avancé)